

哈尔滨工业大学

硕士学位论文开题报告

题 目：面向 PCBA 上下料的轮式双臂模仿学习策略
鲁棒性改进研究
(学位论文)

学 院 (部)	航天学院
学科/专业学位类别	机械
导 师	刘延芳研究员
研 究 生	聂靖轩
学 号	25S118238
开题报告日期	2026 年 9 月

研究生院制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源与研究背景	1
1.2 研究目的与意义	5
2 国内外研究现状及分析	7
2.1 国内外工业具身机器人研究现状	7
2.2 国内外 VLA 模型研究现状	9
2.3 国内外 VLA 模仿学习策略鲁棒性改进研究现状	11
2.4 国内外研究现状简析	14
3 主要内容及方案	15
3.1 研究主线与总体技术路线	15
3.2 任务定义与工位停靠误差传递问题	16
3.3 面向停靠误差补偿的模仿学习方法	18
3.4 分阶段动作序列执行方法	19
3.5 基于预测偏差的在线失败检测与恢复方法	21
3.6 整体验证方案	22
3.7 可行性分析	24
4 预期达到的目标	24
5 已完成的学术研究/实践工作	25
5.1 实验平台与坐标系定义	25
5.2 基于 VR 遥操作的示范数据采集	26
5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与真机闭环	29
5.4 阶段性工作小结	31
6 进度安排	32
7 为完成课题所需的条件	33
8 研究过程中可能遇到的问题以及解决的措施	33
9 参考文献	34

1 课题来源及研究的目的和意义

1.1 课题来源与研究背景

工业机器人是面向工业环境设计、可自动控制、可重复编程的多关节机械装置，凭借高精度、高节拍和长时间稳定运行的优势，长期承担焊接、喷涂、搬运、装配等重复性作业，是制造业自动化的核心装备。国际机器人联合会（International Federation of Robotics, IFR）发布的 2025 年世界机器人报告显示，2024 年全球工业机器人新装机量达 54.2 万台，较十年前增长一倍以上，全球在役存量达 466 万台；其中中国新装机 29.5 万台，占全球的 54%，在役存量突破 200 万台，连续多年保持全球最大的工业机器人市场^[1]。电子电气行业是工业机器人的主要应用行业之一，电路板组件的上下料、插件与检测等环节对机器人替代人工存在持续需求。然而，传统工业机器人依赖示教编程或离线编程，在结构化环境中沿预设轨迹重复运动，其可靠性建立在工件位姿、夹具和工艺流程高度固定的前提之上^[2,3]。当产线面临多品种、小批量、快速换型的需求，或工件位置、来料状态存在不确定性时，机器人需要重新示教、重新标定甚至重新设计工装，部署周期与成本显著上升；固定安装的机器人还需要依靠传送带或专用输送设备衔接不同工位，难以独立承担跨工位的物料流转任务。图1从焊接、汽车装配、码垛和电子制造四类作业展示了工业机器人的应用广度。这些系统虽然末端工具和工艺对象不同，但通常都通过固定工位、专用工装与预先编程来保证稳定性。

与传统工业机器人依赖精确编程不同，具身智能（Embodied Intelligence）强调智能体通过物理载体与环境的动态交互，在感知、决策与行动的闭环中持续学习和进化，从而突破静态数据训练模型的局限，获得更强的环境适应性与泛化能力^[4]。近年来，在互联网规模数据上预训练的大语言模型与视觉-语言模型（Vision-Language Model, VLM）展现出开放词汇视觉识别、常识推理与任务规划能力，推动机器人基础模型成为具身智能的技术核心^[5]。在操作技能层面，RT-1 与 RT-2 将 Transformer 架构和网络规模的视觉语言知识引入真机控制，使机器人能够从大规模示范数据中学习语言条件下的操作技能^[6,7]；Open X-Embodiment 汇集跨本体、跨机构的机器人数据，验证了跨机器人数据的正向迁移^[8]；视觉-语言-动作（Vision-Language-Action, VLA）模型以预训练 VLM 为主干、以动作专家生成连续动作，在开放环境中对新物体、新场景与新指令表现出泛化能力^[9-11]。与此同时，低成本遥操作与动作分块模仿学习使双臂精细操作可以从数十至数百条人类示范中直接学得^[12,13]；移动操作机器人因兼具移动、规划与操作能力，成为具身智能优先选择的硬件载体^[14]。具身智能机器人由此呈现出与传统工业机器人不同的技术形态：通过数据驱动策略降低对逐点示教和完全结构化环境的依赖，并在闭环感知中生成




(a) 机器人焊接



(b) 汽车车身装配



(c) 食品箱码垛




(d) PCB 元件贴装

图 1: 工业机器人的典型应用场景

动作。图2展示了人形、四足、轮式移动操作和轮式双臂四类本体。它们的自由度、可达空间和运动方式存在明显差异，说明具身智能并不对应单一外形；其共同特征是将感知、策略与可对环境施加作用的身体统一在交互闭环中。

将具身智能引入工业制造，使机器人在产线上具备自主感知、决策与操作能力，正在成为工业机器人技术演进的新方向。2025 年《政府工作报告》首次将具身智能列为国家重点培育的未来产业^[15]；智能制造也正经历从基于规则的自动化制造、数据驱动的数字化智能制造向具身智能赋能的智能制造的演进，具身智能在生产制造、仓储物流、检测维护和人机协作等环节具有直接的赋能作用^[2,16]。然而，工业场景要求机器人更高效、更准确、更可靠、更安全地完成作业，对具身智能提出了不同于开放家庭场景的挑战^[3]：操作对象往往是对准公差小、失效代价高的精密工件，产线对节拍与合格率有明确约束，策略还须在多台机器人之间稳定部署。本课题前期调试反复遇到由移动底盘停靠偏差引起的精细操作失效，而现有标称停靠示范不覆盖这类状态。如何在固定 PCBA 型号、来料位姿、工装几何与光照等环境条件下，量化并提高策略对工位停靠误差的容忍能力，是本课题的研究出发点。图3从机床上下料、厂内物流、在线质量监测和协作机器人作业四个环节展示了具身智能可能进入的制造链条。四类环节分别强调精密操作、跨工位移动、过程感知与安全协作，因而需要将自主策略与现有工艺节拍、质量标准



(a) 人形机器人



(b) 四足机器人



(c) 轮式移动操作机器人



(d) 轮式双臂机器人


图 2: 具身智能可采用的不同机器人本体

和安全边界同时纳入系统设计。

本课题面向的印制电路板组件 (Printed Circuit Board Assembly, PCBA) 检测工位上下料正是这样一个典型场景，它是电子制造产线中重复性高、节拍受限的环节。一次完整的上下料由四个物理工位上的五个操作子任务组成：从上料百叶车夹取待测 PCBA、移动至扫码工位完成扫码登记、从检测台取出已完成检测的上一块 PCBA、将当前 PCBA 放入检测台、最后将上一块 PCBA 放入下料百叶车；检测台的取出与放入共用一次停靠。工位间移动由导航系统完成，不计入 VLA 动作阶段；PCBA 在百叶车料槽中的插入与取出、在检测台上的放置与取出等接触对准操作属于精细操作阶段，机械臂在工位内的接近、搬运与撤离属于自由空间阶段。本课题所用轮式双臂机器人由移动底盘、四自由度腰部、两条七自由度机械臂、二自由度头部与末端夹爪组成，配置头部相机和左右腕部相机，并由激光雷达定位与传统导航算法在工位间移动。前期观测表明实际停靠同时存在厘米量级的位置误差和度量级的航向误差，其统计分布及对操作成功率的影响将在正式实验中按统一协议测量。



(a) 机床上下料



(b) 厂内物流



(c) 焊接过程在线质量监测



(d) 协作机器人产线作业

图 3: 具身智能面向工业制造的典型切入环节

面向这类多阶段双臂任务，以遥操作示范驱动的模仿学习已成为主流策略学习路线。动作分块 Transformer (Action Chunking with Transformers, ACT) 通过一次预测一段动作序列，提出了降低长时序行为克隆有效决策时域的动作分块思想^[12]；流匹配 VLA 模型进一步继承连续动作序列表示，并借助预训练视觉语言表征支持多任务与语言条件控制^[10,11]。本课题已在上述平台上完成“虚拟现实 (Virtual Reality, VR) 遥操作数据采集-基于 OpenPI 的 $\pi_{0.5}$ 微调-真机执行”流水线，已在标称停靠位姿下跑通从观测到动作执行再到新观测的接口闭环。ACT 为动作分块策略提供了方法基础，本文在 $\pi_{0.5}$ 上研究工位停靠误差。前期调试已经观察到停靠偏差条件下 PCBA 插入料槽与放置于检测台时的失败及机械挤压风险，但失败概率随误差的变化仍待分档重复实验量化。

本研究将该现象归纳为一条误差传递链，如图4所示。首先，导航停靠产生平面位置与航向误差；其次，位置误差近似等幅改变目标相对位置，航向误差则经目标到基座的距离转化为横向误差，两者在 PCBA 插入料槽、放置于检测台限位等精细操作阶段与装配公差处于同一量级；最后，系统虽在动作序列重规划边界形成视觉闭环，但一次提交的 s 个控制步在策略层面开环执行，其间的新观测不进入策略，错误动作因而可能持续至下一次重规划。该链条上的三个环节对应三种不同性质的缺陷：状态输入缺少工位相对位姿信息、策略级开环区间与阶段精

度需求不匹配、运行时缺少失败检测与恢复机制。




图 4: PCBA 上下料任务中的模仿学习策略闭环与工位停靠误差传递链

针对上述三个环节，本课题提出基于工位停靠误差传递链的分层鲁棒增强框架。该框架由面向停靠误差补偿的模仿学习方法、分阶段动作序列执行方法和基于预测偏差的在线失败检测与恢复方法构成：误差补偿学习方法将定位系统估计的停靠误差作为 $\pi_{0.5}$ 的显式误差输入，并以随机停靠示范扩大数据覆盖；分阶段执行方法按任务阶段调节动作序列执行时域，在精细操作阶段缩短开环区间，并以实时动作分块（Real-Time Chunking, RTC）连续衔接相邻动作序列；失败检测与恢复方法利用 RTC 重叠区中新旧动作序列的归一化逐步差值检测失败风险，并以固定模板执行恢复与重试。三项方法均不改变策略网络主体结构，分别作用于数据与状态、推理执行和运行时监控，可依次叠加并在同一误差注入协议下比较。这一从已贯通 $\pi_{0.5}$ 数据-推理-动作执行接口链路的真机需求出发、沿误差传递链构建分层增强机制的研究情境，构成本课题的直接来源。

1.2 研究目的与意义

本研究的总体目的是，面向 PCBA 上下料这一跨多工位、含精细对准阶段的轮式双臂任务，在已贯通的 OpenPI $\pi_{0.5}$ 数据-推理-动作执行接口链路基础上，沿工位停靠误差传递链建立可逐层叠加、可统一验证的策略鲁棒性改进方法。 $\pi_{0.5}$ 是本课题唯一的工程部署与实验主线，具体目的包括以下三个方面。

- (1) 面向停靠误差补偿的模仿学习：将激光雷达定位估计 $\hat{\delta}^{\text{loc}} = (\hat{\delta}_x^{\text{loc}}, \hat{\delta}_y^{\text{loc}}, \hat{\delta}_\theta^{\text{loc}})$ 作为显式误差输入，并在示范采集时用导航指令 δ^{cmd} 对 x 、 y 各施加 ± 3 厘米、

对航向施加 $\pm 3^\circ$ 的随机停靠，使策略学习“估计误差-动作修正”的对应关系；通过固定停靠、随机停靠和随机停靠加误差输入三组消融，分离数据覆盖与显式误差输入两种作用。

- (2) 分阶段动作序列执行：在不重新训练模型的前提下，按自由空间与精细操作两类阶段设置不同的执行时域，精细操作阶段仅执行动作序列前部即重新推理，并以 RTC 冻结已确定动作、引导重叠区和生成后续动作，以缩短开环执行区间并保持相邻动作序列连续性；与固定执行时域方式在成功率和推理时延两方面比较。
- (3) 基于预测偏差的在线失败检测与恢复：以 RTC 重叠区中新旧动作序列的归一化逐步差值定义预测偏差量，以成功回合的平滑预测偏差分布确定阈值，实现无需失败训练数据和额外模型训练的失败检测，并配合回退至安全高度、整链最多重试一次的模板化恢复；先在记录的 C2 回合上离线评价召回率、误报率和预警提前量，再在 C3 回合中评价条件恢复成功率、最终整链成功率及额外时延。

图5给出了本课题的研究切入路线。已贯通并完成单回合功能验证的 OpenPI $\pi_{0.5}$ 接口链路提供了功能基线与真机测试条件；真机部署中的失败观察引出工位停靠误差传递链；分层鲁棒增强框架中的三个方法分别对应链条的三个环节，并在统一的误差注入协议、五子任务链和四台机器人条件下按“C0 基线-C1 误差补偿-C2 分阶段执行-C3 检测与恢复”的顺序验证。验证结果还将反向修正示范采集规范与部署参数。

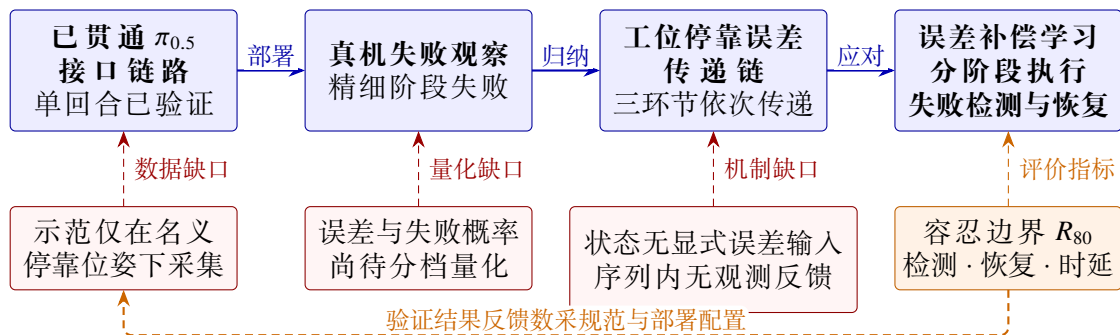


图 5: 从已贯通接口链路到分层鲁棒增强框架的研究切入路线

本研究的工程意义在于形成一套能够按误差、成功率、时延和安全事件验收的部署方案。显式误差输入与随机停靠数据增强旨在相对于 C0 正式测得的基线扩大容忍边界；分阶段执行旨在缩短精细操作阶段的开环执行区间；失败检测与

模板恢复旨在报警后限制错误动作持续时间。三项方法是否减少失败和人工接管由统一真机试验判定，其结论限定于相同 PCBA 型号和工装条件下的四台机器人，并为同类工位迁移提供接口与实验依据。

本研究的方法意义在于，将“模仿学习策略对位姿扰动不鲁棒”这一笼统判断分解为误差传递链上三个可独立度量、可分层验证的问题。三项方法均围绕 OpenPI $\pi_{0.5}$ 实现：误差输入只扩展状态维度，分阶段执行与 RTC 只调整推理侧逻辑，失败检测复用动作序列滚动推理的重叠区，无需失败训练数据和额外检测模型。上述属性可以由实现改动、训练数据和运行时开销直接核验；其对其他流匹配策略和移动操作任务的可迁移性不在本课题中作性能承诺。

综上，本课题的研究必要性源于模仿学习策略从实验室名义条件走向产线部署时，对工位停靠误差、执行粒度和运行时失败三方面缺乏系统处理的现状。为明确相关问题的已有解决路径与适用边界，后续按研究对象与方法类型对国内外相关研究进行梳理与评述。

2 国内外研究现状及分析

本节按“研究对象-策略模型-部署鲁棒性”的顺序梳理相关工作：首先考察工业具身机器人的研究与落地现状，明确其对策略学习方法提出的要求；其次考察 VLA 模型如何回应这些要求，以及通用模型经任务微调后遗留的部署问题；最后针对遗留问题梳理 VLA 模仿学习策略鲁棒性改进研究，并指出与本课题误差传递链对应的空白。三部分之间为递进关系，后者以前者的未解问题为出发点。

2.1 国内外工业具身机器人研究现状

工业具身机器人是将具身智能的感知-决策-行动闭环引入工业作业的机器人系统，其与传统工业机器人的核心区别在于以数据驱动策略取代逐点示教与固定工装，从而应对多品种、短周期和非完全结构化的产线环境^[3,16]。袁依格等把制造业中的具身智能应用归纳为生产制造、仓储物流、检测维护和人机协作四类环节，并指出精密操作与跨工位移动是其中对策略可靠性要求最高的两类任务^[2]；兰洋卜等则从系统角度指出移动操作机器人兼具移动、规划与操作能力，是工业具身智能优先采用的硬件载体^[14]。这一定位意味着工业具身机器人的策略需要同时处理跨工位移动带来的位姿变化和工位上的精细操作。

面向工业操作的学习方法最早集中于接触丰富的装配任务。Levine 等以引导策略搜索将局部轨迹优化的结果蒸馏为神经网络策略^[17]；Inoue 等在高精度轴孔装配中用深度强化学习学习搜索与插入动作^[18]；残差强化学习保留既有控制器，仅学习基础控制之外的修正量^[19]。国内近期工作沿同一思路推进：Ding 等提出以人类示范引导的集成强化学习框架完成高精度轴孔装配^[20]，Su 等在受限区域内结合


示范强化学习与变导纳控制完成装配^[21]。IndustReal 在仿真中训练取放与插装策略并迁移至真实工业机械臂，为此专门设计了几何奖励、采样课程和部署端动作积分器^[22]。对接触丰富操作的综述指出，样本效率、奖励建模、仿真到真机迁移与安全约束是这类方法进入产线的主要障碍^[23]。上述工作面向固定工位上的单一装配动作，策略与工件、工装和坐标系强绑定，工序更换即需重新设计奖励或重新训练，难以覆盖跨工位、多子任务的产线流程。

基于示范的方法降低了对奖励设计与真机试错的依赖。早期工作把装配任务分解为接近、搜索、对准和插入等阶段，再以动态或概率运动原语表示各阶段轨迹分布^[24-26]；Sóti 等针对精密抓放改进 Transporter 网络的平移与旋转精度，并以由粗到细的迭代推理在真实插块任务上验证，说明毫米级放置偏差即决定任务成败^[27]。这些方法对少量数据友好、中间变量便于解释，但依赖人工分段与任务坐标系先验，同样难以复用到对象和指令持续变化的任务。RoboMimic 基准对不同质量的人类示范与多类离线学习算法进行了系统比较，表明观测空间、历史信息与示范质量都会显著影响策略性能^[28]，端到端行为克隆由此成为示范驱动路线的主流。

在移动操作层面，Mobile ALOHA 将双臂系统安装在移动底盘上，以全身遥操作同步采集底盘与双臂示范，并表明与静态数据协同训练可显著提高移动任务的数据效率，但其移动与操作由同一策略端到端输出，未显式处理停靠误差^[13]。ReLMoGen 让学习策略只预测子目标，由经典运动生成器负责到达^[29]；N²M² 在给定末端轨迹的条件下学习底盘与躯干运动，使机器人在未知环境中保持末端可达^[30]；MOMA-Force 在真实移动操作接触任务中同时模仿动作与目标力，由导纳控制器吸收底盘停靠偏差带来的末端接触误差^[31]；WildLMa 以全身控制器为底层、示范技能中层、大语言模型组合技能为高层完成长时序移动操作^[32]。这些工作把底盘运动纳入学习或规划范围，但均以底盘持续运动或力觉补偿为前提，与产线上“停靠后锁定底盘、仅由双臂操作”的流程不同。

工业具身机器人的产线落地在国内已出现规模化案例。据公开报道，智元机器人的轮式双臂机器人精灵 G2 自 2024 年 12 月起在龙旗科技南昌平板制造工厂开展上下料压测与生产环境适配，随后并入真实产线承担测试工序：机器人从流水线传送带抓取组装完成的平板，转腰将其放入身后的测试柜，完成多媒体界面、音频、辐射杂散发射和耦合等检测后倒序取出并送回产线，单件流程约 20 秒，并与工厂制造执行系统（Manufacturing Execution System, MES）及测试设备实时互通；2026 年 4 月的 8 小时公开直播中完成 2283 次任务且无失败，同年 6 月部署规模由 4 台增至 8 台，6 天内完成检测 17 625 件，作业成功率达 99.99%^[33,34]。图6展

示了该案例中的检测工位操作与多机并线作业场景。龙旗方面指出，传统自动化设备刚性强、换型周期长，难以适配多品类平板混线检测，而具身机器人无需定制专用工装即可承接多道差异化工序，场景标定最快约 15 分钟完成；智元方面则承认当前作业效率与人工基本持平、整机成本偏高，且并线过程中暴露的问题需要联合团队逐一解决^[34]。智元同期开源了 AgiBot World 大规模双臂操作数据集及其上预训练的通用策略 GO-1^[35]，但产线部署所用策略的训练与适配细节未见公开；该案例仍足以说明，以预训练通用策略经产线数据适配后进入 3C 精密制造工序已具备可行性。



(a) 检测工位操作

(b) 多机并线作业

图 6: 智元精灵 G2 在龙旗科技平板产线的作业场景^[33,34]

该案例对本课题的意义体现在两方面。一方面，它表明工业具身机器人的竞争力并非单点精度，而是以一套通用策略经少量示范微调后覆盖多道工序的柔性，这直接要求策略模型具备语言条件、多任务与跨场景迁移能力，而这正是前述强化学习装配与任务专用示范方法所不具备的。另一方面，公开报道中的机器人在单一站位面对传送带与测试柜作业，其“自适应位置偏差与产线扰动”的实现方式并未披露；本课题的 PCBA 上下料则需在四个物理工位间导航停靠，每次停靠都引入新的位姿偏差，鲁棒性问题更为突出。因此，工业具身机器人研究向策略学习提出的核心问题是：如何获得一种从示范中学习、可跨工序复用、并在产线位姿偏差下保持可靠的操作策略。前半问题由 VLA 模型研究回应，后半问题则构成本课题的研究对象。

2.2 国内外 VLA 模型研究现状

为了实现从示范学习的专一性到通用工序的泛化性，策略学习经历了从任务专用的动作分块模仿学习到语言条件通用模型的演进。ACT 用条件变分自编码器概括示范动作的多模态分布，并以 Transformer 在时刻 t 一次预测长度为 H 的动作序列^[12]：

$$\mathbf{A}_t = [\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}]. \quad (1)$$

动作序列联合预测把逐步决策转化为块级决策，缩短了长时序行为克隆的有效决策时域，使多阶段双臂操作可以直接从数十条低成本遥操作示范中学得。ACT 执行时对多次推理中指向同一目标时刻的重叠预测作指数加权的时序集成以降低抖动，说明执行时域决定新观测进入控制回路的频率，而重叠预测包含可用于判断相邻动作序列连续性的信息。扩散策略将动作序列建模为条件去噪过程，以滚动时域方式执行预测序列的近期部分后重新规划^[36]，其结构如图7所示；3D 扩散策略与 RISE 以点云替代图像提高了对视角与外观变化的鲁棒性^[37,38]，航点式模仿学习自动抽取关键路点以缩短决策时域^[39]。这类策略为每个任务单独采集示范、单独训练，不含语言条件与预训练表征，示范需求随工序数量线性增长，无法满足产线多工序复用的要求。




图 7: 扩散视觉动作策略：基于观测的动作序列生成框架^[36]

VLA 模型在上述视觉动作策略基础上引入语言条件与视觉语言预训练知识，使一个模型能够处理多任务与语言指令，并显著减少下游任务微调所需的示范量。国外研究起步较早：RT-1 以 Transformer 在大规模真机数据上学习语言条件策略^[6]，RT-2 把视觉语言模型直接微调为动作输出模型，将互联网知识迁移到机器人控制^[7]；Open X-Embodiment 聚合多机构、多本体数据训练 RT-X 模型^[8]，Octo 与 Open-VLA 在其上分别以扩散动作头和离散动作词元建立开源通用策略^[9,40]，DROID 提供了跨场景、跨操作者的大规模真机示范^[41]。国内研究围绕双臂操作、部署效率与数据规模形成特色：RDT-1B 采用扩散 Transformer 与统一动作空间学习双臂表示^[42]；TinyVLA、RoboMamba 与 UniVLA 分别从轻量骨干、高效序列建模和任务中心潜在动作方面降低训练与推理成本^[43-45]；智元发布的 AgiBot World 以百余台同构双臂机器人采集逾百万条轨迹，并以潜在动作预训练通用策略 GO-1，在真实长时序任务上超越 RDT^[35]，为前述产线落地提供了数据与模型基础。

在动作表示方面，Physical Intelligence 提出的 π_0 将预训练视觉语言模型与独

立的动作专家结合，动作专家以流匹配目标生成连续动作序列，从而在保留语义表征的同时适配高频连续控制；其训练区分覆盖多任务、多本体数据的预训练与面向下游技能的后训练^[10]。 π_0 -FAST 采用频域动作序列标记化（Frequency-space Action Sequence Tokenization, FAST）将高频连续轨迹压缩为离散动作标记，以自回归方式提高大规模训练效率^[46]。 $\pi_{0.5}$ 整合两条路线：预训练阶段采用 FAST 离散标记，使机器人动作数据能与图文、目标检测和高层语义预测等异构任务共同训练；后训练阶段加入流匹配动作专家以连续动作序列支持实时控制；推理时先根据观测与总体指令预测语言形式的高层子任务，再以其为条件生成低层动作，从而把任务分解与动作控制纳入同一模型^[11]。OpenVLA-OFT 系统比较了 VLA 微调中的动作解码方式、动作表示与学习目标，表明并行解码、连续动作与回归目标的组合在成功率与动作吞吐率上均优于自回归离散方案^[47]。由此， π 系列形成“ π_0 建立流匹配动作专家- π_0 -FAST 提高训练效率- $\pi_{0.5}$ 通过异构协同训练和高低层统一推理扩展开放环境泛化”的演进路径，也是本课题选择 $\pi_{0.5}$ 作为部署主线的依据。

VLA 模型解决了工业具身机器人对“通用策略经少量示范微调后跨工序复用”的要求，但并未改变微调后策略的本质：它仍是以行为克隆目标在有限示范上拟合的模仿学习策略，其动作输出仍以固定长度的动作序列在策略层面开环执行。由此遗留三个部署问题。第一，预训练带来的泛化主要体现在物体与场景语义层面，对示范分布之外的本体-工位相对位姿扰动缺乏保证，而产线停靠误差恰属此类扰动。第二， $\pi_{0.5}$ 等模型把动作序列长度与执行时域作为固定超参数，未区分自由空间移动与精细对准阶段对闭环频率的不同需求。第三，模型本身不判断当前动作是否已经失败，错误动作会持续至任务终止。这三个问题分别对应本课题误差传递链的三个环节，也是下一小节梳理鲁棒性改进研究的线索。

2.3 国内外 VLA 模仿学习策略鲁棒性改进研究现状

围绕上述三个遗留问题，本小节按误差传递链的顺序梳理鲁棒性改进研究：位姿扰动下的分布偏移处理面向误差源头，动作序列闭环执行面向误差放大环节，运行时失败检测与恢复面向错误动作持续环节。三类研究同样构成递进关系：前者不能完全消除的残余误差由后者处理。

(1) 位姿扰动下的分布偏移处理。 模仿学习策略对训练分布之外的观测缺乏保证，位姿扰动是工业部署中最常见的分布偏移来源。Pumacay 等提出的 THE COLOSSEUM 基准把对象位姿、相机位姿、光照、背景、干扰物与物理参数等扰动轴分离开来，逐轴报告策略性能随扰动强度的退化曲线，从而把“泛化能力”转化为可分级度量的指标^[48]，其组织方式如图8所示。Jin 等的案例分析表明视觉策略可能同时依赖任务相关物理线索与背景视觉属性^[49]；Ishida 等针对移动操作机器

人换工位后自遮挡与背景变化导致的失败，提出关注任务相关视角与图像区域的鲁棒模仿学习方法，说明停靠位姿差异会同时改变本体状态与图像观测^[50]。提高鲁棒性的途径有二。其一是扩大训练数据对扰动的覆盖：动力学随机化通过扩大参数分布提高策略对模型偏差的容忍度^[51]，其思想同样适用于真机示范采集中的初始位姿随机化；DROID 与 Open X-Embodiment 以跨场景、跨本体的数据多样性换取泛化^[8,41]；Mobile ALOHA 表明静态与移动数据协同训练可提高数据效率^[13]。其二是向策略提供扰动的显式输入或由底层控制吸收扰动：MOMA-Force 以力觉模仿与导纳控制吸收停靠偏差^[31]；Mandlekar 等的人在回路任务与运动规划框架把自由空间搬运交给自动规划、仅对接触段采集示范，从数据采集角度区分了自由空间与精细操作阶段^[52]。评价方面，CALVIN 以语言条件长时序任务链呈现误差随链长的累积^[53]，LIBERO 以程序化任务套件评估知识迁移^[54]，RoboMimic 强调示范质量与训练终止规则对结论的影响^[28]。在本文纳入比较的研究中，尚未发现把定位系统估计的工位停靠误差作为策略显式状态、同时在示范采集中系统覆盖随机停靠的方案，数据覆盖与显式误差输入的相对贡献也缺少对应消融。这是面向停靠误差补偿的模仿学习方法的出发点。




图 8: Pumacay 等提出的 THE COLOSSEUM 基准：任务层级与扰动维度^[48]

(2) 动作序列策略的闭环执行。误差补偿只能依据单次状态输入作粗粒度修正，精细对准阶段的残余偏差仍需依靠视觉反馈在执行中持续修正，而反馈频率由动作序列的执行时域决定。ACT 的消融表明动作序列长度增大总体上提高成

功率，时序集成通过对重叠预测加权平均进一步改善平滑性^[12]；扩散策略同样采用固定的预测与执行时域，并指出执行时域过长会削弱对新观测的响应^[36]。但对扩散或流匹配策略直接平均不同生成样本可能产生不可执行的中间动作，ACT 的时序集成不能直接视为 $\pi_{0.5}$ 的原生机制。RTC 针对动作分块流策略，将推理延迟内已确定执行的动作冻结为前缀，并在重叠区引导生成过程、补全后续动作，从而在不重新训练的条件下实现异步连续执行^[55]。OpenVLA-OFT 把动作吞吐率作为与成功率并列的评价指标^[47]，FAST 通过频域词元压缩缩短自回归解码长度^[46]， $\pi_{0.5}$ 以流匹配动作专家非自回归地生成整段序列^[11]，三者都把降低单次推理成本作为高频闭环的前提。然而上述方法在部署时均采用单一执行时域：对 PCBA 上下料这类自由空间移动与精细对准交替的任务，长执行时域在插入料槽、放置于检测台限位等阶段过度开环，全程短执行时域又增加推理次数。在推理侧按阶段切换执行时域、以 RTC 处理相邻动作序列衔接，并同时报告条件成功率、推理频率和时延，尚需系统实现与评价，这是分阶段动作序列执行方法所要验证的内容。

(3) 运行时失败检测与恢复。 前两类方法扩展了策略的误差容忍边界，但停靠误差过大或工件位置异常仍会使状态越出边界，此时模仿学习策略不会自行停止。FAIL-Detect 提出只用成功示范数据的模块化在线失败检测方法：从观测、视觉特征与策略动作中提取失败相关标量，以流密度估计建模不确定性，并用保形预测校准时变阈值，把失败识别表述为序列分布外检测，无需预先枚举失败类型^[56]。Liu 等在交互式模仿学习部署中于共享潜空间训练动力学模型与失败分类器，通过对未来轨迹采样预测异常并触发人工介入^[57]。在恢复方面，RACER 以视觉语言模型监督器在线描述错误与空间修正，由语言条件策略执行恢复动作^[58]；REFLECT 把多模态历史压缩为可解释的失败报告，并由语言规划器生成纠正方案^[59]。这些方案依赖额外的密度估计、分类器或恢复模块，其信号来源与策略自身的动作生成过程相互独立，增加了部署代价。动作序列滚动推理天然提供了另一类信号：前一动作序列的未执行尾部与当前观测下的新动作提议在时间上重叠，状态处于示范分布内时二者差异应当较小，状态被停靠误差推离分布或末端卡滞时差异可能增大。分阶段执行在精细操作阶段更频繁地重新推理，恰好使失败最易发生的阶段拥有最密集的重叠预测。利用 RTC 引导前时间对齐的新旧动作序列构造预测偏差量、以成功回合分位数标定阈值，既不直接平均不同流匹配样本，也无需额外模型或失败训练数据；该信号能否稳定先于失败上升，仍需在本课题任务中实证检验，由此形成基于预测偏差的在线失败检测与恢复方法。

2.4 国内外研究现状简析

以上三部分呈现出清晰的问题传递关系。工业具身机器人研究表明，产线对机器人的核心要求已从单点精度转向以通用策略经少量示范微调后覆盖多道工序的柔性，智元与龙旗的产线案例证明这一路线在 3C 精密制造中可行，但也暴露出位置偏差、产线扰动与偶发失败仍依赖现场适配和人工介入；任务专用的强化学习装配与运动原语方法难以满足跨工序复用要求。VLA 模型以语言条件与视觉语言预训练回应了通用性要求， π 系列进一步以流匹配动作专家和异构协同训练兼顾连续控制与开放环境泛化；但微调后的 VLA 仍是有限示范上的模仿学习策略，遗留位姿扰动下的分布偏移、固定执行时域与缺少失败自知三个部署问题。鲁棒性改进研究分别以数据覆盖与显式输入、闭环执行机制、运行时监控回应这三个问题，且三者递进：前者不能消除的残余误差由后者处理。

就本次检索的代表性样本而言，国外研究在动作分块模仿学习、移动操作全身遥操作、通用 VLA 模型、实时执行与失败检测框架方面起步较早^[9,12,13,55,56]；国内团队在双臂扩散基础模型、轻量高效 VLA 结构、大规模双臂数据与产线落地方面形成了针对性较强的研究与实践^[35,42-45]，哈工大团队在精密装配示范学习方面也有持续积累^[20,26]。上述比较限于所选代表性样本及相应的方法侧重。

将上述进展映射到本课题的目标场景，仍有三个问题有待验证。其一，在本文纳入比较的研究中，尚未发现把定位系统估计的工位停靠误差作为策略显式状态、同时在示范采集中系统覆盖随机停靠的方案，数据覆盖与显式误差输入的相对贡献也缺少对应消融。其二，按自由空间与精细操作阶段区别设置执行时域，并通过 RTC 处理流匹配动作序列异步衔接，其成功率收益和计算代价需要在同一控制接口下评价。其三，RTC 重叠区中新旧动作序列逐步差值能否作为无需额外模型训练的失败信号，以及其回合级召回、误报和报警提前量，仍需在独立测试集上实证。

基于以上问题，本研究以已贯通并完成单回合功能验证的 OpenPI $\pi_{0.5}$ 接口链路为基线，沿“工位停靠误差-精细操作阶段显现-错误动作持续”的传递链构建分层鲁棒增强框架，并在统一的误差注入协议、五子任务链和四台机器人条件下依次叠加验证。核心可检验问题分别落实为容忍边界 R_{80} 、精细子任务条件成功率与推理代价、检测召回率与回合误报率、报警提前量、恢复后整链成功率及安全事件数，所有改善结论均以预先规定的统计判据判断。

3 主要内容及方案

3.1 研究主线与总体技术路线

本课题的研究主线是工位停靠误差在 $\pi_{0.5}$ 策略执行过程中的传递与显现。底盘停靠后产生厘米量级的位置误差与度量级的航向误差；位置误差近似等幅改变操作目标在基座系中的位置，航向误差经目标距离转化为横向偏差，两者在 PCBA 插入料槽、放置于检测台限位等精细操作阶段与装配公差处于同一量级；偏差一旦超出策略的纠正能力，动作序列内部不接收观测反馈的执行方式又使错误动作持续至下一次推理。上述过程构成“工位停靠误差-精细操作阶段显现-错误动作持续”的误差传递链。本课题据此构建分层鲁棒增强框架，针对链上三个环节各提出一项方法，三项方法与误差传递链的对应关系及其相互依赖如图9所示。




图 9: 工位停靠误差传递链与分层鲁棒增强框架的逻辑关系

(1) 面向停靠误差补偿的模仿学习方法。 作用于误差传递链的源头。该方法一方面在示范采集中对每次停靠施加随机误差，使训练分布覆盖部署时的停靠偏差；另一方面将定位系统估计的停靠误差归一化后拼入策略状态，使策略在进入操作阶段前即获得显式误差输入，从而减少进入精细操作阶段的初始偏差。该方法只扩展状态维度与示范分布，不改变策略网络主体结构。其给出的误差容忍曲线是后两项方法共同的评价基准，其误差注入手段也为失败检测与恢复方法提供可控的失败样本。

(2) 分阶段动作序列执行方法。 作用于误差放大环节。误差补偿学习方法的补偿来自单次状态输入，属于粗粒度补偿，残余偏差仍需在精细操作阶段依靠

视觉反馈持续修正。该方法在推理侧按自由空间与精细操作两类阶段切换执行时域：自由空间阶段执行完整动作序列以降低推理开销，精细操作阶段仅执行动作序列前部即重新推理，并以 RTC 保持相邻动作序列连续，从而提高闭环频率、将误差容忍边界向外推移。该方法不改变训练，可直接叠加在误差补偿学习训练所得的策略之上；其在精细操作阶段更频繁的重新推理，也为失败检测与恢复方法提供更密集的重叠预测。

(3) 基于预测偏差的在线失败检测与恢复方法。 作用于错误动作持续环节，处理前两项方法仍无法消除的失败。该方法利用相邻动作序列在重叠区的预测差异构造预测偏差量，以成功回合分位数标定分阶段阈值，在失败造成损坏之前触发模板恢复或安全停机。检测信号直接来自策略自身的滚动推理，无需额外模型或失败训练数据，同样只作用于推理侧。

综上，三项方法沿误差传递链依次设置，分别补偿初始误差、缩短误差放大后的开环执行区间、截断已经失败的执行过程，并在评价基准、失败信号与失败样本三方面相互依赖。策略模型统一采用基于 OpenPI 微调的 $\pi_{0.5}$ 。实验按“C0 基线–C1 误差补偿–C2 分阶段执行–C3 检测与恢复”的顺序逐层叠加，在同一误差注入协议和同一条五子任务链上比较，既考察每一项方法的边际贡献，也给出完整系统的端到端性能。

3.2 任务定义与工位停靠误差传递问题

PCBA 上下料任务由四个物理工位上的五个操作子任务顺序组成，记子任务集合为 $\mathcal{L} = \{\text{上料车取料, 扫码, 检测台下料, 检测台上料, 下料车放料}\}$ ，分别对应从上料百叶车夹取 PCBA、扫码登记、从检测台取出上一块 PCBA、将当前 PCBA 放入检测台以及将上一块 PCBA 放入下料百叶车，如图10所示。外部任务状态机顺序给出语言条件 $\ell_t \in \mathcal{L}$ ， $\pi_{0.5}$ 生成低层连续动作。机器人导航至工位并锁定底盘后执行操作；检测台下料和上料在同一次停靠中连续完成，因而一条完整任务链包含四次停靠事件和五次子任务判定。

以一条完整的五子任务链为一个测试回合。取料类子任务以 PCBA 被夹持并完全离开原承载区域为完成条件，扫码以扫码器返回有效编码为完成条件，放置类子任务以 PCBA 到达目标料槽或检测台限位并在释放后保持稳定为完成条件；掉落、触发接触保护或急停、人工介入以及超时均判为失败。成功与否依据同步视频、夹爪状态与工位传感记录复核，不直接采用在线状态机的转移结果。令 $Y_{e,m} \in \{0, 1\}$ 表示回合 e 的第 m 个子任务是否成功，则整链成功率和第 m 个子任务的条件成功

率分别定义为

$$\hat{S}_{\text{chain}} = \frac{1}{N} \sum_{e=1}^N \prod_{m=1}^5 Y_{e,m}, \quad \hat{S}_m^{\text{cond}} = \frac{\sum_{e=1}^N Y_{e,m} \prod_{q=1}^{m-1} Y_{e,q}}{\sum_{e=1}^N \prod_{q=1}^{m-1} Y_{e,q}}, \quad (2)$$

其中空乘积取 1。整链成功率反映端到端性能，条件成功率则把某个子任务的表现与前序子任务的失败分离开，便于单独考察精细子任务。




图 10: PCBA 上下料五子任务链与工位停靠误差的定义

为描述工位停靠误差，对第 k 个工位定义固连于环境的标称停靠坐标系 $\{S_k\}$ ，该坐标系在示范采集时与机器人基座系 $\{B\}$ 重合。记 ${}^A\mathbf{T}_C$ 为把 $\{C\}$ 中坐标变换到 $\{A\}$ 中的齐次变换， ${}^O\mathbf{T}_{S_k}$ 为标称停靠位姿， ${}^O\mathbf{T}_B$ 为实际停靠后的基座位姿，则停靠误差为

$$\Delta\mathbf{T}_k = ({}^O\mathbf{T}_{S_k})^{-1} {}^O\mathbf{T}_B = \begin{bmatrix} \mathbf{R}(\delta\theta_k) & \delta\mathbf{p}_k \\ \mathbf{0}^T & 1 \end{bmatrix}, \quad \delta_k = (\delta x_k, \delta y_k, \delta\theta_k)^T, \quad (3)$$

式中，底盘停靠于水平地面，误差退化为平面位姿； $\delta\mathbf{p}_k = (\delta x_k, \delta y_k)^T$ 为标称停靠系中的位置误差， $\delta\theta_k$ 为航向误差， $\mathbf{R}(\cdot)$ 为平面旋转矩阵。同一停靠误差在实验中对三个量：写入导航目标的注入量 δ_k^{cmd} 为实验施加的干预变量，激光雷达定位给出的估计 $\hat{\delta}_k^{\text{loc}}$ 为策略的状态观测量，由工位固定视觉基准标记独立测得的参考值 δ_k^{ref} 为评价用的物理真值。参考值的获取方式为：在每个工位固定一块位置经标定的平面基准标记（ArUco 标记），停靠并锁定底盘后，由头部相机在操作开始前采集多帧图像，经透视 n 点求解标记相对相机的位姿，再经头部关节角与一次性标定的头部相机-基座外参换算为基座相对标称停靠系的平面位姿。该测量在一米

内的精度为毫米量级，优于容忍曲线 1 厘米与 1° 的误差量化步长，且不依赖导航栈与激光雷达定位。三者分别记录，测试结果以参考值为真值归档。

工位停靠误差对操作精度的影响可由目标点在基座系中的位置变化刻画。设料槽、检测台定位限位等操作目标固连于工位，在标称停靠系中的平面位置为 $\mathbf{p}_G^{S_k}$ 。示范策略隐含地假定基座与标称停靠系重合，其动作以 $\mathbf{p}_G^{S_k}$ 为目标；实际停靠后，同一目标在基座系中的位置变为 $\mathbf{R}(\delta\theta_k)^T(\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k)$ ，与策略隐含目标之差及其上界为

$$\mathbf{e}_p = (\mathbf{R}(\delta\theta_k)^T - \mathbf{I}) \mathbf{p}_G^{S_k} - \mathbf{R}(\delta\theta_k)^T \delta\mathbf{p}_k, \quad \|\mathbf{e}_p\| \leq \|\delta\mathbf{p}_k\| + |\delta\theta_k| \|\mathbf{p}_G^{S_k}\|, \quad (4)$$

式(4)表明，位置误差近似等幅传递，航向误差项随目标距离放大。本课题各工位的操作目标与停靠位置之间的距离由工装布置决定，近似固定，取 0.5 米估计： 1° 航向误差对应约 8.7 毫米的末端偏差， 3° 对应约 26.2 毫米，与位置误差同处厘米量级，均已达到或超过 PCBA 插入料槽所允许的装配公差。这是停靠误差在精细操作阶段显现为夹取或放置失败的几何原因。

3.3 面向停靠误差补偿的模仿学习方法

停靠误差是整条误差链的起点。若策略只见过标称停靠位下的示范，部署时的误差会直接转化为末端操作偏差。误差补偿学习方法从数据分布与显式误差输入两个方面处理这一问题。数据层面，示范采集时对每次停靠事件独立采样随机停靠误差

$$\delta x_k, \delta y_k \sim \mathcal{U}(-3 \text{ cm}, 3 \text{ cm}), \quad \delta\theta_k \sim \mathcal{U}(-3^\circ, 3^\circ), \quad (5)$$

使训练数据本身覆盖不同的停靠偏差，操作者在遥操作中对误差的修正随之成为动作标签。各子任务的示范在位置象限与航向正负方向上均衡采集，固定停靠组取相同回合数，以避免数据量差异与误差覆盖效应混杂。

状态层面，将定位系统估计的停靠误差经归一化后拼接到已贯通 OpenPI 接口的 14 维本体状态，形成误差增广状态与观测

$$\tilde{\mathbf{x}}_t = \begin{bmatrix} \mathbf{x}_t^T, \bar{\boldsymbol{\delta}}_k^T \end{bmatrix}^T \in \mathbb{R}^{17}, \quad \bar{\boldsymbol{\delta}}_k = \left(\frac{\hat{\delta}_{x,k}^{\text{loc}} - \mu_x}{\sigma_x}, \frac{\hat{\delta}_{y,k}^{\text{loc}} - \mu_y}{\sigma_y}, \frac{\hat{\delta}_{\theta,k}^{\text{loc}} - \mu_\theta}{\sigma_\theta} \right)^T, \quad (6)$$

$$\bar{\mathbf{o}}_t = \{I_t^{\text{head}}, I_t^{\text{wrist},L}, I_t^{\text{wrist},R}, \tilde{\mathbf{x}}_t, \ell_t\},$$

式中， $\mathbf{x}_t$ 为原 14 维双臂末端位姿与夹爪状态， μ 与 σ 为训练集上各误差分量的均值与标准差。误差估计在一次停靠期间保持不变，仅在机器人重新导航并停靠后更新；检测台连续执行的下料与上料共用同一估计。策略网络主体和流匹配训练目标保持不变，仅状态接口由 14 维扩展为 17 维，因而该方法可直接复用现有微调

流水线。显式误差输入使策略能够感知当前停靠偏差并对整体动作作出补偿；视觉输入能否隐式完成同样的补偿，则由消融实验回答。

实验包括误差容忍曲线与消融两部分。容忍曲线在部署时人为注入参考误差，平移幅值取 $\{0, 1, 2, 3, 4, 5\}$ 厘米、航向幅值取 $\{0, 1, 2, 3, 4, 5\}^\circ$ ，分别绘制整链成功率随误差幅值变化的曲线，并以成功率不低于 80% 的最大误差幅值定义容忍边界 R_{80} ，量化策略对停靠误差的容忍范围。消融按表1设置三组配置：(a) 固定标称停靠且不输入误差，即 C0；(b) 随机停靠扩充数据覆盖但不输入误差；(c) 随机停靠并输入误差，即 C1。(a) 与 (b) 的差异给出数据覆盖的贡献，(b) 与 (c) 的差异给出显式误差输入的贡献。三组从同一预训练检查点以相同示范回合数和训练预算微调，且 (b) 与 (c) 使用完全相同的随机停靠回合。C1 的容忍曲线同时是后两项方法的共同基准：分阶段执行方法的目标是把这条边界向外推，失败检测与恢复方法的目标是在边界之外把失败安全地兜住。

表 1: 误差补偿学习方法的消融配置

配置	训练数据停靠方式	状态含误差	考察问题
(a)	固定标称停靠	否	现有流水线基线，给出名义条件下的性能与误差注入下的退化速度
(b)	$\delta x, \delta y \in [-3, 3]$ 厘米， $\delta \theta \in [-3, 3]^\circ$	否	仅靠数据覆盖，策略能否从图像中隐式推断并补偿误差
(c)	与 (b) 相同的随机停靠回合	是	显式误差输入在数据覆盖之外能否进一步扩大容忍边界

3.4 分阶段动作序列执行方法

误差补偿学习方法的补偿来自单次状态输入，属于粗粒度补偿；对于插入料槽、放置于检测台限位等毫米级配合的接触对准阶段，残余误差需要依靠视觉反馈在执行过程中持续修正。 $\pi_{0.5}$ 每次推理生成长度为 H 的动作序列 $\hat{\mathbf{A}}_t$ ，机器人执行其中前 s 步后重新推理。固定的执行时域在两类阶段之间存在矛盾：自由空间中的大范围运动希望 s 长一些，以减少推理次数、降低时延；精细操作阶段则希望 s 短一些，以便及时根据最新观测修正动作。分阶段执行方法不改变训练，只在推理侧按阶段调整执行时域，因而可以直接叠加在误差补偿学习训练好的策略之上。

将时刻 t 的执行阶段记为 $\phi_t \in \{\text{free}, \text{fine}\}$ ，精细操作阶段对应 PCBA 插入与取出料槽、放置于检测台限位等接触对准操作，自由空间阶段对应工位内的接近、搬

运与撤离。阶段由当前子任务标签和末端到操作目标的距离共同判定，并采用进入阈值 d_{enter} 与退出阈值 $d_{\text{exit}} > d_{\text{enter}}$ 的滞回规则避免在阈值附近反复切换：

$$\phi_t = \begin{cases} \text{fine}, & \ell_t \in \mathcal{L}_{\text{fine}} \text{ 且 } \|{}^B\mathbf{p}_{E,t} - {}^B\mathbf{p}_{G_{\ell_t}}\| \leq d_{\text{enter}}, \\ \text{free}, & \ell_t \notin \mathcal{L}_{\text{fine}} \text{ 或 } \|{}^B\mathbf{p}_{E,t} - {}^B\mathbf{p}_{G_{\ell_t}}\| \geq d_{\text{exit}}, \quad s_t = s_{\phi_t}, \quad s_{\text{fine}} < s_{\text{free}} \leq H, \\ \phi_{t-1}, & \text{其他}, \end{cases} \quad (7)$$

式中， ${}^B\mathbf{p}_{E,t}$ 为当前操作臂在基座系中的末端位置， ${}^B\mathbf{p}_{G_{\ell_t}}$ 为由工位标定和停靠误差估计换算得到的操作目标位置， $\mathcal{L}_{\text{fine}}$ 为含精细区段的子任务集合，即扫码以外的四个子任务， s_{free} 与 s_{fine} 分别为两类阶段的执行时域。每个子任务初始阶段置为 free，阶段信号由外部任务状态机和距离规则共同确定，不依赖 $\pi_{0.5}$ 自身的高层预测。

缩短执行时域受推理延迟约束。设第 i 次推理在控制步 n_i 启动，其耗时折算为 d_i 个控制步，则下一次推理在 $n_{i+1} = n_i + s_{\phi}$ 启动，且须满足 $d_i \leq s_{\phi}$ 与 $s_{\phi} + d_i \leq H$ ，即新动作序列必须在前一动作序列耗尽之前返回。为此，执行采用适用于流匹配 VLA 的实时动作分块机制^[55]：新一轮推理进行时，机器人继续执行前一动作序列；生成新动作序列时，将延迟 d_i 内已经确定的动作冻结为前缀，对其后的重叠区施加逐步减弱的引导，再由流匹配动作头补全后续动作，从而在不停顿的前提下连续衔接相邻动作序列。图11给出了两类阶段的执行时序：自由空间阶段采用较长执行时域以减少推理次数，精细操作阶段采用较短执行时域，使新观测更快进入控制回路。 s_{fine} 的下限由目标硬件上实测的推理延迟确定， s_{free} 取接近 H 的值，两者在正式测试前确定并保持不变。




图 11: 分阶段执行时域与 RTC 相邻动作序列连续衔接时序

实验在 C1 策略上进行，比较分阶段执行（即 C2）与全程固定短、中、长三档执行时域的对照组。四组均启用相同的 RTC，因而 C2 与对照组的差异只归因于阶段切换；C1 不使用 RTC，C1 与 C2 之差则反映 RTC 与分阶段组成的整个控制模块的效应。评价指标同时报告成功率与时延：成功率以精细子任务的条件成功率为主，时延报告推理次数、每链累计推理时间与首动作延迟，以验证该方法能够在不牺牲整体效率的前提下提高精细操作阶段的成功率。同时在注入误差的条件下重复误差补偿学习方法的容忍曲线实验，检验闭环频率的提高是否使容忍边界外移。

3.5 基于预测偏差的在线失败检测与恢复方法

经过前两层改进，策略的容忍范围得到扩展，但仍会遇到超出容忍边界的情况，例如停靠误差过大或 PCBA 在百叶车中的位置异常。此时模仿学习策略通常不会自行停止，而是继续执行错误动作，可能造成 PCBA 损坏或机械臂卡滞。失败检测与恢复方法为此提供一种无需额外训练、可在线运行的失败检测与恢复机制。

失败信号来自 RTC 连续执行产生的重叠动作序列。相邻两次推理对同一未来时段各给出一段预测：在策略熟悉的状态下，两段预测应当接近；进入分布偏移或卡滞前，新旧预测的分歧往往先于失败增大。设第 $i-1$ 次推理的动作序列在执行 s_{i-1} 步后留下尾部 $\hat{\mathbf{A}}_i^{\text{prev}}$ ，第 i 次推理在 RTC 引导前给出原始动作提议 $\hat{\mathbf{A}}_i^{\text{raw}}$ ，两者按绝对控制步对齐，重叠区的逐步差值为

$$\mathcal{J}_i = \{j : 0 \leq j < H - s_{i-1}\}, \quad \mathbf{e}_{i,j} = \text{diff}(\hat{\mathbf{a}}_{i,j}^{\text{raw}}, \hat{\mathbf{a}}_{i,j}^{\text{prev}}), \quad j \in \mathcal{J}_i, \quad (8)$$

式中， diff 对位置分量作普通差，对姿态分量作包角差，对夹爪分量按开合状态是否相同取 0 或 1。原始提议在固定参考噪声下生成，以抑制流匹配采样随机性对检测分数的影响。将重叠区归一化逐步差值的加权均值 r_i 称为预测偏差量，将其在连续 L 次推理上的滑动均值 $\tilde{r}_i$ 称为平滑预测偏差：

$$r_i = \frac{\sum_{j \in \mathcal{J}_i} \omega_{i,j} \|\Lambda^{-1/2} \mathbf{e}_{i,j}\|_2^2}{\sum_{j \in \mathcal{J}_i} \omega_{i,j}}, \quad \tilde{r}_i = \frac{1}{L} \sum_{q=i-L+1}^i r_q, \quad (9)$$

式中， $\omega_{i,j}$ 为 RTC 的引导权重，在冻结前缀取 1、在重叠区逐步衰减^[55]，使检测重点落在即将执行的近期动作上； Λ 为由训练集估计的各动作维度方差，用于消除量纲差异。该分数直接复用策略已有的预测，不引入额外网络；其对各类失败模式的覆盖范围由实验给出。

阈值只由成功回合确定，不使用失败标签。在 C2 配置下采集一批成功回合作

为标定集，取每个回合平滑预测偏差的全程最大值，以其 95 分位数作为阈值：

$$M^e = \max_i \tilde{r}_i^e, \quad \eta = Q_{0.95}(\{M^e : e \in \mathcal{E}_{\text{cal}}\}), \quad \text{报警} \iff \tilde{r}_i > \eta \text{ 连续 } n_{\text{hold}} \text{ 次}, \quad (10)$$

式中， $\mathcal{E}_{\text{cal}}$ 为成功标定集。按回合最大值取阈值，意味着成功回合中约有 5% 会出现误报，误报率由此得到直接控制；要求连续超阈则用于过滤单次尖峰。阈值在检测评价前确定并冻结。

检测质量以召回率、误报率和预警提前量评价。利用误差补偿学习方法的误差注入手段，在容忍边界之外制造受控的失败样本；先对记录的 C2 回合离线回放检测器，只产生报警而不改变动作，因而原始失败时刻仍可观察。失败回合中，报警须落在失败发生之前、且早于机器人安全停止所需的时间，才计为及时检出；成功回合中的任何报警计为误报；报警时刻到失败时刻之差为预警提前量。这一评价方式把检测器的表现与恢复动作的效果分离开来。

检测参数确定后，在新的回合中启用固定模板恢复，形成 C3 配置，流程如图12所示。报警后先停止当前动作序列；在夹爪状态正常且回退路径安全的前提下，沿工位竖直方向退至安全高度，回到当前子任务的入口位姿，重新获取观测并重试当前子任务一次。恢复动作采用固定模板执行，不由模型生成，以保证恢复过程本身可靠、可控。若重试后再次报警，或初次报警时安全前提不满足，则立即停机并交由人工处理。C3 报告条件恢复成功率、恢复后的最终整链成功率以及监测和恢复带来的额外时延，并与匹配的 C2 回合比较；同时报告人工接管率与安全事件数，防止额外重试掩盖原策略的退化。

3.6 整体验证方案

三项方法按表2依次叠加为四个配置，在同一套误差注入条件和同一条五子任务链上比较端到端成功率与任务时延，既能看出每一层的边际贡献，也能给出完整系统的最终性能。C0 与 C1 的比较对应误差补偿学习方法，C1 与 C2 的比较对应分阶段执行方法，C2 与 C3 的比较对应失败检测与恢复方法；各方法内部的消融与对照见前述各节。

示范只由一台源机器人采集，其余三台机器人不进入策略训练，用于检验策略在不同本体上的表现，四台机器人的结果分别报告。所有配置使用统一的日志时钟，逐次记录配置、阶段、执行时域、预测偏差量、报警、恢复和子任务结果，并关联机器人、工位、模型检查点与误差档位。以回合为统计单位，成功率等比例指标附置信区间。




图 12: 基于相邻动作序列预测偏差的失败检测与模板恢复流程

表 2: 整体验证的叠加配置

配置	组成	主要考察指标
C0	$\pi_{0.5}$ 固定执行时域基线	标称停靠下的成功率; 误差注入下的退化速度
C1 误差补偿	C0 加入随机停靠示范与停靠误差状态输入	误差容忍曲线与容忍边界 R_{80} ; 相对 C0 及消融 (b) 的成功率差
C2 分阶段执行	C1 加入分阶段执行时域与 RTC	精细子任务条件成功率; 推理次数与时延; 容忍边界是否外移
C3 检测与恢复	C2 加入预测偏差检测与一次模板恢复	检测召回率、误报率与提前量; 恢复成功率、最终整链成功率与额外时延

3.7 可行性分析

本课题的可行性建立在已完成接口和方法的可分步实现上。其一, 第5节所述 VR 示范采集、OpenPI 数据组织、 $\pi_{0.5}$ 任务微调与动作序列执行接口已经贯通, 可直接作为 C0 基线。其二, 三项方法均不改变策略网络主体结构: 误差输入只扩展状态接口, 微调可在课题分配的一张 A100 80G 显卡上完成; 分阶段执行、RTC 与预测偏差监测均位于推理侧; 检测阈值只需成功回合标定, 不需要失败训练数据。其三, 导航目标可程序化注入, 激光雷达定位提供策略输入, 独立工位测量负责实际误差归档, 三者职责分离, 误差注入实验可控、可重复。其四, 四台机器人可并行开展实验, 示范采集与策略训练只占用其中一台及一张显卡。可能的风险与应对措施见第8节。

4 预期达到的目标

本课题预期在已贯通的 OpenPI $\pi_{0.5}$ 接口链路基础上, 建立基于工位停靠误差传递链的分层鲁棒增强框架, 并在轮式双臂机器人和真实的 PCBA 四工位五子任务链上完成验证。具体目标如下。

对于误差补偿学习方法, 预期显式误差输入与随机停靠示范能够使策略在注入误差下的成功率退化明显放缓, 平移与航向两条容忍曲线的容忍边界相对基线向外扩展; 消融结果能够分离数据覆盖与显式误差输入各自的贡献。

对于分阶段执行方法, 预期在精细操作阶段缩短执行时域并以 RTC 连续衔接后, 精细子任务的条件成功率不低于全程短时域配置, 而推理开销明显低于该配置; 相对全程长时域配置, 精细子任务的条件成功率明显提高; 容忍边界相对 C1 进一步外移。

对于失败检测与恢复方法, 预期平滑预测偏差能够在多数误差诱发的失败发

生之前触发报警，成功回合中的误报保持在标定所设定的水平，且报警提前量足以让机器人安全停止；模板恢复能够挽回一部分失败回合，使最终整链成功率相对 C2 提高，同时不引入新的物料或夹具损伤，监测与恢复带来的额外时延不影响精细操作阶段的执行期限。

预期成果形式包括：面向 OpenPI $\pi_{0.5}$ 的工位停靠误差鲁棒性改进方法及其真机验证；四个叠加配置在统一误差协议下的真机实验数据、容忍曲线、检测与恢复结果；以及以上内容为主体的硕士学位论文。

5 已完成的学术研究/实践工作

5.1 实验平台与坐标系定义

本研究已在轮式双臂机器人平台上完成示范采集与策略执行所需的基础接口建设。机器人上半身由左右两条七自由度机械臂、四自由度腰部和二自由度头部组成，共包含 20 个转动关节，并配置末端夹爪、头部相机和腕部相机。现阶段的双臂操作以左右机械臂末端笛卡尔位姿和夹爪状态作为核心状态与动作变量，执行模型将腰部、头部和移动底盘位姿作为固定参数，仅更新左右机械臂的关节状态。移动底盘由激光雷达定位与传统导航算法在工位间移动并停靠，停靠后锁定，操作阶段仅由双臂执行。

为统一描述机器人、工位与虚拟现实 (Virtual Reality, VR) 设备之间的空间关系，本文以 $\alpha \in \{L, R\}$ 区分左、右机械臂，并定义以下坐标系：世界坐标系记为 $\{O\}$ ，机器人基座坐标系记为 $\{B\}$ ，左右末端执行器坐标系记为 $\{E_\alpha\}$ ，第 k 个工位固连于环境且与示范时名义基座位姿重合的停靠坐标系记为 $\{S_k\}$ ；VR 参考坐标系记为 $\{V\}$ ，左右手控制器坐标系记为 $\{H_\alpha\}$ 。其中， ${}^A\mathbf{T}_C$ 表示坐标系 $\{C\}$ 相对于坐标系 $\{A\}$ 的位姿，即把 $\{C\}$ 中的齐次坐标变换到 $\{A\}$ 中。该表示写为

$${}^A\mathbf{T}_C = \begin{bmatrix} {}^A\mathbf{R}_C & {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}, \quad (11)$$

式中， ${}^A\mathbf{R}_C \in \text{SO}(3)$ 为旋转矩阵， ${}^A\mathbf{p}_C \in \mathbb{R}^3$ 为坐标系原点的位置向量。若空间点在 $\{C\}$ 中的齐次坐标为 $\bar{\mathbf{p}}^C$ ，则其在 $\{A\}$ 中的表示为 $\bar{\mathbf{p}}^A = {}^A\mathbf{T}_C \bar{\mathbf{p}}^C$ 。连续坐标变换满足

$${}^A\mathbf{T}_D = {}^A\mathbf{T}_C {}^C\mathbf{T}_D, \quad ({}^A\mathbf{T}_C)^{-1} = \begin{bmatrix} ({}^A\mathbf{R}_C)^T & -({}^A\mathbf{R}_C)^T {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}. \quad (12)$$

式(11)和式(12)构成 VR 增量映射、工位坐标系与前文停靠误差定义的统一表示基础。基座系与末端系之间的正逆运动学由平台现有笛卡尔控制模块提供，本文不再展开。

5.2 基于 VR 遥操作的示范数据采集

在上述坐标关系基础上，本研究已构建基于 VR 设备的双臂遥操作与示范采集链路。系统读取头显及左右手控制器的空间位姿和交互信号，在遥操作回合开始时分别记录控制器初始位姿 ${}^V\mathbf{T}_{H_\alpha}(t_0)$ 与机器人末端初始位姿 ${}^B\mathbf{T}_{E_\alpha}(t_0)$ 。固定标定旋转 ${}^B\mathbf{R}_V$ 用于统一 VR 参考系与机器人基座系的轴向约定，比例系数 λ_α 用于调节操作者手部平移与机器人末端平移的尺度。由此，控制器相对初始位置的增量被映射为

$${}^B\mathbf{p}_{E_{\alpha,d}}(t) = {}^B\mathbf{p}_{E_\alpha}(t_0) + \lambda_\alpha {}^B\mathbf{R}_V ({}^V\mathbf{p}_{H_\alpha}(t) - {}^V\mathbf{p}_{H_\alpha}(t_0)). \quad (13)$$

该增量形式以遥操作开始时的实际末端位置为基准，VR 空间的绝对坐标用于计算控制器相对初始位姿的运动增量。

控制器姿态首先相对于初始姿态计算，再经标定旋转映射到机器人基座系。末端目标姿态表示为

$${}^B\mathbf{R}_{E_{\alpha,d}}(t) = {}^B\mathbf{R}_V \left[{}^V\mathbf{R}_{H_\alpha}(t) ({}^V\mathbf{R}_{H_\alpha}(t_0))^T \right] {}^V\mathbf{R}_B {}^B\mathbf{R}_{E_\alpha}(t_0), \quad (14)$$

其中 ${}^V\mathbf{R}_B = ({}^B\mathbf{R}_V)^T$ 。式(13)与式(14)分别生成末端目标位置和姿态，两者组成 ${}^B\mathbf{T}_{E_{\alpha,d}}(t)$ ，再由已有笛卡尔控制接口执行。手柄交互量 $u_\alpha(t)$ 通过既定映射

$$g_{\alpha,d}(t) = \mathcal{G}_\alpha(u_\alpha(t)) \quad (15)$$

转换为左右夹爪的开合指令。映射函数 $\mathcal{G}_\alpha(\cdot)$ 的触发阈值与夹爪行程参数由平台配置确定。

机器人示范数据通常以一次完整的任务回合作为基本组织单元，将视觉观测、机器人状态与动作按时间步对齐，并在回合层关联任务指令；统一的数据语义有助于后续按不同观测窗口和动作空间构造训练样本^[8]。参照这一组织方式，本研究将当前采集的数据划分为任务、回合和时间步三个层级：任务层以自然语言描述界定操作目标，回合层对应一次完整的遥操作过程，时间步层则以动作时刻为索引，关联头部与左右腕部图像、双臂末端状态、夹爪状态及相应动作。第 n 个任务回合可表示为

$$\tau^{(n)} = \left\{ \left(t_k, I_k^{\text{head}}, I_k^{\text{wrist,L}}, I_k^{\text{wrist,R}}, \mathbf{x}_k, \mathbf{a}_k \right) \right\}_{k=1}^{K_n}, \quad (16)$$

其中， $\mathbf{x}_k$ 包含左右末端位姿与夹爪状态， $\mathbf{a}_k$ 包含对应时刻的双臂笛卡尔动作与夹爪指令。任务语言描述作为策略的语义条件与相应示范回合关联；一个示范回合对应一次低层子任务执行，正式评价中的五子任务链则由状态机串联这些子任务。上述层级将任务语义与单次执行序列分开，同时保持观测、状态和动作在回合内

部逐时对应，可直接为后续视觉-语言-动作策略构造单步样本或动作序列样本。现有示范均在标称停靠位姿下采集，第3.3节将把采集扩展为随机停靠，并在回合层同步记录所属停靠事件的 δ_k^{cmd} 、 $\hat{\delta}_k^{\text{loc}}$ 与 δ_k^{ref} 。

以“将印制电路板组件（Printed Circuit Board Assembly, PCBA）放置到百叶车指定承载位置”为例，该回合以右臂为操作臂，左臂保持固定。机器人在夹爪夹持状态下携带 PCBA 接近百叶车，调整末端位置和姿态完成放置，随后松开夹爪并撤离放置区域。该回合共包含 177 个时间对齐样本；每个时间步包含三路分辨率为 240×320 的彩色图像，以及 14 维双臂末端状态和 14 维双臂动作。状态与动作均按左右臂各 7 维组织，分别由三维位置、滚转-俯仰-偏航姿态和夹爪状态或指令组成。该样例表明，现有采集链路能够将多视角观测、机器人本体状态与遥操作动作组织为式(16)所定义的完整回合。

图13给出了该回合的起始、中间和结束观测，以及右手末端的三维运动轨迹。上部三幅图分别对应第 0、88 和 176 帧：前两帧处于夹持状态，结束帧处于松开状态；下部曲线以颜色和线型区分夹爪语义状态，以箭头表示工具坐标系 +Z 轴方向。轨迹在第 120 帧由夹持切换为松开，使视觉观测、末端位姿和 PCBA 释放事件能够在同一时间轴上对应。

图14概括了已完成系统中数据采集与策略执行之间的接口关系。VR 位姿经过增量映射后进入笛卡尔控制模块，机器人动作及多视角观测由同步记录模块组织为示范轨迹；示范数据经 OpenPI 数据接口适配后用于 $\pi_{0.5}$ 微调，部署阶段由任务状态机提供动态低层语言指令，模型接收新观测并通过同一笛卡尔接口输出动作序列。由此，“VR 数采- $\pi_{0.5}$ 微调-OpenPI 推理-真机执行”的接口链路已经贯通并完成单回合功能验证，示范阶段与推理阶段共享机器人状态、动作定义和底层执行链路。




图 13: 将 PCBA 放置到百叶车任务的示例观测、右手轨迹与夹爪状态




图 14: 已贯通的 VR 数采- $\pi_{0.5}$ 微调-OpenPI 推理-真机执行接口链路

5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与真机闭环

在示范采集链路基础上，现有系统已完成 OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调、在线推理服务接入和真机动作序列执行。当前部署使用 OpenPI 公开的 $\pi_{0.5}$ 模型及流匹配动作头：模型接收头部与左右腕部图像、双臂本体状态和任务状态机提供的低层语言指令，生成连续动作序列，再由笛卡尔控制接口执行并在动作序列边界回传新观测。这里仅声称数据采集-微调-动作序列执行的软件与真机接口链路已经贯通；五子任务整链成功率、工位停靠误差敏感性和相对性能尚待 C0-C3 实验统计。

为说明当前实现所用模型的算法基础，原始 $\pi_{0.5}$ 在 π_0 连续动作生成框架的基础上引入异构协同训练与语义子任务预测，将长时程任务中的高层语义决策与低层动作序列生成组织在统一模型中，其结构及训练流程如图15所示^[11]。

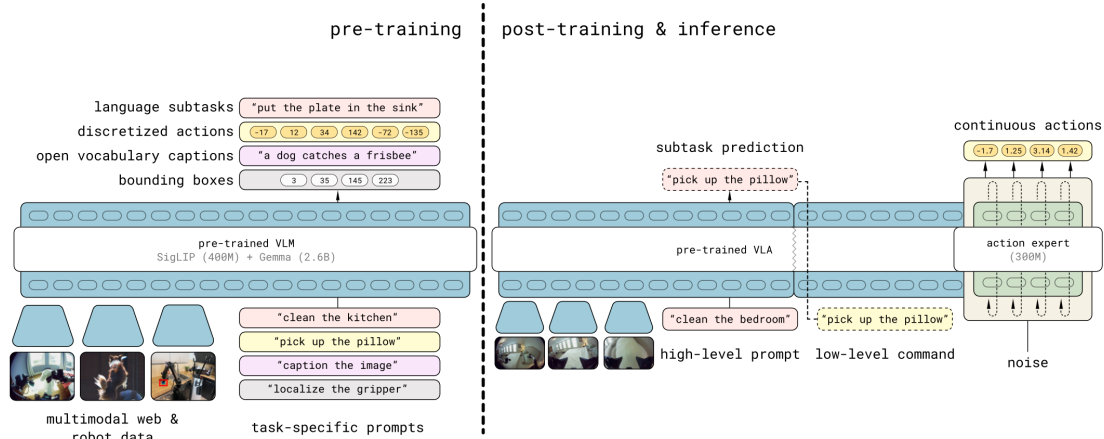


图 15: $\pi_{0.5}$ 模型结构及两阶段训练流程^[11]

图15左侧为预训练阶段。模型以 SigLIP 视觉编码器和 Gemma 语言模型组成的预训练 VLM 为主干，将多模态网络数据、异构机器人数据和任务提示统一表示为序列，并同时学习语义子任务、离散动作、图像描述及目标框等输出。机器人动作在该阶段由 FAST 分词器压缩为离散词元，使动作预测能够与语言建模任务共同采用自回归的下一词元预测目标。图中右侧为后训练与推理阶段：预训练得到的 VLA 模型继续承担图像与语言理解，并在主干之外加入参数量较小的动作专家；动作专家接收连续动作的含噪中间状态，采用条件流匹配逐步生成连续动作序列。由此，模型既保留预训练阶段获得的视觉与语义能力，又能以非自回归方式输出适用于实时控制的连续动作。

在层级推理过程中，VLA 主干首先根据当前多视角观测和高层任务指令 g_t 自

回归生成语义子任务 $\widehat{\ell}_t$ ，例如将“整理卧室”转化为“拿起枕头”；随后，该子任务作为低层语言条件输入动作专家，后者由随机噪声生成长度为 H 的连续动作序列。原模型的联合分布可分解为

$$\pi_{\theta}(\mathbf{A}_t, \widehat{\ell}_t | \mathbf{z}_t, g_t) = \pi_{\theta}(\mathbf{A}_t | \mathbf{z}_t, \widehat{\ell}_t) \pi_{\theta}(\widehat{\ell}_t | \mathbf{z}_t, g_t), \quad (17)$$

其中， $\mathbf{z}_t$ 表示图像与机器人本体状态， g_t 表示原模型的高层任务指令。式(17)的第二项对应原模型的子任务预测，第一项对应动作专家的连续动作生成。上述异构预训练与高层子任务预测属于原始 $\pi_{0.5}$ 的模型能力。当前真机接口直接使用 OpenPI 公开模型及流匹配动作头，由外部任务状态机根据五个子任务直接提供动态低层语言指令 ℓ_t 。为与现有推理接口保持一致，时刻 t 的策略输入写为

$$\mathbf{o}_t = \{I_t^{\text{head}}, I_t^{\text{wrist}, L}, I_t^{\text{wrist}, R}, \mathbf{x}_t, \ell_t\}, \quad (18)$$

其中， ℓ_t 为运行时给定的动态任务语言指令。策略一次推理输出长度为 H 的动作序列：

$$\widehat{\mathbf{A}}_t = \pi_{\theta}(\mathbf{o}_t) = [\widehat{\mathbf{a}}_t, \widehat{\mathbf{a}}_{t+1}, \dots, \widehat{\mathbf{a}}_{t+H-1}]. \quad (19)$$

动作序列中的每个元素均按照前述双臂笛卡尔动作与夹爪指令接口解释。机器人执行其中时域为 s 的近期动作，且 $1 \leq s \leq H$ ；完成该段动作后，系统重新获取多视角图像和末端状态，并结合当前语言指令构造下一轮输入。该过程在动作序列边界形成“状态感知-策略推理-动作序列执行-状态更新”的视觉闭环，而每次提交的 s 个控制步在策略层面不接收新观测。现有部署中 s 为全任务统一的固定值，第3.4节将其改为按阶段取值并加入 RTC 衔接。

(1) **面向 $\pi_{0.5}$ 的模仿学习推导。** 将式(16)所示的专家示范按照长度为 H 的滑动窗口组织，可得动作序列示教数据集

$$\mathcal{D}_E = \left\{ \left(\mathbf{o}_t^{(n)}, \mathbf{A}_t^{\text{E}, (n)} \right) \right\}_{n,t}, \quad \mathbf{A}_t^{\text{E}} = [\mathbf{a}_t^{\text{E}}, \dots, \mathbf{a}_{t+H-1}^{\text{E}}]. \quad (20)$$

行为克隆的基本目标是在专家数据分布上最大化条件动作序列的对数似然，即

$$\theta_{\text{IL}} = \arg \min_{\theta} \mathcal{L}_{\text{IL}}(\theta), \quad \mathcal{L}_{\text{IL}}(\theta) = -\mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^{\text{E}}) \sim \mathcal{D}_E} [\log \pi_{\theta}(\mathbf{A}_t^{\text{E}} | \mathbf{o}_t)]. \quad (21)$$

该目标使策略分布逼近专家在给定多视角图像、机器人状态和语言指令条件下的动作分布；动作序列联合建模还保留了同一操作片段内各时刻动作之间的相关性。

$\pi_{0.5}$ 采用条件流匹配表示连续动作序列分布^[10,11]。对归一化后的专家动作序列 $\mathbf{A}_t^{\text{E}}$ ，采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $\tau \in [0, 1]$ ，构造从噪声到数据的线性概

率路径

$$\mathbf{A}_t^\tau = (1 - \tau)\boldsymbol{\epsilon} + \tau\mathbf{A}_t^E, \quad \mathbf{u}_t^\tau = \frac{\partial \mathbf{A}_t^\tau}{\partial \tau} = \mathbf{A}_t^E - \boldsymbol{\epsilon}. \quad (22)$$

设动作专家输出的条件向量场为 $\mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau)$ ，则模仿微调可写为条件流匹配损失

$$\mathcal{L}_{\text{FM}}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tau \sim p(\tau)} \left[\|\mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau) - (\mathbf{A}_t^E - \boldsymbol{\epsilon})\|_2^2 \right]. \quad (23)$$

最小化式(23)使网络学习式(22)的条件速度场。推理时从 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，沿

$$\frac{d\mathbf{A}_t^\tau}{d\tau} = \mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau) \quad (24)$$

由 $\tau = 0$ 正向积分至 $\tau = 1$ ，即可得到条件动作序列样本 $\hat{\mathbf{A}}_t = \mathbf{A}_t^1$ 。以步长 $\Delta\tau > 0$ 进行欧拉离散时，单步更新为

$$\mathbf{A}_t^{\tau+\Delta\tau} = \mathbf{A}_t^\tau + \Delta\tau \mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau). \quad (25)$$

因此，式(23)给出了示教动作对模型参数的监督关系，式(24)和式(25)则给出了从随机噪声生成连续动作序列的推理过程。

5.4 阶段性工作小结

本节明确了已完成工作与待开展研究的边界。已完成部分包括机器人平台与坐标接口、VR 遥操作和示范数据采集、OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调以及“状态感知–OpenPI 推理–动作序列执行–状态更新”的单回合接口功能验证；激光雷达定位与导航停靠作为平台既有能力可直接调用。尚未开展的部分对应本课题的三项方法：工位停靠误差尚未进入 $\pi_{0.5}$ 状态，示范仍在标称停靠下采集，执行时域仍为全任务固定值，推理侧尚未加入 RTC 连续衔接、相邻动作序列预测偏差检测和模板恢复。因尚无统一误差注入协议下的统计数据，本节不对现有接口链路声明整链成功率或性能优势。

6 进度安排

研究进度将从 2026 年 7 月进入课题时开始计算，至 2027 年 12 月完成论文与答辩准备。各阶段按照“时间段-主要任务-阶段产出”编排，并在后期预留补充实验、设备维护和论文修改时间。

表 3: 研究进度安排

时间	主要任务	阶段产出
2026.07–2026.08	梳理文献与现有平台接口，确定四工位五子任务链及完成、失败、超时与安全判据；制定随机停靠示范采集规范与误差注入协议，完成开题。	开题报告、任务规范与评价协议初稿。
2026.09–2026.10	实现导航指令、定位估计与独立参考误差的同步记录及工位标定接口，将误差增广状态接入 OpenPI $\pi_{0.5}$ 数据格式；布设各工位基准标记，完成头部相机-基座外参标定与参考测量的重复精度校验，并按规范采集随机停靠示范。	三类误差接口、测量校准记录、版本化示范数据及数据说明。
2026.11–2026.12	由同一预训练检查点完成误差补偿学习三组消融的微调；执行平移 0 至 5 厘米、航向 0 至 5° 的误差容忍曲线测试。	误差补偿学习实验数据、容忍曲线与消融结论。
2027.01–2027.03	实现阶段判定、分阶段动作序列执行与 RTC 连续衔接；完成固定时域对照实验与 C2 分阶段执行配置的容忍曲线测试，记录条件成功率与推理时延。	分阶段执行与 RTC 模块、固定时域对照及运行时统计。
2027.04–2027.06	在 OpenPI 推理侧实现相邻动作序列预测偏差监测和模板恢复；用成功回合标定阈值，先在记录的 C2 回合上离线评价检测器，再完成 C3 检测与恢复配置的在线恢复实验。	检测与恢复模块、召回率与误报率、提前量、最终成功率、安全事件与时延数据。
2027.07–2027.09	在四台机器人上补充完成各配置的整体验证实验，整理失败案例并分开报告源机器人和三台目标机器人。	整体验证数据、失败分类与方法适用边界。

续表 3

时间	主要任务	阶段产出
2027.10–2027.12	核对数据、代码和图表, 完成学位论文撰写、修改、送审与答辩准备。	学位论文定稿与答辩材料。

7 为完成课题所需的条件

本课题所需条件分为硬件与场景、算力、数据、软件四类, 如表4所示。已具备部分为第5节贯通的平台与流水线, 尚需补充部分按表3的阶段逐步完成。

表 4: 完成课题所需的条件

类别	已具备	尚需补充
硬件与场景	轮式双臂机器人(腰 4+ 双臂各 7+ 头 2 自由度, 配夹爪、头部与腕部相机、激光雷达导航); 真实 PCBA 四工位五子任务场景	工位基准标记与标定后的相机参考测量链路
算力	8 卡 A100 80G 服务器, 分配一张显卡, 满足 $\pi_{0.5}$ 微调需求。	无。
数据	标称停靠下的 VR 遥操作示范回合	随机停靠示范; 训练、验证、阈值标定与测试集划分; 失败时刻标注
软件	VR 遥操作与同步记录链路; OpenPI $\pi_{0.5}$ 微调与真机部署流水线; 导航栈与笛卡尔控制接口	停靠误差读取与状态增广接口; 分阶段执行与 RTC 衔接模块; 预测偏差量监测与模板恢复模块; 误差注入与统一日志评价工。

8 研究过程中可能遇到的问题以及解决的措施

研究过程中可能遇到的主要问题及相应的解决措施如表5所示。

表 5: 可能遇到的问题及解决措施

可能遇到的问题	解决措施
多配置对比需反复微调 $\pi_{0.5}$	使用联合培养企业的训练服务器完成模型微调，本地显卡承担推理与小规模验证
随机停靠示范数据采集耗时长、人工成本高	复用已有标称停靠示范，只增量采集随机停靠回合；利用多台机器人并行采集
真机实验中误差注入可能引发碰撞，损坏 PCBA 或夹爪	先以低速与限幅运行验证，设置位置与力的安全阈值和急停机制，逐步放开工况
失败检测阈值难以确定，易出现误报或漏报	以成功回合的预测偏差分布标定分阶段阈值，采用滑窗均值平滑后再判定
真机与算力资源共用，实验进度可能受影响	提前排期预约设备，方法先在离线数据上验证，再集中安排真机实验

9 参考文献

- [1] International Federation of Robotics. World Robotics 2025: Industrial Robots[R/OL]. Frankfurt am Main, Germany: IFR Statistical Department, 2025 [2026-09-02]. <https://ifr.org/worldrobotics/report-2025>.
- [2] 袁依格, 何卓丰, 李威, 等. 具身智能驱动的智能制造应用发展研究[J]. 中国工程科学, 2025, 27(3): 67-82. <http://dx.doi.org/10.15302/J-SSCAE-2025.04.016>.
- [3] Zhang C, Zhang C, Xu Z, et al. Embodied Intelligent Industrial Robotics: Framework and Techniques[J]. Journal of Manufacturing Systems, 2026, 88: 158-189. <http://dx.doi.org/10.1016/j.jmsy.2026.06.001>.
- [4] 郑南宁, 杨劭, 姜维周, 等. 具身智能发展趋势与展望[J]. 中国工程科学, 2026, 28(2): 1-13. <http://dx.doi.org/10.15302/J-SSCAE-2025.07.019>.
- [5] Firoozi R, Tucker J, Tian S, et al. Foundation Models in Robotics: Applications, Challenges, and the Future[J]. The International Journal of Robotics Research, 2025, 44(5): 701-739. <http://dx.doi.org/10.1177/02783649241281508>.
- [6] Brohan A, Brown N, Carbajal J, et al. RT-1: Robotics Transformer for Real-World Control at Scale: arXiv:2212.06817[R/OL]. Mountain View, California, USA: Google Research, 2022 [2026-09-02]. <https://arxiv.org/abs/2212.06817>.
- [7] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C] //Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]:

PMLR, 2023: 2165-2183.

- [8] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 6892-6903. <http://dx.doi.org/10.1109/ICRA57147.2024.10611477>.
- [9] Kim M J, Pertsch K, Karamcheti S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[C] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024.
- [10] Black K, Brown N, Driess D, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control[R/OL]. San Francisco, California, USA: Physical Intelligence, 2024 [2026-08-27]. <https://arxiv.org/abs/2410.24164>.
- [11] Black K, Brown N, Darpinian J, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-25]. <https://www.pi.website/download/pi05.pdf>.
- [12] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.016>.
- [13] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[C] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024: 4066-4083.
- [14] 兰沅卜, 赵文博, 朱凯, 等. 基于具身智能的移动操作机器人系统发展研究[J]. 中国工程科学, 2024, 26(1): 139-148. <http://dx.doi.org/10.15302/J-SSCAE-2024.01.010>.
- [15] 国务院. 政府工作报告——2025 年 3 月 5 日在第十四届全国人民代表大会第三次会议上[R/OL]. 北京: 中华人民共和国国务院, 2025 [2026-09-02]. <http://lianghui.people.com.cn/2025/n1/2025/0312/c460142-40437673.html>.
- [16] Ren L, Dong J, Liu S, et al. Embodied Intelligence Toward Future Smart Manufacturing in the Era of AI Foundation Model[J]. IEEE/ASME Transactions on Mechatronics, 2025, 30(4): 2632-2642. <http://dx.doi.org/10.1109/TMECH.2024.3456250>.
- [17] Levine S, Wagener N, Abbeel P. Learning Contact-Rich Manipulation Skills with Guided Policy Search[C] // 2015 IEEE International Conference on Robotics and Automation (ICRA). 2015: 156-163. <http://dx.doi.org/10.1109/ICRA.2015.7138994>.

- [18] Inoue T, Magistris G D, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C] // 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2017: 819-825. <http://dx.doi.org/10.1109/IROS.2017.8202244>.
- [19] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C] // 2019 International Conference on Robotics and Automation (ICRA). 2019: 6023-6029. <http://dx.doi.org/10.1109/ICRA.2019.8794127>.
- [20] Ding G, Zang X, Wang P, et al. An Ensemble Reinforcement Learning Framework for Robotic High-Precision Peg-in-Hole Assembly via Human Demonstrations[J]. Robotics and Computer-Integrated Manufacturing, 2026, 100: 103279. <http://dx.doi.org/10.1016/j.rcim.2026.103279>.
- [21] Su J, Zheng J, Shen L. Robot Assembly Using Variable Admittance Control with Reinforcement Learning from Demonstrations in a Constrained Region[J]. Robotics and Computer-Integrated Manufacturing, 2026, 100: 103259. <http://dx.doi.org/10.1016/j.rcim.2026.103259>.
- [22] Tang B, Lin M A, Akinola I, et al. IndustReal: Transferring Contact-Rich Assembly Tasks from Simulation to Reality[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.039>.
- [23] Elguea-Aguinaco Í, Serrano-Muñoz A, Chrysostomou D, et al. A Review on Reinforcement Learning for Contact-Rich Robotic Manipulation Tasks[J]. Robotics and Computer-Integrated Manufacturing, 2023, 81: 102517. <http://dx.doi.org/10.1016/j.rcim.2022.102517>.
- [24] Yang C, Zeng C, Cong Y, et al. A Learning Framework of Adaptive Manipulative Skills from Human to Robot[J]. IEEE Transactions on Industrial Informatics, 2019, 15(2): 1153-1161. <http://dx.doi.org/10.1109/TII.2018.2826064>.
- [25] Qin F, Xu D, Zhang D, et al. Robotic Skill Learning for Precision Assembly with Microscopic Vision and Force Feedback[J]. IEEE/ASME Transactions on Mechatronics, 2019, 24(3): 1117-1128. <http://dx.doi.org/10.1109/TMECH.2019.2909081>.
- [26] Zang Y, Wang P, Zha F, et al. Peg-in-Hole Assembly Skill Imitation Learning Method Based on ProMPs under Task Geometric Representation[J]. Frontiers in Neurorobotics, 2023, 17: 1320251. <http://dx.doi.org/10.3389/fnbot.2023.1320251>.
- [27] Soti G, Huang X, Wurll C, et al. Train What You Know – Precise Pick-and-Place with Transporter Networks[C] // 2023 IEEE International Conference on Robotics

- and Automation (ICRA). 2023: 5814-5820. <http://dx.doi.org/10.1109/ICRA48891.2023.10161242>.
- [28] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation[C] // Proceedings of Machine Learning Research, Vol 164: Proceedings of the 5th Conference on Robot Learning. [S.l.]: PMLR, 2022: 1678-1690.
- [29] Xia F, Li C, Martín-Martín R, et al. ReLMoGen: Leveraging Motion Generation in Reinforcement Learning for Mobile Manipulation[C] // 2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 4583-4590. <http://dx.doi.org/10.1109/ICRA48506.2021.9561315>.
- [30] Honerkamp D, Welschhold T, Valada A. N²M²: Learning Navigation for Arbitrary Mobile Manipulation Motions in Unseen and Dynamic Environments[J]. IEEE Transactions on Robotics, 2023, 39(5): 3601-3619. <http://dx.doi.org/10.1109/TRO.2023.3284346>.
- [31] Yang T, Jing Y, Wu H, et al. MOMA-Force: Visual-Force Imitation for Real-World Mobile Manipulation[C] // 2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2023: 6847-6852. <http://dx.doi.org/10.1109/IROS55552.2023.10342371>.
- [32] Qiu R-Z, Song Y, Peng X, et al. WildLMa: Long Horizon Loco-Manipulation in the Wild[C] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 10011-10019. <http://dx.doi.org/10.1109/ICRA55743.2025.11128535>.
- [33] 全球首个具身智能工业产线规模落地：智元精灵 G2 连续 8 小时作业零失误[EB/OL]. 新浪科技, 2026-04-15 [2026-09-04]. <https://finance.sina.com.cn/tech/digi/2026-04-15/doc-inhupvfe0971382.shtml>.
- [34] 孙小程. 智元第 15000 台机器人交付至龙旗产线机器人“工友”交出怎样的答卷? [EB/OL]. 上海证券报, 2026-06-30 [2026-09-04]. https://paper.cnstock.com/html/2026-06/30/content_2237360.htm.
- [35] AgiBot-World-Contributors, Bu Q, Cai J, et al. AgiBot World Colosseo: A Large-Scale Manipulation Platform for Scalable and Intelligent Embodied Systems: arXiv:2503.06669[R/OL]. Shanghai, China: AgiBot, 2025 [2026-09-04]. <https://arxiv.org/abs/2503.06669>.

- [36] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.026>.
- [37] Ze Y, Zhang G, Zhang K, et al. 3D Diffusion Policy: Generalizable Visuomotor Policy Learning via Simple 3D Representations[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.067>.
- [38] Wang C, Fang H, Fang H-S, et al. RISE: 3D Perception Makes Real-World Robot Imitation Simple and Effective[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 2870-2877. <http://dx.doi.org/10.1109/IROS58592.2024.10801678>.
- [39] Shi L X, Sharma A, Zhao T Z, et al. Waypoint-Based Imitation Learning for Robotic Manipulation[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2195-2209.
- [40] Octo Model Team, Ghosh D, Walke H, et al. Octo: An Open-Source Generalist Robot Policy[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.090>.
- [41] Khazatsky A, Pertsch K, Nair S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.120>.
- [42] Liu S, Wu L, Li B, et al. RDT-1B: A Diffusion Foundation Model for Bimanual Manipulation[C] // The Thirteenth International Conference on Learning Representations (ICLR). 2025.
- [43] Wen J, Zhu Y, Li J, et al. TinyVLA: Toward Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation[J]. IEEE Robotics and Automation Letters, 2025, 10(4): 3988-3995. <http://dx.doi.org/10.1109/LRA.2025.3544909>.
- [44] Liu J, Liu M, Wang Z, et al. RoboMamba: Efficient Vision-Language-Action Model for Robotic Reasoning and Manipulation[C] // Advances in Neural Information Processing Systems 37 (NeurIPS). 2024.
- [45] Bu Q, Yang Y, Cai J, et al. UniVLA: Learning to Act Anywhere with Task-centric Latent Actions[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.014>.
- [46] Pertsch K, Stachowicz K, Ichter B, et al. FAST: Efficient Action Tokenization for Vision-Language-Action Models[R/OL]. San Francisco, California, USA: Physical

Intelligence, 2025 [2026-08-27]. <https://arxiv.org/abs/2501.09747>.

- [47] Kim M J, Finn C, Liang P. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success[C] //Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.017>.
- [48] Pumacay W, Singh I, Duan J, et al. THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation[C] //Proceedings of Robotics: Science and Systems. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.133>.
- [49] Jin S, Wang R, Zahid M, et al. How Physics and Background Attributes Impact Video Transformers in Robotic Manipulation: A Case Study on Planar Pushing[C] //2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 7391-7398. <http://dx.doi.org/10.1109/IROS58592.2024.10802583>.
- [50] Ishida Y, Noguchi Y, Kanai T, et al. Robust Imitation Learning for Mobile Manipulator Focusing on Task-Related Viewpoints and Regions[C] //2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024.
- [51] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[C] //2018 IEEE International Conference on Robotics and Automation (ICRA). 2018: 3803-3810. <http://dx.doi.org/10.1109/ICRA.2018.8460528>.
- [52] Mandlekar A, Garrett C, Xu D, et al. Human-in-the-Loop Task and Motion Planning for Imitation Learning[C] //Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 3030-3060.
- [53] Mees O, Hermann L, Rosete-Beas E, et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334. <http://dx.doi.org/10.1109/LRA.2022.3180108>.
- [54] Liu B, Zhu Y, Gao C, et al. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning[C] //Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track (NeurIPS). 2023.
- [55] Black K, Galliker M Y, Levine S. Real-Time Execution of Action Chunking Flow Policies[C] //Advances in Neural Information Processing Systems 38 (NeurIPS). 2025. <http://dx.doi.org/10.52202/085713-1122>.
- [56] Xu C, Nguyen T K, Dixon E, et al. Can We Detect Failures Without Failure Data?

- Uncertainty-Aware Runtime Failure Detection for Imitation Learning Policies[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.073>.
- [57] Liu H, Dass S, Martín-Martín R, et al. Model-Based Runtime Monitoring with Interactive Imitation Learning[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 4154-4161. <http://dx.doi.org/10.1109/ICRA57147.2024.10611038>.
- [58] Dai Y, Lee J, Fazeli N, et al. RACER: Rich Language-Guided Failure Recovery Policies for Imitation Learning[C] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025. <http://dx.doi.org/10.1109/ICRA55743.2025.11127799>.
- [59] Liu Z, Bahety A, Song S. REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023.