

哈尔滨工业大学

硕士学位论文开题报告

题 目：面向 PCBA 上下料的轮式双臂模仿学习策略
鲁棒性改进研究
(学位论文)

学 院 (部)	航天学院
学科/专业学位类别	机械
导 师	刘延芳研究员
研 究 生	聂靖轩
学 号	25S118238
开题报告日期	2026 年 9 月

研究生院制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源与研究背景	1
1.2 研究目的与意义	4
2 国内外研究现状及分析	5
2.1 工业操作策略学习研究现状	5
2.2 移动操作停靠误差鲁棒性研究现状	8
2.3 动作块策略闭环执行研究现状	10
2.4 国内外研究现状简析	11
3 主要内容及方案	12
3.1 研究主线与总体技术路线	12
3.2 任务定义与停车误差传递问题	13
3.3 停车残差条件化模仿学习方法	15
3.4 阶段自适应动作块控制方法	16
3.5 预测一致性驱动的运行时容错方法	17
3.6 整体验证方案	20
3.7 可行性分析	20
4 预期达到的目标	21
5 已完成的学术研究/实践工作	21
5.1 实验平台与坐标系定义	21
5.2 基于 VR 遥操作的示范数据采集	22
5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与真机闭环	25
5.4 阶段性工作小结	27
6 进度安排	28
7 为完成课题所需的条件	29
8 研究过程中可能遇到的问题以及解决的措施	30
9 参考文献	31

1 课题来源及研究的目的和意义

1.1 课题来源与研究背景

【填写提示：课题来源：请填写具体项目或工程需求名称及编号。】

工业机器人是面向工业环境设计、可自动控制、可重复编程的多关节机械装置，凭借高精度、高节拍和长时间稳定运行的优势，长期承担焊接、喷涂、搬运、装配等重复性作业，是制造业自动化的核心装备。国际机器人联合会（International Federation of Robotics, IFR）发布的 2025 年世界机器人报告显示，2024 年全球工业机器人新装机量达 54.2 万台，较十年前增长一倍以上，全球在役存量达 466 万台；其中中国新装机 29.5 万台，占全球的 54%，在役存量突破 200 万台，连续多年保持全球最大的工业机器人市场^[1]。电子电气行业是工业机器人的主要应用行业之一，电路板组件的上下料、插件与检测等环节对机器人替代人工存在持续需求。然而，传统工业机器人依赖示教编程或离线编程，在结构化环境中沿预设轨迹重复运动，其可靠性建立在工件位姿、夹具和工艺流程高度固定的前提之上^[2,3]。当产线面临多品种、小批量、快速换型的需求，或工件位置、来料状态存在不确定性时，机器人需要重新示教、重新标定甚至重新设计工装，部署周期与成本显著上升；固定安装的机器人还需要依靠传送带或专用输送设备衔接不同工位，难以独立承担跨工位的物料流转任务。

与传统工业机器人依赖精确编程不同，具身智能（Embodied Intelligence）强调智能体通过物理载体与环境的动态交互，在感知、决策与行动的闭环中持续学习和进化，从而突破静态数据训练模型的局限，获得更强的环境适应性与泛化能力^[4]。近年来，在互联网规模数据上预训练的大语言模型与视觉-语言模型（Vision-Language Model, VLM）展现出开放词汇视觉识别、常识推理与任务规划能力，推动机器人基础模型成为具身智能的技术核心^[5]。在操作技能层面，RT-1 与 RT-2 将 Transformer 架构和网络规模的视觉语言知识引入真机控制，使机器人能够从大规模示范数据中学习语言条件下的操作技能^[6,7]；Open X-Embodiment 汇集跨本体、跨机构的机器人数据，验证了跨机器人数据的正向迁移^[8]；视觉-语言-动作（Vision-Language-Action, VLA）模型以预训练 VLM 为主干、以动作专家生成连续动作，在开放环境中对新物体、新场景与新指令表现出泛化能力^[9-11]。与此同时，低成本遥操作与动作分块模仿学习使双臂精细操作可以从数十至数百条人类示范中直接学得^[12,13]；移动操作机器人因兼具移动、规划与操作能力，成为具身智能优先选择的硬件载体^[14]。具身智能机器人由此呈现出与传统工业机器人不同的技术形态：不再依赖精确编程与结构化环境，而是依靠数据驱动的策略在闭环感知中自主生成动作。

将具身智能引入工业制造，使机器人在产线上具备自主感知、决策与操作能力，正在成为工业机器人技术演进的新方向。2025 年《政府工作报告》首次将具身智能列为国家重点培育的未来产业^[15]；智能制造也正经历从基于规则的自动化制造、数据驱动的数字化智能制造向具身智能赋能的智能制造的演进，具身智能在生产制造、仓储物流、检测维护和人机协作等环节具有直接的赋能作用^[2,16]。然而，工业场景要求机器人更高效、更准确、更可靠、更安全地完成作业，对具身智能提出了不同于开放家庭场景的挑战^[3]：操作对象往往是对准公差小、失效代价高的精密工件，产线对节拍与合格率有明确约束，策略还须在多台机器人、多条产线之间可复制地部署。当前具身智能策略在实验室名义条件下的成功率与其在真实产线扰动下的可靠性之间仍存在明显差距，其中由移动底盘停靠误差、来料位置偏差等引起的位姿扰动最为常见，也最难通过单纯增加示范数据完全覆盖。如何在保留数据驱动策略泛化优势的同时，使其在产线扰动下达到工业可用的鲁棒性，是工业具身智能落地必须解决的问题，也是本课题的研究出发点。

本课题面向的印制电路板组件（Printed Circuit Board Assembly, PCBA）检测工位上下料正是这样一个典型场景，它是电子制造产线中重复性高、节拍要求明确的环节。一次完整的上下料包含五个子任务：从上料百叶车夹取待测 PCBA、移动至扫码工位完成扫码登记、从检测台取出已完成检测的上一块 PCBA、将当前 PCBA 放入检测台、最后将上一块 PCBA 放入下料百叶车。上述子任务分布在不同工位，机器人需要在工位间移动并停靠；其中夹取百叶车槽位中的 PCBA、将 PCBA 插入检测台以及放回百叶车槽位均属于对准精度要求接近槽位间隙的精细操作，其余移动与抓取则属于容差较大的自由空间运动。本课题所用轮式双臂机器人由移动底盘、四自由度腰部、两条七自由度机械臂、二自由度头部与末端夹爪组成，配置头部相机和左右腕部相机，并由激光雷达定位与传统导航算法在工位间移动。该平台在感知与操作能力上能够覆盖上述五个子任务，但工位停靠精度由导航与定位模块决定，通常处于厘米级。

面向这类多阶段双臂任务，以遥操作示范驱动的模仿学习已成为主流策略学习路线。动作分块 Transformer（Action Chunking with Transformers, ACT）通过一次预测一段动作序列，提出了降低长时序行为克隆有效决策时域的动作分块思想^[12]；流匹配 VLA 模型进一步继承连续动作块表示，并借助预训练视觉语言表征支持多任务与语言条件控制^[10,11]。本课题已在上述平台上完成“虚拟现实（Virtual Reality, VR）遥操作数据采集-基于 OpenPI 的 $\pi_{0.5}$ 微调-真机闭环执行”流水线，在名义停靠位姿下具备端到端功能。ACT 为动作分块策略提供了方法基础，本文在已完成闭环部署的 $\pi_{0.5}$ 上开展面向停车误差的鲁棒性改进。然而，现有示范数据均在名

义停靠位姿下采集，当机器人实际停靠位姿偏离名义位姿时，策略在精细阶段的成功率将随偏差增大而下降，并且失败往往伴随对 PCBA 或夹具的机械挤压。

本研究将该现象归纳为一条误差传递链，如图1所示。首先，激光雷达定位与导航停靠产生厘米级的位置与航向残差；其次，策略未曾见过带残差的观测与状态组合，动作块推理在自由空间阶段尚可依赖视觉纠正，进入进槽、落台等精细阶段后，残差经机械臂作业半径被放大为末端对准误差；最后，动作块以开环方式整段执行，策略不感知偏差，错误动作持续输出直至任务失败或造成损坏。该链条上的三个环节对应三种不同性质的缺陷：状态输入缺少停车残差信息、动作块执行粒度与阶段精度需求不匹配、运行时缺少失败检测与恢复机制。




图 1: PCBA 上下料任务中的模仿学习策略闭环与停车误差传递链

针对上述三个环节，本课题提出基于停车误差传递链的分层鲁棒增强框架。该框架由停车残差条件化模仿学习方法、阶段自适应动作块控制方法和预测一致性驱动的运行时容错方法构成：条件化学习方法将停车残差作为 $\pi_{0.5}$ 的状态条件，并以随机停车示范扩大条件空间的数据覆盖；自适应控制方法按任务阶段调节动作块执行时域，在精细阶段缩短开环区间，并以实时动作分块（Real-Time Chunking, RTC）连续衔接前后动作块；运行时容错方法利用 RTC 重叠区中新旧动作块的归一化一致性残差检测失败风险，并以固定模板执行恢复与重试。三项方法均不改变策略网络主体结构，分别作用于数据与状态、推理执行和运行时监控，可依次叠加并在同一残差注入协议下比较。这一从已跑通 $\pi_{0.5}$ 闭环的真机部署需求出发、沿误差传递链构建分层增强机制的研究情境，构成本课题的直接来源。

1.2 研究目的与意义

本研究的总体目的是，面向 PCBA 上下料这一跨多工位、含精细对准阶段的轮式双臂任务，在已跑通的 OpenPI $\pi_{0.5}$ 闭环基础上，沿停车误差传递链建立可逐层叠加、可统一验证的策略鲁棒性改进方法。 $\pi_{0.5}$ 是本课题唯一的工程部署与实验主线，具体目的包括以下三个方面。

- (1) 停车残差条件化模仿学习：将激光雷达定位给出的停车残差 $(\delta x, \delta y, \delta \theta)$ 作为显式状态输入拼接到策略本体状态中，并在示范采集时引入 ± 3 厘米范围的随机停靠，使策略学习“残差-动作修正”的对应关系；通过固定停车、随机停车和随机停车加残差输入三组消融，分离数据覆盖与显式条件两种作用。
- (2) 阶段自适应动作块控制：在不重新训练模型的前提下，按自由空间与精细操作两类阶段设置不同的执行时域，精细阶段仅执行动作块前部即重新推理，并以 RTC 冻结已确定动作、引导重叠区和生成后续动作，以缩短开环执行区间并保持跨块连续性；与固定执行时域方式在成功率和推理时延两方面比较。
- (3) 预测一致性驱动的运行容错：以 RTC 重叠区中新旧动作块的归一化残差定义跨块不一致度，以成功回合的分位数标定阈值，实现无需额外模型训练的在线失败检测，并配合回退至安全高度、重试一次的模板化恢复；以召回率、误报率、提前量和最终成功率评价其收益。

图2给出了本课题的研究切入路线。已跑通的 OpenPI $\pi_{0.5}$ 闭环提供了可复现的基线与真机测试条件；真机部署中的失败观察引出停车误差传递链；分层鲁棒增强框架中的三个方法分别对应链条的三个环节，并在统一的残差注入协议、五工位任务链和多台机器人条件下按“C0 基线方法-C1 条件化学习-C2 叠加自适应控制-C3 完整框架”的顺序验证。验证结果还将反向修正示范采集规范与部署参数。




图 2: 从已跑通流水线到分层鲁棒增强框架的研究切入路线

本研究的工程意义在于提高模仿学习策略在真实产线条件下的可用性与物料安全性。工位停靠误差是移动操作机器人部署中不可避免的扰动，若策略只能在名义停靠位姿附近工作，则每次部署都需要人工校准或高精度定位设备。显式残差输入与随机停车数据增强使策略对停靠偏差具备一定容忍度；分阶段执行降低精细阶段的开环风险；失败检测与模板恢复则在策略已经出错时限制损失范围，避免持续挤压 PCBA 或夹具。三者共同作用可以降低对定位精度和人工干预的依赖，为在多台机器人、多条产线上复用同一策略提供条件。

本研究的方法意义在于，将“模仿学习策略对位姿扰动不鲁棒”这一笼统判断分解为误差传递链上三个可独立度量、可分层验证的问题，并给出对应的低成本解决方案。三项方法均围绕 OpenPI $\pi_{0.5}$ 实现：残差输入只扩展状态维度，分阶段执行与 RTC 只调整推理侧逻辑，失败检测只利用动作块滚动推理已有的重叠区。因此，相关结论有望为其他流匹配动作块策略和移动操作任务提供参考。基于跨动作块一致性残差的失败检测还为 VLA 模型的部署提供了一种无需失败数据、无需额外模型训练的运行时监控手段。

综上，本课题的研究必要性源于模仿学习策略从实验室名义条件走向产线部署时，对停靠误差、执行粒度和运行时失败三方面缺乏系统处理的现状。为明确相关问题的已有解决路径与适用边界，后续按研究对象与方法类型对国内外相关研究进行梳理与评述。

2 国内外研究现状及分析

2.1 工业操作策略学习研究现状

本研究关注的对象是工业场景中由机器人闭环完成的抓取、放置与插接类操作，其特点是对准公差小、失效代价高、节拍要求明确。早期学习方法主要面向接触

丰富的装配任务，通过强化学习或力控制在交互中学习插入与对准动作。Levine 等将引导策略搜索用于接触操作，以局部轨迹优化为神经网络策略提供监督信号^[17]；Inoue 等在高精度装配中采用深度强化学习，使策略根据状态反馈学习探索与插入动作^[18]；残差强化学习保留既有控制器，仅学习基础控制之外的修正量^[19]。对接触丰富操作的综述指出，样本效率、奖励建模、仿真到真机迁移与安全约束是该类方法进入产线的主要障碍^[20]。上述路线依赖真机交互或高保真仿真，在多阶段、跨工位的产线任务中难以直接铺开。

基于示范的模仿学习通过专家轨迹建立观测到动作的映射，能够在不进行大范围随机探索的条件下为机器人提供可执行的策略。早期方法通常将任务分解为接近、搜索、对准和插入等阶段，再以动态或概率运动原语显式表示轨迹分布^[21-23]。这类方法对少量数据较为友好，且中间变量便于解释，但依赖人工分段与任务坐标系先验，难以复用到对象、场景和指令持续变化的任务中。RoboMimic 基准对不同质量的人类示范和多类离线学习算法进行了系统比较，表明观测空间、历史信息、示范质量与模型选择都会影响策略性能^[24]，端到端行为克隆由此成为主流。

动作分块是当前端到端模仿学习的核心技术，其与低成本遥操作的结合使多阶段双臂操作可以直接从示范中学得，而无需人工设计接触模式或奖励。ACT 用条件变分自编码器概括示范动作的多模态分布，并以 Transformer 在时刻 t 一次预测长度为 H 的动作块^[12]：

$$\mathbf{A}_t = [\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}]. \quad (1)$$

动作块联合预测把逐步决策转化为较短的块级决策，从而缩短长时序行为克隆的有效决策时域。ACT 执行时对多次推理中指向同一目标时刻的重叠预测作指数加权的时序集成，以降低动作抖动；这说明执行时域决定新观测进入控制回路的频率，而重叠动作块包含可用于判断跨块连续性的信息。ACT 本身是面向任务的视觉-本体状态策略，不含语言条件和预训练通用表征，因此在本文中只作为动作分块与重叠预测思想的算法背景，不作为研究模型或实验对象。

扩散策略将动作序列建模为条件去噪过程，以概率生成方式表达同一观测下的多种合理动作，并以滚动时域方式执行预测序列的近期部分后重新规划^[25]，其总体结构如图3所示。3D 扩散策略与 RISE 分别以点云替代图像作为输入，提高了策略对视角与外观变化的鲁棒性^[26,27]；航点式模仿学习则自动从示范中抽取少量关键路点，以缩短行为克隆的决策时域^[28]。这些工作均把预测时域和每次执行的时域作为固定超参数：预测时域增大有利于序列一致性，但若执行时域随之增长会延长开环区间；缩短执行时域能够提高闭环反馈频率，却增加推理负担与跨块

衔接需求。




图 3: 扩散视觉动作策略的观测条件化与动作序列生成框架^[25]

视觉-语言-动作模型在上述视觉动作策略基础上引入语言条件和视觉语言预训练知识，使下游任务微调所需示范量显著减少，并能够在在一个模型中处理多任务与语言指令^[11]。RT-1 以 Transformer 在大规模真机数据上学习语言条件策略^[6]，RT-2 把视觉语言模型直接微调为动作输出模型^[7]；Open X-Embodiment 聚合多机构、多本体数据训练 RT-X 模型^[8]，Octo 与 OpenVLA 在其上分别以扩散动作头和离散动作词元建立开源通用策略^[9,29]；DROID 提供了跨场景、跨操作者的大规模真机示范数据^[30]。围绕双臂操作与部署效率，RDT-1B 采用扩散 Transformer 与统一动作空间学习双臂表示^[31]，TinyVLA、RoboMamba 与 UniVLA 分别从轻量骨干、高效序列建模和任务中心潜在动作方面降低训练与推理成本^[32-34]。

在动作表示方面，Physical Intelligence 提出的 π_0 将预训练视觉语言模型与独立的动作专家结合，动作专家以流匹配目标生成连续动作块，从而在保留语言与视觉语义表征的同时适配高频、连续的机器人控制^[10]。其训练过程区分覆盖多任务、多本体数据的预训练与面向下游技能的后训练：前者用于获得可迁移的通用能力，后者使用质量更高的任务示教形成稳定执行策略。ACT 所代表的任务专用动作分块行为克隆说明了序列化动作输出的价值； π_0 则把连续动作块作为 VLA 动作专家的生成对象，并把任务示教微调纳入通用模型的训练链路。二者在动作块表示上存在方法联系，但模型条件、训练数据与生成机制并不相同。

随后， π_0 -FAST 采用频域动作序列标记化（Frequency-space Action Sequence Tokenization, FAST），将高频连续轨迹压缩为离散动作标记，以自回归方式提高大规模 VLA 训练效率^[35]。该方法与 π_0 的流匹配路线形成连续动作生成和离散动作建模两种实现。 $\pi_{0.5}$ 在此基础上进一步整合两条路线：预训练阶段采用 FAST 离散动作标记，以便将机器人动作数据与图文、目标检测和高层语义预测等异构任务

共同训练；后训练阶段加入与 π_0 一致的流匹配动作专家，以连续动作块支持实时控制^[11]。在推理阶段， $\pi_{0.5}$ 先根据视觉观测与总体指令预测语言形式的高层子任务，再以该子任务为条件生成低层连续动作，从而把任务分解与动作控制纳入同一模型。由此， π 系列形成了“ π_0 建立流匹配动作专家- π_0 -FAST 提高动作序列训练效率- $\pi_{0.5}$ 通过异构协同训练和高低层统一推理扩展开放环境泛化”的演进路径。

尽管示范驱动的策略学习大幅降低了工程门槛，工业抓放对精度的要求并未降低。IndustReal 在仿真中训练取放与插装策略并迁移到真实工业机械臂，为此专门设计了几何奖励、采样课程与部署端动作积分器，以消除接触仿真误差与稳态对准误差^[36]；Sóti 等针对精密抓放改进 Transporter 网络的平移与旋转精度，并以由粗到细的迭代推理在真实插块任务上验证，说明毫米级的放置偏差即决定任务成败^[37]。因此，模仿学习策略进入工业抓放场景时，需要在示范驱动的便利性与精细阶段的对准精度之间建立明确的处理机制。本课题的 PCBA 进槽与落台正属于此类精细阶段。

综上，VLA 模仿学习已形成基于通用模型、通过任务示范进行下游微调的技术路线，且以动作块作为重要输出形式。ACT 为动作分块策略提供了方法基础，本文在已完成闭环部署的 $\pi_{0.5}$ 上开展面向停车误差的鲁棒性改进，重点检验数据与状态输入、动作块执行粒度和运行时监控三个环节能否与上述精度需求相匹配。

2.2 移动操作停靠误差鲁棒性研究现状

轮式双臂机器人在工位间移动后再执行操作，属于移动操作（Mobile Manipulation）问题，其核心困难之一是底盘定位误差向操作阶段的传递。Mobile ALOHA 将 ALOHA 双臂系统安装在移动底盘上，以全身遥操作同步采集底盘与双臂示范，并把底盘速度纳入模仿学习的动作空间；该工作还表明与静态 ALOHA 数据协同训练能够显著提高移动任务的数据效率，但其移动与操作由同一策略端到端输出，未显式处理停靠残差^[13]。ReLMoGen 让学习策略只预测子目标，由经典运动生成器负责到达，体现了学习决策与经典运动执行分层的思路^[38]；N²M² 在给定末端轨迹的条件下学习底盘与躯干运动，使移动操作机器人在未知环境中保持末端运动学可达^[39]。上述工作把底盘运动纳入学习范围，但均以底盘持续运动为前提，与本课题“停靠后锁定底盘、仅由双臂操作”的产线流程不同。

对停靠后操作误差的补偿主要出现在力觉与技能组合研究中。MOMA-Force 在真实移动操作接触任务中同时模仿动作与目标力/力矩，由导纳式全身控制器跟踪，直接处理底盘定位残差带来的末端接触误差^[40]；WildLMa 以全身控制器为底层、少量示范技能为中层、大语言模型组合技能为高层，在真实环境中完成长时序移动操作^[41]。Mandlekar 等提出的人在回路任务与运动规划框架把自由空间搬

运交给自动规划，仅对接触段采集遥操作示范，从数据采集角度区分了自由空间与精细阶段^[42]。Ishida 等针对移动操作机器人换工位后自遮挡与背景变化导致的失败，提出关注任务相关视角与图像区域的鲁棒模仿学习方法，说明停靠位姿差异会同时改变本体状态与图像观测^[43]。

综合来看，现有研究已认识到底盘定位残差对操作阶段的影响，但处理方式集中在力控补偿、技能组合或视觉表征，尚未见把激光雷达定位给出的停车残差直接作为策略状态输入、并在示范采集中系统覆盖随机停靠的工作。从策略学习的角度看，停车残差本质上是一类位姿扰动，其度量与应对可借鉴更一般的位姿扰动鲁棒性研究。

模仿学习策略对训练分布之外的观测缺乏保证，位姿扰动是工业部署中最常见的分布偏移来源之一。Pumacay 等提出的 THE COLOSSEUM 基准把对象位姿、相机位姿、光照、背景、干扰物与物理参数等扰动轴分离开来，逐轴报告策略性能随扰动强度的变化，从而把“泛化能力”转化为可分级度量的退化曲线^[44]，其任务与扰动组织方式如图4所示。Jin 等的案例分析进一步表明，视觉策略可能同时依赖任务相关物理线索与背景视觉属性^[45]；前述 Ishida 等的工作则说明，移动操作中的视角与背景变化同样源于停靠位姿差异^[43]。停车残差同时改变本体状态与三路相机视角，属于典型的多轴耦合扰动。




图 4: Pumacay 等提出的 THE COLOSSEUM 基准：任务层级与扰动维度^[44]

提高扰动鲁棒性的主要途径是扩大训练数据对扰动的覆盖，或向策略提供扰

动的显式条件。动力学随机化通过扩大仿真参数分布提高策略对模型偏差的容忍度^[46]，其思想同样适用于真机示范采集中的初始位姿随机化；航点式模仿学习把动作锚定在少量关键路点上，减少了对精确轨迹复现的依赖^[28]。在评价协议方面，CALVIN 以语言条件的长时序任务链考察策略连续完成多个子任务的成功率，显式呈现误差随任务链长度的累积^[47]；LIBERO 以程序化生成的任务套件评估策略的知识迁移与遗忘^[48]；DROID 与 Open X-Embodiment 均建议按机器人、场景或日期分组留出以避免评价泄漏^[8,30]；RoboMimic 则强调示范质量与训练终止规则对结论的影响^[24]。

对本课题而言，上述工作提供了两方面依据。其一，停车残差可以作为一条明确的扰动轴，以程序化注入的方式分级施加，并绘制成功率随残差幅值变化的容忍曲线；其二，“随机停车数据增强”对应数据覆盖，“残差状态输入”对应显式条件，二者在文献中通常独立出现，其相对贡献需要通过固定停车、随机停车、随机停车加残差输入三组消融来识别。这正是停车残差条件化模仿学习方法的出发点与实验设计来源。

2.3 动作块策略闭环执行研究现状

动作块策略部署后，每次执行的时域决定了观测反馈的闭环频率，运行时失败检测则在任务层面闭合回路，二者共同决定策略在真实系统中的实时性与安全性。在执行方式上，现有工作的核心是开环区间长度与推理频率之间的权衡。ACT 的消融表明块长增大总体上提高成功率，而时序集成通过对重叠预测加权平均进一步改善动作平滑性；该结果在方法层面说明重叠动作块具有连续性信息^[12]。扩散策略同样采用固定的预测时域与执行时域，并指出执行时域过长会削弱对新观测的响应^[25]。但对扩散或流匹配策略直接平均不同生成样本可能产生不可执行的中间动作，不能把 ACT 时序集成直接视为 $\pi_{0.5}$ 的原生机制。RTC 针对动作分块流策略，将推理延迟内已确定执行的动作冻结为前缀，并在重叠区引导生成过程、补全后续动作，从而在不重新训练策略的条件下实现异步连续执行^[49]。OpenVLA-OFT 系统比较了 VLA 微调中的动作解码方式、动作表示与学习目标，并把动作吞吐率作为与成功率并列的评价指标^[50]；FAST 通过频域动作词元压缩缩短自回归解码长度^[35]， $\pi_{0.5}$ 则以流匹配动作专家非自回归地生成整段动作块^[11]，两者都把降低单次推理成本作为实时控制的前提。

现有工作普遍将预测时域视为训练期确定的超参数，并在部署时对整个任务采用单一执行时域。对于 PCBA 上下料这类自由空间移动与精细对准交替出现的任务，长执行时域在进槽、落台等接触阶段可能过度开环，而全程采用短执行时域又会显著提高推理开销。自由空间阶段可以容忍较长的开环执行，精细阶段则需

要更短的执行区间以便及时纠正残差引起的偏差。在推理侧按阶段切换执行时域、以 RTC 处理跨块衔接，并同时报告成功率与时延，尚需系统实现与评价，这是阶段自适应动作块控制方法所要验证的内容。

模仿学习策略在分布外状态下的失败往往在动作层面提前显现，运行时失败检测的目标是在造成损坏之前发出预警。FAIL-Detect 提出只用成功示范数据进行模仿策略在线失败检测的模块化方法：从观测、视觉特征与策略动作中提取失败相关标量，以流密度估计建模不确定性，并用保形预测校准时变阈值，将失败识别表述为序列分布外检测，从而无需预先枚举失败类型或采集失败数据^[51]。Liu 等在交互式模仿学习部署中于共享潜空间训练动力学模型与失败分类器，通过对未来轨迹采样预测异常与失败，并结合分布外判据触发人工介入^[52]。在恢复方面，RACER 以视觉语言模型监督器在线描述错误与空间修正，由语言条件策略执行恢复动作，训练数据包含自动生成的扰动与恢复轨迹^[53]；REFLECT 把多模态历史压缩为可解释的失败报告，并由语言规划器生成纠正方案^[54]。

上述检测器普遍需要额外训练密度模型、分类器或恢复策略，且其信号来源与策略本身的动作生成过程相互独立。动作块滚动推理天然提供了另一类信号：前一动作块的未执行尾部与当前观测下的新动作提议在时间上存在重叠，当状态处于示范分布内时，二者应具有较高一致性；当停车残差把状态推离示范分布或末端已经卡滞时，跨块残差可能增大。本文利用 RTC 构造流匹配策略的连续执行边界，同时在 RTC 引导前比较时间对齐的新旧动作块，以归一化残差定义不一致度，并用成功回合分位数标定阈值。这样既不直接平均不同流匹配样本，也无需引入额外模型或失败训练数据；该信号能否稳定先于失败上升，仍需在本课题任务中实证检验，由此形成预测一致性驱动的运行时空容错方法。

2.4 国内外研究现状简析

现有研究已形成三点共识。第一，多阶段双臂操作可以通过低成本遥操作示范与动作分块模仿学习获得，VLA 预训练进一步降低了下游任务的示范需求。第二，位姿扰动是模仿学习策略部署中的主要分布偏移来源，扩大数据覆盖与提供显式条件是两条互补的鲁棒性途径，评价应报告性能随扰动强度的退化曲线而非单一成功率。第三，动作块的执行方式与运行时监控直接决定策略在真实系统中的安全性，成功率之外还需要报告时延、误报与干预次数。

就本次检索的代表性样本而言，国外研究在动作分块模仿学习、移动操作全身遥操作、通用 VLA 模型与失败检测框架方面起步较早^[9,12,13,51]；国内团队在双臂扩散基础模型、轻量与高效 VLA 结构和三维输入模仿学习方面形成了针对性较强的研究^[26,27,31-34]，哈工大团队在精密装配示范学习方面也有持续积累^[23]。上述

比较限于所选代表性样本及相应的方法侧重。

将上述进展映射到本课题的目标场景，仍有三个问题有待验证。其一，移动操作研究已认识到底盘定位残差的影响，但尚无工作把激光雷达定位给出的停车残差作为策略的显式状态输入，并在示范采集中系统覆盖随机停靠；数据覆盖与显式条件的相对贡献亦缺少消融证据。其二，动作块执行时域在现有工作中通常是全任务统一的固定超参数，按自由空间与精细阶段区别设置执行时域，并通过 RTC 处理流匹配动作块异步衔接的收益与时延代价尚需系统评价。其三，现有失败检测器依赖额外训练，RTC 重叠区中新旧动作块的一致性残差能否作为免训练的失败信号、其召回率与误报率能否满足产线要求，仍需实证。

基于以上问题，本研究以已跑通的 OpenPI $\pi_{0.5}$ 闭环为基线，沿“停车误差-精细阶段放大-错误动作持续”的传递链构建分层鲁棒增强框架，并在统一的残差注入协议、五工位任务链和多台机器人条件下依次叠加验证。研究的核心可检验问题是：条件化学习、自适应控制和运行时容错能否在不改变策略网络主体结构的前提下，分别并累计地提高策略对停车误差的容忍度、精细阶段的成功率与失败发生后的可控性。

3 主要内容及方案

3.1 研究主线与总体技术路线

本课题的研究主线是停车误差在 $\pi_{0.5}$ 策略执行过程中的传递与放大。如图5所示，误差传递链包含三个环节：激光雷达定位与导航停靠产生厘米级的位置与航向残差；残差在进槽、落台等精细阶段经机械臂作业半径放大为末端对准误差；动作块开环执行使错误动作持续输出直至失败或损坏。针对三个环节，本课题构建基于停车误差传递链的分层鲁棒增强框架：停车残差条件化模仿学习方法通过状态条件和示范分布提高策略对残差的适应能力；阶段自适应动作块控制方法通过调节执行时域并采用 RTC 连续衔接来缩短精细阶段的开环区间；预测一致性驱动的运行时容错方法通过监测 RTC 重叠区的跨块一致性残差触发模板化恢复。三项方法在技术与实验上相互依赖：残差注入下的容忍曲线是共同的评价基准；自适应控制方法在精细阶段提高滚动推理频率，为运行时容错方法提供密集的跨块重叠区；条件化学习方法所采用的残差注入在容忍边界之外制造受控的失败回合，为运行时容错方法提供检测评价样本。

策略模型统一采用基于 OpenPI 微调的 $\pi_{0.5}$ ，三项方法围绕其数据接口与流匹配动作块推理接口实现。所有方法均不改变策略网络主体结构：条件化学习方法只扩展状态维度与归一化统计量，自适应控制方法和运行时容错方法只作用于推理侧。整体验证设置“C0 $\pi_{0.5}$ 固定执行时域基线-C1 加入停车残差条件化学习-C2




图 5: 停车误差传递链与分层鲁棒增强方法的对应关系

加入阶段自适应执行时域与 RTC 连续衔接—C3 加入跨动作块一致性检测与模板恢复”四种配置，在相同的残差注入档位、相同的五工位任务链和相同的机器人上比较端到端成功率与时延。

3.2 任务定义与停车误差传递问题

PCBA 上下料任务由五个子任务顺序组成，记子任务集合为 $\mathcal{L} = \{\text{上料车取料, 扫码, 检测台下料, 检测台上料, 下料车放料}\}$ ，分别对应从上料百叶车夹取 PCBA、扫码登记、从检测台取出上一块 PCBA、将当前 PCBA 放入检测台以及将上一块 PCBA 放入下料百叶车，如图6所示。子任务由任务状态机顺序调度：机器人经激光雷达定位与导航移动至对应工位并停靠，底盘锁定后由双臂策略在语言指令 $\ell_t \in \mathcal{L}$ 条件下执行操作，子任务完成后切换至下一工位。检测台上的取出与放入两个子任务在同一停靠位姿下连续完成。

为描述停车误差，对第 k 个工位定义名义工位坐标系 $\{S_k\}$ ，其世界坐标系 $\{O\}$ 中的位姿 ${}^O\mathbf{T}_{S_k}$ 为示范采集时的名义停靠位姿；机器人实际停靠后，激光雷达定位给出基座坐标系 $\{B\}$ 的位姿 ${}^O\mathbf{T}_B$ 。按式(14)，停车残差定义为实际基座相对于名义工位的变换

$$\Delta\mathbf{T}_k = ({}^O\mathbf{T}_{S_k})^{-1} {}^O\mathbf{T}_B = \begin{bmatrix} \mathbf{R}(\delta\theta_k) & \delta\mathbf{p}_k \\ \mathbf{0}^T & 1 \end{bmatrix}, \quad \delta_k = (\delta x_k, \delta y_k, \delta\theta_k)^T, \quad (2)$$

式中，底盘停靠于水平地面，残差退化为平面位姿； $\delta\mathbf{p}_k = (\delta x_k, \delta y_k)^T$ 为名义工位




图 6: PCBA 上下料五工位任务链与工位停车残差的定义

系中的位置残差, $\delta\theta_k$ 为航向残差, $\mathbf{R}(\cdot)$ 为平面旋转矩阵。以平面位姿 (x, y, θ) 表示时,

$$\delta\theta_k = \theta_B - \theta_{S_k}, \quad \delta\mathbf{p}_k = \mathbf{R}(\theta_{S_k})^T \left(\begin{bmatrix} x_B \\ y_B \end{bmatrix} - \begin{bmatrix} x_{S_k} \\ y_{S_k} \end{bmatrix} \right). \quad (3)$$

停车残差对操作精度的影响可由目标点在基座系中的位置变化刻画。设槽位、检测台卡口等操作目标固连于工位, 在名义工位系中的平面位置为 $\mathbf{p}_G^{S_k}$ 。示范策略隐含地假定基座与工位系重合, 其动作以 $\mathbf{p}_G^{S_k}$ 为目标; 实际停靠后, 同一目标在基座系中的位置为 $\mathbf{R}(\delta\theta_k)^T (\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k)$, 与策略隐含目标之差为

$$\mathbf{e}_p = \mathbf{R}(\delta\theta_k)^T (\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k) - \mathbf{p}_G^{S_k} \approx -\delta\mathbf{p}_k - \delta\theta_k \mathbf{J} \mathbf{p}_G^{S_k}, \quad \mathbf{J} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad (4)$$

其中, 近似取到 $\delta\theta_k$ 的一阶项。由此得到末端对准误差的上界

$$\|\mathbf{e}_p\| \leq \|\delta\mathbf{p}_k\| + |\delta\theta_k| \|\mathbf{p}_G^{S_k}\|. \quad (5)$$

式(5)表明, 位置残差直接进入末端误差, 航向残差则经目标距离 $\|\mathbf{p}_G^{S_k}\|$ 放大; 后者与机械臂作业半径同量级, 因此零点几度的航向残差即可贡献毫米级误差。二者叠加后与 PCBA 进槽、落台的对准间隙同量级, 这是误差传递链第一环节“厘米级停车误差在精细阶段放大”的定量依据。自由空间阶段的抓取目标容差较大, 策略可依赖视觉纠正; 精细阶段的偏差一旦超过间隙, 动作块继续执行便导致卡滞或挤压。

3.3 停车残差条件化模仿学习方法

条件化学习方法从数据分布与状态条件两个方面处理残差。数据层面，示范采集时不再要求机器人停靠于名义位姿，而是在名义位姿基础上叠加随机偏移：位置偏移 $\delta x_k, \delta y_k \sim \mathcal{U}(-3 \text{ cm}, 3 \text{ cm})$ ，航向偏移由导航停靠过程自然产生，不额外控制；每个回合的实际残差 δ_k 由激光雷达定位按式(3)计算并随回合记录。由此，示范数据覆盖了残差范围内的观测与动作组合，操作者在遥操作中对残差的自然修正被同步记录为动作标签。

状态层面，将残差拼接到式(20)中的本体状态，形成残差增广状态与观测

$$\begin{aligned}\tilde{\mathbf{x}}_t &= \left[\mathbf{x}_t^T, \bar{\delta}_k^T \right]^T \in \mathbb{R}^{17}, \quad \bar{\delta}_k = \left(\frac{\delta x_k}{\sigma_x}, \frac{\delta y_k}{\sigma_y}, \frac{\delta \theta_k}{\sigma_\theta} \right)^T, \\ \tilde{\mathbf{o}}_t &= \{ I_t^{\text{head}}, I_t^{\text{wrist},L}, I_t^{\text{wrist},R}, \tilde{\mathbf{x}}_t, \ell_t \},\end{aligned}\tag{6}$$

式中， $\mathbf{x}_t$ 为原 14 维双臂末端位姿与夹爪状态， σ_x 、 σ_y 、 σ_θ 为训练集上残差各分量的标准差，用于与其余状态分量保持相同量级。残差在一次停靠内为常量，在子任务切换后更新。对于 OpenPI $\pi_{0.5}$ ，该改动只需扩展状态维度与归一化统计量，模型结构与式(25)的训练目标不变。策略由此可以学习“残差-动作修正”的对应关系，而不必仅从图像中隐式推断停靠偏差。

条件化学习方法的实验设计包括容忍曲线与消融两部分。容忍曲线在测试时以程序化方式注入停车残差：在导航停靠后，按 0 至 5 厘米、间隔 1 厘米的档位人为设定位置偏移，记录各档位下五个子任务的成功率，得到成功率随残差幅值变化的曲线。消融按表1设置三组配置，分别考察数据覆盖与显式条件的作用：配置 (a) 与 (b) 的差异反映随机停车数据增强的贡献，配置 (b) 与 (c) 的差异反映残差状态输入在数据覆盖之外的增量贡献。三组配置的示范回合数、训练步数与测试残差档位保持一致。

表 1: 停车残差条件化模仿学习的消融配置

配置	训练数据停车方式	状态含残差	考察问题
(a)	固定名义停靠	否	现有流水线基线，给出名义条件下的性能与残差注入下的退化速度
(b)	± 3 厘米随机停靠	否	仅靠数据覆盖，策略能否从图像中隐式推断并补偿残差

续表 1

配置	训练数据停车方式	状态含残差	考察问题
(c)	± 3 厘米随机停靠	是	显式残差输入在数据覆盖之外能否进一步减缓退化、扩大容忍范围

3.4 阶段自适应动作块控制方法

自适应控制方法不改变训练，只在推理侧按阶段调整每次推理后的执行时域。将时刻 t 的执行阶段记为 $\phi_t \in \{\text{free}, \text{fine}\}$ ，其中精细阶段对应进槽、落台等对准操作，自由阶段对应工位内的接近、搬运与撤离。阶段由当前子任务与末端到目标的距离共同判定：

$$\phi_t = \begin{cases} \text{fine}, & \ell_t \in \mathcal{L}_{\text{fine}} \text{ 且 } \|\mathbf{p}_{E,t} - {}^B\mathbf{p}_G\| < d_{\text{fine}}, \\ \text{free}, & \text{其他}, \end{cases} \quad s_t = s_{\phi_t}, \quad s_{\text{fine}} < s_{\text{free}} \leq H, \quad (7)$$

式中， $\mathcal{L}_{\text{fine}} \subset \mathcal{L}$ 为含精细对准的子任务集合， $\mathbf{p}_{E,t}$ 为操作臂末端位置， ${}^B\mathbf{p}_G$ 为由工位标定与残差换算得到的基座系目标位置， d_{fine} 为进入精细阶段的距离阈值； H 为模型每次生成的预测时域， s_{free} 与 s_{fine} 分别为两类阶段的执行时域。阶段信号由外部任务状态机给出的子任务 ℓ_t 与距离规则共同确定，不依赖原始 $\pi_{0.5}$ 的高层子任务预测。

设第 i 次推理在时刻 t_i 启动，得到式(21)所示长度为 H 的动作块 $\hat{\mathbf{A}}_{t_i}$ ，下一次推理启动时刻为 $t_{i+1} = t_i + s_{\phi_{t_i}}$ 。将该次推理耗时折算为控制步数

$$d_i = \left\lceil \frac{\tau_{\text{inf},i}}{\Delta t} \right\rceil, \quad T_\phi = s_\phi \Delta t, \quad d_i \leq s_\phi, \quad s_\phi + d_i \leq H, \quad (8)$$

式中， Δt 为控制周期， $\tau_{\text{inf},i}$ 为单次推理耗时， d_i 为相应的推理延迟， T_ϕ 为重规划周期。执行采用适用于流匹配 VLA 的 RTC 机制^[49]：新一轮推理进行时，机器人继续执行前一动作块；在生成新块时，将延迟 d_i 内已经确定的动作冻结为前缀，对其后的重叠区施加逐步减弱的引导，再由 $\pi_{0.5}$ 流匹配动作头补全后续动作。该机制保持动作生成的多模态结构，不对两个独立流匹配样本作直接平均。式(8)保证下一动作块能在旧块预测时域耗尽前完成；若实测延迟不满足约束，则增大执行时域或降低推理频率。图7给出了两类阶段的执行时序：自由阶段采用较长执行时域以减少推理次数，精细阶段采用较短执行时域，使新观测更快进入控制回路，并由 RTC 连续衔接重叠动作块。

自适应控制方法的对照为固定执行时域方式。模型按预测时域 H 训练一次，




图 7: 分阶段执行时域与 RTC 跨动作块连续衔接时序

对照组在整个任务中分别采用满足式(8)的短、中、长三档固定执行时域 $s_{\text{short}} < s_{\text{middle}} < s_{\text{long}} \leq H$, 具体步数依据实测控制周期与推理延迟标定; 分阶段组按式(7)切换, 并保持相同的 RTC 衔接机制。评价指标包括分阶段成功率、稳态推理频率、首动作延迟与推理时延的 95 分位数, 后三项参照 OpenVLA-OFT 的吞吐率报告方式^[50]。为检验自适应控制方法对残差的作用, 在条件化学习方法的基础上重做残差注入容忍曲线, 比较分阶段执行与各固定执行时域在不同残差档位下的成功率差异。

3.5 预测一致性驱动的运行时空容错方法

运行时容错方法利用 RTC 连续执行产生的重叠动作块构造失败信号, 而不直接平均不同的流匹配样本。设第 $i-1$ 次 RTC 输出动作块在执行 s_{i-1} 步后留下时间对齐的尾部 $\hat{\mathbf{A}}_i^{\text{prev}}$, 第 i 次推理在固定参考噪声 ϵ_{ref} 下、RTC 引导前得到原始动作提议 $\hat{\mathbf{A}}_i^{\text{raw}}$ 。二者的重叠索引集合及逐步残差定义为

$$\begin{aligned} \mathcal{J}_i &= \{j : 0 \leq j < H - s_{i-1}\}, \\ \mathbf{e}_{i,j} &= \hat{\mathbf{a}}_{i,j}^{\text{raw}} - \hat{\mathbf{a}}_{i,j}^{\text{prev}}, \quad j \in \mathcal{J}_i. \end{aligned} \quad (9)$$

固定 ϵ_{ref} 用于抑制流匹配采样随机性对检测分数的影响; 它只服务于一致性计算, 实际执行仍使用 RTC 引导后生成的动作块。RTC 掩码权重 $\omega_{i,j} \in [0, 1]$ 在延迟内的冻结前缀取 1, 在可编辑重叠区逐步衰减, 并在重叠区外取 0^[49]。因此, 该权重既规定新旧动作的连续约束, 也确定一致性检测重点关注的近期动作。

跨动作块不一致度定义为重叠区归一化残差的加权均值, 并在连续 L 次推理

上平滑：

$$r_i = \frac{\sum_{j \in \mathcal{J}_i} \omega_{i,j} \|\mathbf{\Lambda}^{-1/2} \mathbf{e}_{i,j}\|_2^2}{\sum_{j \in \mathcal{J}_i} \omega_{i,j}}, \quad \tilde{r}_i = \frac{1}{L} \sum_{q=i-L+1}^i r_q. \quad (10)$$

式中， $\mathbf{\Lambda}$ 为训练集上各动作维度方差构成的对角矩阵，用于消除位置、姿态与夹爪分量的量纲差异。当状态处于示范分布内时，相邻观测条件下对同一未来时段的预测应当接近， r_i 较小；当停车残差把状态推离示范分布或末端已经卡滞时，新旧动作块的差异可能增大， r_i 随之上升。该分数是待实验验证的失效先兆，而非对所有失败均成立的先验结论。

阈值由成功回合标定，无需失败数据与额外模型训练。记配置 C2 下的成功回合集合为 $\mathcal{E}_{\text{succ}}$ ，并以 $\mathcal{I}_{\phi}^{\text{succ}}$ 表示其中属于阶段 ϕ 的推理索引，按阶段分别取 $\tilde{r}_i$ 的 95 分位数作为阈值，并要求连续超阈值以抑制瞬时波动：

$$\begin{aligned} \mathcal{I}_{\phi}^{\text{succ}} &= \{(e, i) : e \in \mathcal{E}_{\text{succ}}, \phi_{i_i}^e = \phi\}, \\ \eta_{\phi} &= Q_{0.95} \left(\{\tilde{r}_i^e : (e, i) \in \mathcal{I}_{\phi}^{\text{succ}}\} \right), \end{aligned} \quad (11)$$

报警 $\iff \tilde{r}_i > \eta_{\phi_{i_i}}$ 连续 n_{hold} 次推理。

若四台机器人的不一致度分布存在系统差异，则按机器人分别标定。检测器以召回率、误报率与提前量评价：

$$\text{Rec} = \frac{|\{e \in \mathcal{E}_{\text{fail}} : t_a^e \leq t_f^e\}|}{|\mathcal{E}_{\text{fail}}|}, \quad \text{FAR} = \frac{|\{e \in \mathcal{E}_{\text{succ}} : \text{报警}\}|}{|\mathcal{E}_{\text{succ}}|}, \quad \Delta t_{\text{lead}} = t_f^e - t_a^e, \quad (12)$$

式中， $\mathcal{E}_{\text{fail}}$ 为失败回合集合， t_a^e 为回合 e 的首次报警时刻， t_f^e 为按人工标注确定的失败发生时刻，如卡滞或挤压开始的时刻。失败回合主要由条件化学习方法所采用的残差注入在容忍边界之外产生，从而使检测评价与容忍曲线共用同一批测试数据。

报警后执行固定模板恢复，不由模型生成恢复动作：停止当前动作块的执行；沿工位系竖直方向回退至安全高度 z_{safe} ，夹爪状态保持不变；回到当前子任务的入口位姿；重新获取观测并推理，重试一次；若重试过程中再次报警，则停机并交由人工处理。恢复模板参数由工位几何确定，与 RACER 等学习型恢复策略相比不需要失败恢复数据^[53]。整个监测与恢复流程如图8所示。运行时容错方法的评价除式(12)外，还包括加入恢复后的最终成功率以及 RTC 引导与残差计算带来的附加时延。该方案借鉴 FAIL-Detect^[51] 仅以成功数据标定失败分数的思路，但检测量直接来自 $\pi_{0.5}$ 跨动作块重叠区，不额外训练分数网络。




图 8: 基于跨动作块一致性残差的失败检测与模板恢复流程

3.6 整体验证方案

分层鲁棒增强框架按表2的四种配置依次叠加验证。所有配置使用相同的残差注入档位、相同的五工位任务链和相同的四台机器人，每台机器人在每个残差档位上执行相同数量的回合。端到端指标包括整链成功率与逐子任务的条件成功率，后者参照 CALVIN 对长时序任务链的评价方式^[47]，用于定位失败集中的阶段；同时记录各配置的稳态推理频率、首动作延迟与附加时延。数据划分按机器人与采集日期分组留出，避免同一回合的样本同时出现在训练与测试中。示范采集由一台机器人完成，四台机器人参与测试，以检验各方法对本体差异的稳健性。

表 2: 整体验证的叠加配置

配置	组成	主要考察指标
C0	已完成闭环的 $\pi_{0.5}$	名义条件功能验证、残差注入下的退化曲线 固定执行时域基线
C1	C0 加入随机停车示范和停车残差状态	容忍曲线的偏移量，消融 (a)(b)(c) 的差异
C2	C1 加入阶段自适应执行时域与 RTC 连续衔接	精细阶段成功率、推理频率与时延，与固定执行时域对照
C3	C2 加入跨动作块一致性检测与模板恢复	召回率、误报率、提前量、恢复后的最终成功率、附加时延

3.7 可行性分析

本课题的可行性建立在已完成工作与所提方法的低侵入性之上。其一，基于 OpenPI 的 $\pi_{0.5}$ 流水线已在目标平台上端到端跑通，第5节所述的 VR 示范采集、数据组织、模型微调与动作块推理闭环可直接复用，仅需在其上增加接口与推理逻辑。其二，三项方法均不改变策略网络主体结构：残差输入只扩展状态维度，OpenPI 微调在单张 A100 80G 显卡上即可完成；分阶段执行与 RTC 只涉及推理侧代码；失败检测无需失败数据与额外模型。其三，停车残差可直接由平台的激光雷达定位模块与工位标定结果按式(3)计算，随机停靠与程序化残差注入均可通过修改导航目标位姿实现。其四，四台机器人与真实的五工位场景为叠加验证提供了足够的重复条件。可能的风险与应对措施见第8节。

4 预期达到的目标

本课题预期在已跑通的 OpenPI $\pi_{0.5}$ 模仿学习闭环基础上，建立基于停车误差传递链的分层鲁棒增强框架，并在四台轮式双臂机器人和真实的 PCBA 五工位上下料任务上完成叠加验证。总体目标是：在不改变策略网络主体结构的前提下，使策略对工位停车误差的容忍范围明显扩大，精细阶段的成功率与安全性明显提高，失败发生后能够被及时检测并以可控方式恢复或停机。

对于条件化学习方法，预期残差注入下的成功率随残差幅值的衰减明显缓于固定停靠基线，容忍曲线整体向更大残差方向偏移；消融结果预期表明显式残差输入在随机停车数据覆盖之外具有额外收益。全部消融均在同一 OpenPI $\pi_{0.5}$ 模型上完成。

对于自适应控制方法，预期分阶段执行在精细阶段的成功率高于任一固定执行时域方式，同时整体推理开销不高于全程采用短执行时域的方式，首动作延迟与推理时延分位数保持在可用范围内；在残差注入条件下，该方法与条件化学习方法叠加后的容忍曲线优于单独采用条件化学习方法。

对于运行时容错方法，预期基于跨动作块一致性残差的检测器在无需失败数据与额外模型训练的条件下，对残差引起的精细阶段失败具有较高的召回率与可接受的误报率，报警时刻早于卡滞或挤压发生；配合模板恢复后，部分失败回合转为成功，RTC 引导与监测带来的附加时延不影响任务节拍。

预期成果形式包括：面向 OpenPI $\pi_{0.5}$ 的停车误差鲁棒性改进及其真机验证；四种配置在统一残差注入协议下的真机实验数据、容忍曲线与失败检测评价结果；以及以上述内容为主体的硕士学位论文。

5 已完成的学术研究/实践工作

5.1 实验平台与坐标系定义

本研究已在轮式双臂机器人平台上完成示范采集与策略执行所需的基础接口建设。机器人上半身由左右两条七自由度机械臂、四自由度腰部和二自由度头部组成，共包含 20 个转动关节，并配置末端夹爪、头部相机和腕部相机。现阶段的双臂操作以左右机械臂末端笛卡尔位姿和夹爪状态作为核心状态与动作变量，执行模型将腰部、头部和移动底盘位姿作为固定参数，仅更新左右机械臂的关节状态。移动底盘由激光雷达定位与传统导航算法在工位间移动并停靠，停靠后锁定，操作阶段仅由双臂执行。

为统一描述机器人、工位与虚拟现实 (Virtual Reality, VR) 设备之间的空间关系，本文以 $\alpha \in \{L, R\}$ 区分左、右机械臂，并定义以下坐标系：世界坐标系记为 $\{O\}$ ，机器人基座坐标系记为 $\{B\}$ ，左右末端执行器坐标系记为 $\{E_\alpha\}$ ，第 k 个工

位的名义工位坐标系记为 $\{S_k\}$ ；VR 参考坐标系记为 $\{V\}$ ，左右手控制器坐标系记为 $\{H_\alpha\}$ 。其中， ${}^A\mathbf{T}_C$ 表示坐标系 $\{C\}$ 相对于坐标系 $\{A\}$ 的位姿，即把 $\{C\}$ 中的齐次坐标变换到 $\{A\}$ 中。该表示写为

$${}^A\mathbf{T}_C = \begin{bmatrix} {}^A\mathbf{R}_C & {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}, \quad (13)$$

式中， ${}^A\mathbf{R}_C \in \text{SO}(3)$ 为旋转矩阵， ${}^A\mathbf{p}_C \in \mathbb{R}^3$ 为坐标系原点的位置向量。若空间点在 $\{C\}$ 中的齐次坐标为 $\bar{\mathbf{p}}^C$ ，则其在 $\{A\}$ 中的表示为 $\bar{\mathbf{p}}^A = {}^A\mathbf{T}_C \bar{\mathbf{p}}^C$ 。连续坐标变换满足

$${}^A\mathbf{T}_D = {}^A\mathbf{T}_C {}^C\mathbf{T}_D, \quad ({}^A\mathbf{T}_C)^{-1} = \begin{bmatrix} ({}^A\mathbf{R}_C)^T & -({}^A\mathbf{R}_C)^T {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}. \quad (14)$$

式(13)和式(14)构成后续 VR 增量映射、工位坐标系与停车残差定义的统一表示基础。基座系与末端系之间的正逆运动学由平台现有笛卡尔控制模块提供，本文不再展开。

5.2 基于 VR 遥操作的示范数据采集

在上述坐标关系基础上，本研究已构建基于 VR 设备的双臂遥操作与示范采集链路。系统读取头显及左右手控制器的空间位姿和交互信号，在遥操作回合开始时分别记录控制器初始位姿 ${}^V\mathbf{T}_{H_\alpha}(t_0)$ 与机器人末端初始位姿 ${}^B\mathbf{T}_{E_\alpha}(t_0)$ 。固定标定旋转 ${}^B\mathbf{R}_V$ 用于统一 VR 参考系与机器人基座系的轴向约定，比例系数 λ_α 用于调节操作者手部平移与机器人末端平移的尺度。由此，控制器相对初始位置的增量被映射为

$${}^B\mathbf{p}_{E_{\alpha,d}}(t) = {}^B\mathbf{p}_{E_\alpha}(t_0) + \lambda_\alpha {}^B\mathbf{R}_V ({}^V\mathbf{p}_{H_\alpha}(t) - {}^V\mathbf{p}_{H_\alpha}(t_0)). \quad (15)$$

该增量形式以遥操作开始时的实际末端位置为基准，VR 空间的绝对坐标用于计算控制器相对初始位姿的运动增量。

控制器姿态首先相对于初始姿态计算，再经标定旋转映射到机器人基座系。末端目标姿态表示为

$${}^B\mathbf{R}_{E_{\alpha,d}}(t) = {}^B\mathbf{R}_V \left[{}^V\mathbf{R}_{H_\alpha}(t) ({}^V\mathbf{R}_{H_\alpha}(t_0))^T \right] {}^V\mathbf{R}_B {}^B\mathbf{R}_{E_\alpha}(t_0), \quad (16)$$

其中 ${}^V\mathbf{R}_B = ({}^B\mathbf{R}_V)^T$ 。式(15)与式(16)分别生成末端目标位置和姿态，两者组成 ${}^B\mathbf{T}_{E_{\alpha,d}}(t)$ ，再由已有笛卡尔控制接口执行。手柄交互量 $u_\alpha(t)$ 通过既定映射

$$g_{\alpha,d}(t) = \mathcal{G}_\alpha(u_\alpha(t)) \quad (17)$$

转换为左右夹爪的开合指令。映射函数 $\mathcal{G}_\alpha(\cdot)$ 的触发阈值与夹爪行程参数由平台配置确定。

机器人示范数据通常以一次完整的任务回合作为基本组织单元，将视觉观测、机器人状态与动作按时间步对齐，并在回合层关联任务指令；统一的数据语义有助于后续按不同观测窗口和动作空间构造训练样本^[8]。参照这一组织方式，本研究将当前采集的数据划分为任务、回合和时间步三个层级：任务层以自然语言描述界定操作目标，回合层对应一次完整的遥操作过程，时间步层则以动作时刻为索引，关联头部与左右腕部图像、双臂末端状态、夹爪状态及相应动作。第 n 个任务回合可表示为

$$\tau^{(n)} = \left\{ \left(t_k, I_k^{\text{head}}, I_k^{\text{wrist},L}, I_k^{\text{wrist},R}, \mathbf{x}_k, \mathbf{a}_k \right) \right\}_{k=1}^{K_n}, \quad (18)$$

其中， $\mathbf{x}_k$ 包含左右末端位姿与夹爪状态， $\mathbf{a}_k$ 包含对应时刻的双臂笛卡尔动作与夹爪指令。任务语言描述作为策略的语义条件与相应任务回合关联。上述层级将任务语义与单次执行序列分开，同时保持观测、状态和动作在回合内部逐时对应，可直接为后续视觉-语言-动作策略构造单步样本或动作块样本。现有示范均在名义停靠位姿下采集，第3.3节将把采集扩展为随机停靠，并在回合层同步记录停车残差 δ_k 。

以“将印制电路板组件（Printed Circuit Board Assembly, PCBA）放置到百叶车指定承载位置”为例，该回合以右臂为操作臂，左臂保持固定。机器人在夹爪夹持状态下携带 PCBA 接近百叶车，调整末端位置和姿态完成放置，随后松开夹爪并撤离放置区域。该回合共包含 177 个时间对齐样本；每个时间步包含三路分辨率为 240×320 的彩色图像，以及 14 维双臂末端状态和 14 维双臂动作。状态与动作均按左右臂各 7 维组织，分别由三维位置、滚转-俯仰-偏航姿态和夹爪状态或指令组成。该样例表明，现有采集链路能够将多视角观测、机器人本体状态与遥操作动作组织为式(18)所定义的完整回合。

图9给出了该回合的起始、中间和结束观测，以及右手末端的三维运动轨迹。上部三幅图分别对应第 0、88 和 176 帧：前两帧处于夹持状态，结束帧处于松开状态；下部曲线以颜色和线型区分夹爪语义状态，以箭头表示工具坐标系 +Z 轴方向。轨迹在第 120 帧由夹持切换为松开，使视觉观测、末端位姿和 PCBA 释放事件能够在同一时间轴上对应。

图10概括了已完成系统中数据采集与策略执行之间的接口关系。VR 位姿经过增量映射后进入笛卡尔控制模块，机器人动作及多视角观测由同步记录模块组织为示范轨迹；示范数据经 OpenPI 数据接口适配后用于 $\pi_{0.5}$ 微调，部署阶段由任务




图 9: 将 PCBA 放置到百叶车任务的示例观测、右手轨迹与夹爪状态

状态机提供动态低层语言指令，模型接收新观测并通过同一笛卡尔接口输出动作块。由此，“VR 数采- $\pi_{0.5}$ 微调-OpenPI 推理-真机执行”的单一闭环已经建立，示范阶段与推理阶段共享机器人状态、动作定义和底层执行链路。




图 10: 已跑通的 VR 数采- $\pi_{0.5}$ 微调-OpenPI 推理-真机执行闭环

5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与真机闭环

在示范采集链路基础上，现有系统已完成 OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调、在线推理服务接入和真机动作块闭环执行。当前部署使用 OpenPI 公开的 $\pi_{0.5}$ 模型及流匹配动作头：模型接收头部与左右腕部图像、双臂本体状态和任务状态机提供的低层语言指令，生成连续动作块，再由笛卡尔控制接口执行并回传新观测。这里仅声称数据适配、微调与闭环功能已经打通；其在停车残差下的成功率与相对性能尚待 C0-C3 实验统计。

为说明当前实现所用模型的算法基础，原始 $\pi_{0.5}$ 在 π_0 连续动作生成框架的基础上引入异构协同训练与语义子任务预测，将长时程任务中的高层语义决策与低层动作块生成组织在统一模型中，其结构及训练流程如图11所示^[11]。

图11左侧为预训练阶段。模型以 SigLIP 视觉编码器和 Gemma 语言模型组成的预训练 VLM 为主干，将多模态网络数据、异构机器人数据和任务提示统一表示为序列，并同时学习语义子任务、离散动作、图像描述及目标框等输出。机器人动作在该阶段由 FAST 分词器压缩为离散词元，使动作预测能够与语言建模任务共同采用自回归的下一词元预测目标。图中右侧为后训练与推理阶段：预训练得到的 VLA 模型继续承担图像与语言理解，并在主干之外加入参数量较小的动作专家；动作专家接收连续动作的含噪中间状态，采用条件流匹配逐步生成连续动作

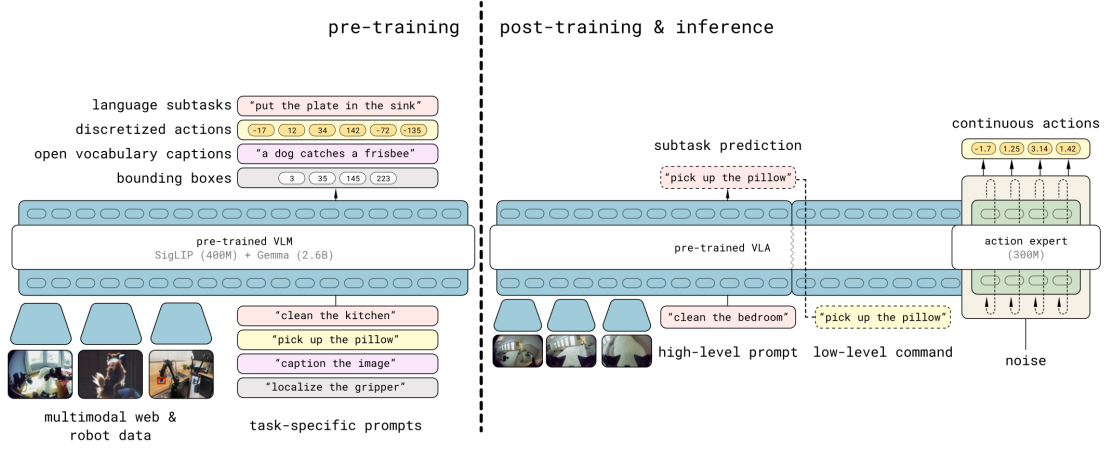


图 11: $\pi_{0.5}$ 模型结构及两阶段训练流程^[11]

块。由此，模型既保留预训练阶段获得的视觉与语义能力，又能以非自回归方式输出适用于实时控制的连续动作。

在层级推理过程中，VLA 主干首先根据当前多视角观测和高层任务指令自回归生成语义子任务 $\hat{\ell}_t$ ，例如将“整理卧室”转化为“拿起枕头”；随后，该子任务作为低层语言条件输入动作专家，后者由随机噪声生成长度为 H 的连续动作块。原模型的联合分布可分解为

$$\pi_{\theta}(\mathbf{A}_t, \hat{\ell}_t | \mathbf{z}_t, \ell_t) = \pi_{\theta}(\mathbf{A}_t | \mathbf{z}_t, \hat{\ell}_t) \pi_{\theta}(\hat{\ell}_t | \mathbf{z}_t, \ell_t), \quad (19)$$

其中， $\mathbf{z}_t$ 表示图像与机器人本体状态， ℓ_t 表示高层任务指令。式(19)的第二项对应原模型的子任务预测，第一项对应动作专家的连续动作生成。上述异构预训练与高层子任务预测属于原始 $\pi_{0.5}$ 的模型能力；本课题不宣称复现其预训练过程，也不把高层子任务预测作为研究变量。当前真机闭环仅使用 OpenPI 公开模型及流匹配动作头，由外部任务状态机根据五个子任务提供动态低层语言指令。为与现有推理接口保持一致，时刻 t 的策略输入写为

$$\mathbf{o}_t = \{I_t^{\text{head}}, I_t^{\text{wrist}, L}, I_t^{\text{wrist}, R}, \mathbf{x}_t, \ell_t\}, \quad (20)$$

其中， ℓ_t 为运行时给定的动态任务语言指令。策略一次推理输出长度为 H 的动作块：

$$\hat{\mathbf{A}}_t = \pi_{\theta}(\mathbf{o}_t) = [\hat{\mathbf{a}}_t, \hat{\mathbf{a}}_{t+1}, \dots, \hat{\mathbf{a}}_{t+H-1}]. \quad (21)$$

动作块中的每个元素均按照前述双臂笛卡尔动作与夹爪指令接口解释。机器人执行其中时域为 s 的近期动作，且 $1 \leq s \leq H$ ；完成该段动作后，系统重新获取多视

角图像和末端状态，并结合当前语言指令构造下一轮输入。该过程形成“状态感知-策略推理-动作块执行-状态更新”的在线闭环。现有部署中 s 为全任务统一的固定值，第3.4节将其改为按阶段取值并加入 RTC 衔接。

(1) 面向 $\pi_{0.5}$ 的模仿学习推导。将式(18)所示的专家示范按照长度为 H 的滑动窗口组织，可得动作块示教数据集

$$\mathcal{D}_E = \left\{ \left(\mathbf{o}_t^{(n)}, \mathbf{A}_t^{E, (n)} \right) \right\}_{n,t}, \quad \mathbf{A}_t^E = [\mathbf{a}_t^E, \dots, \mathbf{a}_{t+H-1}^E]. \quad (22)$$

行为克隆的基本目标是在专家数据分布上最大化条件动作块的对数似然，即

$$\theta_{\text{IL}} = \arg \min_{\theta} \mathcal{L}_{\text{IL}}(\theta), \quad \mathcal{L}_{\text{IL}}(\theta) = -\mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E} [\log \pi_{\theta}(\mathbf{A}_t^E | \mathbf{o}_t)]. \quad (23)$$

该目标使策略分布逼近专家在给定多视角图像、机器人状态和语言指令条件下的动作分布；动作块联合建模还保留了同一操作片段内各时刻动作之间的相关性。

$\pi_{0.5}$ 采用条件流匹配表示连续动作块分布^[10,11]。对归一化后的专家动作块 $\mathbf{A}_t^E$ ，采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $\tau \in [0, 1]$ ，构造从噪声到数据的线性概率路径

$$\mathbf{A}_t^{\tau} = (1 - \tau)\epsilon + \tau\mathbf{A}_t^E, \quad \mathbf{u}_t^{\tau} = \frac{\partial \mathbf{A}_t^{\tau}}{\partial \tau} = \mathbf{A}_t^E - \epsilon. \quad (24)$$

设动作专家输出的条件向量场为 $\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau)$ ，则模仿微调可写为条件流匹配损失

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tau \sim p(\tau)} [\|\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) - (\mathbf{A}_t^E - \epsilon)\|_2^2]. \quad (25)$$

最小化式(25)使网络学习式(24)的条件速度场。推理时从 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，沿

$$\frac{d\mathbf{A}_t^{\tau}}{d\tau} = \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) \quad (26)$$

由 $\tau = 0$ 正向积分至 $\tau = 1$ ，即可得到条件动作块样本 $\hat{\mathbf{A}}_t = \mathbf{A}_t^1$ 。以步长 $\Delta\tau > 0$ 进行欧拉离散时，单步更新为

$$\mathbf{A}_t^{\tau+\Delta\tau} = \mathbf{A}_t^{\tau} + \Delta\tau \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau). \quad (27)$$

因此，式(25)给出了示教动作对模型参数的监督关系，式(26)和式(27)则给出了从随机噪声生成连续动作块的推理过程。

5.4 阶段性工作小结

本节明确了已完成工作与待开展研究的边界。已完成部分包括机器人平台与坐标接口、VR 遥操作和示范数据采集、OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调以及“状态感知-OpenPI 推理-动作块执行-状态更新”的真机闭环功能验证；激光雷达定位与导航停靠作为平台既有能力可直接调用。尚未开展的部分对应本课题的三项方法：停车残差尚未进入 $\pi_{0.5}$ 状态，示范仍在名义停靠下采集，执行时域仍为

全任务固定值，推理侧尚未加入 RTC 连续衔接、跨动作块一致性检测和模板恢复。因尚无统一残差注入协议下的统计数据，本节不对现有闭环声明成功率或性能优势。

6 进度安排

研究进度将从 2026 年 7 月进入课题时开始计算，至 2027 年 12 月完成论文与答辩准备。各阶段按照“时间段-主要任务-阶段产出”编排，并在后期预留补充实验、设备维护和论文修改时间。

表 3: 研究进度安排

时间	主要任务	阶段产出
2026.07–2026.08	梳理文献与现有平台接口,确定五工位任务链、子任务划分与成功/失败判据;制定随机停靠示范采集规范与残差注入协议,完成开题。	开题报告、任务规范与评价协议初稿。
2026.09–2026.10	实现停车残差读取与工位标定接口,将残差增广状态接入 OpenPI $\pi_{0.5}$ 数据格式;按规范采集随机停靠示范并版本化。	残差接口、版本化示范数据与数据说明。
2026.11–2026.12	完成条件化学习方法三组消融的微调与真机测试,绘制 0 至 5 厘米残差注入容忍曲线。	条件化学习方法实验数据、容忍曲线与消融结论。
2027.01–2027.03	实现阶段自适应动作块控制与 RTC 连续衔接,完成与固定执行时域的对照,记录成功率、推理频率与时延分位数;在残差注入下重做容忍曲线。	分阶段执行与 RTC 模块、时延与成功率对照数据。
2027.04–2027.06	在 OpenPI 推理侧实现跨动作块一致性残差计算与模板恢复,标定分阶段阈值;评价召回率、误报率、提前量与恢复后成功率。	失败检测与恢复模块、检测器评价数据。
2027.07–2027.09	在四台机器人上完成四种配置的叠加验证与补充重复实验,整理失败案例并分析本体差异。	整体验证数据、失败分类与方法适用边界。

续表 3

时间	主要任务	阶段产出
2027.10–2027.12	核对数据、代码和图表, 完成学位论文撰写、修改、送审与答辩准备。	学位论文定稿与答辩材料。

7 为完成课题所需的条件

本课题所需条件分为硬件平台、算力、数据、软件与评价环境五类, 其中大部分已由课题组现有平台与前期工作具备, 尚需补充的部分均可在进度安排的前两个阶段内完成, 如表4所示。

表 4: 完成课题所需的条件

类别	已具备	尚需补充
硬件平台	四台轮式双臂机器人, 各含两条七自由度机械臂、四自由度腰部、二自由度头部、末端夹爪、头部与腕部相机, 以及激光雷达定位与导航模块; 一台用于示范采集, 四台用于实验。	工位周边的安全围栏与急停联动, 用于失败注入实验中的物料与设备保护。
算力	8 卡 A100 80G 服务器, 课题分配一张显卡, 满足 OpenPI $\pi_{0.5}$ 任务微调需求。	无。
数据	名义停靠下的 VR 遥操作示范回合, 含 PCBA 放置样例; 数据按任务、回合、时间步三级组织。	随机停靠示范回合及其残差记录; 残差注入测试回合; 失败回合的失败时刻人工标注。
软件	VR 遥操作与同步记录链路; OpenPI $\pi_{0.5}$ 微调与真机部署流水线; 导航栈与笛卡尔控制接口。	停车残差读取与工位标定接口; 残差增广状态的数据格式与归一化; 推理侧的阶段判定、分阶段执行、RTC 连续衔接与跨块一致性监测模块; 模板恢复动作。

续表 4

类别	已具备	尚需补充
评价环境	真实的 PCBA 五工位场景：上料百叶车、扫码工位、检测台、下料百叶车。	程序化残差注入工具；分子任务成功判定与时延记录工具；四台机器人的统一评价脚本。

8 研究过程中可能遇到的问题以及解决的措施

三项方法分别依赖残差估计、阶段判定与不一致度信号的可靠性，其实验又受真机资源与本体差异约束。表5按风险来源列出可能遇到的问题、影响以及预防措施与降级方案。

表 5: 可能遇到的问题与解决措施

问题	影响	预防措施	降级方案
激光雷达定位残差估计存在噪声	残差输入本身带误差,削弱条件化学习方法的收益	停靠后静止采样多帧取均值; 以外部标定装置校验残差估计精度	仅使用估计精度可靠的位置分量, 航向分量退出状态输入
± 3 厘米随机停靠未覆盖真实残差分布	容忍曲线在大残差档位仍快速退化	采集前统计导航停靠残差的实际分布并据此设定范围	扩大随机范围或增加分档示范, 重新训练条件化学习方法
阶段判定错误	精细阶段误判为自由阶段时开环区间过长, 反之推理开销上升	距离阈值留裕量; 以任务状态机子任务标签与距离规则双重校验	退回全程短执行时域, 牺牲部分时延
RTC 与监测增加推理时延	精细阶段执行时域短于推理延迟	异步推理时冻结已确定动作; 一致性残差计算向量化	提高 s_{fine} 至满足式(8)
阈值失准导致误报或漏报	误报触发不必要恢复, 漏报失去预警意义	按阶段与机器人分别标定; 引入连续超阈值步数 n_{hold}	调整分位数并以召回率-误报率曲线选取工作点

续表 5

问题	影响	预防措施	降级方案
模板恢复动作引发碰撞	回退过程中夹爪或 PCBA 与槽位干涉	回退方向沿工位系竖直方向，路径经离线校核；恢复前先停止运动	报警后直接停机交人工，不执行自动恢复
单张显卡算力限制	多组消融与四种配置的微调周期长	复用预训练检查点，只微调必要参数；按进度错峰安排训练	减少消融重复次数，优先保证主线配置
四台机器人本体差异	同一策略在不同机器人上的成功率与不一致度分布不同	统一标定与零位校验；评价按机器人分组报告	阈值按机器人单独标定；必要时按机器人少量微调
VR 示范采集吞吐不足	随机停靠示范数量不够	自由空间段可由导航与预设航点自动完成，仅遥操作精细段 ^[42]	缩小随机停靠范围并减少示范回合数

9 参考文献

- [1] International Federation of Robotics. World Robotics 2025: Industrial Robots[R/OL]. Frankfurt am Main, Germany: IFR Statistical Department, 2025 [2026-09-02]. <https://ifr.org/worldrobotics/report-2025>.
- [2] 袁依格, 何卓丰, 李威, 等. 具身智能驱动的智能制造应用发展研究[J/OL]. 中国工程科学, 2025, 27(3): 67-82. <http://dx.doi.org/10.15302/J-SSCAE-2025.04.016>.
- [3] Zhang C, Zhang C, Xu Z, et al. Embodied Intelligent Industrial Robotics: Framework and Techniques[J/OL]. Journal of Manufacturing Systems, 2026, 88: 158-189. <http://dx.doi.org/10.1016/j.jmsy.2026.06.001>.
- [4] 郑南宁, 杨勐, 姜维周, 等. 具身智能发展趋势与展望[J/OL]. 中国工程科学, 2026, 28(2): 1-13. <http://dx.doi.org/10.15302/J-SSCAE-2025.07.019>.
- [5] Firoozi R, Tucker J, Tian S, et al. Foundation Models in Robotics: Applications, Challenges, and the Future[J/OL]. The International Journal of Robotics Research, 2025, 44(5): 701-739. <http://dx.doi.org/10.1177/02783649241281508>.
- [6] Brohan A, Brown N, Carbajal J, et al. RT-1: Robotics Transformer for Real-World Control at Scale: arXiv:2212.06817[R/OL]. Mountain View, California,

- USA: Google Research, 2022 [2026-09-02]. <https://arxiv.org/abs/2212.06817>.
- [7] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2165-2183. <https://proceedings.mlr.press/v229/zitkovich23a.html>.
- [8] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[C/OL] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 6892-6903. <http://dx.doi.org/10.1109/ICRA57147.2024.10611477>.
- [9] Kim M J, Pertsch K, Karamcheti S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[C/OL] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024. <https://proceedings.mlr.press/v270/kim25c.html>.
- [10] Black K, Brown N, Driess D, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control[R/OL]. San Francisco, California, USA: Physical Intelligence, 2024 [2026-08-27]. <https://arxiv.org/abs/2410.24164>.
- [11] Black K, Brown N, Darpinian J, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-25]. <https://www.pi.website/download/pi05.pdf>.
- [12] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[C/OL] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.016>.
- [13] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[C/OL] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024: 4066-4083. <https://proceedings.mlr.press/v270/fu25b.html>.
- [14] 兰沅卜, 赵文博, 朱凯, 等. 基于具身智能的移动操作机器人系统发展研究[J/OL]. 中国工程科学, 2024, 26(1): 139-148. <http://dx.doi.org/10.15302/J-SSCAE-2024.01.010>.
- [15] 国务院. 政府工作报告——2025 年 3 月 5 日在第十四届全国人民代表大会第三次会议上[R/OL]. 北京: 中华人民共和国国务院, 2025 [2026-09-02]. <http://lianghui.people.com.cn/2025/n1/2025/0312/c460142-40437673.html>.

- [16] Ren L, Dong J, Liu S, et al. Embodied Intelligence Toward Future Smart Manufacturing in the Era of AI Foundation Model[J/OL]. IEEE/ASME Transactions on Mechatronics, 2025, 30(4): 2632-2642. <http://dx.doi.org/10.1109/TMECH.2024.3456250>.
- [17] Levine S, Wagener N, Abbeel P. Learning Contact-Rich Manipulation Skills with Guided Policy Search[C/OL] // 2015 IEEE International Conference on Robotics and Automation (ICRA). 2015: 156-163. <http://dx.doi.org/10.1109/ICRA.2015.7138994>.
- [18] Inoue T, Magistris G D, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C/OL] // 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2017: 819-825. <http://dx.doi.org/10.1109/IROS.2017.8202244>.
- [19] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C/OL] // 2019 International Conference on Robotics and Automation (ICRA). 2019: 6023-6029. <http://dx.doi.org/10.1109/ICRA.2019.8794127>.
- [20] Elguea-Aguinaco Í, Serrano-Muñoz A, Chrysostomou D, et al. A Review on Reinforcement Learning for Contact-Rich Robotic Manipulation Tasks[J/OL]. Robotics and Computer-Integrated Manufacturing, 2023, 81: 102517. <http://dx.doi.org/10.1016/j.rcim.2022.102517>.
- [21] Yang C, Zeng C, Cong Y, et al. A Learning Framework of Adaptive Manipulative Skills from Human to Robot[J/OL]. IEEE Transactions on Industrial Informatics, 2019, 15(2): 1153-1161. <http://dx.doi.org/10.1109/TII.2018.2826064>.
- [22] Qin F, Xu D, Zhang D, et al. Robotic Skill Learning for Precision Assembly with Microscopic Vision and Force Feedback[J/OL]. IEEE/ASME Transactions on Mechatronics, 2019, 24(3): 1117-1128. <http://dx.doi.org/10.1109/TMECH.2019.2909081>.
- [23] Zang Y, Wang P, Zha F, et al. Peg-in-Hole Assembly Skill Imitation Learning Method Based on ProMPs under Task Geometric Representation[J/OL]. Frontiers in Neurorobotics, 2023, 17: 1320251. <http://dx.doi.org/10.3389/fnbot.2023.1320251>.
- [24] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation[C/OL] // Proceedings of Machine Learning Research, Vol 164: Proceedings of the 5th Conference on Robot Learning. [S.l.]: PMLR, 2022: 1678-1690. <https://proceedings.mlr.press/v164/mandlekar22a.html>.
- [25] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C/OL] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.3389/fnbot.2023.1320251>.

15607/RSS.2023.XIX.026.

- [26] Ze Y, Zhang G, Zhang K, et al. 3D Diffusion Policy: Generalizable Visuomotor Policy Learning via Simple 3D Representations[C/OL] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.067>.
- [27] Wang C, Fang H, Fang H-S, et al. RISE: 3D Perception Makes Real-World Robot Imitation Simple and Effective[C/OL] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 2870-2877. <http://dx.doi.org/10.1109/IROS58592.2024.10801678>.
- [28] Shi L X, Sharma A, Zhao T Z, et al. Waypoint-Based Imitation Learning for Robotic Manipulation[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2195-2209. <https://proceedings.mlr.press/v229/shi23b.html>.
- [29] Octo Model Team, Ghosh D, Walke H, et al. Octo: An Open-Source Generalist Robot Policy[C/OL] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.090>.
- [30] Khazatsky A, Pertsch K, Nair S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[C/OL] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.120>.
- [31] Liu S, Wu L, Li B, et al. RDT-1B: A Diffusion Foundation Model for Bimanual Manipulation[C/OL] // The Thirteenth International Conference on Learning Representations (ICLR). 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/49f80e4d2471ad4f2edf4f5f1ab62339-Abstract-Conference.html.
- [32] Wen J, Zhu Y, Li J, et al. TinyVLA: Toward Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation[J/OL]. IEEE Robotics and Automation Letters, 2025, 10(4): 3988-3995. <http://dx.doi.org/10.1109/LRA.2025.3544909>.
- [33] Liu J, Liu M, Wang Z, et al. RoboMamba: Efficient Vision-Language-Action Model for Robotic Reasoning and Manipulation[C/OL] // Advances in Neural Information Processing Systems 37 (NeurIPS). 2024. https://proceedings.neurips.cc/paper_files/paper/2024/hash/46a126492ea6fb87410e55a58df2e189-Abstract-Conference.html.
- [34] Bu Q, Yang Y, Cai J, et al. UniVLA: Learning to Act Anywhere with Task-centric Latent Actions[C/OL] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.014>.

- [35] Pertsch K, Stachowicz K, Ichter B, et al. FAST: Efficient Action Tokenization for Vision-Language-Action Models[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-27]. <https://arxiv.org/abs/2501.09747>.
- [36] Tang B, Lin M A, Akinola I, et al. IndustReal: Transferring Contact-Rich Assembly Tasks from Simulation to Reality[C/OL] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.039>.
- [37] S3ti G, Huang X, Wurll C, et al. Train What You Know – Precise Pick-and-Place with Transporter Networks[C/OL] // 2023 IEEE International Conference on Robotics and Automation (ICRA). 2023: 5814-5820. <http://dx.doi.org/10.1109/ICRA48891.2023.10161242>.
- [38] Xia F, Li C, Mart3n-Mart3n R, et al. ReLMoGen: Leveraging Motion Generation in Reinforcement Learning for Mobile Manipulation[C/OL] // 2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 4583-4590. <http://dx.doi.org/10.1109/ICRA48506.2021.9561315>.
- [39] Honerkamp D, Welschehold T, Valada A. N²M²: Learning Navigation for Arbitrary Mobile Manipulation Motions in Unseen and Dynamic Environments[J/OL]. IEEE Transactions on Robotics, 2023, 39(5): 3601-3619. <http://dx.doi.org/10.1109/TRO.2023.3284346>.
- [40] Yang T, Jing Y, Wu H, et al. MOMA-Force: Visual-Force Imitation for Real-World Mobile Manipulation[C/OL] // 2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2023: 6847-6852. <http://dx.doi.org/10.1109/IROS55552.2023.10342371>.
- [41] Qiu R-Z, Song Y, Peng X, et al. WildLMa: Long Horizon Loco-Manipulation in the Wild[C/OL] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 10011-10019. <http://dx.doi.org/10.1109/ICRA55743.2025.11128535>.
- [42] Mandlekar A, Garrett C, Xu D, et al. Human-in-the-Loop Task and Motion Planning for Imitation Learning[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 3030-3060. <https://proceedings.mlr.press/v229/mandlekar23b.html>.
- [43] Ishida Y, Noguchi Y, Kanai T, et al. Robust Imitation Learning for Mobile Manipulator Focusing on Task-Related Viewpoints and Regions[C/OL] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024. <https://>

//arxiv.org/abs/2410.01292.

- [44] Pumacay W, Singh I, Duan J, et al. THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation[C/OL] // Proceedings of Robotics: Science and Systems. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.133>.
- [45] Jin S, Wang R, Zahid M, et al. How Physics and Background Attributes Impact Video Transformers in Robotic Manipulation: A Case Study on Planar Pushing[C/OL] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 7391-7398. <http://dx.doi.org/10.1109/IROS58592.2024.10802583>.
- [46] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[C/OL] // 2018 IEEE International Conference on Robotics and Automation (ICRA). 2018: 3803-3810. <http://dx.doi.org/10.1109/ICRA.2018.8460528>.
- [47] Mees O, Hermann L, Rosete-Beas E, et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks[J/OL]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334. <http://dx.doi.org/10.1109/LRA.2022.3180108>.
- [48] Liu B, Zhu Y, Gao C, et al. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning[C/OL] // Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track (NeurIPS). 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/8c3c666820ea055a77726d66fc7d447f-Abstract-Datasets_and_Benchmarks.html.
- [49] Black K, Galliker M Y, Levine S. Real-Time Execution of Action Chunking Flow Policies[C/OL] // Advances in Neural Information Processing Systems 38 (NeurIPS). 2025. https://proceedings.neurips.cc/paper_files/paper/2025/hash/300ccb2187dedd4edcc07f7e76d8e553-Abstract-Conference.html.
- [50] Kim M J, Finn C, Liang P. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success[C/OL] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.017>.
- [51] Xu C, Nguyen T K, Dixon E, et al. Can We Detect Failures Without Failure Data? Uncertainty-Aware Runtime Failure Detection for Imitation Learning Policies[C/OL] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.073>.

- [52] Liu H, Dass S, Martín-Martín R, et al. Model-Based Runtime Monitoring with Interactive Imitation Learning[C/OL] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 4154-4161. <http://dx.doi.org/10.1109/ICRA57147.2024.10611038>.
- [53] Dai Y, Lee J, Fazeli N, et al. RACER: Rich Language-Guided Failure Recovery Policies for Imitation Learning[C/OL] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025. <http://dx.doi.org/10.1109/ICRA55743.2025.11127799>.
- [54] Liu Z, Bahety A, Song S. REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023. <https://proceedings.mlr.press/v229/liu23g.html>.