

哈尔滨工业大学

硕士学位论文开题报告

题 目：面向 PCBA 上下料的轮式双臂模仿学习策略
鲁棒性改进研究
(学位论文)

学 院 (部)	航天学院
学科/专业学位类别	机械
导 师	刘延芳研究员
研 究 生	聂靖轩
学 号	25S118238
开题报告日期	2026 年 9 月

研究生院制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源与研究背景	1
1.2 研究目的与意义	5
2 国内外研究现状及分析	7
2.1 工业操作策略学习研究现状	7
2.2 移动操作停靠误差鲁棒性研究现状	10
2.3 动作序列策略闭环执行研究现状	12
2.4 国内外研究现状简析	13
3 主要内容及方案	14
3.1 研究主线与总体技术路线	14
3.2 任务定义与工位停靠误差传递问题	15
3.3 面向停靠误差补偿的模仿学习方法	17
3.4 分阶段动作序列执行方法	18
3.5 基于预测偏差的在线失败检测与恢复方法	20
3.6 整体验证方案	21
3.7 可行性分析	23
4 预期达到的目标	23
5 已完成的学术研究/实践工作	24
5.1 实验平台与坐标系定义	24
5.2 基于 VR 遥操作的示范数据采集	25
5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与真机闭环	28
5.4 阶段性工作小结	30
6 进度安排	31
7 为完成课题所需的条件	32
8 研究过程中可能遇到的问题以及解决的措施	32
8.1 停靠误差估计精度对误差输入的影响	33
8.2 随机停靠示范的覆盖范围与外推行为	33
8.3 阶段判定误差与执行时域下限的耦合	34
8.4 平滑预测偏差与失败之间关系的成立条件	34
8.5 单源示范下的跨本体差异与结果归因	35
9 参考文献	35

1 课题来源及研究的目的和意义

1.1 课题来源与研究背景

工业机器人是面向工业环境设计、可自动控制、可重复编程的多关节机械装置，凭借高精度、高节拍和长时间稳定运行的优势，长期承担焊接、喷涂、搬运、装配等重复性作业，是制造业自动化的核心装备。国际机器人联合会（International Federation of Robotics, IFR）发布的 2025 年世界机器人报告显示，2024 年全球工业机器人新装机量达 54.2 万台，较十年前增长一倍以上，全球在役存量达 466 万台；其中中国新装机 29.5 万台，占全球的 54%，在役存量突破 200 万台，连续多年保持全球最大的工业机器人市场^[1]。电子电气行业是工业机器人的主要应用行业之一，电路板组件的上下料、插件与检测等环节对机器人替代人工存在持续需求。然而，传统工业机器人依赖示教编程或离线编程，在结构化环境中沿预设轨迹重复运动，其可靠性建立在工件位姿、夹具和工艺流程高度固定的前提之上^[2,3]。当产线面临多品种、小批量、快速换型的需求，或工件位置、来料状态存在不确定性时，机器人需要重新示教、重新标定甚至重新设计工装，部署周期与成本显著上升；固定安装的机器人还需要依靠传送带或专用输送设备衔接不同工位，难以独立承担跨工位的物料流转任务。图1从焊接、汽车装配、码垛和电子制造四类作业展示了工业机器人的应用广度。这些系统虽然末端工具和工艺对象不同，但通常都通过固定工位、专用工装与预先编程来保证稳定性。

与传统工业机器人依赖精确编程不同，具身智能（Embodied Intelligence）强调智能体通过物理载体与环境的动态交互，在感知、决策与行动的闭环中持续学习和进化，从而突破静态数据训练模型的局限，获得更强的环境适应性与泛化能力^[4]。近年来，在互联网规模数据上预训练的大语言模型与视觉-语言模型（Vision-Language Model, VLM）展现出开放词汇视觉识别、常识推理与任务规划能力，推动机器人基础模型成为具身智能的技术核心^[5]。在操作技能层面，RT-1 与 RT-2 将 Transformer 架构和网络规模的视觉语言知识引入真机控制，使机器人能够从大规模示范数据中学习语言条件下的操作技能^[6,7]；Open X-Embodiment 汇集跨本体、跨机构的机器人数据，验证了跨机器人数据的正向迁移^[8]；视觉-语言-动作（Vision-Language-Action, VLA）模型以预训练 VLM 为主干、以动作专家生成连续动作，在开放环境中对新物体、新场景与新指令表现出泛化能力^[9-11]。与此同时，低成本遥操作与动作分块模仿学习使双臂精细操作可以从数十至数百条人类示范中直接学得^[12,13]；移动操作机器人因兼具移动、规划与操作能力，成为具身智能优先选择的硬件载体^[14]。具身智能机器人由此呈现出与传统工业机器人不同的技术形态：通过数据驱动策略降低对逐点示教和完全结构化环境的依赖，并在闭环感知中生成




(a) 机器人焊接



(b) 汽车车身装配



(c) 食品箱码垛




(d) PCB 元件贴装

图 1: 工业机器人的典型应用场景

动作。图2展示了人形、四足、轮式移动操作和轮式双臂四类本体。它们的自由度、可达空间和运动方式存在明显差异，说明具身智能并不对应单一外形；其共同特征是将感知、策略与可对环境施加作用的身体统一在交互闭环中。

将具身智能引入工业制造，使机器人在产线上具备自主感知、决策与操作能力，正在成为工业机器人技术演进的新方向。2025 年《政府工作报告》首次将具身智能列为国家重点培育的未来产业^[15]；智能制造也正经历从基于规则的自动化制造、数据驱动的数字化智能制造向具身智能赋能的智能制造的演进，具身智能在生产制造、仓储物流、检测维护和人机协作等环节具有直接的赋能作用^[2,16]。然而，工业场景要求机器人更高效、更准确、更可靠、更安全地完成作业，对具身智能提出了不同于开放家庭场景的挑战^[3]：操作对象往往是对准公差小、失效代价高的精密工件，产线对节拍与合格率有明确约束，策略还须在多台机器人之间稳定部署。本课题前期调试反复遇到由移动底盘停靠偏差引起的精细操作失效，而现有标称停靠示范不覆盖这类状态。如何在固定 PCBA 型号、来料位姿、工装几何与光照等环境条件下，量化并提高策略对工位停靠误差的容忍能力，是本课题的研究出发点。图3从机床上下料、厂内物流、在线质量监测和协作机器人作业四个环节展示了具身智能可能进入的制造链条。四类环节分别强调精密操作、跨工位移动、过程感知与安全协作，因而需要将自主策略与现有工艺节拍、质量标准



(a) 人形机器人



(b) 四足机器人



(c) 轮式移动操作机器人



(d) 轮式双臂机器人


图 2: 具身智能可采用的不同机器人本体

和安全边界同时纳入系统设计。

本课题面向的印制电路板组件 (Printed Circuit Board Assembly, PCBA) 检测工位上下料正是这样一个典型场景, 它是电子制造产线中重复性高、节拍受限的环节。一次完整的上下料由四个物理工位上的五个操作子任务组成: 从上料百叶车夹取待测 PCBA、移动至扫码工位完成扫码登记、从检测台取出已完成检测的上一块 PCBA、将当前 PCBA 放入检测台、最后将上一块 PCBA 放入下料百叶车; 检测台的取出与放入共用一次停靠。工位间移动由导航系统完成, 不计入 VLA 动作阶段; PCBA 在百叶车料槽中的插入与取出、在检测台上的放置与取出等接触对准操作属于精细操作阶段, 机械臂在工位内的接近、搬运与撤离属于自由空间阶段。本课题所用轮式双臂机器人由移动底盘、四自由度腰部、两条七自由度机械臂、二自由度头部与末端夹爪组成, 配置头部相机和左右腕部相机, 并由激光雷达定位与传统导航算法在工位间移动。前期观测表明实际停靠同时存在厘米量级的位置误差和度量级的航向误差, 其统计分布及对操作成功率的影响将在正式实验中按统一协议测量。



(a) 机床上下料



(b) 厂内物流



(c) 焊接过程在线质量监测



(d) 协作机器人产线作业

图 3: 具身智能面向工业制造的典型切入环节

面向这类多阶段双臂任务，以遥操作示范驱动的模仿学习已成为主流策略学习路线。动作分块 Transformer (Action Chunking with Transformers, ACT) 通过一次预测一段动作序列，提出了降低长时序行为克隆有效决策时域的动作分块思想^[12]；流匹配 VLA 模型进一步继承连续动作序列表示，并借助预训练视觉语言表征支持多任务与语言条件控制^[10,11]。本课题已在上述平台上完成“虚拟现实 (Virtual Reality, VR) 遥操作数据采集-基于 OpenPI 的 $\pi_{0.5}$ 微调-真机执行”流水线，已在标称停靠位姿下跑通从观测到动作执行再到新观测的接口闭环。ACT 为动作分块策略提供了方法基础，本文在 $\pi_{0.5}$ 上研究工位停靠误差。前期调试已经观察到停靠偏差条件下 PCBA 插入料槽与放置于检测台时的失败及机械挤压风险，但失败概率随误差的变化仍待分档重复实验量化。

本研究将该现象归纳为一条误差传递链，如图4所示。首先，导航停靠产生平面位置与航向误差；其次，位置误差近似等幅改变目标相对位置，航向误差则经目标到基座的距离转化为横向误差，两者在 PCBA 插入料槽、放置于检测台限位等精细操作阶段与装配公差处于同一量级；最后，系统虽在动作序列重规划边界形成视觉闭环，但一次提交的 s 个控制步在策略层面开环执行，其间的新观测不进入策略，错误动作因而可能持续至下一次重规划。该链条上的三个环节对应三种不同性质的缺陷：状态输入缺少工位相对位姿信息、策略级开环区间与阶段精

度需求不匹配、运行时缺少失败检测与恢复机制。




图 4: PCBA 上下料任务中的模仿学习策略闭环与工位停靠误差传递链

针对上述三个环节，本课题提出基于工位停靠误差传递链的分层鲁棒增强框架。该框架由面向停靠误差补偿的模仿学习方法、分阶段动作序列执行方法和基于预测偏差的在线失败检测与恢复方法构成：误差补偿学习方法将定位系统估计的停靠误差作为 $\pi_{0.5}$ 的显式误差输入，并以随机停靠示范扩大数据覆盖；分阶段执行方法按任务阶段调节动作序列执行时域，在精细操作阶段缩短开环区间，并以实时动作分块（Real-Time Chunking, RTC）连续衔接相邻动作序列；失败检测与恢复方法利用 RTC 重叠区中新旧动作序列的归一化逐步差值检测失败风险，并以固定模板执行恢复与重试。三项方法均不改变策略网络主体结构，分别作用于数据与状态、推理执行和运行时监控，可依次叠加并在同一误差注入协议下比较。这一从已贯通 $\pi_{0.5}$ 数据-推理-动作执行接口链路的真机需求出发、沿误差传递链构建分层增强机制的研究情境，构成本课题的直接来源。

1.2 研究目的与意义

本研究的总体目的是，面向 PCBA 上下料这一跨多工位、含精细对准阶段的轮式双臂任务，在已贯通的 OpenPI $\pi_{0.5}$ 数据-推理-动作执行接口链路基础上，沿工位停靠误差传递链建立可逐层叠加、可统一验证的策略鲁棒性改进方法。 $\pi_{0.5}$ 是本课题唯一的工程部署与实验主线，具体目的包括以下三个方面。

- (1) 面向停靠误差补偿的模仿学习：将激光雷达定位估计 $\hat{\delta}^{\text{loc}} = (\hat{\delta}_x^{\text{loc}}, \hat{\delta}_y^{\text{loc}}, \hat{\delta}_\theta^{\text{loc}})$ 作为显式误差输入，并在示范采集时用导航指令 δ^{cmd} 对 x 、 y 各施加 ± 3 厘米、

对航向施加 $\pm 3^\circ$ 的随机停靠，使策略学习“估计误差-动作修正”的对应关系；通过固定停靠、随机停靠和随机停靠加误差输入三组消融，分离数据覆盖与显式误差输入两种作用。

- (2) 分阶段动作序列执行：在不重新训练模型的前提下，按自由空间与精细操作两类阶段设置不同的执行时域，精细操作阶段仅执行动作序列前部即重新推理，并以 RTC 冻结已确定动作、引导重叠区和生成后续动作，以缩短开环执行区间并保持相邻动作序列连续性；与固定执行时域方式在成功率和推理时延两方面比较。
- (3) 基于预测偏差的在线失败检测与恢复：以 RTC 重叠区中新旧动作序列的归一化逐步差值定义预测偏差量，以成功回合的平滑预测偏差分布确定阈值，实现无需失败训练数据和额外模型训练的失败检测，并配合回退至安全高度、整链最多重试一次的模板化恢复；先在记录的 C2 回合上离线评价召回率、误报率和预警提前量，再在 C3 回合中评价条件恢复成功率、最终整链成功率及额外时延。

图5给出了本课题的研究切入路线。已贯通并完成单回合功能验证的 OpenPI $\pi_{0.5}$ 接口链路提供了功能基线与真机测试条件；真机部署中的失败观察引出工位停靠误差传递链；分层鲁棒增强框架中的三个方法分别对应链条的三个环节，并在统一的误差注入协议、五子任务链和四台机器人条件下按“C0 基线-C1 误差补偿-C2 分阶段执行-C3 检测与恢复”的顺序验证。验证结果还将反向修正示范采集规范与部署参数。




图 5: 从已贯通接口链路到分层鲁棒增强框架的研究切入路线

本研究的工程意义在于形成一套能够按误差、成功率、时延和安全事件验收的部署方案。显式误差输入与随机停靠数据增强旨在相对于 C0 正式测得的基线扩大容忍边界；分阶段执行旨在缩短精细操作阶段的开环执行区间；失败检测与

模板恢复旨在报警后限制错误动作持续时间。三项方法是否减少失败和人工接管由统一真机试验判定，其结论限定于相同 PCBA 型号和工装条件下的四台机器人，并为同类工位迁移提供接口与实验依据。

本研究的方法意义在于，将“模仿学习策略对位姿扰动不鲁棒”这一笼统判断分解为误差传递链上三个可独立度量、可分层验证的问题。三项方法均围绕 OpenPI $\pi_{0.5}$ 实现：误差输入只扩展状态维度，分阶段执行与 RTC 只调整推理侧逻辑，失败检测复用动作序列滚动推理的重叠区，无需失败训练数据和额外检测模型。上述属性可以由实现改动、训练数据和运行时开销直接核验；其对其他流匹配策略和移动操作任务的可迁移性不在本课题中作性能承诺。

综上，本课题的研究必要性源于模仿学习策略从实验室名义条件走向产线部署时，对工位停靠误差、执行粒度和运行时失败三方面缺乏系统处理的现状。为明确相关问题的已有解决路径与适用边界，后续按研究对象与方法类型对国内外相关研究进行梳理与评述。

2 国内外研究现状及分析

2.1 工业操作策略学习研究现状

本研究关注的对象是工业场景中由机器人闭环完成的抓取、放置与插接类操作，其特点是对准公差小、失效代价高、节拍要求明确。早期学习方法主要面向接触丰富的装配任务，通过强化学习或力控制在交互中学习插入与对准动作。Levine 等将引导策略搜索用于接触操作，以局部轨迹优化为神经网络策略提供监督信号^[17]；Inoue 等在高精度装配中采用深度强化学习，使策略根据状态反馈学习探索与插入动作^[18]；残差强化学习保留既有控制器，仅学习基础控制之外的修正量^[19]。对接触丰富操作的综述指出，样本效率、奖励建模、仿真到真机迁移与安全约束是该类方法进入产线的主要障碍^[20]。上述路线依赖真机交互或高保真仿真，在多阶段、跨工位的产线任务中难以直接铺开。

基于示范的模仿学习通过专家轨迹建立观测到动作的映射，能够在不进行大范围随机探索的条件下为机器人提供可执行的策略。早期方法通常将任务分解为接近、搜索、对准和插入等阶段，再以动态或概率运动原语显式表示轨迹分布^[21-23]。这类方法对少量数据较为友好，且中间变量便于解释，但依赖人工分段与任务坐标系先验，难以复用到对象、场景和指令持续变化的任务中。RoboMimic 基准对不同质量的人类示范和多类离线学习算法进行了系统比较，表明观测空间、历史信息、示范质量与模型选择都会影响策略性能^[24]，端到端行为克隆由此成为主流。

动作分块是当前端到端模仿学习的核心技术，其与低成本遥操作的结合使多阶段双臂操作可以直接从示范中学得，而无需人工设计接触模式或奖励。ACT 用

条件变分自编码器概括示范动作的多模态分布，并以 Transformer 在时刻 t 一次预测长度为 H 的动作序列^[12]：

$$\mathbf{A}_t = [\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}]. \quad (1)$$

动作序列联合预测把逐步决策转化为较短的块级决策，从而缩短长时序行为克隆的有效决策时域。ACT 执行时对多次推理中指向同一目标时刻的重叠预测作指数加权的时序集成，以降低动作抖动；这说明执行时域决定新观测进入控制回路的频率，而重叠动作序列包含可用于判断相邻动作序列连续性的信息。ACT 本身是面向任务的视觉-本体状态策略，不含语言条件和预训练通用表征，因此在本文中作为动作分块与重叠预测思想的算法背景。

扩散策略将动作序列建模为条件去噪过程，以概率生成方式表达同一观测下的多种合理动作，并以滚动时域方式执行预测序列的近期部分后重新规划^[25]，其总体结构如图6所示。3D 扩散策略与 RISE 分别以点云替代图像作为输入，提高了策略对视角与外观变化的鲁棒性^[26,27]；航点式模仿学习则自动从示范中抽取少量关键路点，以缩短行为克隆的决策时域^[28]。这些工作均把预测时域和每次执行的时域作为固定超参数：预测时域增大有利于序列连贯性，但若执行时域随之增长会延长开环区间；缩短执行时域能够提高闭环反馈频率，却增加推理负担与相邻动作序列衔接需求。




图 6: 扩散视觉动作策略：基于观测的动作序列生成框架^[25]

视觉-语言-动作模型在上述视觉动作策略基础上引入语言条件和视觉语言预训练知识，使下游任务微调所需示范量显著减少，并能够在在一个模型中处理多任务与语言指令^[11]。RT-1 以 Transformer 在大规模真机数据上学习语言条件策略^[6]，RT-2 把视觉语言模型直接微调为动作输出模型^[7]；Open X-Embodiment 聚合多机构、多本体数据训练 RT-X 模型^[8]，Octo 与 OpenVLA 在其上分别以扩散动作头和离散动作词元建立开源通用策略^[9,29]；DROID 提供了跨场景、跨操作者的大规模

真机示范数据^[30]。围绕双臂操作与部署效率，RDT-1B 采用扩散 Transformer 与统一动作空间学习双臂表示^[31]，TinyVLA、RoboMamba 与 UniVLA 分别从轻量骨干、高效序列建模和任务中心潜在动作方面降低训练与推理成本^[32–34]。

在动作表示方面，Physical Intelligence 提出的 π_0 将预训练视觉语言模型与独立的动作专家结合，动作专家以流匹配目标生成连续动作序列，从而在保留语言与视觉语义表征的同时适配高频、连续的机器人控制^[10]。其训练过程区分覆盖多任务、多本体数据的预训练与面向下游技能的后训练：前者用于获得可迁移的通用能力，后者使用质量更高的任务示教形成稳定执行策略。ACT 所代表的任务专用动作分块行为克隆说明了序列化动作输出的价值； π_0 则把连续动作序列作为 VLA 动作专家的生成对象，并把任务示教微调纳入通用模型的训练链路。二者在动作序列表示上存在方法联系，但模型条件、训练数据与生成机制并不相同。

随后， π_0 -FAST 采用频域动作序列标记化（Frequency-space Action Sequence Tokenization, FAST），将高频连续轨迹压缩为离散动作标记，以自回归方式提高大规模 VLA 训练效率^[35]。该方法与 π_0 的流匹配路线形成连续动作生成和离散动作建模两种实现。 $\pi_{0.5}$ 在此基础上进一步整合两条路线：预训练阶段采用 FAST 离散动作标记，以便将机器人动作数据与图文、目标检测和高层语义预测等异构任务共同训练；后训练阶段加入与 π_0 一致的流匹配动作专家，以连续动作序列支持实时控制^[11]。在推理阶段， $\pi_{0.5}$ 先根据视觉观测与总体指令预测语言形式的高层子任务，再以该子任务为条件生成底层连续动作，从而把任务分解与动作控制纳入同一模型。由此， π 系列形成了“ π_0 建立流匹配动作专家- π_0 -FAST 提高动作序列训练效率- $\pi_{0.5}$ 通过异构协同训练和高低层统一推理扩展开放环境泛化”的演进路径。

尽管示范驱动的策略学习大幅降低了工程门槛，工业抓放对精度的要求并未降低。IndustReal 在仿真中训练取放与插装策略并迁移到真实工业机械臂，为此专门设计了几何奖励、采样课程与部署端动作积分器，以消除接触仿真误差与稳态对准误差^[36]；Sóti 等针对精密抓放改进 Transporter 网络的平移与旋转精度，并以由粗到细的迭代推理在真实插块任务上验证，说明毫米级的放置偏差即决定任务成败^[37]。因此，模仿学习策略进入工业抓放场景时，需要在示范驱动的便利性与精细操作阶段的对准精度之间建立明确的处理机制。本课题中 PCBA 插入料槽与放置于检测台限位的操作正属于此类精细操作阶段。

综上，VLA 模仿学习已形成基于通用模型、通过任务示范进行下游微调的技术路线，且以动作序列作为重要输出形式。ACT 为动作分块策略提供了方法基础，本文在已贯通接口链路的 $\pi_{0.5}$ 上开展面向工位停靠误差的鲁棒性改进，重点检验

数据与状态输入、动作序列执行粒度和运行时监控三个环节能否与上述精度需求相匹配。

2.2 移动操作停靠误差鲁棒性研究现状

轮式双臂机器人在工位间移动后再执行操作，属于移动操作（Mobile Manipulation）问题，其核心困难之一是底盘定位误差向操作阶段的传递。Mobile ALOHA 将 ALOHA 双臂系统安装在移动底盘上，以全身遥操作同步采集底盘与双臂示范，并把底盘速度纳入模仿学习的动作空间；该工作还表明与静态 ALOHA 数据协同训练能够显著提高移动任务的数据效率，但其移动与操作由同一策略端到端输出，未显式处理停靠误差^[13]。ReLMoGen 让学习策略只预测子目标，由经典运动生成器负责到达，体现了学习决策与经典运动执行分层的思路^[38]；N²M² 在给定末端轨迹的条件下学习底盘与躯干运动，使移动操作机器人在未知环境中保持末端运动学可达^[39]。上述工作把底盘运动纳入学习范围，但均以底盘持续运动为前提，与本课题“停靠后锁定底盘、仅由双臂操作”的产线流程不同。

对停靠后操作误差的补偿主要出现在力觉与技能组合研究中。MOMA-Force 在真实移动操作接触任务中同时模仿动作与目标力/力矩，由导纳式全身控制器跟踪，直接处理底盘停靠偏差带来的末端接触误差^[40]；WildLMa 以全身控制器为底层、少量示范技能为中层、大语言模型组合技能为高层，在真实环境中完成长时序移动操作^[41]。Mandlekar 等提出的人在回路任务与运动规划框架把自由空间搬运交给自动规划，仅对接触段采集遥操作示范，从数据采集角度区分了自由空间与精细操作阶段^[42]。Ishida 等针对移动操作机器人换工位后自遮挡与背景变化导致的失败，提出关注任务相关视角与图像区域的鲁棒模仿学习方法，说明停靠位姿差异会同时改变本体状态与图像观测^[43]。

综合来看，在本文检索并纳入比较的代表性研究中，底盘停靠偏差主要通过力控补偿、技能组合或视觉表征处理，尚未发现同时把定位系统估计的工位停靠误差作为策略状态输入、并在示范采集中系统覆盖随机停靠的方案。从策略学习的角度看，工位停靠误差本质上是一类位姿扰动，其度量与应对可借鉴更一般的位姿扰动鲁棒性研究。

模仿学习策略对训练分布之外的观测缺乏保证，位姿扰动是工业部署中常见的分布偏移来源之一。Pumacay 等提出的 THE COLOSSEUM 基准把对象位姿、相机位姿、光照、背景、干扰物与物理参数等扰动轴分离开来，逐轴报告策略性能随扰动强度的变化，从而把“泛化能力”转化为可分级度量的退化曲线^[44]，其任务与扰动组织方式如图7所示。Jin 等的案例分析进一步表明，视觉策略可能同时依赖任务相关物理线索与背景视觉属性^[45]；前述 Ishida 等工作则说明，移动操作

中的视角与背景变化同样源于停靠位姿差异^[43]。工位停靠误差改变目标在三路相机中的相对视角和基座-工位几何关系，而原 14 维本体状态不含后一关系，因此形成视觉分布变化与显式误差输入缺失的耦合问题。




图 7: Pumacay 等提出的 THE COLOSSEUM 基准：任务层级与扰动维度^[44]

提高扰动鲁棒性的主要途径是扩大训练数据对扰动的覆盖，或向策略提供扰动的显式误差输入。动力学随机化通过扩大仿真参数分布提高策略对模型偏差的容忍度^[46]，其思想同样适用于真机示范采集中的初始位姿随机化；航点式模仿学习把动作锚定在少量关键路点上，减少了对精确轨迹复现的依赖^[28]。在评价协议方面，CALVIN 以语言条件的长时序任务链考察策略连续完成多个子任务的成功率，显式呈现误差随任务链长度的累积^[47]；LIBERO 以程序化生成的任务套件评估策略的知识迁移与遗忘^[48]；DROID 与 Open X-Embodiment 提供了跨机器人、跨场景的大规模数据组织范式^[8,30]；RoboMimic 则强调示范质量与训练终止规则对结论的影响^[24]。据此，本课题将训练、超参数验证、阈值标定与最终测试按采集日期和回合分组隔离，避免同一轨迹片段跨集合出现。

对本课题而言，上述工作提供了两方面依据。其一，工位停靠误差可以作为一条明确的扰动轴，以程序化注入的方式分级施加，并绘制成功率随误差幅值变化的容忍曲线；其二，“随机停靠数据增强”对应数据覆盖，“误差状态输入”对应显式误差输入，二者在文献中通常独立出现，其相对贡献需要通过固定停靠、随机停靠、随机停靠加误差输入三组消融来识别。这正是面向停靠误差补偿的模仿

学习方法的出发点与实验设计来源。

2.3 动作序列策略闭环执行研究现状

动作序列策略部署后，每次执行的时域决定了观测反馈的闭环频率，运行时失败检测则在任务层面闭合回路，二者共同影响真实系统的响应速度与错误动作持续时间。在执行方式上，本文比较的代表性方法体现了策略级开环区间长度与推理频率之间的权衡。ACT 的消融表明动作序列长度增大总体上提高成功率，而时序集成通过对重叠预测加权平均进一步改善动作平滑性；该结果在方法层面说明重叠动作序列具有连续性信息^[12]。扩散策略同样采用固定的预测时域与执行时域，并指出执行时域过长会削弱对新观测的响应^[25]。但对扩散或流匹配策略直接平均不同生成样本可能产生不可执行的中间动作，不能把 ACT 时序集成直接视为 $\pi_{0.5}$ 的原生机制。RTC 针对动作分块流策略，将推理延迟内已确定执行的动作冻结为前缀，并在重叠区引导生成过程、补全后续动作，从而在不重新训练策略的条件下实现异步连续执行^[49]。OpenVLA-OFT 系统比较了 VLA 微调中的动作解码方式、动作表示与学习目标，并把动作吞吐率作为与成功率并列的评价指标^[50]；FAST 通过频域动作词元压缩缩短自回归解码长度^[35]， $\pi_{0.5}$ 则以流匹配动作专家非自回归地生成整段动作序列^[11]，两者都把降低单次推理成本作为连续控制的前提。

本文所比较的动作分块与滚动时域方法通常在部署时采用单一执行时域。对于 PCBA 上下料这类自由空间移动与精细对准交替出现的任务，长执行时域在插入料槽、放置于检测台限位等接触对准阶段可能过度开环，而全程采用短执行时域又会增加推理次数。自由空间阶段可以容忍较长的开环执行区间，精细操作阶段则需要更短的执行区间以便及时利用新观测。在推理侧按阶段切换执行时域、以 RTC 处理相邻动作序列衔接，并同时报告条件成功率、推理频率和时延，尚需系统实现与评价，这是分阶段动作序列执行方法所要验证的内容。

部分由停靠误差引起的失败可能在动作预测差异中提前显现，运行时失败检测的目标是在造成损坏之前识别这一先兆；该假设需要由带失败时刻标注的独立测试回合验证。FAIL-Detect 提出只用成功示范数据进行模仿策略在线失败检测的模块化方法：从观测、视觉特征与策略动作中提取失败相关标量，以流密度估计建模不确定性，并用保形预测校准时变阈值，将失败识别表述为序列分布外检测，从而无需预先枚举失败类型或采集失败训练数据^[51]。Liu 等在交互式模仿学习部署中于共享潜空间训练动力学模型与失败分类器，通过对未来轨迹采样预测异常与失败，并结合分布外判据触发人工介入^[52]。在恢复方面，RACER 以视觉语言模型监督器在线描述错误与空间修正，由语言条件策略执行恢复动作，训练数据包含自动生成的扰动与恢复轨迹^[53]；REFLECT 把多模态历史压缩为可解释的失败

报告，并由语言规划器生成纠正方案^[54]。

多种代表性检测方案依赖额外的密度估计、分类器或恢复模块，且其信号来源与策略本身的动作生成过程相互独立。动作序列滚动推理天然提供了另一类信号：前一动作序列的未执行尾部与当前观测下的新动作提议在时间上存在重叠，当状态处于示范分布内时，二者的预测偏差应当较小；当工位停靠误差把状态推离示范分布或末端已经卡滞时，预测偏差可能增大。本文利用 RTC 构造流匹配策略的连续执行边界，同时在 RTC 引导前比较时间对齐的新旧动作序列，以归一化逐步差值定义预测偏差量，并用成功回合分位数标定阈值。这样既不直接平均不同流匹配样本，也无需引入额外模型或失败训练数据；该信号能否稳定先于失败上升，仍需在本课题任务中实证检验，由此形成基于预测偏差的在线失败检测与恢复方法。

2.4 国内外研究现状简析

上述代表性研究呈现出三点共同趋势。第一，多阶段双臂操作可以通过低成本遥操作示范与动作分块模仿学习获得，VLA 预训练进一步降低了下游任务的示范需求。第二，位姿扰动是模仿学习策略部署中的重要分布偏移来源，扩大数据覆盖与提供显式误差输入是两条互补的鲁棒性途径，评价应报告性能随扰动强度的退化曲线而非单一成功率。第三，动作序列执行方式与运行时监控需要同时评价任务结果和部署代价，指标应覆盖条件成功率、推理时延、回合级误报、报警提前量、人工接管和安全事件。

就本次检索的代表性样本而言，国外研究在动作分块模仿学习、移动操作全身遥操作、通用 VLA 模型与失败检测框架方面起步较早^[9,12,13,51]；国内团队在双臂扩散基础模型、轻量与高效 VLA 结构和三维输入模仿学习方面形成了针对性较强的研究^[26,27,31–34]，哈工大团队在精密装配示范学习方面也有持续积累^[23]。上述比较限于所选代表性样本及相应的方法侧重。

将上述进展映射到本课题的目标场景，仍有三个问题有待验证。其一，在本文纳入比较的研究中，尚未发现把定位系统估计的工位停靠误差作为策略显式状态，同时在示范采集中系统覆盖随机停靠的方案，数据覆盖与显式误差输入的相对贡献也缺少对应消融。其二，按自由空间与精细操作阶段区别设置执行时域，并通过 RTC 处理流匹配动作序列异步衔接，其成功率收益和计算代价需要在同一控制接口下评价。其三，RTC 重叠区中新旧动作序列逐步差值能否作为无需额外模型训练的失败信号，以及其回合级召回、误报和报警提前量，仍需在独立测试集上实证。

基于以上问题，本研究以已贯通并完成单回合功能验证的 OpenPI $\pi_{0.5}$ 接口链

路为基线，沿“工位停靠误差-精细操作阶段显现-错误动作持续”的传递链构建分层鲁棒增强框架，并在统一的误差注入协议、五子任务链和四台机器人条件下依次叠加验证。核心可检验问题分别落实为容忍边界 R_{80} 、精细子任务条件成功率与推理代价、检测召回率与回合误报率、报警提前量、恢复后整链成功率及安全事件数，所有改善结论均以预先规定的统计判据判断。

3 主要内容及方案

3.1 研究主线与总体技术路线

本课题的研究主线是工位停靠误差在 $\pi_{0.5}$ 策略执行过程中的传递与显现。底盘停靠后产生厘米量级的位置误差与度量级的航向误差；位置误差近似等幅改变操作目标在基座系中的位置，航向误差经目标距离转化为横向偏差，两者在 PCBA 插入料槽、放置于检测台限位等精细操作阶段与装配公差处于同一量级；偏差一旦超出策略的纠正能力，动作序列内部不接收观测反馈的执行方式又使错误动作持续至下一次推理。上述过程构成“工位停靠误差-精细操作阶段显现-错误动作持续”的误差传递链。本课题据此构建分层鲁棒增强框架，针对链上三个环节各提出一项方法，三项方法与误差传递链的对应关系及其相互依赖如图8所示。




图 8: 工位停靠误差传递链与分层鲁棒增强框架的逻辑关系

(1) 面向停靠误差补偿的模仿学习方法。 作用于误差传递链的源头。该方法一方面在示范采集中对每次停靠施加随机误差，使训练分布覆盖部署时的停靠偏差；另一方面将定位系统估计的停靠误差归一化后拼入策略状态，使策略在进

入操作阶段前即获得显式误差输入，从而减少进入精细操作阶段的初始偏差。该方法只扩展状态维度与示范分布，不改变策略网络主体结构。其给出的误差容忍曲线是后两项方法共同的评价基准，其误差注入手段也为失败检测与恢复方法提供可控的失败样本。

(2) 分阶段动作序列执行方法。 作用于误差放大环节。误差补偿学习方法的补偿来自单次状态输入，属于粗粒度补偿，残余偏差仍需在精细操作阶段依靠视觉反馈持续修正。该方法在推理侧按自由空间与精细操作两类阶段切换执行时域：自由空间阶段执行完整动作序列以降低推理开销，精细操作阶段仅执行动作序列前部即重新推理，并以 RTC 保持相邻动作序列连续，从而提高闭环频率、将误差容忍边界向外推移。该方法不改变训练，可直接叠加在误差补偿学习训练所得的策略之上；其在精细操作阶段更频繁的重新推理，也为失败检测与恢复方法提供更密集的重叠预测。

(3) 基于预测偏差的在线失败检测与恢复方法。 作用于错误动作持续环节，处理前两项方法仍无法消除的失败。该方法利用相邻动作序列在重叠区的预测差异构造预测偏差量，以成功回合分位数标定分阶段阈值，在失败造成损坏之前触发模板恢复或安全停机。检测信号直接来自策略自身的滚动推理，无需额外模型或失败训练数据，同样只作用于推理侧。

综上，三项方法沿误差传递链依次设置，分别补偿初始误差、缩短误差放大后的开环执行区间、截断已经失败的执行过程，并在评价基准、失败信号与失败样本三方面相互依赖。策略模型统一采用基于 OpenPI 微调的 $\pi_{0.5}$ 。实验按“C0 基线-C1 误差补偿-C2 分阶段执行-C3 检测与恢复”的顺序逐层叠加，在同一误差注入协议和同一条五子任务链上比较，既考察每一项方法的边际贡献，也给出完整系统的端到端性能。

3.2 任务定义与工位停靠误差传递问题

PCBA 上下料任务由四个物理工位上的五个操作子任务顺序组成，记子任务集合为 $\mathcal{L} = \{\text{上料车取料, 扫码, 检测台下料, 检测台上料, 下料车放料}\}$ ，分别对应从上料百叶车夹取 PCBA、扫码登记、从检测台取出上一块 PCBA、将当前 PCBA 放入检测台以及将上一块 PCBA 放入下料百叶车，如图9所示。外部任务状态机顺序给出语言条件 $\ell_t \in \mathcal{L}$ ， $\pi_{0.5}$ 生成低层连续动作。机器人导航至工位并锁定底盘后执行操作；检测台下料和上料在同一次停靠中连续完成，因而一条完整任务链包含四次停靠事件和五次子任务判定。

以一条完整的五子任务链为一个测试回合。取料类子任务以 PCBA 被夹持并完全离开原承载区域为完成条件，扫码以扫码器返回有效编码为完成条件，放置类

子任务以 PCBA 到达目标料槽或检测台限位并在释放后保持稳定为完成条件；掉落、触发接触保护或急停、人工介入以及超时均判为失败。成功与否依据同步视频、夹爪状态与工位传感记录复核，不直接采用在线状态机的转移结果。令 $Y_{e,m} \in \{0, 1\}$ 表示回合 e 的第 m 个子任务是否成功，则整链成功率和第 m 个子任务的条件成功率分别定义为

$$\hat{S}_{\text{chain}} = \frac{1}{N} \sum_{e=1}^N \prod_{m=1}^5 Y_{e,m}, \quad \hat{S}_m^{\text{cond}} = \frac{\sum_{e=1}^N Y_{e,m} \prod_{q=1}^{m-1} Y_{e,q}}{\sum_{e=1}^N \prod_{q=1}^{m-1} Y_{e,q}}, \quad (2)$$

其中空乘积取 1。整链成功率反映端到端性能，条件成功率则把某个子任务的表现与前序子任务的失败分离开，便于单独考察精细子任务。




图 9: PCBA 上下料五子任务链与工位停靠误差的定义

为描述工位停靠误差，对第 k 个工位定义固连于环境的标称停靠坐标系 $\{S_k\}$ ，该坐标系在示范采集时与机器人基座系 $\{B\}$ 重合。记 ${}^A\mathbf{T}_C$ 为把 $\{C\}$ 中坐标变换到 $\{A\}$ 中的齐次变换， ${}^o\mathbf{T}_{S_k}$ 为标称停靠位姿， ${}^o\mathbf{T}_B$ 为实际停靠后的基座位姿，则停靠误差为

$$\Delta\mathbf{T}_k = ({}^o\mathbf{T}_{S_k})^{-1} {}^o\mathbf{T}_B = \begin{bmatrix} \mathbf{R}(\delta\theta_k) & \delta\mathbf{p}_k \\ \mathbf{0}^T & 1 \end{bmatrix}, \quad \delta_k = (\delta x_k, \delta y_k, \delta\theta_k)^T, \quad (3)$$

式中，底盘停靠于水平地面，误差退化为平面位姿； $\delta\mathbf{p}_k = (\delta x_k, \delta y_k)^T$ 为标称停靠系中的位置误差， $\delta\theta_k$ 为航向误差， $\mathbf{R}(\cdot)$ 为平面旋转矩阵。同一停靠误差在实验中对三个量：写入导航目标的注入量 δ_k^{cmd} 为实验施加的干预变量，激光雷达定位给出的估计 $\hat{\delta}_k^{\text{loc}}$ 为策略的状态观测量，由工位固定视觉基准标记独立测得的参考

值 δ_k^{ref} 为评价用的物理真值。参考值的获取方式为：在每个工位固定一块位置经标定的平面基准标记（ArUco 标记），停靠并锁定底盘后，由头部相机在操作开始前采集多帧图像，经透视 n 点求解标记相对相机的位姿，再经头部关节角与一次性标定的头部相机-基座外参换算为基座相对标称停靠系的平面位姿。该测量在一米内的精度为毫米量级，优于容忍曲线 1 厘米与 1° 的误差量化步长，且不依赖导航栈与激光雷达定位。三者分别记录，测试结果以参考值为真值归档。

工位停靠误差对操作精度的影响可由目标点在基座系中的位置变化刻画。设料槽、检测台定位限位等操作目标固连于工位，在标称停靠系中的平面位置为 $\mathbf{p}_G^{S_k}$ 。示范策略隐含地假定基座与标称停靠系重合，其动作以 $\mathbf{p}_G^{S_k}$ 为目标；实际停靠后，同一目标在基座系中的位置变为 $\mathbf{R}(\delta\theta_k)^T(\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k)$ ，与策略隐含目标之差及其上界为

$$\mathbf{e}_p = (\mathbf{R}(\delta\theta_k)^T - \mathbf{I}) \mathbf{p}_G^{S_k} - \mathbf{R}(\delta\theta_k)^T \delta\mathbf{p}_k, \quad \|\mathbf{e}_p\| \leq \|\delta\mathbf{p}_k\| + |\delta\theta_k| \|\mathbf{p}_G^{S_k}\|, \quad (4)$$

式(4)表明，位置误差近似等幅传递，航向误差项随目标距离放大。本课题各工位的操作目标与停靠位置之间的距离由工装布置决定，近似固定，取 0.5 米估计： 1° 航向误差对应约 8.7 毫米的末端偏差， 3° 对应约 26.2 毫米，与位置误差同处厘米量级，均已达到或超过 PCBA 插入料槽所允许的装配公差。这是停靠误差在精细操作阶段显现为夹取或放置失败的几何原因。

3.3 面向停靠误差补偿的模仿学习方法

停靠误差是整条误差链的起点。若策略只见过标称停靠位下的示范，部署时的误差会直接转化为末端操作偏差。误差补偿学习方法从数据分布与显式误差输入两个方面处理这一问题。数据层面，示范采集时对每次停靠事件独立采样随机停靠误差

$$\delta x_k, \delta y_k \sim \mathcal{U}(-3 \text{ cm}, 3 \text{ cm}), \quad \delta\theta_k \sim \mathcal{U}(-3^\circ, 3^\circ), \quad (5)$$

使训练数据本身覆盖不同的停靠偏差，操作者在遥操作中对误差的修正随之成为动作标签。各子任务的示范在位置象限与航向正负方向上均衡采集，固定停靠组取相同回合数，以避免数据量差异与误差覆盖效应混杂。

状态层面，将定位系统估计的停靠误差经归一化后拼接到已贯通 OpenPI 接口的 14 维本体状态，形成误差增广状态与观测

$$\tilde{\mathbf{x}}_t = [\mathbf{x}_t^T, \bar{\boldsymbol{\delta}}_k^T]^T \in \mathbb{R}^{17}, \quad \bar{\boldsymbol{\delta}}_k = \left(\frac{\hat{\delta}_{x,k}^{\text{loc}} - \mu_x}{\sigma_x}, \frac{\hat{\delta}_{y,k}^{\text{loc}} - \mu_y}{\sigma_y}, \frac{\hat{\delta}_{\theta,k}^{\text{loc}} - \mu_\theta}{\sigma_\theta} \right)^T, \quad (6)$$

$$\tilde{\mathbf{o}}_t = \{I_t^{\text{head}}, I_t^{\text{wrist},L}, I_t^{\text{wrist},R}, \tilde{\mathbf{x}}_t, \ell_t\},$$

式中， $\mathbf{x}_t$ 为原 14 维双臂末端位姿与夹爪状态， μ 与 σ 为训练集上各误差分量的均值与标准差。误差估计在一次停靠期间保持不变，仅在机器人重新导航并停靠后更新；检测台连续执行的下料与上料共用同一估计。策略网络主体和流匹配训练目标保持不变，仅状态接口由 14 维扩展为 17 维，因而该方法可直接复用现有微调流水线。显式误差输入使策略能够感知当前停靠偏差并对整体动作作出补偿；视觉输入能否隐式完成同样的补偿，则由消融实验回答。

实验包括误差容忍曲线与消融两部分。容忍曲线在部署时人为注入参考误差，平移幅值取 $\{0, 1, 2, 3, 4, 5\}$ 厘米、航向幅值取 $\{0, 1, 2, 3, 4, 5\}^\circ$ ，分别绘制整链成功率随误差幅值变化的曲线，并以成功率不低于 80% 的最大误差幅值定义容忍边界 R_{80} ，量化策略对停靠误差的容忍范围。消融按表1设置三组配置：(a) 固定标称停靠且不输入误差，即 C0；(b) 随机停靠扩充数据覆盖但不输入误差；(c) 随机停靠并输入误差，即 C1。(a) 与 (b) 的差异给出数据覆盖的贡献，(b) 与 (c) 的差异给出显式误差输入的贡献。三组从同一预训练检查点以相同示范回合数和训练预算微调，且 (b) 与 (c) 使用完全相同的随机停靠回合。C1 的容忍曲线同时是后两项方法的共同基准：分阶段执行方法的目标是把这条边界向外推，失败检测与恢复方法的目标是在边界之外把失败安全地兜住。

表 1: 误差补偿学习方法的消融配置

配置	训练数据停靠方式	状态含误差	考察问题
(a)	固定标称停靠	否	现有流水线基线，给出名义条件下的性能与误差注入下的退化速度
(b)	$\delta x, \delta y \in [-3, 3]$ 厘米， $\delta \theta \in [-3, 3]^\circ$	否	仅靠数据覆盖，策略能否从图像中隐式推断并补偿误差
(c)	与 (b) 相同的随机停靠回合	是	显式误差输入在数据覆盖之外能否进一步扩大容忍边界

3.4 分阶段动作序列执行方法

误差补偿学习方法的补偿来自单次状态输入，属于粗粒度补偿；对于插入料槽、放置于检测台限位等毫米级配合的接触对准阶段，残余误差需要依靠视觉反馈在执行过程中持续修正。 $\pi_{0.5}$ 每次推理生成长度为 H 的动作序列 $\hat{\mathbf{A}}_t$ ，机器人执行其中前 s 步后重新推理。固定的执行时域在两类阶段之间存在矛盾：自由空间中的大范围运动希望 s 长一些，以减少推理次数、降低时延；精细操作阶段则希望

s 短一些，以便及时根据最新观测修正动作。分阶段执行方法不改变训练，只在推理侧按阶段调整执行时域，因而可以直接叠加在误差补偿学习训练好的策略之上。

将时刻 t 的执行阶段记为 $\phi_t \in \{\text{free}, \text{fine}\}$ ，精细操作阶段对应 PCBA 插入与取出料槽、放置于检测台限位等接触对准操作，自由空间阶段对应工位内的接近、搬运与撤离。阶段由当前子任务标签和末端到操作目标的距离共同判定，并采用进入阈值 d_{enter} 与退出阈值 $d_{\text{exit}} > d_{\text{enter}}$ 的滞回规则避免在阈值附近反复切换：

$$\phi_t = \begin{cases} \text{fine}, & \ell_t \in \mathcal{L}_{\text{fine}} \text{ 且 } \|{}^B\mathbf{p}_{E,t} - {}^B\mathbf{p}_{G_{\ell_t}}\| \leq d_{\text{enter}}, \\ \text{free}, & \ell_t \notin \mathcal{L}_{\text{fine}} \text{ 或 } \|{}^B\mathbf{p}_{E,t} - {}^B\mathbf{p}_{G_{\ell_t}}\| \geq d_{\text{exit}}, \quad s_t = s_{\phi_t}, \quad s_{\text{fine}} < s_{\text{free}} \leq H, \\ \phi_{t-1}, & \text{其他}, \end{cases} \quad (7)$$

式中， ${}^B\mathbf{p}_{E,t}$ 为当前操作臂在基座系中的末端位置， ${}^B\mathbf{p}_{G_{\ell_t}}$ 为由工位标定和停靠误差估计换算得到的操作目标位置， $\mathcal{L}_{\text{fine}}$ 为含精细区段的子任务集合，即扫码以外的四个子任务， s_{free} 与 s_{fine} 分别为两类阶段的执行时域。每个子任务初始阶段置为 free ，阶段信号由外部任务状态机和距离规则共同确定，不依赖 $\pi_{0.5}$ 自身的高层预测。

缩短执行时域受推理延迟约束。设第 i 次推理在控制步 n_i 启动，其耗时折算为 d_i 个控制步，则下一次推理在 $n_{i+1} = n_i + s_{\phi}$ 启动，且须满足 $d_i \leq s_{\phi}$ 与 $s_{\phi} + d_i \leq H$ ，即新动作序列必须在前一动作序列耗尽之前返回。为此，执行采用适用于流匹配 VLA 的实时动作分块机制^[49]：新一轮推理进行时，机器人继续执行前一动作序列；生成新动作序列时，将延迟 d_i 内已经确定的动作冻结为前缀，对其后的重叠区施加逐步减弱的引导，再由流匹配动作头补全后续动作，从而在不停顿的前提下连续衔接相邻动作序列。图10给出了两类阶段的执行时序：自由空间阶段采用较长执行时域以减少推理次数，精细操作阶段采用较短执行时域，使新观测更快进入控制回路。 s_{fine} 的下限由目标硬件上实测的推理延迟确定， s_{free} 取接近 H 的值，两者在正式测试前确定并保持不变。

实验在 C1 策略上进行，比较分阶段执行（即 C2）与全程固定短、中、长三档执行时域的对照组。四组均启用相同的 RTC，因而 C2 与对照组的差异只归因于阶段切换；C1 不使用 RTC，C1 与 C2 之差则反映 RTC 与分阶段组成的整个控制模块的效应。评价指标同时报告成功率与时延：成功率以精细子任务的条件成功率为主，时延报告推理次数、每链累计推理时间与首动作延迟，以验证该方法能够在不牺牲整体效率的前提下提高精细操作阶段的成功率。同时在注入误差的条件下重复误差补偿学习方法的容忍曲线实验，检验闭环频率的提高是否使容忍边界




图 10: 分阶段执行时域与 RTC 相邻动作序列连续衔接时序

外移。

3.5 基于预测偏差的在线失败检测与恢复方法

经过前两层改进, 策略的容忍范围得到扩展, 但仍会遇到超出容忍边界的情况, 例如停靠误差过大或 PCBA 在百叶车中的位置异常。此时模仿学习策略通常不会自行停止, 而是继续执行错误动作, 可能造成 PCBA 损坏或机械臂卡滞。失败检测与恢复方法为此提供一种无需额外训练、可在线运行的失败检测与恢复机制。

失败信号来自 RTC 连续执行产生的重叠动作序列。相邻两次推理对同一未来时段各给出一段预测: 在策略熟悉的状态下, 两段预测应当接近; 进入分布偏移或卡滞前, 新旧预测的分歧往往先于失败增大。设第 $i-1$ 次推理的动作序列在执行 s_{i-1} 步后留下尾部 $\hat{\mathbf{A}}_i^{\text{prev}}$, 第 i 次推理在 RTC 引导前给出原始动作提议 $\hat{\mathbf{A}}_i^{\text{raw}}$, 两者按绝对控制步对齐, 重叠区的逐步差值为

$$\mathcal{J}_i = \{j : 0 \leq j < H - s_{i-1}\}, \quad \mathbf{e}_{i,j} = \text{diff}(\hat{\mathbf{a}}_{i,j}^{\text{raw}}, \hat{\mathbf{a}}_{i,j}^{\text{prev}}), \quad j \in \mathcal{J}_i, \quad (8)$$

式中, diff 对位置分量作普通差, 对姿态分量作包角差, 对夹爪分量按开合状态是否相同取 0 或 1。原始提议在固定参考噪声下生成, 以抑制流匹配采样随机性对检测分数的影响。将重叠区归一化逐步差值的加权均值 r_i 称为预测偏差量, 将其在连续 L 次推理上的滑动均值 $\tilde{r}_i$ 称为平滑预测偏差:

$$r_i = \frac{\sum_{j \in \mathcal{J}_i} \omega_{i,j} \|\Lambda^{-1/2} \mathbf{e}_{i,j}\|_2^2}{\sum_{j \in \mathcal{J}_i} \omega_{i,j}}, \quad \tilde{r}_i = \frac{1}{L} \sum_{q=i-L+1}^i r_q, \quad (9)$$

式中, $\omega_{i,j}$ 为 RTC 的引导权重, 在冻结前缀取 1、在重叠区逐步衰减^[49], 使检测重点落在即将执行的近期动作上; Λ 为由训练集估计的各动作维度方差, 用于消

除量纲差异。该分数直接复用策略已有的预测，不引入额外网络；其对各类失败模式的覆盖范围由实验给出。

阈值只由成功回合确定，不使用失败标签。在 C2 配置下采集一批成功回合作为标定集，取每个回合平滑预测偏差的全程最大值，以其 95 分位数作为阈值：

$$M^e = \max_i \tilde{r}_i^e, \quad \eta = Q_{0.95}(\{M^e : e \in \mathcal{E}_{\text{cal}}\}), \quad \text{报警} \iff \tilde{r}_i > \eta \text{ 连续 } n_{\text{hold}} \text{ 次}, \quad (10)$$

式中， $\mathcal{E}_{\text{cal}}$ 为成功标定集。按回合最大值取阈值，意味着成功回合中约有 5% 会出现误报，误报率由此得到直接控制；要求连续超阈则用于过滤单次尖峰。阈值在检测评价前确定并冻结。

检测质量以召回率、误报率和预警提前量评价。利用误差补偿学习方法的误差注入手段，在容忍边界之外制造受控的失败样本；先对记录的 C2 回合离线回放检测器，只产生报警而不改变动作，因而原始失败时刻仍可观察。失败回合中，报警须落在失败发生之前、且早于机器人安全停止所需的时间，才计为及时检出；成功回合中的任何报警计为误报；报警时刻到失败时刻之差为预警提前量。这一评价方式把检测器的表现与恢复动作的效果分离开来。

检测参数确定后，在新的回合中启用固定模板恢复，形成 C3 配置，流程如图11所示。报警后先停止当前动作序列；在夹爪状态正常且回退路径安全的前提下，沿工位竖直方向退至安全高度，回到当前子任务的入口位姿，重新获取观测并重试当前子任务一次。恢复动作采用固定模板执行，不由模型生成，以保证恢复过程本身可靠、可控。若重试后再次报警，或初次报警时安全前提不满足，则立即停机并交由人工处理。C3 报告条件恢复成功率、恢复后的最终整链成功率以及监测和恢复带来的额外时延，并与匹配的 C2 回合比较；同时报告人工接管率与安全事件数，防止额外重试掩盖原策略的退化。

3.6 整体验证方案

三项方法按表2依次叠加为四个配置，在同一套误差注入条件和同一条五子任务链上比较端到端成功率与任务时延，既能看出每一层的边际贡献，也能给出完整系统的最终性能。C0 与 C1 的比较对应误差补偿学习方法，C1 与 C2 的比较对应分阶段执行方法，C2 与 C3 的比较对应失败检测与恢复方法；各方法内部的消融与对照见前述各节。

示范只由一台源机器人采集，其余三台机器人不进入策略训练，用于检验策略在不同本体上的表现，四台机器人的结果分别报告。所有配置使用统一的日志时钟，逐次记录配置、阶段、执行时域、预测偏差量、报警、恢复和子任务结果，




图 11: 基于相邻动作序列预测偏差的失败检测与模板恢复流程

并关联机器人、工位、模型检查点与误差档位。以回合为统计单位，成功率等比例指标附置信区间。

表 2: 整体验证的叠加配置

配置	组成	主要考察指标
C0	$\pi_{0.5}$ 固定执行时域基线	标称停靠下的成功率；误差注入下的退化速度
C1 误差补偿	C0 加入随机停靠示范与停靠误差状态输入	误差容忍曲线与容忍边界 R_{80} ；相对 C0 及消融 (b) 的成功率差
C2 分阶段执行	C1 加入分阶段执行时域与 RTC	精细子任务条件成功率；推理次数与时延；容忍边界是否外移
C3 检测与恢复	C2 加入预测偏差检测与一次模板恢复	检测召回率、误报率与提前量；恢复成功率、最终整链成功率与额外时延

3.7 可行性分析

本课题的可行性建立在已完成接口和方法的可分步实现上。其一，第5节所述 VR 示范采集、OpenPI 数据组织、 $\pi_{0.5}$ 任务微调与动作序列执行接口已经贯通，可直接作为 C0 基线。其二，三项方法均不改变策略网络主体结构：误差输入只扩展状态接口，微调可在课题分配的一张 A100 80G 显卡上完成；分阶段执行、RTC 与预测偏差监测均位于推理侧；检测阈值只需成功回合标定，不需要失败训练数据。其三，导航目标可程序化注入，激光雷达定位提供策略输入，独立工位测量负责实际误差归档，三者职责分离，误差注入实验可控、可重复。其四，四台机器人可并行开展实验，示范采集与策略训练只占用其中一台及一张显卡。可能的风险与应对措施见第8节。

4 预期达到的目标

本课题预期在已贯通的 OpenPI $\pi_{0.5}$ 接口链路基础上，建立基于工位停靠误差传递链的分层鲁棒增强框架，并在轮式双臂机器人和真实的 PCBA 四工位五子任务链上完成验证。具体目标如下。

对于误差补偿学习方法，预期显式误差输入与随机停靠示范能够使策略在注入误差下的成功率退化明显放缓，平移与航向两条容忍曲线的容忍边界相对基线向外扩展；消融结果能够分离数据覆盖与显式误差输入各自的贡献。

对于分阶段执行方法，预期在精细操作阶段缩短执行时域并以 RTC 连续衔接后，精细子任务的条件成功率不低于全程短时域配置，而推理开销明显低于该配

置；相对全程长时域配置，精细子任务的条件成功率明显提高；容忍边界相对 C1 进一步外移。

对于失败检测与恢复方法，预期平滑预测偏差能够在多数误差诱发的失败发生之前触发报警，成功回合中的误报保持在标定所设定的水平，且报警提前量足以让机器人安全停止；模板恢复能够挽回一部分失败回合，使最终整链成功率相对 C2 提高，同时不引入新的物料或夹具损伤，监测与恢复带来的额外时延不影响精细操作阶段的执行期限。

预期成果形式包括：面向 OpenPI $\pi_{0.5}$ 的工位停靠误差鲁棒性改进方法及其真机验证；四个叠加配置在统一误差协议下的真机实验数据、容忍曲线、检测与恢复结果；以及以上内容为主体的硕士学位论文。

5 已完成的学术研究/实践工作

5.1 实验平台与坐标系定义

本研究已在轮式双臂机器人平台上完成示范采集与策略执行所需的基础接口建设。机器人上半身由左右两条七自由度机械臂、四自由度腰部和二自由度头部组成，共包含 20 个转动关节，并配置末端夹爪、头部相机和腕部相机。现阶段的双臂操作以左右机械臂末端笛卡尔位姿和夹爪状态作为核心状态与动作变量，执行模型将腰部、头部和移动底盘位姿作为固定参数，仅更新左右机械臂的关节状态。移动底盘由激光雷达定位与传统导航算法在工位间移动并停靠，停靠后锁定，操作阶段仅由双臂执行。

为统一描述机器人、工位与虚拟现实（Virtual Reality, VR）设备之间的空间关系，本文以 $\alpha \in \{L, R\}$ 区分左、右机械臂，并定义以下坐标系：世界坐标系记为 $\{O\}$ ，机器人基座坐标系记为 $\{B\}$ ，左右末端执行器坐标系记为 $\{E_\alpha\}$ ，第 k 个工位固连于环境且与示范时名义基座位姿重合的停靠坐标系记为 $\{S_k\}$ ；VR 参考坐标系记为 $\{V\}$ ，左右手控制器坐标系记为 $\{H_\alpha\}$ 。其中， ${}^A\mathbf{T}_C$ 表示坐标系 $\{C\}$ 相对于坐标系 $\{A\}$ 的位姿，即把 $\{C\}$ 中的齐次坐标变换到 $\{A\}$ 中。该表示写为

$${}^A\mathbf{T}_C = \begin{bmatrix} {}^A\mathbf{R}_C & {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}, \quad (11)$$

式中， ${}^A\mathbf{R}_C \in \text{SO}(3)$ 为旋转矩阵， ${}^A\mathbf{p}_C \in \mathbb{R}^3$ 为坐标系原点的位置向量。若空间点在 $\{C\}$ 中的齐次坐标为 $\bar{\mathbf{p}}^C$ ，则其在 $\{A\}$ 中的表示为 $\bar{\mathbf{p}}^A = {}^A\mathbf{T}_C \bar{\mathbf{p}}^C$ 。连续坐标变换满足

$${}^A\mathbf{T}_D = {}^A\mathbf{T}_C {}^C\mathbf{T}_D, \quad ({}^A\mathbf{T}_C)^{-1} = \begin{bmatrix} ({}^A\mathbf{R}_C)^T & -({}^A\mathbf{R}_C)^T {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}. \quad (12)$$

式(11)和式(12)构成 VR 增量映射、工位坐标系与前文停靠误差定义的统一表示基础。基座系与末端系之间的正逆运动学由平台现有笛卡尔控制模块提供，本文不再展开。

5.2 基于 VR 遥操作的示范数据采集

在上述坐标关系基础上，本研究已构建基于 VR 设备的双臂遥操作与示范采集链路。系统读取头显及左右手控制器的空间位姿和交互信号，在遥操作回合开始时分别记录控制器初始位姿 ${}^V\mathbf{T}_{H_\alpha}(t_0)$ 与机器人末端初始位姿 ${}^B\mathbf{T}_{E_\alpha}(t_0)$ 。固定标定旋转 ${}^B\mathbf{R}_V$ 用于统一 VR 参考系与机器人基座系的轴向约定，比例系数 λ_α 用于调节操作者手部平移与机器人末端平移的尺度。由此，控制器相对初始位置的增量被映射为

$${}^B\mathbf{p}_{E_{\alpha,d}}(t) = {}^B\mathbf{p}_{E_\alpha}(t_0) + \lambda_\alpha {}^B\mathbf{R}_V ({}^V\mathbf{p}_{H_\alpha}(t) - {}^V\mathbf{p}_{H_\alpha}(t_0)). \quad (13)$$

该增量形式以遥操作开始时的实际末端位置为基准，VR 空间的绝对坐标用于计算控制器相对初始位姿的运动增量。

控制器姿态首先相对于初始姿态计算，再经标定旋转映射到机器人基座系。末端目标姿态表示为

$${}^B\mathbf{R}_{E_{\alpha,d}}(t) = {}^B\mathbf{R}_V \left[{}^V\mathbf{R}_{H_\alpha}(t) ({}^V\mathbf{R}_{H_\alpha}(t_0))^T \right] {}^V\mathbf{R}_B {}^B\mathbf{R}_{E_\alpha}(t_0), \quad (14)$$

其中 ${}^V\mathbf{R}_B = ({}^B\mathbf{R}_V)^T$ 。式(13)与式(14)分别生成末端目标位置和姿态，两者组成 ${}^B\mathbf{T}_{E_{\alpha,d}}(t)$ ，再由已有笛卡尔控制接口执行。手柄交互量 $u_\alpha(t)$ 通过既定映射

$$g_{\alpha,d}(t) = \mathcal{G}_\alpha(u_\alpha(t)) \quad (15)$$

转换为左右夹爪的开合指令。映射函数 $\mathcal{G}_\alpha(\cdot)$ 的触发阈值与夹爪行程参数由平台配置确定。

机器人示范数据通常以一次完整的任务回合作为基本组织单元，将视觉观测、机器人状态与动作按时间步对齐，并在回合层关联任务指令；统一的数据语义有助于后续按不同观测窗口和动作空间构造训练样本^[8]。参照这一组织方式，本研究将当前采集的数据划分为任务、回合和时间步三个层级：任务层以自然语言描述界定操作目标，回合层对应一次完整的遥操作过程，时间步层则以动作时刻为索引，关联头部与左右腕部图像、双臂末端状态、夹爪状态及相应动作。第 n 个任务回合可表示为

$$\tau^{(n)} = \left\{ \left(t_k, I_k^{\text{head}}, I_k^{\text{wrist},L}, I_k^{\text{wrist},R}, \mathbf{x}_k, \mathbf{a}_k \right) \right\}_{k=1}^{K_n}, \quad (16)$$

其中， $\mathbf{x}_k$ 包含左右末端位姿与夹爪状态， $\mathbf{a}_k$ 包含对应时刻的双臂笛卡尔动作与夹

爪指令。任务语言描述作为策略的语义条件与相应示范回合关联；一个示范回合对应一次低层子任务执行，正式评价中的五子任务链则由状态机串联这些子任务。上述层级将任务语义与单次执行序列分开，同时保持观测、状态和动作在回合内部逐时对应，可直接为后续视觉-语言-动作策略构造单步样本或动作序列样本。现有示范均在标称停靠位姿下采集，第3.3节将把采集扩展为随机停靠，并在回合层同步记录所属停靠事件的 δ_k^{cmd} 、 $\hat{\delta}_k^{\text{loc}}$ 与 δ_k^{ref} 。

以“将印制电路板组件（Printed Circuit Board Assembly, PCBA）放置到百叶车指定承载位置”为例，该回合以右臂为操作臂，左臂保持固定。机器人在夹爪夹持状态下携带 PCBA 接近百叶车，调整末端位置和姿态完成放置，随后松开夹爪并撤离放置区域。该回合共包含 177 个时间对齐样本；每个时间步包含三路分辨率为 240×320 的彩色图像，以及 14 维双臂末端状态和 14 维双臂动作。状态与动作均按左右臂各 7 维组织，分别由三维位置、滚转-俯仰-偏航姿态和夹爪状态或指令组成。该样例表明，现有采集链路能够将多视角观测、机器人本体状态与遥操作动作组织为式(16)所定义的完整回合。

图12给出了该回合的起始、中间和结束观测，以及右手末端的三维运动轨迹。上部三幅图分别对应第 0、88 和 176 帧：前两帧处于夹持状态，结束帧处于松开状态；下部曲线以颜色和线型区分夹爪语义状态，以箭头表示工具坐标系 +Z 轴方向。轨迹在第 120 帧由夹持切换为松开，使视觉观测、末端位姿和 PCBA 释放事件能够在同一时间轴上对应。

图13概括了已完成系统中数据采集与策略执行之间的接口关系。VR 位姿经过增量映射后进入笛卡尔控制模块，机器人动作及多视角观测由同步记录模块组织为示范轨迹；示范数据经 OpenPI 数据接口适配后用于 $\pi_{0.5}$ 微调，部署阶段由任务状态机提供动态低层语言指令，模型接收新观测并通过同一笛卡尔接口输出动作序列。由此，“VR 数采- $\pi_{0.5}$ 微调-OpenPI 推理-真机执行”的接口链路已经贯通并完成单回合功能验证，示范阶段与推理阶段共享机器人状态、动作定义和底层执行链路。




图 12: 将 PCBA 放置到百叶车任务的示例观测、右手轨迹与夹爪状态




图 13: 已贯通的 VR 数采- $\pi_{0.5}$ 微调-OpenPI 推理-真机执行接口链路

5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与真机闭环

在示范采集链路基础上，现有系统已完成 OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调、在线推理服务接入和真机动作序列执行。当前部署使用 OpenPI 公开的 $\pi_{0.5}$ 模型及流匹配动作头：模型接收头部与左右腕部图像、双臂本体状态和任务状态机提供的低层语言指令，生成连续动作序列，再由笛卡尔控制接口执行并在动作序列边界回传新观测。这里仅声称数据采集-微调-动作序列执行的软件与真机接口链路已经贯通；五子任务整链成功率、工位停靠误差敏感性和相对性能尚待 C0-C3 实验统计。

为说明当前实现所用模型的算法基础，原始 $\pi_{0.5}$ 在 π_0 连续动作生成框架的基础上引入异构协同训练与语义子任务预测，将长时程任务中的高层语义决策与低层动作序列生成组织在统一模型中，其结构及训练流程如图14所示^[11]。




图 14: $\pi_{0.5}$ 模型结构及两阶段训练流程^[11]

图14左侧为预训练阶段。模型以 SigLIP 视觉编码器和 Gemma 语言模型组成的预训练 VLM 为主干，将多模态网络数据、异构机器人数据和任务提示统一表示为序列，并同时学习语义子任务、离散动作、图像描述及目标框等输出。机器人动作在该阶段由 FAST 分词器压缩为离散词元，使动作预测能够与语言建模任务共同采用自回归的下一词元预测目标。图中右侧为后训练与推理阶段：预训练得到的 VLA 模型继续承担图像与语言理解，并在主干之外加入参数量较小的动作专家；动作专家接收连续动作的含噪中间状态，采用条件流匹配逐步生成连续动作序列。由此，模型既保留预训练阶段获得的视觉与语义能力，又能以非自回归方式输出适用于实时控制的连续动作。

在层级推理过程中，VLA 主干首先根据当前多视角观测和高层任务指令 g_t 自

回归生成语义子任务 $\widehat{\ell}_t$ ，例如将“整理卧室”转化为“拿起枕头”；随后，该子任务作为低层语言条件输入动作专家，后者由随机噪声生成长度为 H 的连续动作序列。原模型的联合分布可分解为

$$\pi_{\theta}(\mathbf{A}_t, \widehat{\ell}_t | \mathbf{z}_t, g_t) = \pi_{\theta}(\mathbf{A}_t | \mathbf{z}_t, \widehat{\ell}_t) \pi_{\theta}(\widehat{\ell}_t | \mathbf{z}_t, g_t), \quad (17)$$

其中， $\mathbf{z}_t$ 表示图像与机器人本体状态， g_t 表示原模型的高层任务指令。式(17)的第二项对应原模型的子任务预测，第一项对应动作专家的连续动作生成。上述异构预训练与高层子任务预测属于原始 $\pi_{0.5}$ 的模型能力。当前真机接口直接使用 OpenPI 公开模型及流匹配动作头，由外部任务状态机根据五个子任务直接提供动态低层语言指令 ℓ_t 。为与现有推理接口保持一致，时刻 t 的策略输入写为

$$\mathbf{o}_t = \{I_t^{\text{head}}, I_t^{\text{wrist}, L}, I_t^{\text{wrist}, R}, \mathbf{x}_t, \ell_t\}, \quad (18)$$

其中， ℓ_t 为运行时给定的动态任务语言指令。策略一次推理输出长度为 H 的动作序列：

$$\widehat{\mathbf{A}}_t = \pi_{\theta}(\mathbf{o}_t) = [\widehat{\mathbf{a}}_t, \widehat{\mathbf{a}}_{t+1}, \dots, \widehat{\mathbf{a}}_{t+H-1}]. \quad (19)$$

动作序列中的每个元素均按照前述双臂笛卡尔动作与夹爪指令接口解释。机器人执行其中时域为 s 的近期动作，且 $1 \leq s \leq H$ ；完成该段动作后，系统重新获取多视角图像和末端状态，并结合当前语言指令构造下一轮输入。该过程在动作序列边界形成“状态感知-策略推理-动作序列执行-状态更新”的视觉闭环，而每次提交的 s 个控制步在策略层面不接收新观测。现有部署中 s 为全任务统一的固定值，第3.4节将其改为按阶段取值并加入 RTC 衔接。

(1) **面向 $\pi_{0.5}$ 的模仿学习推导。** 将式(16)所示的专家示范按照长度为 H 的滑动窗口组织，可得动作序列示教数据集

$$\mathcal{D}_E = \left\{ \left(\mathbf{o}_t^{(n)}, \mathbf{A}_t^{\text{E}, (n)} \right) \right\}_{n,t}, \quad \mathbf{A}_t^{\text{E}} = [\mathbf{a}_t^{\text{E}}, \dots, \mathbf{a}_{t+H-1}^{\text{E}}]. \quad (20)$$

行为克隆的基本目标是在专家数据分布上最大化条件动作序列的对数似然，即

$$\theta_{\text{IL}} = \arg \min_{\theta} \mathcal{L}_{\text{IL}}(\theta), \quad \mathcal{L}_{\text{IL}}(\theta) = -\mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^{\text{E}}) \sim \mathcal{D}_E} [\log \pi_{\theta}(\mathbf{A}_t^{\text{E}} | \mathbf{o}_t)]. \quad (21)$$

该目标使策略分布逼近专家在给定多视角图像、机器人状态和语言指令条件下的动作分布；动作序列联合建模还保留了同一操作片段内各时刻动作之间的相关性。

$\pi_{0.5}$ 采用条件流匹配表示连续动作序列分布^[10,11]。对归一化后的专家动作序列 $\mathbf{A}_t^{\text{E}}$ ，采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $\tau \in [0, 1]$ ，构造从噪声到数据的线性概

率路径

$$\mathbf{A}_t^\tau = (1 - \tau)\boldsymbol{\epsilon} + \tau\mathbf{A}_t^E, \quad \mathbf{u}_t^\tau = \frac{\partial \mathbf{A}_t^\tau}{\partial \tau} = \mathbf{A}_t^E - \boldsymbol{\epsilon}. \quad (22)$$

设动作专家输出的条件向量场为 $\mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau)$ ，则模仿微调可写为条件流匹配损失

$$\mathcal{L}_{\text{FM}}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E, \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tau \sim p(\tau)} \left[\|\mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau) - (\mathbf{A}_t^E - \boldsymbol{\epsilon})\|_2^2 \right]. \quad (23)$$

最小化式(23)使网络学习式(22)的条件速度场。推理时从 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，沿

$$\frac{d\mathbf{A}_t^\tau}{d\tau} = \mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau) \quad (24)$$

由 $\tau = 0$ 正向积分至 $\tau = 1$ ，即可得到条件动作序列样本 $\hat{\mathbf{A}}_t = \mathbf{A}_t^1$ 。以步长 $\Delta\tau > 0$ 进行欧拉离散时，单步更新为

$$\mathbf{A}_t^{\tau+\Delta\tau} = \mathbf{A}_t^\tau + \Delta\tau \mathbf{v}_\theta(\mathbf{A}_t^\tau, \mathbf{o}_t, \tau). \quad (25)$$

因此，式(23)给出了示教动作对模型参数的监督关系，式(24)和式(25)则给出了从随机噪声生成连续动作序列的推理过程。

5.4 阶段性工作小结

本节明确了已完成工作与待开展研究的边界。已完成部分包括机器人平台与坐标接口、VR 遥操作和示范数据采集、OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调以及“状态感知–OpenPI 推理–动作序列执行–状态更新”的单回合接口功能验证；激光雷达定位与导航停靠作为平台既有能力可直接调用。尚未开展的部分对应本课题的三项方法：工位停靠误差尚未进入 $\pi_{0.5}$ 状态，示范仍在标称停靠下采集，执行时域仍为全任务固定值，推理侧尚未加入 RTC 连续衔接、相邻动作序列预测偏差检测和模板恢复。因尚无统一误差注入协议下的统计数据，本节不对现有接口链路声明整链成功率或性能优势。

6 进度安排

研究进度将从 2026 年 7 月进入课题时开始计算，至 2027 年 12 月完成论文与答辩准备。各阶段按照“时间段-主要任务-阶段产出”编排，并在后期预留补充实验、设备维护和论文修改时间。

表 3: 研究进度安排

时间	主要任务	阶段产出
2026.07–2026.08	梳理文献与现有平台接口，确定四工位五子任务链及完成、失败、超时与安全判据；制定随机停靠示范采集规范与误差注入协议，完成开题。	开题报告、任务规范与评价协议初稿。
2026.09–2026.10	实现导航指令、定位估计与独立参考误差的同步记录及工位标定接口，将误差增广状态接入 OpenPI $\pi_{0.5}$ 数据格式；布设各工位基准标记，完成头部相机-基座外参标定与参考测量的重复精度校验，并按规范采集随机停靠示范。	三类误差接口、测量校准记录、版本化示范数据及数据说明。
2026.11–2026.12	由同一预训练检查点完成误差补偿学习三组消融的微调；执行平移 0 至 5 厘米、航向 0 至 5° 的误差容忍曲线测试。	误差补偿学习实验数据、容忍曲线与消融结论。
2027.01–2027.03	实现阶段判定、分阶段动作序列执行与 RTC 连续衔接；完成固定时域对照实验与 C2 分阶段执行配置的容忍曲线测试，记录条件成功率与推理时延。	分阶段执行与 RTC 模块、固定时域对照及运行时统计。
2027.04–2027.06	在 OpenPI 推理侧实现相邻动作序列预测偏差监测和模板恢复；用成功回合标定阈值，先在记录的 C2 回合上离线评价检测器，再完成 C3 检测与恢复配置的在线恢复实验。	检测与恢复模块、召回率与误报率、提前量、最终成功率、安全事件与时延数据。
2027.07–2027.09	在四台机器人上补充完成各配置的整体验证实验，整理失败案例并分开报告源机器人和三台目标机器人。	整体验证数据、失败分类与方法适用边界。

续表 3

时间	主要任务	阶段产出
2027.10–2027.12	核对数据、代码和图表, 完成学位论文撰写、修改、送审与答辩准备。	学位论文定稿与答辩材料。

7 为完成课题所需的条件

本课题所需条件分为硬件与场景、算力、数据、软件四类, 如表4所示。已具备部分为第5节贯通的平台与流水线, 尚需补充部分按表3的阶段逐步完成。

表 4: 完成课题所需的条件

类别	已具备	尚需补充
硬件与场景	轮式双臂机器人(腰 4+ 双臂各 7+ 头 2 自由度, 配夹爪、头部与腕部相机、激光雷达导航); 真实 PCBA 四工位五子任务场景	工位基准标记与标定后的相机参考测量链路
算力	8 卡 A100 80G 服务器, 分配一张显卡, 满足 $\pi_{0.5}$ 微调需求。	无。
数据	标称停靠下的 VR 遥操作示范回合	随机停靠示范; 训练、验证、阈值标定与测试集划分; 失败时刻标注
软件	VR 遥操作与同步记录链路; OpenPI $\pi_{0.5}$ 微调与真机部署流水线; 导航栈与笛卡尔控制接口	停靠误差读取与状态增广接口; 分阶段执行与 RTC 衔接模块; 预测偏差量监测与模板恢复模块; 误差注入与统一日志评价工。

8 研究过程中可能遇到的问题以及解决的措施

三项方法分别依赖停靠误差估计、阶段判定和预测偏差量三种信号, 其有效性各自建立在一个可被实验推翻的假设之上; 整体验证又要求在示范来自单台机器人的条件下, 把方法效应与本体差异、数据覆盖等因素区分开。下面选取五个对研究结论影响最大的问题, 分别说明其成因、可能后果和应对思路。应对思路的共同原则是: 参数与阈值在测试之前确定, 达不到预设条件的项目报告为未通过。

8.1 停靠误差估计精度对误差输入的影响

误差补偿学习方法把定位系统给出的停靠误差估计 $\hat{\delta}_k^{\text{loc}}$ 作为状态输入，但该估计本身带有噪声与系统偏差，且真实误差在部署时不可直接获得。若估计误差与误差分档步长同量级，策略从误差输入中获得的信息会被噪声淹没，误差补偿方法相对于仅靠数据覆盖的消融 (b) 将难以体现优势；更严重的是，若训练阶段与部署阶段的误差来源不一致，策略学到的补偿关系在部署时不再成立。

应对思路建立在两点区分之上。其一，区分“策略输入”与“评价真值”。策略在训练与部署中始终使用同一来源的定位估计，因而输入通道在两个阶段的分布一致，策略学到的是对“该估计值”的补偿，而不是对不可得真值的补偿；估计噪声在训练数据中已经存在，其影响被一并学入。以头部相机对工位基准标记的独立测量则用作误差注入的参考值与实验归档，与策略输入相互独立。其二，量化噪声的量级并据此决定实验是否可行。停靠后静止采样多帧取均值以抑制随机噪声；在正式实验前，用基准标记测量对定位估计作重复精度与系统偏差评定，要求各轴的重复精度不超过对应分档步长的三分之一。达不到该条件的轴先改善标记尺寸、布设距离或相机-基座外参标定，仍不满足则暂缓该轴的容忍曲线实验并说明原因。

8.2 随机停靠示范的覆盖范围与外推行为

误差补偿学习方法在示范采集时按式(5)注入 ± 3 厘米与 $\pm 3^\circ$ 的随机误差，而容忍曲线的注入幅值最大到 5 厘米与 5° 。这里存在两个方向的问题。一方面，若自然停靠的误差分布超出训练覆盖，误差补偿方法的收益在实际部署条件下无从体现；另一方面，随机停靠使示范在相同回合数下更加分散，可能降低标称停靠条件下的成功率，即鲁棒性的提高以名义性能为代价，而这一代价若不被单独度量，会与方法收益混淆。

对第一个问题，采集随机停靠示范之前先在五个工位上多次自然停靠并用基准标记测量误差，以其分布确定覆盖范围是否足够； ± 3 厘米与 $\pm 3^\circ$ 是根据现有导航精度预设的范围，若实测分布更宽，则在追加采集阶段扩展范围并重新微调，扩展决定依据自然停靠测量。对第二个问题，消融设计本身提供了答案：固定停靠组 (a) 与随机停靠组 (b)、(c) 取相同回合数并在位置象限与航向正负方向上均衡采集，使三组之间只有停靠方式与误差输入两个变量；容忍曲线中零误差点的成功率直接给出名义性能的变化。若随机示范确实降低了名义成功率，将其作为方法代价与容忍边界 R_{80} 的收益一并报告。训练覆盖之外的 4 至 5 厘米注入点用于观察策略的外推退化速度，这一区间的结果用于刻画退化趋势。

8.3 阶段判定误差与执行时域下限的耦合

分阶段执行方法依据子任务标签和末端到操作目标的距离切换执行阶段。该距离在基座系中计算，而操作目标定义于工位系，两者之间的变换恰恰包含停靠误差；若误差估计有偏，进入与退出精细操作阶段的时刻会整体前移或后移。将精细操作阶段误判为自由空间阶段时，策略在接触对准区间以长时域开环执行，失去了缩短时域的意义；反向误判则使推理次数与时延上升，削弱自由空间段的效率收益。与此耦合的另一约束是，精细操作阶段的执行时域不能短于策略的推理延迟，否则 RTC^[49] 无法在前一动作序列耗尽前给出下一动作序列，机器人只能停顿等待。

应对思路分三步。首先，阶段判定采用任务标签与距离双重条件，并以进入阈值 d_{enter} 与退出阈值 d_{exit} 构成滞回区间，使判定对距离的小幅偏差不敏感；两个阈值由预试验中精细操作起止时刻对应的末端距离分布确定，且退出阈值留有超过最大误差幅值的裕量，即便误差估计有偏，也只会使精细操作阶段提前进入、延后退出，而不会在接触对准区间内误判为自由空间阶段。其次，在确定精细操作阶段执行时域之前先实测推理链路的延迟分布，取执行时域下限大于延迟的上分位数；若延迟接近所需时域，先通过异步推理、冻结已确定动作前缀与逐步差值向量化等手段优化推理链路，不在正式实验中放宽时域约束。最后，若预试验表明阶段判定的错误率仍不可接受，主实验改为全程短时域配置，此时 C2 相对于 C1 只保留 RTC 的贡献，分阶段时域记为未通过，其结果与原因一并报告。

8.4 平滑预测偏差与失败之间关系的成立条件

失败检测与恢复方法假设相邻动作序列在重叠区的分歧会先于失败增大。这一假设并非对所有失败模式都成立。一类反例是“自信的错误”：当停靠误差过大使策略进入一个看似熟悉、实则错误的状态时，新旧预测可能保持一致，策略稳定地执行错误动作直至卡滞，预测偏差量不会升高。另一类反例来自示范本身的多模态性：同一状态下若示范包含多种可接受的操作方式，相邻预测在两种方式之间切换会产生高分歧，但并不预示失败。前者造成漏报，后者造成误报，两者都会削弱检测器的实用价值。

应对思路首先在于阈值标定方式。按式(10)，阈值取成功回合平滑预测偏差全程最大值的 95 分位数，多模态引起的分歧在成功回合中已经出现并被计入阈值，因此由多模态造成的误报率在标定时即被控制在预设水平，而无需事先识别哪些状态是多模态的。其次在于评价方式。检测器先在记录的 C2 回合上离线回放，只产生报警而不改变动作，原始失败时刻仍可观察，因此可以按失败模式分别统计召回率与提前量：对于分歧先于失败的模式，检测器给出提前报警；对于“自信的

错误”，记为漏报，并分析该类失败在误差幅值上的分布。若某一失败模式的召回率显著偏低，考虑以子任务超时、夹爪状态异常等与策略无关的简单规则作为补充触发条件，补充规则的贡献单独统计。最后，阈值在检测评价前确定并冻结；检测器对各失败模式的有效范围作为实验结论给出。

8.5 单源示范下的跨本体差异与结果归因

示范只由一来源机器人采集，其余三台机器人不参与训练。四台机器人在关节零位、相机外参、夹爪磨损等方面存在差异，这些差异同时作用于三项方法：误差输入到末端补偿的映射、阶段判定所用的末端距离以及预测偏差量的基准分布都会随本体变化。若把四台机器人的回合混合统计，本体差异带来的成功率下降会被归因于方法，或者反过来掩盖方法的收益；若在目标机器人上按结果调整参数，则 C0 至 C3 的比较不再公平。

应对思路是把本体差异当作一个受控的实验因素而非噪声。实验前对四台机器人执行统一的标定流程与零位校验，并在标称停靠下运行同一 C0 策略，以其成功率作为各机器人的本体基线；所有结果按源机器人与三台目标机器人分组报告，各配置之间的比较只在同一机器人内进行，跨机器人的差异作为独立结论给出。对于平滑预测偏差阈值，允许每台机器人用自身的成功回合按同一标定规则确定阈值，这属于不使用失败标签的校准，与方法本身的规则一致；除此之外，主实验对目标机器人保持参数不变，按机器人微调策略作为主实验之后的补充实验单独报告。以回合为统计单位并为成功率附置信区间，以区分方法效应与有限回合数下的本体差异或随机波动。

9 参考文献

- [1] International Federation of Robotics. World Robotics 2025: Industrial Robots[R/OL]. Frankfurt am Main, Germany: IFR Statistical Department, 2025 [2026-09-02]. <https://ifr.org/worldrobotics/report-2025>.
- [2] 袁依格, 何卓丰, 李威, 等. 具身智能驱动的智能制造应用发展研究[J]. 中国工程科学, 2025, 27(3): 67-82. <http://dx.doi.org/10.15302/J-SSCAE-2025.04.016>.
- [3] Zhang C, Zhang C, Xu Z, et al. Embodied Intelligent Industrial Robotics: Framework and Techniques[J]. Journal of Manufacturing Systems, 2026, 88: 158-189. <http://dx.doi.org/10.1016/j.jmsy.2026.06.001>.
- [4] 郑南宁, 杨勐, 姜维周, 等. 具身智能发展趋势与展望[J]. 中国工程科学, 2026, 28(2): 1-13. <http://dx.doi.org/10.15302/J-SSCAE-2025.07.019>.
- [5] Firoozi R, Tucker J, Tian S, et al. Foundation Models in Robotics: Applications, Challenges, and the Future[J]. The International Journal of Robotics Research, 2025,

- 44(5): 701-739. <http://dx.doi.org/10.1177/02783649241281508>.
- [6] Brohan A, Brown N, Carbajal J, et al. RT-1: Robotics Transformer for Real-World Control at Scale: arXiv:2212.06817[R/OL]. Mountain View, California, USA: Google Research, 2022 [2026-09-02]. <https://arxiv.org/abs/2212.06817>.
 - [7] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2165-2183.
 - [8] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 6892-6903. <http://dx.doi.org/10.1109/ICRA57147.2024.10611477>.
 - [9] Kim M J, Pertsch K, Karamcheti S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[C] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024.
 - [10] Black K, Brown N, Driess D, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control[R/OL]. San Francisco, California, USA: Physical Intelligence, 2024 [2026-08-27]. <https://arxiv.org/abs/2410.24164>.
 - [11] Black K, Brown N, Darpinian J, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-25]. <https://www.pi.website/download/pi05.pdf>.
 - [12] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.016>.
 - [13] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[C] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024: 4066-4083.
 - [14] 兰沅卜, 赵文博, 朱凯, 等. 基于具身智能的移动操作机器人系统发展研究[J]. 中国工程科学, 2024, 26(1): 139-148. <http://dx.doi.org/10.15302/J-SSCAE-2024.01.010>.
 - [15] 国务院. 政府工作报告——2025 年 3 月 5 日在第十四届全国人民代表大会第三次会议上[R/OL]. 北京: 中华人民共和国国务院, 2025 [2026-09-02]. http://www.gov.cn/jq/202503/20250305_10149794900_1.htm.

//lianghui.people.com.cn/2025/n1/2025/0312/c460142-40437673.html.

- [16] Ren L, Dong J, Liu S, et al. Embodied Intelligence Toward Future Smart Manufacturing in the Era of AI Foundation Model[J]. IEEE/ASME Transactions on Mechatronics, 2025, 30(4): 2632-2642. <http://dx.doi.org/10.1109/TMECH.2024.3456250>.
- [17] Levine S, Wagener N, Abbeel P. Learning Contact-Rich Manipulation Skills with Guided Policy Search[C] // 2015 IEEE International Conference on Robotics and Automation (ICRA). 2015: 156-163. <http://dx.doi.org/10.1109/ICRA.2015.7138994>.
- [18] Inoue T, Magistris G D, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C] // 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2017: 819-825. <http://dx.doi.org/10.1109/IROS.2017.8202244>.
- [19] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C] // 2019 International Conference on Robotics and Automation (ICRA). 2019: 6023-6029. <http://dx.doi.org/10.1109/ICRA.2019.8794127>.
- [20] Elguea-Aguinaco Í, Serrano-Muñoz A, Chrysostomou D, et al. A Review on Reinforcement Learning for Contact-Rich Robotic Manipulation Tasks[J]. Robotics and Computer-Integrated Manufacturing, 2023, 81: 102517. <http://dx.doi.org/10.1016/j.rcim.2022.102517>.
- [21] Yang C, Zeng C, Cong Y, et al. A Learning Framework of Adaptive Manipulative Skills from Human to Robot[J]. IEEE Transactions on Industrial Informatics, 2019, 15(2): 1153-1161. <http://dx.doi.org/10.1109/TII.2018.2826064>.
- [22] Qin F, Xu D, Zhang D, et al. Robotic Skill Learning for Precision Assembly with Microscopic Vision and Force Feedback[J]. IEEE/ASME Transactions on Mechatronics, 2019, 24(3): 1117-1128. <http://dx.doi.org/10.1109/TMECH.2019.2909081>.
- [23] Zang Y, Wang P, Zha F, et al. Peg-in-Hole Assembly Skill Imitation Learning Method Based on ProMPs under Task Geometric Representation[J]. Frontiers in Neurorobotics, 2023, 17: 1320251. <http://dx.doi.org/10.3389/fnbot.2023.1320251>.
- [24] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation[C] // Proceedings of Machine Learning Research, Vol 164: Proceedings of the 5th Conference on Robot Learning. [S.l.]: PMLR, 2022: 1678-1690.
- [25] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.37554/2023.9.1>.

15607/RSS.2023.XIX.026.

- [26] Ze Y, Zhang G, Zhang K, et al. 3D Diffusion Policy: Generalizable Visuomotor Policy Learning via Simple 3D Representations[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.067>.
- [27] Wang C, Fang H, Fang H-S, et al. RISE: 3D Perception Makes Real-World Robot Imitation Simple and Effective[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 2870-2877. <http://dx.doi.org/10.1109/IROS58592.2024.10801678>.
- [28] Shi L X, Sharma A, Zhao T Z, et al. Waypoint-Based Imitation Learning for Robotic Manipulation[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2195-2209.
- [29] Octo Model Team, Ghosh D, Walke H, et al. Octo: An Open-Source Generalist Robot Policy[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.090>.
- [30] Khazatsky A, Pertsch K, Nair S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.120>.
- [31] Liu S, Wu L, Li B, et al. RDT-1B: A Diffusion Foundation Model for Bimanual Manipulation[C] // The Thirteenth International Conference on Learning Representations (ICLR). 2025.
- [32] Wen J, Zhu Y, Li J, et al. TinyVLA: Toward Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation[J]. IEEE Robotics and Automation Letters, 2025, 10(4): 3988-3995. <http://dx.doi.org/10.1109/LRA.2025.3544909>.
- [33] Liu J, Liu M, Wang Z, et al. RoboMamba: Efficient Vision-Language-Action Model for Robotic Reasoning and Manipulation[C] // Advances in Neural Information Processing Systems 37 (NeurIPS). 2024.
- [34] Bu Q, Yang Y, Cai J, et al. UniVLA: Learning to Act Anywhere with Task-centric Latent Actions[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.014>.
- [35] Pertsch K, Stachowicz K, Ichter B, et al. FAST: Efficient Action Tokenization for Vision-Language-Action Models[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-27]. <https://arxiv.org/abs/2501.09747>.
- [36] Tang B, Lin M A, Akinola I, et al. IndustReal: Transferring Contact-Rich Assembly

- Tasks from Simulation to Reality[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.039>.
- [37] Soti G, Huang X, Wurll C, et al. Train What You Know – Precise Pick-and-Place with Transporter Networks[C] // 2023 IEEE International Conference on Robotics and Automation (ICRA). 2023: 5814-5820. <http://dx.doi.org/10.1109/ICRA48891.2023.10161242>.
- [38] Xia F, Li C, Martín-Martín R, et al. ReLMoGen: Leveraging Motion Generation in Reinforcement Learning for Mobile Manipulation[C] // 2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 4583-4590. <http://dx.doi.org/10.1109/ICRA48506.2021.9561315>.
- [39] Honerkamp D, Welschehold T, Valada A. N²M²: Learning Navigation for Arbitrary Mobile Manipulation Motions in Unseen and Dynamic Environments[J]. IEEE Transactions on Robotics, 2023, 39(5): 3601-3619. <http://dx.doi.org/10.1109/TRO.2023.3284346>.
- [40] Yang T, Jing Y, Wu H, et al. MOMA-Force: Visual-Force Imitation for Real-World Mobile Manipulation[C] // 2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2023: 6847-6852. <http://dx.doi.org/10.1109/IROS55552.2023.10342371>.
- [41] Qiu R-Z, Song Y, Peng X, et al. WildLMA: Long Horizon Loco-Manipulation in the Wild[C] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 10011-10019. <http://dx.doi.org/10.1109/ICRA55743.2025.11128535>.
- [42] Mandlekar A, Garrett C, Xu D, et al. Human-in-the-Loop Task and Motion Planning for Imitation Learning[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 3030-3060.
- [43] Ishida Y, Noguchi Y, Kanai T, et al. Robust Imitation Learning for Mobile Manipulator Focusing on Task-Related Viewpoints and Regions[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024.
- [44] Pumacay W, Singh I, Duan J, et al. THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation[C] // Proceedings of Robotics: Science and Systems. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.133>.
- [45] Jin S, Wang R, Zahid M, et al. How Physics and Background Attributes Impact Video

- Transformers in Robotic Manipulation: A Case Study on Planar Pushing[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 7391-7398. <http://dx.doi.org/10.1109/IROS58592.2024.10802583>.
- [46] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[C] // 2018 IEEE International Conference on Robotics and Automation (ICRA). 2018: 3803-3810. <http://dx.doi.org/10.1109/ICRA.2018.8460528>.
- [47] Mees O, Hermann L, Rosete-Beas E, et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334. <http://dx.doi.org/10.1109/LRA.2022.3180108>.
- [48] Liu B, Zhu Y, Gao C, et al. LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning[C] // Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track (NeurIPS). 2023.
- [49] Black K, Galliker M Y, Levine S. Real-Time Execution of Action Chunking Flow Policies[C] // Advances in Neural Information Processing Systems 38 (NeurIPS). 2025. <http://dx.doi.org/10.52202/085713-1122>.
- [50] Kim M J, Finn C, Liang P. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.017>.
- [51] Xu C, Nguyen T K, Dixon E, et al. Can We Detect Failures Without Failure Data? Uncertainty-Aware Runtime Failure Detection for Imitation Learning Policies[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.073>.
- [52] Liu H, Dass S, Martín-Martín R, et al. Model-Based Runtime Monitoring with Interactive Imitation Learning[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 4154-4161. <http://dx.doi.org/10.1109/ICRA57147.2024.10611038>.
- [53] Dai Y, Lee J, Fazeli N, et al. RACER: Rich Language-Guided Failure Recovery Policies for Imitation Learning[C] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025. <http://dx.doi.org/10.1109/ICRA55743.2025.11127799>.

- [54] Liu Z, Bahety A, Song S. REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023.