

哈尔滨工业大学

硕士学位论文开题报告

题 目：面向 **PCBA** 上下料的轮式双臂模仿学习策略
鲁棒性改进研究
(学位论文)

学 院 (部) 航天学院

学科/专业学位类别 机械

导 师 刘延芳研究员

研 究 生 聂靖轩

学 号 25S118238

开题报告日期 2026 年 9 月

研究生院制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源与研究背景	1
1.2 研究目的与意义	5
2 国内外研究现状及分析	7
2.1 国内外工业具身机器人研究现状	7
2.2 国内外 VLA 模型研究现状	9
2.3 国内外 VLA 模仿学习策略鲁棒性改进研究现状	11
2.4 国内外研究现状简析	14
3 主要内容及方案	15
3.1 总体技术路线	15
3.2 任务定义与工位停靠误差传递问题	17
3.3 基于 $\pi_{0.5}$ 的 VLA 策略与动作序列建模	18
3.4 基于停靠误差融合输入的泛化训练方法	21
3.5 基于增广状态输入的风险判别模型	24
3.6 基于在线风险预测的动作序列调度方法	27
3.7 整体验证方案	29
3.8 可行性分析	30
4 预期达到的目标	30
5 已完成的学术研究/实践工作	31
5.1 实验平台与坐标系定义	31
5.2 基于 VR 遥操作的示范数据采集	32
5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与实体机器人闭环执行	33
5.4 阶段性工作小结	37
6 进度安排	38
7 为完成课题所需的条件	39
8 研究过程中可能遇到的问题以及解决的措施	39
9 参考文献	40

1 课题来源及研究的目的和意义

1.1 课题来源与研究背景

工业机器人是面向工业环境设计、可自动控制、可重复编程的多关节机械装置，凭借高精度、高节拍和长时间稳定运行的优势，长期承担焊接、喷涂、搬运、装配等重复性作业，是制造业自动化的核心装备。国际机器人联合会（International Federation of Robotics, IFR）发布的 2025 年世界机器人报告显示，2024 年全球工业机器人新装机量达 54.2 万台，较十年前增长一倍以上，全球在役存量达 466 万台；其中中国新装机 29.5 万台，占全球的 54%，在役存量超过 200 万台，连续多年保持全球最大的工业机器人市场^[1]。电子电气行业是工业机器人的主要应用行业之一，电路板组件的上下料、插件与检测等环节存在由机器人替代工作人员完成相关操作的持续需求。然而，传统工业机器人依赖示教编程或离线编程，在结构化环境中沿预设轨迹重复运动，其可靠性建立在工件位姿、夹具和工艺流程高度固定的前提之上^[2,3]。当生产线面临多品种、小批量、快速换型的需求，或工件位置、来料状态存在不确定性时，机器人需要重新示教、重新标定甚至重新设计工装，部署周期与成本显著上升；固定安装的机器人还需要依靠传送带或专用输送设备衔接不同工位，难以独立承担跨工位的物料流转任务。图1从焊接、汽车装配、码垛和电子制造四类作业展示了工业机器人的应用广度。这些系统虽然末端工具和工艺对象不同，但通常都通过固定工位、专用工装与预先编程来保证稳定性。

与传统工业机器人依赖精确编程不同，具身智能（Embodied Intelligence）强调智能体通过物理载体与环境动态交互，并在感知、决策与行动的闭环中提高环境适应性与泛化能力，从而缓解仅依赖静态离线数据训练所导致的适应性限制^[4]。近年来，在互联网规模数据上预训练的大语言模型与视觉-语言模型（Vision-Language Model, VLM）展现出开放词汇视觉识别、常识推理与任务规划能力，推动机器人基础模型成为具身智能的重要技术基础^[5]。在操作技能层面，RT-1 与 RT-2 将 Transformer 架构和从互联网规模数据中学习的视觉-语言知识引入实体机器人控制，使机器人能够从大规模示范数据中学习语言条件下的操作技能^[6,7]；Open X-Embodiment 汇集跨本体、跨机构的机器人数据，验证了跨机器人数据的正向迁移^[8]；视觉-语言-动作（Vision-Language-Action, VLA）模型以预训练 VLM 为主干网络、以动作专家生成连续动作，在开放环境中对新物体、新场景与新指令表现出泛化能力^[9-11]。与此同时，低成本遥操作与动作分块模仿学习使双臂精细操作策略能够利用数十至数百条人类示范完成训练^[12,13]；移动操作机器人因兼具移动、规划与操作能力，成为较适合具身智能任务的机器人平台形态^[14]。具身智能机器人由此呈现出与传统工业机器人不同的系统架构：通过数据驱动策略降低对逐点




(a) 机器人焊接



(b) 汽车车身装配



(c) 食品箱码垛




(d) 印制电路板元器件贴装

图 1: 工业机器人的典型应用场景

示教和完全结构化环境的依赖，并在闭环感知中生成动作。图2展示了人形、四足、轮式移动操作和轮式双臂四类本体。它们的自由度、可达空间和运动方式存在明显差异，说明具身智能并不对应单一外形；其共同特征是将感知、策略以及能够与物理环境交互的机器人机体和执行机构统一在交互闭环中。

将具身智能引入工业制造，使机器人在生产线上具备自主感知、决策与操作能力，正在成为工业机器人技术演进的新方向。2025 年《政府工作报告》首次将具身智能列为国家重点培育的未来产业^[15]；智能制造也正经历从基于规则的自动化制造、数据驱动的数字化智能制造向具身智能支持的智能制造演进，具身智能有望提高生产制造、仓储物流、检测维护和人机协作等环节的自主性^[2,16]。然而，工业场景通常以作业节拍、定位与操作误差、任务成功率和安全事件数约束机器人作业，对具身智能提出了不同于开放家庭场景的挑战^[3]：操作对象往往是对准公差小、失效代价高的精密工件，生产线对节拍与合格率有明确约束，策略还须在多台机器人之间稳定部署。在前期调试中，本课题多次观察到移动底盘停靠偏差引起的精细操作失效，而现有标称停靠示范不覆盖这类状态。如何在固定的印制电路板组件（Printed Circuit Board Assembly, PCBA）型号、来料位姿、工装几何与光照等环境条件下，量化并提高策略对工位停靠误差的容忍能力，是本课题的研究



(a) 人形机器人



(b) 四足机器人



(c) 轮式移动操作机器人



(d) 轮式双臂机器人


图 2: 具身智能可采用的不同机器人本体

出发点。图3从机床上下料、厂内物流、在线质量监测和协作机器人作业四个环节展示了具身智能可能进入的制造流程。四类环节分别强调精密操作、跨工位移动、过程感知与安全协作，因而需要将自主策略与现有工艺节拍、质量标准和安全边界同时纳入系统设计。

本课题面向的 **PCBA** 检测工位上下料是此类任务的典型实例，也是电子制造生产线中重复性高、节拍受限的环节。一次完整的上下料由四个物理工位上的五个操作子任务组成：从上料百叶车夹取待测 **PCBA**、移动至编码扫描工位完成编码登记、从检测台取出已完成检测的上一块 **PCBA**、将当前 **PCBA** 放入检测台、最后将上一块 **PCBA** 放入下料百叶车；检测台的取出与放入共用一次停靠。工位间移动由导航系统完成，不计入 **VLA** 动作阶段；**PCBA** 在百叶车料槽中的插入与取出、在检测台上的放置与取出等接触对准操作属于精细操作阶段，机械臂在工位内的接近、搬运与撤离属于自由空间阶段。本课题所用轮式双臂机器人由移动底盘、四自由度腰部、两条七自由度机械臂、二自由度头部与末端夹爪组成，配置头部相机和左右腕部相机，并由激光雷达定位与基于地图的经典导航方法实现在工位间的移动。前期观测表明实际停靠同时存在厘米量级的位置误差和数度量级的航向误差，其统计分布及对操作成功率的影响将在正式实验中按统一协议测量。



(a) 机床上下料



(b) 厂内物流



(c) 焊接过程在线质量监测



(d) 协作机器人生产线作业

图 3: 具身智能在工业制造中的典型应用环节

面向这类多阶段双臂任务，以遥操作示范驱动的模仿学习已成为常用策略学习方法之一。动作分块 Transformer（Action Chunking with Transformers, ACT）通过一次预测一段动作序列，提出了降低长时序行为克隆有效决策时域的动作分块思想^[12]；流匹配 VLA 模型进一步继承连续动作序列表示，并借助预训练视觉语言表征支持多任务与语言条件控制^[10,11]。本课题已在上述平台上建立“虚拟现实（Virtual Reality, VR）遥操作数据采集-基于 OpenPI 的 $\pi_{0.5}$ 微调-实体机器人执行”的模型训练与部署流程，并已在标称停靠位姿下完成观测、策略推理、动作执行和新观测反馈的闭环控制流程集成及单回合功能验证。ACT 为动作分块策略提供了方法基础，本研究以 $\pi_{0.5}$ 模型为基础研究工位停靠误差问题。前期调试已经观察到停靠偏差条件下 PCBA 插入料槽与放置于检测台时的失败及机械挤压风险，但失败概率随误差的变化仍需按预设误差水平开展重复试验并进行量化分析。

本研究将该现象归纳为一条误差传递链，如图4所示。首先，导航停靠产生平面位置与航向误差；其次，位置误差近似等幅改变目标相对位置，航向误差则经目标到基座的距离转化为横向误差，两者在 PCBA 插入料槽、放置于检测台限位等精细操作阶段与装配公差处于同一量级；最后，系统虽在动作序列重规划边界形成视觉闭环，但一次提交的 s 个控制步在策略层面开环执行，其间的新观测不进入

策略，错误动作因而可能持续至下一次重规划。该链条上的三个环节对应三类部署问题：状态输入缺少工位相对位姿信息、运行时缺少执行风险预测与停止机制、固定执行时域难以兼顾成功率与效率。




图 4: PCBA 上下料任务中的模仿学习策略闭环与工位停靠误差传递链

针对上述三个环节，本课题拟研究基于工位停靠误差传递链的分层鲁棒增强框架。该框架由基于停靠误差融合输入的泛化训练方法、基于增广状态输入的风险判别模型和基于在线风险预测的动作序列调度方法构成：停靠误差融合训练方法在训练阶段将腕部局部视觉估计的停靠误差作为 $\pi_{0.5}$ 的显式误差输入，并通过随机停靠示范扩展训练数据对停靠误差取值空间的覆盖范围；风险判别方法在冻结的 $\pi_{0.5}$ 之上训练轻量风险判别模型，在动作序列下发前预测其执行风险，风险过大时提前停止以防止碰撞；风险驱动调度方法以在线风险分数动态调节每次推理后实际执行的步数，并以实时动作分块（Real-Time Chunking, RTC）连续衔接相邻动作序列，探索在兼顾成功率的前提下提高效率的可能性。三项方法均拟在保持策略网络主体结构的基础上开展，分别作用于数据与状态、运行时监控和推理执行，可依次叠加并在同一误差注入协议下比较。上述研究问题源于前期实体机器人试验中观察到的停靠偏差与操作失败现象，其影响机制和改进效果仍需系统研究。

1.2 研究目的与意义

本研究面向 PCBA 上下料这一跨多工位、含精细对准阶段的轮式双臂任务，拟研究停靠偏差对模仿学习策略成功率与执行效率的影响，沿“停靠误差-精细操作

阶段显现“碰撞失败或保守低效”的传递链，探索误差表征、风险预测与动作序列调度相结合的鲁棒性改进方法。本课题以 OpenPI 的 $\pi_{0.5}$ 为统一研究对象，具体研究目的包括以下三个方面。

1. 基于停靠误差融合输入的泛化训练方法：研究随机停靠示范与显式停靠误差输入对策略泛化能力的作用，探索如何利用作业前局部视觉观测补充工位相对位姿信息，并区分示范覆盖范围与误差表征的贡献。
2. 基于增广状态输入的风险判别模型：研究观测特征、动作序列与停靠误差等信息对失败风险的表征能力，探索在动作序列下发前识别危险趋势的方法，分析误报、漏报与预警提前量之间的关系，以及提前停止对碰撞与损坏的抑制作用。
3. 基于在线风险预测的动作序列调度方法：研究在线风险与实际执行步数之间的关系，结合 RTC 探索相邻动作序列的连续衔接，分析观测更新频率、任务成功率与执行效率之间的权衡。

图5给出了本课题的研究路径。前期平台与策略功能验证提供实验基础，实体机器人上的失败观察引出停靠误差传递问题，三项研究分别围绕偏差适应、风险预警与效率权衡展开。拟通过统一误差条件下的对照与消融实验考察各项方法的作用，再逐步结合三项方法分析其相互影响与适用边界。




图 5: 停靠误差问题驱动的鲁棒性改进研究路径

本研究的应用意义在于，为含精细对准阶段的移动操作任务提供应对停靠偏差的研究依据。通过分析停靠误差对操作失败的影响，探索策略适应、风险预警和执行调度的共同作用，有望减少碰撞、工件损坏与人工接管，并缓解保守执行带来的效率损失。相关结论拟在相同 PCBA 型号和工装条件下的四台机器人上检验，为同类任务的后续研究提供参考。

本研究的方法意义在于，将模仿学习策略在停靠扰动下的鲁棒性问题分解为三个相互关联的研究问题：显式误差表征能否改善策略泛化，增广状态能否支持失败前的风险识别，以及风险信息能否支持成功率与效率的合理权衡。以 $\pi_{0.5}$ 为共同研究对象，有助于在一致的策略基础上分析各项方法的贡献及其依赖关系；方法的有效性与适用范围需由后续实验确定。

综上，本课题的研究必要性源于模仿学习策略由实验室标称工况向实际生产线部署迁移时，对工位停靠误差、运行时失败风险和执行效率三方面缺乏系统处理的现状。为明确相关问题的已有解决路径与适用边界，后续按研究对象与方法类型对国内外相关研究进行梳理与评述。

2 国内外研究现状及分析

本节按“研究对象-策略模型-部署鲁棒性”的顺序梳理相关工作：首先考察工业具身机器人的研究与应用现状，明确其对策略学习方法提出的要求；其次考察 VLA 模型如何回应这些要求，以及通用模型经任务微调后遗留的部署问题；最后针对遗留问题梳理 VLA 模仿学习策略鲁棒性改进研究，并指出与本课题误差传递链对应的空白。三部分之间为递进关系，后者以前者的未解问题为出发点。

2.1 国内外工业具身机器人研究现状

工业具身机器人是将具身智能的感知-决策-行动闭环引入工业作业的机器人系统，其与传统工业机器人的核心区别在于以数据驱动策略取代逐点示教与固定工装，从而应对多品种、短周期和非完全结构化的生产线环境^[3,16]。袁依格等将制造业中的具身智能应用归纳为生产制造、仓储物流、检测维护和人机协作四类环节，并指出精密操作与跨工位移动是其中对策略可靠性要求最高的两类任务^[2]；兰泮卜等则从系统角度指出移动操作机器人兼具移动、规划与操作能力，是工业具身智能常用的机器人平台^[14]。这一定位意味着工业具身机器人的策略需要同时处理跨工位移动带来的位姿变化和工位上的精细操作。

面向工业操作的学习方法最早集中于接触密集型（contact-rich）装配任务。Levine 等以引导策略搜索将局部轨迹优化的结果蒸馏为神经网络策略^[17]；Inoue 等在高精度轴孔装配中用深度强化学习搜索与插入动作^[18]；残差强化学习保留既有控制器，仅学习基础控制之外的修正量^[19]。国内近期工作沿同一思路推进：Ding 等提出以人类示范引导的集成强化学习框架完成高精度轴孔装配^[20]，Su 等在受限区域内结合示范强化学习与变导纳控制完成装配^[21]。IndustReal 在仿真中训练取放与插装策略并迁移至实体工业机械臂，为此专门设计了几何奖励、采样课程和部署端动作积分器^[22]。对接触密集型操作的综述指出，样本效率、奖励建模、仿真到实体机器人迁移与安全约束是这类方法进入生产线的主要障碍^[23]。上述工


作面向固定工位上的单一装配动作，策略高度依赖特定工件、工装和坐标系，工序更换即需重新设计奖励或重新训练，难以覆盖跨工位、多子任务的生产线流程。

基于示范的方法降低了对奖励设计与实体机器人在线试验的依赖。早期工作将装配任务分解为接近、搜索、对准和插入等阶段，再以动态或概率运动原语表示各阶段轨迹分布^[24-26]；Sóti 等针对精密抓放改进 Transporter 网络的平移与旋转精度，并以由粗到细的迭代推理在实体插块任务上验证，说明毫米级放置偏差即决定任务成败^[27]。这些方法在小样本条件下具有较高的数据效率，中间变量也便于解释，但依赖人工分段与任务坐标系先验，同样难以复用到对象和指令持续变化的任务。RoboMimic 基准对不同质量的人类示范与多类离线学习算法进行了系统比较，表明观测空间、历史信息与示范质量都会显著影响策略性能^[28]，端到端行为克隆由此成为示范驱动路线的主流。

在移动操作层面，Mobile ALOHA 将双臂系统安装在移动底盘上，以全身遥操作同步采集底盘与双臂示范，并表明与静态数据协同训练可显著提高移动任务的数据效率，但其移动与操作由同一策略端到端输出，未显式处理停靠误差^[13]。ReLMoGen 使学习策略仅预测子目标，并由经典运动生成器生成到达轨迹^[29]；N²M² 在给定末端轨迹的条件下学习底盘与躯干运动，使机器人在未知环境中保持末端可达^[30]；MOMA-Force 在实体移动操作接触任务中同时模仿动作与目标力，由导纳控制器补偿底盘停靠偏差造成的末端接触误差^[31]；WildLMa 以全身控制器为底层、示范技能为中层、大语言模型组合技能为高层完成长时序移动操作^[32]。这些工作将底盘运动纳入学习或规划范围，但均以底盘持续运动或力觉补偿为前提，与生产线上“停靠后锁定底盘、仅由双臂操作”的流程不同。

国内已有工业具身机器人规模化应用于生产线的案例。据公开报道，智元机器人的轮式双臂机器人精灵 G2 自 2024 年 12 月起在龙旗科技南昌平板电脑制造工厂开展上下料连续运行可靠性测试与生产环境适配，随后并入实际生产线承担测试工序：机器人从流水线传送带抓取组装完成的平板电脑，转动腰部将其放入身后的测试柜，完成多媒体界面、音频、辐射杂散发射和耦合等检测后按相反顺序取出并送回生产线，单件流程约 20 秒，并与工厂制造执行系统（Manufacturing Execution System, MES）及测试设备实时互通；2026 年 4 月的 8 小时公开直播中完成 2283 次任务且无失败，同年 6 月部署规模由 4 台增至 8 台，6 天内完成检测 17 625 件，作业成功率达 99.99%^[33,34]。图6展示了该案例中的检测工位操作与多机并线作业场景。龙旗方面指出，传统自动化设备刚性、换型周期长，难以适配多品类平板电脑混线检测，而具身机器人无需定制专用工装即可承接多道差异化工序，场景标定最快约 15 分钟完成；智元方面则承认当前作业效率与人工操作效

率基本相当、整机成本偏高，且并线过程中暴露的问题需要联合团队逐一解决^[34]。智元同期开源了 AgiBot World 大规模双臂操作数据集及在其上预训练的通用策略 GO-1^[35]，但生产线部署所用策略的训练与适配细节未见公开；该案例支持如下判断：预训练通用策略经生产线数据适配后进入计算机、通信和消费电子（3C）精密制造工序已具备可行性。



(a) 检测工位操作

(b) 多机并线作业

图 6: 智元精灵 G2 在龙旗科技平板电脑生产线的作业场景^[33,34]

该案例对本课题的意义体现在两方面。一方面，它表明工业具身机器人的竞争力并非仅体现为单点精度，还体现为通用策略经少量示范微调后覆盖多道工序的柔性。这要求策略模型具备语言条件、多任务与跨场景迁移能力，而前述强化学习装配与任务专用示范方法尚难满足该要求。另一方面，公开报道中的机器人在单一站位对传送带和测试柜执行操作，其适应位置偏差和生产线扰动的实现方式并未披露；本课题的 PCBA 上下料则需在四个物理工位间导航停靠，每次停靠都引入新的位姿偏差，因而鲁棒性问题更为突出。因此，工业具身机器人研究向策略学习提出的核心问题是：如何获得一种从示范中学习、可跨工序复用，并在生产线位姿偏差下保持可靠的操作策略。前述通用性问题由 VLA 模型研究回应，后述部署鲁棒性问题则构成本课题的研究对象。

2.2 国内外 VLA 模型研究现状

为实现从任务专用模仿学习向跨任务通用策略演进，策略学习方法已由任务专用的动作分块模仿学习发展至语言条件通用模型。ACT 用条件变分自编码器概括示范动作的多模态分布，并以 Transformer 在时刻 t 一次预测长度为 H 的动作序列^[12]：

$$\mathbf{A}_t = [\mathbf{a}_t, \dots, \mathbf{a}_{t+H-1}]. \quad (1)$$

动作序列联合预测将逐步决策转化为块级决策，缩短了长时序行为克隆的有效决策时域，使多阶段双臂操作策略能够利用数十条低成本遥操作示范完成训练。ACT

执行时对多次推理中指向同一目标时刻的重叠预测作指数加权的时序集成以降低抖动,说明执行时域决定新观测进入控制回路的频率,而重叠预测包含可用于判断相邻动作序列连续性的信息。扩散策略将动作序列建模为条件去噪过程,以滚动时域方式执行预测序列的近期部分后重新规划^[36],其结构如图7所示;三维(three-dimensional, 3D)扩散策略与 RISE 以点云替代图像提高了对视角与外观变化的鲁棒性^[37,38],航点式模仿学习自动抽取关键路点以缩短决策时域^[39]。这类策略为每个任务单独采集示范、单独训练,不含语言条件与预训练表征,示范需求随工序数量线性增长,无法满足生产线多工序复用的要求。




图 7: 扩散视觉动作策略：基于观测的动作序列生成框架^[36]

VLA 模型在上述视觉动作策略基础上引入语言条件与视觉语言预训练知识,使一个模型能够处理多任务与语言指令,并显著减少下游任务微调所需的示范量。国外研究起步较早: RT-1 以 Transformer 在大规模实体机器人数据上学习语言条件策略^[6], RT-2 将视觉语言模型直接微调为动作输出模型,将互联网知识迁移到机器人控制^[7]; Open X-Embodiment 聚合多机构、多本体数据训练 RT-X 模型^[8], Octo 与 OpenVLA 在其上分别以扩散动作预测头和离散动作词元建立开源通用策略^[9,40], DROID 提供了跨场景、跨操作者的大规模实体机器人示范^[41]。国内研究主要集中于双臂操作、部署效率与数据规模: RDT-1B 采用扩散 Transformer 与统一动作空间学习双臂表示^[42]; TinyVLA、RoboMamba 与 UniVLA 分别从轻量级骨干网络、高效序列建模和任务中心潜在动作方面降低训练与推理成本^[43-45]; 智元发布的 AgiBot World 以百余台同构双臂机器人采集逾百万条轨迹,并以潜在动作预训练通用策略 GO-1,在实体机器人长时序任务上超越 RDT-1B^[35],为前述生产线应用提供了数据与模型基础。

在动作表示方面, Physical Intelligence 提出的 π_0 将预训练视觉语言模型与独立的动作专家结合,动作专家以流匹配目标生成连续动作序列,从而在保留语义表征的同时适配高频连续控制;其训练区分覆盖多任务、多本体数据的预训练与面向

下游技能的后训练^[10]。 π_0 -FAST 采用频域动作序列标记化（Frequency-space Action Sequence Tokenization, FAST）将高频连续轨迹压缩为离散动作标记，以自回归方式提高大规模训练效率^[46]。 $\pi_{0.5}$ 整合两条路线：预训练阶段采用 FAST 离散标记，使机器人动作数据能与图像-文本数据、目标检测和高层语义预测等异构任务共同训练；后训练阶段加入流匹配动作专家，以连续动作序列支持实时控制；推理时先根据观测与总体指令预测语言形式的高层子任务，再以其为条件生成低层动作，从而将高层语义子任务预测与低层动作生成纳入同一模型^[11]。OpenVLA-OFT 系统比较了 VLA 微调中的动作解码方式、动作表示与学习目标，表明并行解码、连续动作与回归目标的组合在成功率与动作吞吐率上均优于自回归离散方案^[47]。由此， π 系列形成“ π_0 建立流匹配动作专家- π_0 -FAST 提高训练效率- $\pi_{0.5}$ 通过异构协同训练以及高层语义子任务预测与低层动作生成的统一推理扩展开放环境泛化”的演进路径，也是本课题选择 $\pi_{0.5}$ 作为统一实验模型的依据。

VLA 模型在一定程度上满足了工业具身机器人对“通用策略经少量示范微调后跨工序复用”的需求，但并未改变微调后策略的本质：它仍是以行为克隆目标在有限示范上拟合的模仿学习策略，其动作输出仍以固定长度的动作序列在策略层面开环执行。由此遗留三个部署问题。第一，预训练带来的泛化主要体现在物体与场景语义层面，对示范分布之外的本体-工位相对位姿扰动缺乏保证，而生产线停靠误差属于此类扰动。第二，模型未包含对动作序列执行风险或失败状态的在线预测机制，偏差超出纠正能力后错误动作会持续至碰撞或任务终止。第三， $\pi_{0.5}$ 等模型将动作序列长度与执行时域作为固定超参数，为容忍偏差而全程采用短执行时域会增加推理次数、降低效率，而长执行时域又延长开环执行区间。这三个问题分别对应本课题误差传递链的三个环节，也是下一小节梳理鲁棒性改进研究的线索。

2.3 国内外 VLA 模仿学习策略鲁棒性改进研究现状

围绕上述三个遗留问题，本小节按误差传递链的顺序梳理鲁棒性改进研究：位姿扰动下的分布偏移处理面向误差源头，运行时失败预测与安全停止面向偏差显现为失败的环节，动作序列执行时域与效率面向成功率与效率的权衡环节。三类研究同样构成递进关系：前者不能完全消除的残余误差由后者处理。

（1）位姿扰动下的分布偏移处理。模仿学习策略对训练分布之外的观测缺乏保证，位姿扰动是工业部署中常见的分布偏移来源。Pumacay 等提出的 THE COLOSSEUM 基准将对象位姿、相机位姿、光照、背景、干扰物与物理参数等扰动轴分离，逐轴报告策略性能随扰动强度的退化曲线，从而将“泛化能力”转化为可分级度量的指标^[48]，其组织方式如图8所示。Jin 等的案例分析表明视觉策略

可能同时依赖任务相关物理线索与背景视觉属性^[49]；Ishida 等针对移动操作机器人迁移至新工位后自遮挡与背景变化导致的失败，提出关注任务相关视角与图像区域的鲁棒模仿学习方法，说明停靠位姿差异会同时改变本体状态与图像观测^[50]。提高鲁棒性的途径有二。其一是扩展训练数据对扰动取值空间的覆盖范围：动力学随机化通过扩大参数分布提高策略对模型偏差的容忍度^[51]，其思想同样适用于实体机器人示范采集中的初始位姿随机化；DROID 与 Open X-Embodiment 通过提高跨场景、跨本体的数据多样性改善泛化性能^[8,41]；Mobile ALOHA 表明静态与移动数据协同训练可提高数据效率^[13]。其二是向策略提供扰动的显式输入或由底层控制补偿扰动：MOMA-Force 以力觉模仿与导纳控制补偿停靠偏差^[31]；Mandlekar 等的人在回路任务与运动规划框架由自动运动规划模块完成自由空间搬运，仅对接触段采集示范，从数据采集角度区分了自由空间与精细操作阶段^[52]。评价方面，CALVIN 以语言条件长时序任务链呈现误差随任务链长度的累积^[53]，LIBERO 以程序化任务套件评估知识迁移^[54]，RoboMimic 强调示范质量与训练终止规则对结论的影响^[28]。面向本课题的工位停靠变化，固定观察位姿下的局部视觉能否提供可靠的相对位姿信息，以及该信息与随机停靠示范相结合能否提高策略泛化能力，仍需进一步研究；训练数据覆盖与显式误差输入的相对贡献也需通过消融实验区分。这是基于停靠误差融合输入的泛化训练方法的出发点。




图 8: Pumacay 等提出的 THE COLOSSEUM 基准：任务层级与扰动维度^[48]

(2) 运行时失败预测与安全停止。 停靠误差融合只能依据训练分布内的停靠误差作补偿, 停靠误差过大或工件位置异常仍会使状态超出训练数据分布, 而模仿学习策略未包含自动停止机制。Liu 等提出基于模型的运行时监控: 在交互式模仿学习部署中于共享潜空间训练动力学模型、策略与失败分类器, 对未来轨迹采样预测异常和失败概率, 在错误发生前触发人工介入^[55]。FAIL-Detect 提出只用成功示范数据的模块化在线失败检测方法: 从观测、视觉特征与策略动作中提取失败相关标量, 以流密度估计建模不确定性, 并用保形预测校准时变阈值, 将失败识别表述为序列分布外检测, 无需预先枚举失败类型^[56]。在恢复方面, RACER 以视觉语言模型监督器在线描述错误与空间修正, 由语言条件策略执行恢复动作^[57]; REFLECT 将多模态历史压缩为可解释的失败报告, 并由语言规划器生成纠正方案^[58]。上述工作表明, 在失败发生前预测风险并介入是可行的, 但其监控信号或依赖独立训练的动力学模型与感知模块, 或只利用与策略动作生成过程无关的密度估计, 未直接利用 VLA 模型自身的观测特征与动作序列提议; 面向本课题, 动作序列滚动推理还提供了另一类信号: 前一动作序列的未执行尾部与当前观测下的新动作提议在时间上重叠, 状态处于示范分布内时二者差异应当较小, 状态被停靠误差推离分布或末端卡滞时差异可能增大。以冻结 VLA 模型的观测特征、动作序列提议和上述预测偏差量为输入训练轻量风险判别模型, 在动作序列下发前预测其执行风险并在风险过大时提前停止, 其召回率、误报率与告警提前量能否满足安全制动要求, 仍需在本课题任务中实证检验, 由此形成基于增广状态输入的风险判别模型。

(3) 动作序列执行时域与效率。 动作序列策略的执行时域同时决定新观测进入控制回路的频率与推理开销。ACT 的消融表明动作序列长度增大总体上提高成功率, 时序集成通过对重叠预测加权平均进一步改善平滑性^[12]; 扩散策略同样采用固定的预测与执行时域, 并指出执行时域过长会削弱对新观测的响应^[36]。但对扩散或流匹配策略直接平均不同生成样本可能产生不可执行的中间动作, ACT 的时序集成不能直接视为 $\pi_{0.5}$ 的既有执行机制。RTC 针对动作分块流策略, 将推理延迟内已确定执行的动作冻结为前缀, 并在重叠区引导生成过程、补全后续动作, 从而在不重新训练的条件下实现异步连续执行, 且允许执行时域在推理之间变化^[59]。OpenVLA-OFT 将动作吞吐率作为与成功率并列的评价指标^[47], FAST 通过频域词元压缩缩短自回归解码长度^[46], $\pi_{0.5}$ 以流匹配动作专家非自回归地生成整段序列^[11], 三者都将降低单次推理成本作为高频闭环的前提。然而上述方法在部署时均采用单一执行时域: 对 PCBA 上下料这类自由空间移动与精细对准交替的任务, 长执行时域在插入料槽、放置于检测台限位等阶段造成开环执行时域过

长，全程短执行时域又增加推理次数、延长回合时间。按任务阶段固定切换执行时域需要人工划定阶段边界，且不能反映同一阶段内因停靠误差不同而变化的失败风险。以在线风险分数为依据逐次决定执行时域、以 RTC 处理相邻动作序列衔接，并同时报告成功率、回合时间和推理次数，尚需系统实现与评价，这是基于在线风险预测的动作序列调度方法所要验证的内容。

2.4 国内外研究现状简析

以上三部分呈现出清晰的问题传递关系。工业具身机器人研究表明，生产线对机器人的要求已从单点精度转向通用策略经少量示范微调后覆盖多道工序的柔性。智元与龙旗的生产线案例支持这一路线在 3C 精密制造中的可行性，但位置偏差、生产线扰动与偶发失败仍依赖现场适配和人工介入；任务专用的强化学习装配与运动原语方法难以满足跨工序复用要求。VLA 模型以语言条件与视觉语言预训练回应了通用性要求， π 系列进一步以流匹配动作专家和异构协同训练兼顾连续控制与开放环境泛化；但微调后的 VLA 仍是有限示范上的模仿学习策略，遗留位姿扰动下的分布偏移、缺少运行时风险预测与停止机制、固定执行时域下成功率与效率难以兼顾三个部署问题。鲁棒性改进研究分别以训练数据扰动分布覆盖与显式输入、运行时监控、闭环执行机制回应这三个问题，且三者递进：前者不能消除的残余误差由后者处理。

从本节分析可以看出，国外研究在动作分块模仿学习、移动操作全身遥操作、通用 VLA 模型、实时执行与失败检测框架方面起步较早^[9,12,13,56,59]；国内团队主要围绕双臂扩散基础模型、轻量高效 VLA 结构、大规模双臂数据与生产线应用开展研究与实践^[35,42-45]，哈工大团队在精密装配示范学习方面也有持续积累^[20,26]。上述比较限于所选代表性样本及相应的方法侧重。

将上述进展映射到本课题的目标场景，仍有三个问题有待验证。其一，面向本课题的工位停靠变化，固定观察位姿下的局部视觉能否提供可靠的相对位姿信息，以及该信息与随机停靠示范相结合能否提高策略泛化能力，仍需进一步研究；训练数据覆盖与显式误差输入的相对贡献也需通过消融实验区分。其二，以冻结 VLA 模型的观测特征、动作序列提议和相邻动作序列预测偏差量为输入的轻量风险判别模型，能否在碰撞发生前以满足安全制动要求的提前量预测执行风险，其回合级召回率与误报率仍需在独立测试集上实证。其三，以在线风险分数逐次决定执行时域、并通过 RTC 处理流匹配动作序列异步衔接，相对固定执行时域和按阶段固定切换在成功率与回合时间上的差异需要在同一控制接口下评价。

基于以上问题，本研究拟以 OpenPI 的 $\pi_{0.5}$ 为研究对象，沿“工位停靠误差-精细操作阶段显现-碰撞失败或保守低效”的传递链探索分层鲁棒性改进方法。以成

功率随实际停靠误差变化的曲线描述策略的容忍能力，以召回率、误报率和预警提前量衡量风险预测质量，并结合碰撞与损坏事件数、任务时间和推理次数，分析三项方法对可靠性与效率的影响。

3 主要内容及方案

3.1 总体技术路线

本课题的主要研究对象是底盘导航导致的工位停靠误差在 $\pi_{0.5}$ 策略执行过程中的传递与显现，及其对任务成功率和效率的影响。底盘停靠后产生厘米量级的位置误差与数度量级的航向误差；位置误差近似等幅改变操作目标在基座系中的位置，航向误差经目标距离转化为横向偏差，两者在 PCBA 插入料槽、放置于检测台限位等精细操作阶段与装配公差处于同一量级；偏差一旦超出策略的纠正能力，动作序列内部不接收观测反馈的执行方式使错误动作持续至下一次推理，直至碰撞、卡滞或工件损坏；而为容忍偏差全程缩短执行时域，又使推理次数增加、回合时间延长。上述过程构成“工位停靠误差-精细操作阶段显现-碰撞失败或保守低效”的误差传递链。本课题据此构建分层鲁棒增强框架，针对链上三个环节各提出一项方法，三项方法与误差传递链的对应关系及其相互依赖如图9所示。




图 9: 工位停靠误差传递链与分层鲁棒增强框架的逻辑关系

（1）基于停靠误差融合输入的泛化训练方法。 作用于误差传递链的源头。拟通过固定观察位姿下的腕部局部视觉估计工位停靠偏差，将其归一化后与策略状态融合，并结合随机停靠示范扩展训练数据的覆盖范围。该方法在保持策略网络主体结构的基础上，研究作业前相对位姿感知与显式误差输入能否增强策略对停靠变化的适应能力，减轻停靠偏差对精细操作的影响。其误差容忍曲线将作为后两项方法的共同评价基准，误差注入回合将为风险判别模型提供训练与评价数

据。

(2) 基于增广状态输入的风险判别模型。 作用于偏差显现为失败的环节。拟在冻结的 $\pi_{0.5}$ 上训练轻量风险模型，联合利用观测特征、候选动作序列、误差增广状态、子任务指令与相邻动作序列预测偏差，在动作序列下发前预测失败风险。重点研究不同信息对风险识别的贡献、预警及时性与误报之间的关系，并考察提前停止对碰撞和工件损坏的影响。训练与评价数据拟来自停靠误差注入实验。

(3) 基于在线风险预测的动作序列调度方法。 作用于成功率与效率的权衡环节。拟利用前一项研究得到的在线风险分数调整实际执行步数：低风险时延长执行区间以减少推理次数，风险升高时缩短执行区间以更快引入新观测，并利用 RTC 衔接相邻动作序列。研究重点是风险变化与闭环更新需求之间的关系，以及动态调度对任务成功率和时间开销的综合影响；提前停止机制在调度过程中继续保留。

三项研究沿误差传递链依次展开，并共享实验基础：停靠误差研究提供容忍曲线和误差注入数据，风险判别研究利用这些数据学习失败风险，动作序列调度研究进一步利用风险信息探索效率改进。拟先分别验证各项研究假设，再在统一的四工位五子任务链与误差条件下逐步结合三项方法，分析各自的增量作用及组合后的表现。总体研究关系如图10所示。




图 10: 分层鲁棒增强框架的总体研究架构

3.2 任务定义与工位停靠误差传递问题

PCBA 上下料任务由四个物理工位上的五个操作子任务顺序组成，记子任务集合为 $\mathcal{L} = \{\text{上料车取料, 编码扫描, 检测台下料, 检测台上料, 下料车放料}\}$ ，分别对应从上料百叶车夹取 PCBA、完成编码登记、从检测台取出上一块 PCBA、将当前 PCBA 放入检测台以及将上一块 PCBA 放入下料百叶车，如图11所示。各操作子任务以语言条件表示为 $\ell_i \in \mathcal{L}$ ， $\pi_{0.5}$ 生成低层连续动作。机器人导航至工位并锁定底盘后执行操作；检测台下料和上料在同一次停靠中连续完成，因而一条完整任务链包含四次停靠事件和五次子任务判定。

以一条完整的五子任务链为一个测试回合。取料类子任务以 PCBA 被夹持并完全离开原承载区域为完成条件，编码扫描以编码读取设备返回有效编码为完成条件，放置类子任务以 PCBA 到达目标料槽或检测台限位并在释放后保持稳定为完成条件；掉落、触发接触保护或紧急停止（急停）、人工介入以及超时均判为失败。成功与否依据同步视频、夹爪状态与工位传感记录复核，避免仅依据策略自身的完成判断。令 $Y_{e,m} \in \{0, 1\}$ 表示回合 e 的第 m 个子任务是否成功，则完整任务链成功率和第 m 个子任务的条件成功率分别定义为

$$\hat{S}_{\text{chain}} = \frac{1}{N} \sum_{e=1}^N \prod_{m=1}^5 Y_{e,m}, \quad \hat{S}_m^{\text{cond}} = \frac{\sum_{e=1}^N Y_{e,m} \prod_{q=1}^{m-1} Y_{e,q}}{\sum_{e=1}^N \prod_{q=1}^{m-1} Y_{e,q}}, \quad (2)$$

其中空乘积取 1。完整任务链成功率反映端到端性能，条件成功率消除了前序子任务失败对当前子任务评价指标的影响，便于单独考察精细子任务。




图 11: PCBA 上下料五子任务链与工位停靠误差的定义

为描述工位停靠误差，对第 k 个工位定义固连于环境的标称停靠坐标系 $\{S_k\}$ ，

该坐标系在示范采集时与机器人基座系 $\{B\}$ 重合。记 ${}^A\mathbf{T}_C$ 为将 $\{C\}$ 中坐标变换至 $\{A\}$ 中的齐次变换， ${}^O\mathbf{T}_{S_k}$ 为标称停靠位姿， ${}^O\mathbf{T}_B$ 为实际停靠后的基座位姿，则停靠误差为

$$\Delta\mathbf{T}_k = ({}^O\mathbf{T}_{S_k})^{-1} {}^O\mathbf{T}_B = \begin{bmatrix} \mathbf{R}(\delta\theta_k) & \delta\mathbf{p}_k \\ \mathbf{0}^T & 1 \end{bmatrix}, \quad \delta_k = (\delta x_k, \delta y_k, \delta\theta_k)^T, \quad (3)$$

式中，底盘停靠于水平地面，误差退化为平面位姿； $\delta\mathbf{p}_k = (\delta x_k, \delta y_k)^T$ 为标称停靠系中的位置误差， $\delta\theta_k$ 为航向误差， $\mathbf{R}(\cdot)$ 为平面旋转矩阵。为区分实验干预、策略观测与评价依据，分别记录导航目标的注入量 δ_k^{cmd} 、作业前腕部局部视觉估计 $\hat{\delta}_k^{\text{vis}}$ 以及独立参考测量值 δ_k^{ref} 。激光雷达定位估计 $\hat{\delta}_k^{\text{loc}}$ 另行记录，用于比较不同信息来源的偏差估计能力。参考测量拟通过经标定的工位视觉基准标记与头部相机获得，其准确性与重复性须经核验后方可用于评价；基准标记仅用于参考测量，并与策略观测区域隔离，避免其进入策略输入或腕部偏差估计过程。测试结果按独立参考测量得到的实际误差归档，导航指令及各类估计均不直接作为误差真值。

工位停靠误差对操作精度的影响可由目标点在基座系中的位置变化刻画。设料槽、检测台定位限位等操作目标固连于工位，在标称停靠系中的平面位置为 $\mathbf{p}_G^{S_k}$ 。示范策略隐含地假定基座与标称停靠系重合，其动作以 $\mathbf{p}_G^{S_k}$ 为目标；实际停靠后，同一目标在基座系中的位置变为 $\mathbf{R}(\delta\theta_k)^T(\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k)$ ，与策略隐含目标之差及其上界为

$$\mathbf{e}_p = (\mathbf{R}(\delta\theta_k)^T - \mathbf{I}) \mathbf{p}_G^{S_k} - \mathbf{R}(\delta\theta_k)^T \delta\mathbf{p}_k, \quad \|\mathbf{e}_p\| \leq \|\delta\mathbf{p}_k\| + |\delta\theta_k| \|\mathbf{p}_G^{S_k}\|, \quad (4)$$

式(4)表明，位置误差近似等幅传递，航向误差项随目标距离放大。本课题各工位的操作目标与停靠位置之间的距离由工装布置决定，近似固定。取目标距离为 0.5 m 进行估算，1° 航向误差对应约 8.7 mm 的末端偏差，3° 对应约 26.2 mm，与位置误差同处厘米量级，均已达到或超过 PCBA 插入料槽所允许的装配公差。这是停靠误差在精细操作阶段显现为夹取或放置失败的几何原因。

3.3 基于 $\pi_{0.5}$ 的 VLA 策略与动作序列建模

本课题以 $\pi_{0.5}$ 为共同的策略模型，分别研究状态表征、失败风险与执行时域对鲁棒性的影响。本小节介绍其观测与动作表示以及流匹配学习原理，为后续三项研究提供统一的模型基础。

原始 $\pi_{0.5}$ 在 π_0 连续动作生成框架的基础上引入异构协同训练与语义子任务预测，将长时程任务中的高层语义决策与低层动作序列生成组织在统一模型中，其结构及训练流程如图12所示^[11]。




图 12: $\pi_{0.5}$ 模型结构及两阶段训练流程^[11]

图12左侧为预训练阶段。模型由 SigLIP 视觉编码器和 Gemma 语言模型组成预训练 VLM 主干网络，将多模态网络数据、异构机器人数据和任务提示统一表示为序列，并同时学习语义子任务、离散动作、图像描述及目标边界框等输出。机器人动作在该阶段由 FAST 分词器压缩为离散词元，使动作预测能够与语言建模任务共同采用自回归的下一词元预测目标。图中右侧为后训练与推理阶段：预训练得到的 VLA 模型继续承担图像与语言理解，并在主干网络之外加入参数量较小的动作专家；动作专家接收连续动作的含噪中间状态，采用条件流匹配逐步生成连续动作序列。由此，模型既保留预训练阶段获得的视觉与语义能力，又能以非自回归方式输出适用于实时控制的连续动作。

在层级推理过程中，VLA 主干网络首先根据当前多视角观测和高层任务指令 g_t 自回归生成语义子任务 $\hat{\ell}_t$ ，例如将“整理卧室”转化为“拿起枕头”；随后，该子任务作为低层语言条件输入动作专家，后者由随机噪声生成长度为 H 的连续动作序列。原模型的联合分布可分解为

$$\pi_{\theta}(\mathbf{A}_t, \hat{\ell}_t | \mathbf{z}_t, g_t) = \pi_{\theta}(\mathbf{A}_t | \mathbf{z}_t, \hat{\ell}_t) \pi_{\theta}(\hat{\ell}_t | \mathbf{z}_t, g_t), \quad (5)$$

其中， $\mathbf{z}_t$ 表示图像与机器人本体状态， g_t 表示原模型的高层任务指令。式(5)的第二项对应原模型的子任务预测，第一项对应动作专家的连续动作生成。上述异构预训练与高层子任务预测属于原始 $\pi_{0.5}$ 的模型能力。本课题采用 OpenPI 公开的 $\pi_{0.5}$ 模型及流匹配动作预测头，不使用其高层子任务预测，而由第3.2节的外部任务状态机按五个子任务直接提供动态低层语言指令 ℓ_t ，即只保留式(5)的第一项并以 ℓ_t

替代 $\widehat{\ell}_t$ 。相应地，时刻 t 的策略输入写为

$$\mathbf{o}_t = \{I_t^{\text{head}}, I_t^{\text{wrist},L}, I_t^{\text{wrist},R}, \mathbf{x}_t, \ell_t\}, \quad (6)$$

其中， I_t^{head} 、 $I_t^{\text{wrist},L}$ 与 $I_t^{\text{wrist},R}$ 为头部与左右腕部相机图像， $\mathbf{x}_t \in \mathbb{R}^{14}$ 为左右末端位姿与夹爪状态组成的本体状态， ℓ_t 为运行时给定的动态任务语言指令。图像与语言指令经 VLM 主干网络编码为条件序列，本体状态经 OpenPI 状态接口一并输入模型。策略一次推理输出长度为 H 的动作序列：

$$\widehat{\mathbf{A}}_t = \pi_{\theta}(\mathbf{o}_t) = [\widehat{\mathbf{a}}_t, \widehat{\mathbf{a}}_{t+1}, \dots, \widehat{\mathbf{a}}_{t+H-1}]. \quad (7)$$

动作序列中的每个元素为双臂笛卡尔动作与夹爪指令，与 $\mathbf{x}_t$ 同为 14 维。机器人执行其中时域为 s 的近期动作，且 $1 \leq s \leq H$ ；完成该段动作后，系统重新获取多视角图像和末端状态，并结合当前语言指令构造下一轮输入。该过程在动作序列边界形成“状态感知-策略推理-动作序列执行-状态更新”的视觉闭环，而每次提交的 s 个控制步在策略层面不接收新观测。

(1) 面向 $\pi_{0.5}$ 的模仿学习推导。将专家示范回合中时间对齐的观测与动作按照长度为 H 的滑动窗口组织，可得动作序列示教数据集

$$\mathcal{D}_E = \left\{ \left(\mathbf{o}_t^{(n)}, \mathbf{A}_t^{E,(n)} \right) \right\}_{n,t}, \quad \mathbf{A}_t^E = [\mathbf{a}_t^E, \dots, \mathbf{a}_{t+H-1}^E], \quad (8)$$

式中， n 为示范回合编号，示范回合的采集与组织方式见第5节。行为克隆的基本目标是在专家数据分布上最大化条件动作序列的对数似然，即

$$\theta_{\text{IL}} = \arg \min_{\theta} \mathcal{L}_{\text{IL}}(\theta), \quad \mathcal{L}_{\text{IL}}(\theta) = -\mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E} [\log \pi_{\theta}(\mathbf{A}_t^E | \mathbf{o}_t)]. \quad (9)$$

该目标使策略分布逼近专家在给定多视角图像、机器人状态和语言指令条件下的动作分布；动作序列联合建模还保留了同一操作片段内各时刻动作之间的相关性。

$\pi_{0.5}$ 采用条件流匹配表示连续动作序列分布^[10,11]。对归一化后的专家动作序列 $\mathbf{A}_t^E$ ，采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $\tau \in [0, 1]$ ，构造从噪声到数据的线性概率路径

$$\mathbf{A}_t^{\tau} = (1 - \tau)\epsilon + \tau\mathbf{A}_t^E, \quad \mathbf{u}_t^{\tau} = \frac{\partial \mathbf{A}_t^{\tau}}{\partial \tau} = \mathbf{A}_t^E - \epsilon. \quad (10)$$

设动作专家输出的条件向量场为 $\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau)$ ，则模仿微调可写为条件流匹配损失

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tau \sim p(\tau)} [\|\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) - (\mathbf{A}_t^E - \epsilon)\|_2^2]. \quad (11)$$

最小化式(11)使网络学习式(10)的条件速度场。推理时从 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，沿

$$\frac{d\mathbf{A}_t^{\tau}}{d\tau} = \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) \quad (12)$$

由 $\tau = 0$ 正向积分至 $\tau = 1$ ，即可得到条件动作序列样本 $\hat{\mathbf{A}}_t = \mathbf{A}_t^1$ 。以步长 $\Delta\tau > 0$ 进行欧拉离散时，单步更新为

$$\mathbf{A}_t^{\tau+\Delta\tau} = \mathbf{A}_t^{\tau} + \Delta\tau \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau). \quad (13)$$

因此，式(11)给出了示教动作对模型参数的监督关系，式(12)和式(13)则给出了从随机噪声生成连续动作序列的推理过程。

(2) 三项方法在模型中的作用位置。停靠误差融合训练方法研究式(6)中的状态表征与式(8)中的示范分布，在保持策略主体结构及流匹配训练目标不变的条件下，考察相对位姿信息对动作学习的影响。风险判别方法联合利用观测、动作与增广状态，在动作序列下发前估计失败风险；相邻动作序列的预测偏差作为补充信息参与判别。风险驱动调度方法进一步根据风险分数选择式(7)中的实际执行步数 s ，并借助 RTC 研究变长执行条件下的动作连续性。三项方法与策略模型的关系如图13所示。

3.4 基于停靠误差融合输入的泛化训练方法

移动底盘在工位停靠后的平移与航向偏差，会改变操作目标相对于机器人基座的位置，并影响后续精细操作。现有示范主要在标称停靠位姿下采集，对不同停靠条件下的观测与动作变化覆盖不足。同时，导航定位主要描述机器人在环境地图中的位姿，其估计结果对机器人与局部工装之间相对位姿的表征能力仍需检验。本研究拟结合随机停靠示范与作业前局部视觉观测，将工位相对位姿偏差作为策略的显式输入，研究其对模仿学习策略停靠误差泛化能力的影响。

图14展示了停靠误差融合与泛化训练的研究思路。橙色粗框突出本项研究关注的内容，蓝灰色表示共同的策略基础；后续两项研究采用相同的图示约定。拟在固定执行步数下比较不同示范分布与状态输入，考察其对停靠误差适应能力的影响。

(1) 固定观察位姿下的工位相对位姿感知。拟在各工位设置相对于机器人基座固定的观察位姿。底盘停稳并锁定后，保持腰部姿态一致，使机械臂到达预设观察位姿，利用腕部彩色与深度相机获取工装局部的视觉信息。以标称停靠条件下建立的工位参考观测为依据，考察检测台边框、定位结构及百叶车立柱等固定几何特征在不同停靠条件下的观测变化，估计机器人相对于标称停靠位姿的平移与航向偏差。该思路拟利用工装自身可辨识的结构信息，减少运行阶段对附加人工标记的依赖。研究中将重点考察观察位姿的一致性、工装特征的可辨识性以及夹持工件造成的遮挡对估计可靠性的影响，并明确其适用条件。作业前观测用于获取停靠偏差信息，底盘保持当前停靠位置，后续操作中的动作调整由策略完成。图15给出了固定观察位姿下的工装局部观测与停靠偏差估计思路，图中观测与偏




图 13: 策略模型、风险判别与执行调度的结构关系




图 14: 停靠误差融合与泛化训练的研究思路

差均为概念示意。

(2) 停靠误差融合与示范分布扩展。 拟将局部视觉估计的平移与航向偏差统一表示在工位标称停靠坐标系中，经归一化后与机器人本体状态融合，作为 $\pi_{0.5}$ 策略的补充条件。该输入描述当前停靠状态相对于示范参考状态的整体差异，与操作期间持续获取的视觉观测共同支持动作生成。为衔接后续风险判别模型，记融合后的状态为

$$\tilde{\mathbf{x}}_t = \left[\mathbf{x}_t^T, \bar{\boldsymbol{\delta}}_k^T \right]^T, \quad \widehat{\boldsymbol{\delta}}_k^{\text{vis}} = \left(\widehat{\delta}_{x,k}^{\text{vis}}, \widehat{\delta}_{y,k}^{\text{vis}}, \widehat{\delta}_{\theta,k}^{\text{vis}} \right)^T, \quad (14)$$

其中， $\mathbf{x}_t$ 为本体状态， $\widehat{\boldsymbol{\delta}}_k^{\text{vis}}$ 为作业前视觉估计的停靠误差， $\bar{\boldsymbol{\delta}}_k$ 为其归一化表示，归一化参数由训练集确定。相应的增广观测记为 $\tilde{\mathbf{o}}_t$ ，由式(6)中的本体状态替换为 $\tilde{\mathbf{x}}_t$ 得到。在底盘与工位相对位置保持不变的条件下，同一次停靠期间共用该误差估计；检测台取出与放入两个子任务共用一次停靠观测。

在示范采集阶段，拟通过随机停靠扩展平移与航向偏差的覆盖范围，采集不同初始相对位姿下完成任务的遥操作示范，使数据包含与停靠变化相对应的动作调整。训练与部署采用一致的作业前观测和误差表示方式，在保持策略网络主体结构与既有微调框架的基础上，研究策略能否建立停靠偏差与操作调整之间的对




图 15: 基于腕部局部彩色与深度观测的停靠偏差估计示意

应关系。其中，随机停靠用于扩展示范分布，显式误差输入用于补充工位相对位姿信息，两者的贡献拟通过对照实验分别考察。

(3) 拟验证的问题及与后续研究的关系。 本研究拟从偏差估计与策略泛化两个层面开展验证。在偏差估计层面，以经精度核验的独立参考测量为依据，比较腕部局部视觉与导航定位对工位停靠偏差的估计误差，考察机械臂重复到位、工装观测条件及测量耗时的影响，确定作业前视觉观测能否提供可靠的补充信息。在策略泛化层面，拟设置 (a) 固定停靠且不输入误差、(b) 随机停靠但不输入误差、(c) 随机停靠并融合视觉误差三组对照，以考察示范分布扩展与误差输入的作用。各组控制示范数量与训练条件，后两组使用相同的随机停靠示范，以区分数据覆盖范围与显式误差输入的作用；同时考察估计不准确时策略性能的变化。测试时通过导航目标施加停靠扰动，以独立参考测量记录实际偏差，比较完整任务链与精细子任务成功率随误差变化的趋势，并计入作业前观测所增加的时间开销。所得误差容忍曲线将作为后续风险判别与动作序列调度研究的共同评价基准，误差注入回合及其失败事件记录将为风险判别模型的训练与评价提供数据依据。

3.5 基于增广状态输入的风险判别模型

即使通过误差融合改善策略的适应能力，超出示范覆盖范围的停靠偏差仍可能引起操作失败。拟研究在动作执行前，能否从当前观测、候选动作与相邻预测的变化中识别失败趋势，并通过提前停止减少碰撞与工件损坏。

图16展示了风险判别研究与误差融合策略的关系。风险模型联合使用多种信息，相邻动作序列的预测偏差仅作为其中一项输入，其独立作用和互补性拟通过消融实验考察。




图 16: 增广状态风险判别与提前停止的研究思路

(1) 失败风险的表征与学习。 拟将风险定义为当前候选动作序列执行后，在未来预警窗口内发生碰撞、接触保护、卡滞或掉落等事件的概率。设第 i 次推理时刻为 t_i ，失败事件首次发生时刻为 t_{fail} ，成功回合取 $t_{\text{fail}} = \infty$ ，则可构造监督标签与风险模型：

$$y_i = \mathbb{I}[t_i \leq t_{\text{fail}} \leq t_i + T_{\text{pre}}], \quad (15)$$

$$\rho_i = f_{\psi}(\zeta_i) \in [0, 1], \quad \zeta_i = \{\mathbf{z}_i, \hat{\mathbf{A}}_i^{\text{raw}}, \tilde{\mathbf{x}}_{t_i}, \ell_{t_i}, r_i\}.$$

式中, T_{pre} 为预警窗口, 其选择需兼顾失败可预测性与安全停止所需时间; $\mathbf{z}_i$ 为策略对当前观测的特征表示, $\hat{\mathbf{A}}_i^{\text{raw}}$ 为尚未施加 RTC 连续性约束的候选动作序列, $\hat{\mathbf{x}}_{t_i}$ 为误差增广状态, ℓ_{t_i} 为子任务指令, r_i 为相邻动作序列的预测偏差。拟在保持 $\pi_{0.5}$ 参数冻结的条件下训练轻量风险模型, 研究策略已有表征能否支持失败风险预测, 以及不同输入信息对预测质量的贡献。

相邻两次推理对同一未来时段的预测差异, 可能反映策略对当前状态的判断发生变化。该差异也可能来自正常动作调整与采样随机性, 因此不能直接等同于失败风险。拟将重叠时段内的动作预测对齐, 构造归一化偏差量:

$$r_i = \frac{1}{|\mathcal{J}_i|} \sum_{j \in \mathcal{J}_i} \left\| \Lambda^{-1/2} \text{diff}(\hat{\mathbf{a}}_{i,j}^{\text{raw}}, \hat{\mathbf{a}}_{i,j}^{\text{prev}}) \right\|_2^2. \quad (16)$$

其中, $\mathcal{J}_i$ 为相邻序列按同一控制时刻对齐后的非空重叠区, $\hat{\mathbf{a}}_{i,j}^{\text{prev}}$ 为前一序列对该时刻的预测, diff 表示考虑姿态周期性的动作差, Λ 为由训练数据确定的尺度归一化矩阵。上述表达用于刻画预测差异; 研究中还需考察动作采样随机性、重叠区长度以及 RTC 约束对该信息的影响。

训练数据拟来自停靠误差注入回合, 并根据失败时刻构造预警窗口内的正样本和正常运行负样本。以类别加权的二元交叉熵作为候选学习目标:

$$\mathcal{L}(\psi) = - \sum_{e \in \mathcal{E}_{\text{tr}}} \sum_i \left[w_+ y_i^e \log \rho_i^e + (1 - y_i^e) \log(1 - \rho_i^e) \right]. \quad (17)$$

式中, $\mathcal{E}_{\text{tr}}$ 为训练回合集, w_+ 用于调节失败样本在学习目标中的权重。拟重点分析失败样本稀缺、事件标注误差与工位差异对模型的影响。数据按完整回合划分训练、验证与测试集, 避免同一回合的相邻时刻跨集合而高估预测能力。

(2) **提前停止与预警有效性。** 拟依据风险分数及其时间变化研究提前停止判据, 在动作序列下发前决定是否继续执行。停止阈值和时间平滑等候选判定方式将在验证集上比较, 重点分析降低误报与保持预警及时性之间的权衡。触发判据后停止操作, 具体停止过程应满足实验平台的安全约束; 本课题关注风险判别能否提供足够提前量。图17给出了风险学习、判定与评价之间的关系。

(3) **拟验证的问题。** 首先在独立测试回合上离线评价召回率、回合级误报率与预警提前量, 考察风险信号能否早于失败出现, 且留出足够的安全停止时间。通过分别去除停靠误差、候选动作或相邻预测偏差等信息, 分析各输入的贡献。随后在新的实体机器人回合中比较启用与不启用风险判别的表现, 观察碰撞与损坏事件、提前停止后的安全状态、完整任务链成功率、人工接管率及额外时延。提前停止的回合仍计为任务未完成, 并单独统计其是否避免碰撞, 区分风险抑制与任务完成两个评价目标。




图 17: 风险判别学习与提前停止的验证思路

3.6 基于在线风险预测的动作序列调度方法

$\pi_{0.5}$ 每次推理生成一段动作序列，实际执行步数决定了新观测进入策略的频率。较长执行区间有利于减少推理开销，较短执行区间有利于及时修正偏差。拟研究能否以在线风险作为调整执行步数的依据，使观测更新频率适应操作过程中的风险变化。

图18展示了调度研究与前两项研究的关系。拟在保持误差融合策略与风险模型不变的基础上，利用风险分数调节执行步数，并以 RTC 衔接相邻动作序列；提前停止机制继续保留。

(1) 风险与执行时域的关系。 拟建立风险分数到实际执行步数的映射：

$$s_i = g(\rho_i), \quad s_{\min} \leq s_i \leq s_{\max} \leq H, \quad g(\rho) \text{ 随 } \rho \text{ 增大而非增}. \quad (18)$$

其中， ρ_i 为风险分数， s_i 为本次实际执行的步数， H 为预测序列长度， $s_{\min}$ 与 $s_{\max}$ 分别为可选执行步数的下界与上界。该关系表达低风险时适当延长执行区间、风险升高时缩短执行区间的基本假设。拟比较不同映射形式及参数选择对成功率与效率的影响，并考察风险波动或预测偏差是否导致执行步数频繁变化。执行范围还需结合推理时延、动作连续性和风险模型所需的序列重叠条件确定；满足提前停止条件时终止操作。




图 18: 在线风险驱动的动作序列调度研究思路

(2) 变长执行下的动作连续性。 执行步数变化会改变相邻动作序列的切换位置，因而需要同时研究观测更新与动作连续性。拟借鉴适用于流匹配策略的实时动作分块机制 RTC^[59]，利用前一动作序列中的已确定动作及重叠区信息约束后续序列，减轻切换引起的动作不连续。研究将关注推理时延、序列重叠程度与执行步数变化之间的关系，考察连续衔接对风险判别与调度效果的影响。图19示意风险变化与执行区间调整的关系。




图 19: 风险变化与动作序列执行区间调整的示意关系

(3) 拟验证的问题。 拟以固定短、中、长执行步数以及按任务阶段固定切换的方式为对照，比较风险驱动调度在不同停靠误差条件下的表现。对照中保持策略、风险模型和提前停止方式一致；在相同 RTC 条件下比较调度规则，并单独考察 RTC 连续衔接的影响，以区分两者的作用。评价同时关注完整任务链与精细子任务成功率、操作时间、推理次数、平均执行步数以及碰撞事件，操作时间不含工位间导航。通过成功率与时间开销的共同变化，分析风险驱动调度能否缓解保守短执行区间带来的效率损失，并明确其对风险预测准确性的依赖。

3.7 整体验证方案

拟围绕表1中的问题组织验证。首先以标称停靠示范微调的 $\pi_{0.5}$ 策略为基线，观察停靠误差引起的性能变化；随后依次研究误差融合、风险判别与风险驱动调度，并通过消融和逐步组合分析各方法的增量作用与相互影响。各项比较采用相同的误差注入原则、四工位五子任务链和评价口径。

误差条件拟覆盖平移与航向扰动，并结合独立参考测量分析实际误差与策略表现的关系。研究将以完整回合为统计单位，对成功率等比例指标报告置信区间，同时分析精细子任务与典型失败案例。用于示范采集的机器人和其余三台未参与策略训练的机器人分别评价，以考察本体差异对方法适用性的影响。

表 1: 研究问题与验证思路

研究环节	拟回答的问题	对照与评价重点
基线分析	停靠误差如何影响精细操作与任务完成？	标称与扰动条件比较；任务链及子任务成功率、失败类型
停靠误差融合	数据覆盖与显式误差输入分别发挥什么作用？	固定与随机停靠示范、是否输入误差；成功率随实际误差的变化
风险判别	增广信息能否支持及时且可靠的风险识别？	输入消融、是否启用提前停止；召回率、误报率、提前量及碰撞与损坏事件
风险驱动调度	在线风险能否改善成功率与效率的权衡？	固定步数、分阶段切换与风险调度；成功率、操作时间、推理次数及连续性

3.8 可行性分析

前期已完成 VR 示范采集、OpenPI 数据适配、 $\pi_{0.5}$ 微调与实体机器人接口集成及功能验证，为开展对照研究提供了平台基础。三项研究均以现有策略为共同对象，分别考察状态输入、风险表征与执行时域，研究内容可分步验证；误差注入实验产生的数据还可支持风险模型学习和后续调度评价。

现有腕部彩色与深度相机、导航系统及四台机器人提供了观测停靠偏差和开展重复实验的条件；可使用的一张 80 GB 显存 NVIDIA A100 图形处理器（Graphics Processing Unit, GPU）为策略微调提供算力基础。局部视觉估计和独立参考测量的可靠性、失败样本的覆盖程度以及风险预测的及时性仍需进一步验证，相应问题与措施见第8节。

4 预期达到的目标

本课题预期围绕工位停靠误差对轮式双臂模仿学习策略的影响，形成误差融合、风险判别与动作序列调度相结合的鲁棒性改进方法，并通过 PCBA 四工位五子任务实验分析其有效性与适用条件。具体目标如下。

对于停靠误差融合训练方法，预期显式误差输入与随机停靠示范能够降低策

略成功率随注入误差增大而下降的速度，并扩大平移与航向误差的容忍范围；消融结果用于分别评估训练数据误差分布覆盖范围与显式误差输入的贡献。

对于风险判别方法，预期建立利用策略观测、候选动作和误差增广状态预测失败风险的方法，分析误报、漏报与预警提前量之间的关系，并探索提前停止对碰撞和工件损坏的抑制作用。

对于风险驱动调度方法，预期建立在线风险与实际执行步数之间的关联，结合相邻动作序列连续衔接，探索兼顾任务成功率与执行效率的调度方法，并分析其对风险预测质量和推理时延的依赖。

预期成果形式包括：面向 OpenPI $\pi_{0.5}$ 的工位停靠误差鲁棒性改进方法及其实体机器人验证；三项研究在统一误差条件下的对照与消融实验数据、容忍曲线、风险预测与调度分析；以及以上内容为主体的硕士学位论文。

5 已完成的学术研究/实践工作

5.1 实验平台与坐标系定义

本研究已在轮式双臂机器人平台上完成示范采集与策略执行所需的基础接口建设。机器人上半身由左右两条七自由度机械臂、四自由度腰部和二自由度头部组成，共包含 20 个转动关节，并配置末端夹爪、头部相机和腕部相机。现阶段，策略模型的状态变量和动作变量为左右机械臂末端笛卡尔位姿及夹爪状态。策略执行期间，腰部、头部和移动底盘位姿保持固定，笛卡尔控制模块根据策略动作更新左右机械臂的关节指令。移动底盘通过激光雷达定位与基于地图的经典导航方法在工位间移动并停靠，停靠后锁定，操作阶段仅由双臂执行。

为统一描述机器人、工位与虚拟现实（Virtual Reality, VR）设备之间的空间关系，本文以 $\alpha \in \{L, R\}$ 区分左、右机械臂，并定义以下坐标系：世界坐标系记为 $\{O\}$ ，机器人基座坐标系记为 $\{B\}$ ，左右末端执行器坐标系记为 $\{E_\alpha\}$ ，第 k 个工位固连于环境且与示范时标称基座位姿重合的停靠坐标系记为 $\{S_k\}$ ；VR 参考坐标系记为 $\{V\}$ ，左右 VR 手持控制器坐标系记为 $\{H_\alpha\}$ 。其中， ${}^A\mathbf{T}_C$ 表示坐标系 $\{C\}$ 相对于坐标系 $\{A\}$ 的位姿，即将 $\{C\}$ 中的齐次坐标变换到 $\{A\}$ 中。该表示写为

$${}^A\mathbf{T}_C = \begin{bmatrix} {}^A\mathbf{R}_C & {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}, \quad (19)$$

式中， ${}^A\mathbf{R}_C \in \text{SO}(3)$ 为旋转矩阵， ${}^A\mathbf{p}_C \in \mathbb{R}^3$ 为坐标系原点的位置向量。若空间点在 $\{C\}$ 中的齐次坐标为 $\bar{\mathbf{p}}^C$ ，则其在 $\{A\}$ 中的表示为 $\bar{\mathbf{p}}^A = {}^A\mathbf{T}_C \bar{\mathbf{p}}^C$ 。连续坐标变换

满足

$${}^A\mathbf{T}_D = {}^A\mathbf{T}_C {}^C\mathbf{T}_D, \quad ({}^A\mathbf{T}_C)^{-1} = \begin{bmatrix} ({}^A\mathbf{R}_C)^T & -({}^A\mathbf{R}_C)^T {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}. \quad (20)$$

式(19)和式(20)构成 VR 增量映射、工位坐标系与前文停靠误差定义的统一表示基础。基座系与末端系之间的正逆运动学由平台现有笛卡尔控制模块提供，本文不再展开。

5.2 基于 VR 遥操作的示范数据采集

在上述坐标关系基础上，本研究已构建基于 VR 设备的双臂遥操作与示范数据采集流程。系统读取虚拟现实头戴式显示器及左右 VR 手持控制器的空间位姿和交互信号，在遥操作回合开始时分别记录控制器初始位姿 ${}^V\mathbf{T}_{H_\alpha}(t_0)$ 与机器人末端初始位姿 ${}^B\mathbf{T}_{E_\alpha}(t_0)$ 。固定标定旋转 ${}^B\mathbf{R}_V$ 用于统一 VR 参考系与机器人基座系的轴向约定，比例系数 λ_α 用于调节操作者手部平移与机器人末端平移的尺度。由此，控制器相对初始位置的增量被映射为

$${}^B\mathbf{p}_{E_{\alpha,d}}(t) = {}^B\mathbf{p}_{E_\alpha}(t_0) + \lambda_\alpha {}^B\mathbf{R}_V ({}^V\mathbf{p}_{H_\alpha}(t) - {}^V\mathbf{p}_{H_\alpha}(t_0)). \quad (21)$$

该增量形式以遥操作开始时的实际末端位置为基准，VR 空间的绝对坐标用于计算控制器相对初始位姿的运动增量。

控制器姿态首先相对于初始姿态计算，再经标定旋转映射到机器人基座系。末端目标姿态表示为

$${}^B\mathbf{R}_{E_{\alpha,d}}(t) = {}^B\mathbf{R}_V \left[{}^V\mathbf{R}_{H_\alpha}(t) ({}^V\mathbf{R}_{H_\alpha}(t_0))^T \right] {}^V\mathbf{R}_B {}^B\mathbf{R}_{E_\alpha}(t_0), \quad (22)$$

其中 ${}^V\mathbf{R}_B = ({}^B\mathbf{R}_V)^T$ 。式(21)与式(22)分别生成末端目标位置和姿态，两者组成 ${}^B\mathbf{T}_{E_{\alpha,d}}(t)$ ，再由已有笛卡尔控制接口执行。将 VR 手持控制器中用于夹爪开合控制的输入信号记为 $u_\alpha(t)$ ，其与夹爪指令之间的映射表示为

$$g_{\alpha,d}(t) = \mathcal{G}_\alpha(u_\alpha(t)) \quad (23)$$

映射函数 $\mathcal{G}_\alpha(\cdot)$ 将该输入信号转换为左右夹爪的开合指令。函数的触发阈值与夹爪行程参数取自机器人平台配置，并在同组实验中保持不变。

机器人示范数据通常以一次完整的任务回合作为基本组织单元，将视觉观测、机器人状态与动作按时间步对齐，并在回合层关联任务指令；统一的数据语义有助于后续按不同观测窗口和动作空间构造训练样本^[8]。参照这一组织方式，本研究将当前采集的数据划分为任务、回合和时间步三个层级：任务层以自然语言描述界定操作目标，回合层对应一次完整的遥操作过程，时间步层则以动作时刻为

索引，关联头部与左右腕部图像、双臂末端状态、夹爪状态及相应动作。第 n 个任务回合可表示为

$$\tau^{(n)} = \left\{ \left(t_k, I_k^{\text{head}}, I_k^{\text{wrist},L}, I_k^{\text{wrist},R}, \mathbf{x}_k, \mathbf{a}_k \right) \right\}_{k=1}^{K_n}, \quad (24)$$

其中， $\mathbf{x}_k$ 包含左右末端位姿与夹爪状态， $\mathbf{a}_k$ 包含对应时刻的双臂笛卡尔动作与夹爪指令。任务语言描述作为策略的语义条件与相应示范回合关联；一个示范回合对应一次低层子任务执行，正式评价中的五子任务链则由状态机串联这些子任务。上述层级将任务语义与单次执行序列分开，同时保持观测、状态和动作在回合内部逐时对应，可直接为后续视觉–语言–动作策略构造单步样本或动作序列样本。现有示范均在标称停靠位姿下采集，第3.4节将把采集扩展为随机停靠，并在回合层同步记录所属停靠事件的 δ_k^{cmd} 、 $\hat{\delta}_k^{\text{vis}}$ 、 $\hat{\delta}_k^{\text{loc}}$ 与 δ_k^{ref} 。

以“将 PCBA 放置到百叶车指定承载位置”为例，该回合以右臂为操作臂，左臂保持固定。机器人在夹爪夹持状态下携带 PCBA 接近百叶车，调整末端位置和姿态完成放置，随后松开夹爪并撤离放置区域。该回合共包含 177 个时间对齐样本；每个时间步包含三路分辨率为 240×320 的彩色图像，以及 14 维双臂末端状态和 14 维双臂动作。状态与动作均按左右臂各 7 维组织，分别由三维位置、滚转–俯仰–偏航姿态和夹爪状态或指令组成。该示例表明，现有采集流程能够将多视角观测、机器人本体状态与遥操作动作组织为式(24)所定义的完整回合。

图20给出了该回合的起始、中间和结束观测，以及右机械臂末端执行器的三维运动轨迹。上部三幅图分别对应第 0、88 和 176 帧：前两帧处于夹持状态，结束帧处于松开状态；下部曲线以颜色和线型区分夹爪开合状态，以箭头表示工具坐标系 +Z 轴方向。轨迹在第 120 帧由夹持切换为松开，使视觉观测、末端位姿和 PCBA 释放事件能够在同一时间轴上对应。

图21概括了已完成系统中数据采集与策略执行之间的接口关系。VR 位姿经过增量映射后进入笛卡尔控制模块，机器人动作及多视角观测由同步记录模块组织为示范轨迹；示范数据经 OpenPI 数据接口适配后用于 $\pi_{0.5}$ 微调，部署阶段由任务状态机提供动态低层语言指令，模型接收新观测并通过同一笛卡尔接口输出动作序列。由此，“基于 VR 的示范数据采集– $\pi_{0.5}$ 微调–OpenPI 推理–实体机器人执行”的数据与控制接口已完成集成并通过单回合功能验证；示范阶段与推理阶段共享机器人状态、动作定义和底层执行接口。

5.3 基于 OpenPI 的 $\pi_{0.5}$ 微调与实体机器人闭环执行

在示范数据采集流程基础上，现有系统已完成 OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调、在线推理服务接入和实体机器人动作序列执行。当前部署使用 OpenPI 公




图 20: 将 PCBA 放置到百叶车任务的示例观测、右机械臂末端执行器轨迹与夹爪状态




图 21: 基于 VR 的示范数据采集- $\pi_{0.5}$ 微调-OpenPI 推理-实体机器人执行流程

开的 $\pi_{0.5}$ 模型及流匹配动作预测头：模型接收头部与左右腕部图像、双臂本体状态和任务状态机提供的低层语言指令，生成连续动作序列，再由笛卡尔控制接口执行，并在动作序列边界将新观测反馈至推理模块。本节仅确认数据采集-微调-动作序列执行的软件与实体机器人接口已完成集成和功能验证；五子任务完整任务链成功率、工位停靠误差敏感性和相对性能尚待后续对照与消融实验统计。

为说明当前实现所用模型的算法基础，原始 $\pi_{0.5}$ 在 π_0 连续动作生成框架的基础上引入异构协同训练与语义子任务预测，将长时程任务中的高层语义决策与低层动作序列生成组织在统一模型中，其结构及训练流程如图22所示^[11]。




图 22: $\pi_{0.5}$ 模型结构及两阶段训练流程^[11]

图22左侧为预训练阶段。模型以 SigLIP 视觉编码器和 Gemma 语言模型组成

的预训练 VLM 为主干网络，将多模态网络数据、异构机器人数据和任务提示统一表示为序列，并同时学习语义子任务、离散动作、图像描述及目标边界框等输出。机器人动作在该阶段由 FAST 分词器压缩为离散词元，使动作预测能够与语言建模任务共同采用自回归的下一词元预测目标。图中右侧为后训练与推理阶段：预训练得到的 VLA 模型继续承担图像与语言理解，并在主干网络之外加入参数量较小的动作专家；动作专家接收连续动作的含噪中间状态，采用条件流匹配逐步生成连续动作序列。由此，模型既保留预训练阶段获得的视觉与语义能力，又能以非自回归方式输出适用于实时控制的连续动作。

在层级推理过程中，VLA 主干网络首先根据当前多视角观测和高层任务指令 g_t 自回归生成语义子任务 $\widehat{\ell}_t$ ，例如将“整理卧室”转化为“拿起枕头”；随后，该子任务作为低层语言条件输入动作专家，后者由随机噪声生成长度为 H 的连续动作序列。原模型的联合分布可分解为

$$\pi_{\theta}(\mathbf{A}_t, \widehat{\ell}_t | \mathbf{z}_t, g_t) = \pi_{\theta}(\mathbf{A}_t | \mathbf{z}_t, \widehat{\ell}_t) \pi_{\theta}(\widehat{\ell}_t | \mathbf{z}_t, g_t), \quad (25)$$

其中， $\mathbf{z}_t$ 表示图像与机器人本体状态， g_t 表示原模型的高层任务指令。式(25)的第二项对应原模型的子任务预测，第一项对应动作专家的连续动作生成。上述异构预训练与高层子任务预测属于原始 $\pi_{0.5}$ 的模型能力。当前实体机器人接口直接使用 OpenPI 公开模型及流匹配动作预测头，由外部任务状态机根据五个子任务直接提供动态低层语言指令 ℓ_t 。为与现有推理接口保持一致，时刻 t 的策略输入写为

$$\mathbf{o}_t = \{I_t^{\text{head}}, I_t^{\text{wrist}, L}, I_t^{\text{wrist}, R}, \mathbf{x}_t, \ell_t\}, \quad (26)$$

其中， ℓ_t 为运行时给定的动态任务语言指令。策略一次推理输出长度为 H 的动作序列：

$$\widehat{\mathbf{A}}_t = \pi_{\theta}(\mathbf{o}_t) = [\widehat{\mathbf{a}}_t, \widehat{\mathbf{a}}_{t+1}, \dots, \widehat{\mathbf{a}}_{t+H-1}]. \quad (27)$$

动作序列中的每个元素均按照前述双臂笛卡尔动作与夹爪指令接口解释。机器人执行其中时域为 s 的近期动作，且 $1 \leq s \leq H$ ；完成该段动作后，系统重新获取多视角图像和末端状态，并结合当前语言指令构造下一轮输入。该过程在动作序列边界形成“状态感知-策略推理-动作序列执行-状态更新”的视觉闭环，而每次提交的 s 个控制步在策略层面不接收新观测。现有部署中 s 为全任务统一的固定值，第3.6节将其改为按在线风险分数动态取值并加入 RTC 衔接。

(1) 面向 $\pi_{0.5}$ 的模仿学习推导。 将式(24)所示的专家示范按照长度为 H 的滑动窗口组织, 可得动作序列示教数据集

$$\mathcal{D}_E = \left\{ \left(\mathbf{o}_t^{(n)}, \mathbf{A}_t^{E,(n)} \right) \right\}_{n,t}, \quad \mathbf{A}_t^E = [\mathbf{a}_t^E, \dots, \mathbf{a}_{t+H-1}^E]. \quad (28)$$

行为克隆的基本目标是在专家数据分布上最大化条件动作序列的对数似然, 即

$$\theta_{\text{IL}} = \arg \min_{\theta} \mathcal{L}_{\text{IL}}(\theta), \quad \mathcal{L}_{\text{IL}}(\theta) = -\mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E} [\log \pi_{\theta}(\mathbf{A}_t^E | \mathbf{o}_t)]. \quad (29)$$

该目标使策略分布逼近专家在给定多视角图像、机器人状态和语言指令条件下的动作分布; 动作序列联合建模还保留了同一操作片段内各时刻动作之间的相关性。

$\pi_{0.5}$ 采用条件流匹配表示连续动作序列分布^[10,11]。对归一化后的专家动作序列 $\mathbf{A}_t^E$, 采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $\tau \in [0, 1]$, 构造从噪声到数据的线性概率路径

$$\mathbf{A}_t^{\tau} = (1 - \tau)\epsilon + \tau\mathbf{A}_t^E, \quad \mathbf{u}_t^{\tau} = \frac{\partial \mathbf{A}_t^{\tau}}{\partial \tau} = \mathbf{A}_t^E - \epsilon. \quad (30)$$

设动作专家输出的条件向量场为 $\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau)$, 则模仿微调可写为条件流匹配损失

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tau \sim p(\tau)} \left[\left\| \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) - (\mathbf{A}_t^E - \epsilon) \right\|_2^2 \right]. \quad (31)$$

最小化式(31)使网络学习式(30)的条件速度场。推理时从 $\mathbf{A}_t^0 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发, 沿

$$\frac{d\mathbf{A}_t^{\tau}}{d\tau} = \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) \quad (32)$$

由 $\tau = 0$ 正向积分至 $\tau = 1$, 即可得到条件动作序列样本 $\hat{\mathbf{A}}_t = \mathbf{A}_t^1$ 。以步长 $\Delta\tau > 0$ 进行欧拉离散时, 单步更新为

$$\mathbf{A}_t^{\tau+\Delta\tau} = \mathbf{A}_t^{\tau} + \Delta\tau \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau). \quad (33)$$

因此, 式(31)给出了示教动作对模型参数的监督关系, 式(32)和式(33)则给出了从随机噪声生成连续动作序列的推理过程。

5.4 阶段性工作小结

本节明确了已完成工作与待开展研究的边界。已完成部分包括机器人平台与坐标接口、VR 遥操作和示范数据采集、OpenPI 数据适配、 $\pi_{0.5}$ 任务示范微调以及“状态感知–OpenPI 推理–动作序列执行–状态更新”的单回合接口功能验证; 激光雷达定位与导航停靠作为平台既有能力可直接调用。尚未开展的部分对应本课题的三项方法: 作业前腕部视觉偏差估计尚未建立, 工位停靠误差尚未进入 $\pi_{0.5}$ 状态, 示范仍在标称停靠下采集, 推理阶段尚未加入风险判别模型与提前停止, 执行时域仍为全任务固定值, 尚未加入 RTC 连续衔接与风险驱动调度。因尚无统一误

差注入协议下的统计数据，本节不对现有接口流程声明完整任务链成功率或性能优势。

6 进度安排

研究周期自 2026 年 7 月起，至 2027 年 12 月止。各阶段按照“时间段–主要任务–阶段产出”编排，并在后期预留补充实验、设备维护和论文修改时间。

表 2: 研究进度安排

时间	主要任务	阶段产出
2026.07–2026.08	梳理文献与现有平台接口，确定四工位五子任务链及完成、失败、超时与安全判据；制定随机停靠示范采集规范与误差注入协议，完成开题报告撰写及开题答辩。	开题报告、任务规范与评价协议初稿。
2026.09–2026.10	研究局部视觉对工位相对位姿的表征能力，考察停靠误差估计与参考测量的可靠性；采集随机停靠示范，分析数据覆盖范围。	停靠误差表征方案、测量可靠性分析与示范数据集。
2026.11–2026.12	研究随机停靠示范与显式误差输入的作用，通过对照实验分析成功率随平移与航向误差变化的趋势。	停靠误差融合实验数据、容忍曲线与消融结论。
2027.01–2027.03	研究增广状态与候选动作对失败风险的表征能力，开展风险模型学习、输入消融和提前停止实验，分析预测质量与安全收益。	风险判别方法、预警能力与提前停止效果分析。
2027.04–2027.06	研究在线风险与执行步数的关联及 RTC 连续衔接，开展固定步数、分阶段切换与风险调度的对照实验，分析成功率与效率的权衡。	风险驱动调度方法、对照数据与效率权衡分析。
2027.07–2027.09	在四台机器人上开展方法组合与适用性实验，分析本体差异、方法相互影响及典型失败原因。	整体验证数据、失败分类与方法适用边界。

续表 2

时间	主要任务	阶段产出
2027.10–2027.12	核对数据、代码和图表，完成学位论文撰写、修改、送审与答辩准备。	学位论文定稿与答辩材料。

7 为完成课题所需的条件

本课题所需条件分为硬件与场景、算力、数据、软件四类，如表3所示。已具备部分为第5节完成集成的平台与处理流程，尚需补充部分按表2的阶段逐步完成。

表 3: 完成课题所需的条件

类别	已具备	尚需补充
硬件与场景	轮式双臂机器人（腰部 4 自由度、左右机械臂各 7 自由度、头部 2 自由度，配备夹爪、头部与腕部相机以及激光雷达导航系统）；实际物理生产场景中的 PCBA 四工位五子任务流程	固定观察位姿与工位参考观测；经精度核验的独立参考测量流程
算力	配备 8 张 NVIDIA A100 GPU、每张显存容量为 80 GB 的服务器；其中可分配一张 GPU 用于 $\pi_{0.5}$ 微调。	无。
数据	标称停靠下的 VR 遥操作示范回合	随机停靠示范；误差注入回合的训练、验证与测试集划分；失败时刻标注
软件	VR 遥操作与同步记录流程；OpenPI $\pi_{0.5}$ 微调与实体机器人部署流程；导航软件栈与笛卡尔控制接口	支持停靠误差表征、风险模型学习与动作序列调度的实验工具，以及统一的误差注入与评价条件。

8 研究过程中可能遇到的问题以及解决的措施

研究过程中可能遇到的主要问题及相应的解决措施如表4所示。

表 4: 可能遇到的问题及解决措施

可能遇到的问题	解决措施
多配置对比需反复微调 $\pi_{0.5}$ 模型，训练算力需求较大	使用联合培养企业的训练服务器完成模型微调，使用本地图形处理器执行模型推理和小规模验证
随机停靠示范数据采集耗时 长、人工成本高	复用已有标称停靠示范，仅补充采集随机停靠示范回合；利用多台机器人并行采集
实体机器人实验中误差注入 可能引发碰撞，损坏 PCBA 或夹爪	先以低速与限幅运行验证，设置位置与力的安全阈值和紧急停止机制，在安全验证后逐步扩大测试工况范围
风险判别模型的失败样本 少、失败时刻标注存在主观 性，易出现误报或漏报	补充不同误差条件下的受控试验，复核失败事件标注；研究样本不平衡与标注不确定性的影响，并分析误报、漏报和预警提前量之间的权衡
风险驱动调度在风险估计偏 高时退化为全程短时域，效 率提升有限	分析风险预测偏差和调度参数的敏感性，与固定步数及分阶段切换对照，明确风险驱动调度的有效条件
实体机器人与算力资源共用， 实验进度可能受影响	提前制定设备使用计划并完成预约，方法先在离线数据上验证，再集中安排实体机器人实验

9 参考文献

- [1] International Federation of Robotics. World Robotics 2025: Industrial Robots[R/OL]. Frankfurt am Main, Germany: IFR Statistical Department, 2025 [2026-09-02]. <https://ifr.org/worldrobotics/report-2025>.
- [2] 袁依格, 何卓丰, 李威, 等. 具身智能驱动的智能制造应用发展研究[J]. 中国工程科学, 2025, 27(3): 67-82. <http://dx.doi.org/10.15302/J-SSCAE-2025.04.016>.
- [3] Zhang C, Zhang C, Xu Z, et al. Embodied Intelligent Industrial Robotics: Framework and Techniques[J]. Journal of Manufacturing Systems, 2026, 88: 158-189. <http://dx.doi.org/10.1016/j.jmsy.2026.06.001>.
- [4] 郑南宁, 杨劭, 姜维周, 等. 具身智能发展趋势与展望[J]. 中国工程科学, 2026, 28(2): 1-13. <http://dx.doi.org/10.15302/J-SSCAE-2025.07.019>.
- [5] Firoozi R, Tucker J, Tian S, et al. Foundation Models in Robotics: Applications,

- Challenges, and the Future[J]. The International Journal of Robotics Research, 2025, 44(5): 701-739. <http://dx.doi.org/10.1177/02783649241281508>.
- [6] Brohan A, Brown N, Carbajal J, et al. RT-1: Robotics Transformer for Real-World Control at Scale: arXiv:2212.06817[R/OL]. Mountain View, California, USA: Google Research, 2022 [2026-09-02]. <https://arxiv.org/abs/2212.06817>.
- [7] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2165-2183.
- [8] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 6892-6903. <http://dx.doi.org/10.1109/ICRA57147.2024.10611477>.
- [9] Kim M J, Pertsch K, Karamcheti S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[C] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024.
- [10] Black K, Brown N, Driess D, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control[R/OL]. San Francisco, California, USA: Physical Intelligence, 2024 [2026-08-27]. <https://arxiv.org/abs/2410.24164>.
- [11] Black K, Brown N, Darpinian J, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-25]. <https://www.pi.website/download/pi05.pdf>.
- [12] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.016>.
- [13] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[C] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024: 4066-4083.
- [14] 兰沅卜, 赵文博, 朱凯, 等. 基于具身智能的移动操作机器人系统发展研究[J]. 中国工程科学, 2024, 26(1): 139-148. <http://dx.doi.org/10.15302/J-SSCAE-2024.01.010>.
- [15] 国务院. 政府工作报告——2025 年 3 月 5 日在第十四届全国人民代表大会

第三次会议上[R/OL]. 北京: 中华人民共和国国务院, 2025 [2026-09-02]. <http://lianghui.people.com.cn/2025/n1/2025/0312/c460142-40437673.html>.

- [16] Ren L, Dong J, Liu S, et al. Embodied Intelligence Toward Future Smart Manufacturing in the Era of AI Foundation Model[J]. *IEEE/ASME Transactions on Mechatronics*, 2025, 30(4): 2632-2642. <http://dx.doi.org/10.1109/TMECH.2024.3456250>.
- [17] Levine S, Wagener N, Abbeel P. Learning Contact-Rich Manipulation Skills with Guided Policy Search[C] // 2015 IEEE International Conference on Robotics and Automation (ICRA). 2015: 156-163. <http://dx.doi.org/10.1109/ICRA.2015.7138994>.
- [18] Inoue T, Magistris G D, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C] // 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2017: 819-825. <http://dx.doi.org/10.1109/IROS.2017.8202244>.
- [19] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C] // 2019 International Conference on Robotics and Automation (ICRA). 2019: 6023-6029. <http://dx.doi.org/10.1109/ICRA.2019.8794127>.
- [20] Ding G, Zang X, Wang P, et al. An Ensemble Reinforcement Learning Framework for Robotic High-Precision Peg-in-Hole Assembly via Human Demonstrations[J]. *Robotics and Computer-Integrated Manufacturing*, 2026, 100: 103279. <http://dx.doi.org/10.1016/j.rcim.2026.103279>.
- [21] Su J, Zheng J, Shen L. Robot Assembly Using Variable Admittance Control with Reinforcement Learning from Demonstrations in a Constrained Region[J]. *Robotics and Computer-Integrated Manufacturing*, 2026, 100: 103259. <http://dx.doi.org/10.1016/j.rcim.2026.103259>.
- [22] Tang B, Lin M A, Akinola I, et al. IndustReal: Transferring Contact-Rich Assembly Tasks from Simulation to Reality[C] // *Robotics: Science and Systems XIX*. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.039>.
- [23] Elguea-Aguinaco Í, Serrano-Muñoz A, Chrysostomou D, et al. A Review on Reinforcement Learning for Contact-Rich Robotic Manipulation Tasks[J]. *Robotics and Computer-Integrated Manufacturing*, 2023, 81: 102517. <http://dx.doi.org/10.1016/j.rcim.2022.102517>.
- [24] Yang C, Zeng C, Cong Y, et al. A Learning Framework of Adaptive Manipulative Skills from Human to Robot[J]. *IEEE Transactions on Industrial Informatics*, 2019, 15(2): 1153-1161. <http://dx.doi.org/10.1109/TII.2018.2826064>.

- [25] Qin F, Xu D, Zhang D, et al. Robotic Skill Learning for Precision Assembly with Microscopic Vision and Force Feedback[J]. IEEE/ASME Transactions on Mechatronics, 2019, 24(3): 1117-1128. <http://dx.doi.org/10.1109/TMECH.2019.2909081>.
- [26] Zang Y, Wang P, Zha F, et al. Peg-in-Hole Assembly Skill Imitation Learning Method Based on ProMPs under Task Geometric Representation[J]. Frontiers in Neurorobotics, 2023, 17: 1320251. <http://dx.doi.org/10.3389/fnbot.2023.1320251>.
- [27] S3ti G, Huang X, Wurll C, et al. Train What You Know – Precise Pick-and-Place with Transporter Networks[C] // 2023 IEEE International Conference on Robotics and Automation (ICRA). 2023: 5814-5820. <http://dx.doi.org/10.1109/ICRA48891.2023.10161242>.
- [28] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation[C] // Proceedings of Machine Learning Research, Vol 164: Proceedings of the 5th Conference on Robot Learning. [S.l.]: PMLR, 2022: 1678-1690.
- [29] Xia F, Li C, Mart3n-Mart3n R, et al. ReLMoGen: Leveraging Motion Generation in Reinforcement Learning for Mobile Manipulation[C] // 2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 4583-4590. <http://dx.doi.org/10.1109/ICRA48506.2021.9561315>.
- [30] Honerkamp D, Welschehold T, Valada A. N²M²: Learning Navigation for Arbitrary Mobile Manipulation Motions in Unseen and Dynamic Environments[J]. IEEE Transactions on Robotics, 2023, 39(5): 3601-3619. <http://dx.doi.org/10.1109/TRO.2023.3284346>.
- [31] Yang T, Jing Y, Wu H, et al. MOMA-Force: Visual-Force Imitation for Real-World Mobile Manipulation[C] // 2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2023: 6847-6852. <http://dx.doi.org/10.1109/IROS55552.2023.10342371>.
- [32] Qiu R-Z, Song Y, Peng X, et al. WildLMa: Long Horizon Loco-Manipulation in the Wild[C] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 10011-10019. <http://dx.doi.org/10.1109/ICRA55743.2025.11128535>.
- [33] 全球首个具身智能工业产线规模落地：智元精灵 G2 连续 8 小时作业零失误[EB/OL]. 新浪科技, 2026-04-15 [2026-09-04]. <https://finance.sina.com.cn/tech/digi/2026-04-15/doc-inhupvfe0971382.shtml>.

- [34] 孙小程. 智元第 15000 台机器人交付至龙旗产线机器人“工友”交出怎样的答卷? [EB/OL]. 上海证券报, 2026-06-30 [2026-09-04]. https://paper.cnstock.com/html/2026-06/30/content_2237360.htm.
- [35] AgiBot-World-Contributors, Bu Q, Cai J, et al. AgiBot World Colosseo: A Large-Scale Manipulation Platform for Scalable and Intelligent Embodied Systems: arXiv:2503.06669[R/OL]. Shanghai, China: AgiBot, 2025 [2026-09-04]. <https://arxiv.org/abs/2503.06669>.
- [36] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.026>.
- [37] Ze Y, Zhang G, Zhang K, et al. 3D Diffusion Policy: Generalizable Visuomotor Policy Learning via Simple 3D Representations[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.067>.
- [38] Wang C, Fang H, Fang H-S, et al. RISE: 3D Perception Makes Real-World Robot Imitation Simple and Effective[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 2870-2877. <http://dx.doi.org/10.1109/IROS58592.2024.10801678>.
- [39] Shi L X, Sharma A, Zhao T Z, et al. Waypoint-Based Imitation Learning for Robotic Manipulation[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2195-2209.
- [40] Octo Model Team, Ghosh D, Walke H, et al. Octo: An Open-Source Generalist Robot Policy[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.090>.
- [41] Khazatsky A, Pertsch K, Nair S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[C] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.120>.
- [42] Liu S, Wu L, Li B, et al. RDT-1B: A Diffusion Foundation Model for Bimanual Manipulation[C] // The Thirteenth International Conference on Learning Representations (ICLR). 2025.
- [43] Wen J, Zhu Y, Li J, et al. TinyVLA: Toward Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation[J]. IEEE Robotics and Automation Letters, 2025, 10(4): 3988-3995. <http://dx.doi.org/10.1109/LRA.2025.3544909>.
- [44] Liu J, Liu M, Wang Z, et al. RoboMamba: Efficient Vision-Language-Action Model

- for Robotic Reasoning and Manipulation[C] // Advances in Neural Information Processing Systems 37 (NeurIPS). 2024.
- [45] Bu Q, Yang Y, Cai J, et al. UniVLA: Learning to Act Anywhere with Task-centric Latent Actions[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.014>.
 - [46] Pertsch K, Stachowicz K, Ichter B, et al. FAST: Efficient Action Tokenization for Vision-Language-Action Models[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-27]. <https://arxiv.org/abs/2501.09747>.
 - [47] Kim M J, Finn C, Liang P. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.017>.
 - [48] Pumacay W, Singh I, Duan J, et al. THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation[C] // Proceedings of Robotics: Science and Systems. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.133>.
 - [49] Jin S, Wang R, Zahid M, et al. How Physics and Background Attributes Impact Video Transformers in Robotic Manipulation: A Case Study on Planar Pushing[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 7391-7398. <http://dx.doi.org/10.1109/IROS58592.2024.10802583>.
 - [50] Ishida Y, Noguchi Y, Kanai T, et al. Robust Imitation Learning for Mobile Manipulator Focusing on Task-Related Viewpoints and Regions[C] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024.
 - [51] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[C] // 2018 IEEE International Conference on Robotics and Automation (ICRA). 2018: 3803-3810. <http://dx.doi.org/10.1109/ICRA.2018.8460528>.
 - [52] Mandlekar A, Garrett C, Xu D, et al. Human-in-the-Loop Task and Motion Planning for Imitation Learning[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 3030-3060.
 - [53] Mees O, Hermann L, Rosete-Beas E, et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks[J]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334. <http://dx.doi.org/10.1109/LRA.2022.3180108>.

- [54] Liu B, Zhu Y, Gao C, et al. LIBERO: Benchmarking Knowledge Transfer for Life-long Robot Learning[C] // Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track (NeurIPS). 2023.
- [55] Liu H, Dass S, Martín-Martín R, et al. Model-Based Runtime Monitoring with Interactive Imitation Learning[C] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 4154-4161. <http://dx.doi.org/10.1109/ICRA57147.2024.10611038>.
- [56] Xu C, Nguyen T K, Dixon E, et al. Can We Detect Failures Without Failure Data? Uncertainty-Aware Runtime Failure Detection for Imitation Learning Policies[C] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.073>.
- [57] Dai Y, Lee J, Fazeli N, et al. RACER: Rich Language-Guided Failure Recovery Policies for Imitation Learning[C] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025. <http://dx.doi.org/10.1109/ICRA55743.2025.11127799>.
- [58] Liu Z, Bahety A, Song S. REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction[C] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023.
- [59] Black K, Galliker M Y, Levine S. Real-Time Execution of Action Chunking Flow Policies[C] // Advances in Neural Information Processing Systems 38 (NeurIPS). 2025. <http://dx.doi.org/10.52202/085713-1122>.