

哈尔滨工业大学

硕士学位论文开题报告

题 目：面向 PCBA 上下料的轮式双臂模仿学习策略
鲁棒性改进研究
(学位论文)

学 院 (部) 请填写学院 (部)

学科/专业学位类别 请填写学科或专业

导 师 请填写导师姓名及职称

研 究 生 请填写姓名

学 号 请填写学号

开题报告日期 2026 年 9 月

研究生院制

目 录

1 课题来源及研究的目的和意义	1
1.1 课题来源与研究背景	1
1.2 研究目的与意义	2
2 国内外研究现状及分析	4
2.1 工业操作策略学习的技术演进	4
2.2 移动操作与工位停靠误差	4
2.3 动作分块模仿学习与视觉-语言-动作模型	5
2.4 位姿扰动鲁棒性、数据覆盖与评价基准	7
2.5 动作块执行与闭环频率	8
2.6 运行时失败检测与恢复	9
2.7 国内外比较与研究现状评述	9
3 主要内容及方案	10
3.1 研究主线与总体技术路线	10
3.2 任务定义与停车误差传递问题	10
3.3 改进点一：停车残差状态输入与随机停车数据增强（事前）	12
3.4 改进点二：分阶段动作块执行（事中）	13
3.5 改进点三：基于时序集成不一致度的失败检测与模板恢复（事后）	15
3.6 整体验证方案	16
3.7 可行性分析	17
4 预期达到的目标	17
5 已完成的学术研究/实践工作	18
5.1 实验平台与坐标系定义	18
5.2 基于 VR 遥操作的示范数据采集	19
5.3 ACT 对照基线与基于 OpenPI 的 $\pi_{0.5}$ 推理闭环	22
5.4 阶段性工作小结	24
6 进度安排	25
7 为完成课题所需的条件	26
8 研究过程中可能遇到的问题以及解决的措施	27
9 参考文献	28

1 课题来源及研究的目的和意义

1.1 课题来源与研究背景

【填写提示：课题来源：请填写具体项目或工程需求名称及编号。】

印制电路板组件（Printed Circuit Board Assembly, PCBA）检测工位的上下料是电子制造产线中重复性高、节拍要求明确的环节。一次完整的上下料包含五个子任务：从上料百叶车夹取待测 PCBA、移动至扫码工位完成扫码登记、从检测台取出已完成检测的上一块 PCBA、将当前 PCBA 放入检测台、最后将上一块 PCBA 放入下料百叶车。上述子任务分布在不同工位，机器人需要在工位间移动并停靠；其中夹取百叶车槽位中的 PCBA、将 PCBA 插入检测台以及放回百叶车槽位均属于对准精度要求接近槽位间隙的精细操作，其余移动与抓取则属于容差较大的自由空间运动。本课题所用轮式双臂机器人由移动底盘、四自由度腰部、两条七自由度机械臂、二自由度头部与末端夹爪组成，配置头部相机和左右腕部相机，并由激光雷达定位与传统导航算法在工位间移动。该平台在感知与操作能力上能够覆盖上述五个子任务，但工位停靠精度由导航与定位模块决定，通常处于厘米级。

面向这类多阶段双臂任务，以遥操作示范驱动的模仿学习已成为主流策略学习路线。动作分块 Transformer（Action Chunking with Transformers, ACT）以低成本遥操作数据学习精细双臂操作^[1]， $\pi_{0.5}$ 等视觉-语言-动作（Vision-Language-Action, VLA）模型则借助预训练通用表征降低下游任务的示范需求^[2]。课题组已在上述平台上分别打通 ACT 与基于 OpenPI 部署的 $\pi_{0.5}$ 两条“虚拟现实（Virtual Reality, VR）遥操作数据采集-模型微调-真机部署”流水线，能够在名义停靠位姿下完成示范采集、微调与真机执行。然而，示范数据均在名义停靠位姿下采集，当机器人实际停靠位姿偏离名义位姿时，策略在精细阶段的成功率将随偏差增大而下降，并且失败往往伴随对 PCBA 或夹具的机械挤压。

本研究将该现象归纳为一条误差传递链，如图1所示。首先，激光雷达定位与导航停靠产生厘米级的位置与航向残差；其次，策略未曾见过带残差的观测与状态组合，动作块推理在自由空间阶段尚可依赖视觉纠正，进入进槽、落台等精细阶段后，残差经机械臂作业半径被放大为末端对准误差；最后，动作块以开环方式整段执行，策略不感知偏差，错误动作持续输出直至任务失败或造成损坏。该链条上的三个环节对应三种不同性质的缺陷：状态输入缺少停车残差信息、动作块执行粒度与阶段精度需求不匹配、运行时缺少失败检测与恢复机制。

针对上述三个环节，本课题提出“事前-事中-事后”三层设防的鲁棒性改进思路：事前将停车残差作为策略状态输入并以随机停车示范扩大数据覆盖；事中按任务阶段调整动作块的执行长度，在精细阶段缩短开环执行并提高重推理频率；




图 1: PCBA 上下料任务中的模仿学习策略闭环与停车误差传递链

事后利用时序集成中重叠预测之间的不一致度进行免训练的失败检测，并以固定模板执行恢复与重试。三层改进均不改变策略网络结构，分别作用于数据与状态、推理执行和运行时监控，可逐层叠加并在同一残差注入协议下比较。这一从已跑通流水线的真机部署需求出发、沿误差传递链逐环节设防的研究情境，构成本课题的直接来源。

1.2 研究目的与意义

本研究的总体目的是，面向 PCBA 上下料这一跨多工位、含精细对准阶段的轮式双臂任务，在已跑通的模仿学习流水线基础上，沿停车误差传递链建立可逐层叠加、可统一验证的策略鲁棒性改进方法。以基于 OpenPI 微调的 $\pi_{0.5}$ 为主线模型、ACT 为对照基线，具体目的包括以下三个方面。

- (1) 事前：将激光雷达定位给出的停车残差 $(\delta x, \delta y, \delta \theta)$ 作为显式状态输入拼接到策略本体状态中，并在示范采集时引入 ± 3 厘米范围的随机停靠，使策略学习“残差-动作修正”的对应关系；通过固定停车、随机停车和随机停车加残差输入三组消融，分离数据覆盖与显式条件两种作用。
- (2) 事中：在不重新训练模型的前提下，按自由空间与精细操作两类阶段设置不同的动作块执行长度，精细阶段仅执行块首若干步即重新推理，以缩短开环执行区间；与固定执行步数方式在成功率和推理时延两方面比较。
- (3) 事后：以时序集成中多次推理对同一时刻动作预测的方差定义不一致度，以

成功回合的分位数标定阈值，实现无需额外训练的在线失败检测，并配合回退至安全高度、重试一次的模板化恢复；以召回率、误报率、提前量和最终成功率评价其收益。

图2给出了本课题的研究切入路线。已跑通的两条流水线提供了可复现的基线与真机测试条件；真机部署中的失败观察引出停车误差传递链；三层设防分别对应链条的三个环节，并在统一的残差注入协议、五工位任务链和多台机器人条件下按“基线-加改进一-加改进一二-加改进一二三”的顺序叠加验证。验证结果还将反向修正示范采集规范与部署参数。




图 2：从已跑通流水线到三层设防的研究切入路线

本研究的工程意义在于提高模仿学习策略在真实产线条件下的可用性与物料安全性。工位停靠误差是移动操作机器人部署中不可避免的扰动，若策略只能在名义停靠位姿附近工作，则每次部署都需要人工校准或高精度定位设备。显式残差输入与随机停车数据增强使策略对停靠偏差具备一定容忍度；分阶段执行降低精细阶段的开环风险；失败检测与模板恢复则在策略已经出错时限制损失范围，避免持续挤压 PCBA 或夹具。三者共同作用可以降低对定位精度和人工干预的依赖，为在多台机器人、多条产线上复用同一策略提供条件。

本研究的方法意义在于，将“模仿学习策略对位姿扰动不鲁棒”这一笼统判断分解为误差传递链上三个可独立度量、可逐层验证的问题，并给出对应的低成本解决方案。三层改进均不依赖特定网络结构：残差输入只扩展状态维度，分阶段执行只调整推理侧参数，失败检测只利用动作块推理已有的重叠预测。因此，相关结论有望迁移到其他以动作块为输出的模仿学习策略和其他移动操作任务。基于时序集成不一致度的失败检测还为 VLA 模型的部署提供了一种无需失败数据、无需额外训练的运行时监控手段。

综上，本课题的研究必要性源于模仿学习策略从实验室名义条件走向产线部署时，对停靠误差、执行粒度和运行时失败三方面缺乏系统处理的现状。为明确相关问题的已有解决路径与适用边界，后续按研究对象与方法类型对国内外相关研究进行梳理与评述。

2 国内外研究现状及分析

2.1 工业操作策略学习的技术演进

本研究关注的对象是工业场景中由机器人闭环完成的抓取、放置与插接类操作，其特点是对准公差小、失效代价高、节拍要求明确。早期学习方法主要面向接触丰富的装配任务，通过强化学习或力控制在交互中学习插入与对准动作。Levine 等将引导策略搜索用于接触操作，以局部轨迹优化为神经网络策略提供监督信号^[3]；Inoue 等在高精度装配中采用深度强化学习，使策略根据状态反馈学习探索与插入动作^[4]；残差强化学习保留既有控制器，仅学习基础控制之外的修正量^[5]。对接触丰富操作的综述指出，样本效率、奖励建模、仿真到真机迁移与安全约束是该类方法进入产线的主要障碍^[6]。上述路线依赖真机交互或高保真仿真，在多阶段、跨工位的产线任务中难以直接铺开。

低成本遥操作与动作分块模仿学习的出现改变了这一局面。ACT 以自定义遥操作接口采集示范，用条件变分自编码器与 Transformer 一次预测一段动作序列，在少量示范条件下完成开盖、电池入槽等精细双臂任务^[1]；扩散策略将动作序列建模为条件去噪过程，以概率生成方式表达同一观测下的多种合理动作^[7]。二者共同表明，多阶段双臂操作可以直接从示范中学得，而无需人工设计接触模式或奖励。VLA 模型进一步引入视觉语言预训练，使下游任务微调所需示范量显著减少，并能够在同一模型中处理多任务与语言指令^[2]。

与此同时，工业抓放对精度的要求并未降低。IndustReal 在仿真中训练取放与插装策略并迁移到真实工业机械臂，为此专门设计了几何奖励、采样课程与部署端动作积分器，以消除接触仿真误差与稳态对准误差^[8]；Sóti 等针对精密抓放改进 Transporter 网络的平移与旋转精度，并以由粗到细的迭代推理在真实插块任务上验证，说明毫米级的放置偏差即决定任务成败^[9]。因此，模仿学习策略进入工业抓放场景时，需要在示范驱动的便利性与精细阶段的对准精度之间建立明确的处理机制。本课题的 PCBA 进槽与落台正属于此类精细阶段，而策略的输入来源、执行粒度与运行时监控是否与该精度需求相匹配，构成后续评述的主线。

2.2 移动操作与工位停靠误差

轮式双臂机器人在工位间移动后再执行操作，属于移动操作（Mobile Manipulation）问题，其核心困难之一是底盘定位误差向操作阶段的传递。Mobile ALOHA

将 ALOHA 双臂系统安装在移动底盘上，以全身遥操作同步采集底盘与双臂示范，并把底盘速度纳入模仿学习的动作空间；该工作还表明与静态 ALOHA 数据协同训练能够显著提高移动任务的数据效率，但其移动与操作由同一策略端到端输出，未显式处理停靠残差^[10]。ReLMoGen 让学习策略只预测子目标，由经典运动生成器负责到达，体现了学习决策与经典运动执行分层的思路^[11]；N²M² 在给定末端轨迹的条件下学习底盘与躯干运动，使移动操作机器人在未知环境中保持末端运动学可达^[12]。上述工作把底盘运动纳入学习范围，但均以底盘持续运动为前提，与本课题“停靠后锁定底盘、仅由双臂操作”的产线流程不同。

对停靠后操作误差的补偿主要出现在力觉与技能组合研究中。MOMA-Force 在真实移动操作接触任务中同时模仿动作与目标力/力矩，由导纳式全身控制器跟踪，直接处理底盘定位残差带来的末端接触误差^[13]；WildLMa 以全身控制器为底层、少量示范技能为中层、大语言模型组合技能为高层，在真实环境中完成长时序移动操作^[14]。Mandlekar 等提出的人在回路任务与运动规划框架把自由空间搬运交给自动规划，仅对接触段采集遥操作示范，从数据采集角度区分了自由空间与精细阶段^[15]。Ishida 等针对移动操作机器人换工位后自遮挡与背景变化导致的失败，提出关注任务相关视角与图像区域的鲁棒模仿学习方法，说明停靠位姿差异会同时改变本体状态与图像观测^[16]。

综合来看，现有研究已认识到底盘定位残差对操作阶段的影响，但处理方式集中在力控补偿、技能组合或视觉表征，尚未见把激光雷达定位给出的停车残差直接作为策略状态输入、并在示范采集中系统覆盖随机停靠的工作。这一空缺正是本课题改进点一的出发点。

2.3 动作分块模仿学习与视觉-语言-动作模型

基于示范的模仿学习通过专家轨迹建立观测到动作的映射，能够在不进行大范围随机探索的条件下为机器人提供可执行的策略。早期方法通常将任务分解为接近、搜索、对准和插入等阶段，再以动态或概率运动原语显式表示轨迹分布^[17-19]。这类方法对少量数据较为友好，且中间变量便于解释，但依赖人工分段与任务坐标系先验，难以复用到对象、场景和指令持续变化的任务中。RoboMimic 基准对不同质量的人类示范和多类离线学习算法进行了系统比较，表明观测空间、历史信息、示范质量与模型选择都会影响策略性能^[20]，端到端行为克隆由此成为主流。

动作分块是当前端到端模仿学习的核心技术。ACT 不再逐时刻独立预测动作，而是一次生成一段动作序列，并在推理时对多次预测的重叠部分进行指数加权的时序集成，以降低单步行为克隆的误差累积与动作抖动^[1]。扩散策略将动作序列建模为条件去噪过程，以滚动时域方式执行预测序列的近期部分并重新规划^[7]，其

总体结构如图3所示。3D 扩散策略与 RISE 分别以点云替代图像作为输入，提高了策略对视角与外观变化的鲁棒性^[21,22]；航点式模仿学习则自动从示范中抽取少量关键路点，以缩短行为克隆的决策时域^[23]。这些工作均把动作块长度和每次执行的步数作为固定超参数：块长增大有利于时序一致性，但延长了开环执行区间；块长减小提高闭环频率，却增加推理负担与动作抖动。




图 3: 扩散视觉动作策略的观测条件化与动作序列生成框架^[7]

视觉-语言-动作模型在上述视觉动作策略基础上引入语言条件和视觉语言预训练知识。RT-1 以 Transformer 在大规模真机数据上学习语言条件策略^[24]，RT-2 把视觉语言模型直接微调为动作输出模型^[25]；Open X-Embodiment 聚合多机构、多本体数据训练 RT-X 模型^[26]，Octo 与 OpenVLA 在其上分别以扩散动作头和离散动作词元建立开源通用策略^[27,28]；DROID 提供了跨场景、跨操作者的大规模真机示范数据^[29]。围绕双臂操作与部署效率，RDT-1B 采用扩散 Transformer 与统一动作空间学习双臂表示^[30]，TinyVLA、RoboMamba 与 UniVLA 分别从轻量骨干、高效序列建模和任务中心潜在动作方面降低训练与推理成本^[31-33]。

在动作表示方面，Physical Intelligence 提出的 π_0 将预训练视觉语言模型与独立的动作专家结合，动作专家以流匹配目标生成连续动作块，从而在保留语言与视觉语义表征的同时适配高频、连续的机器人控制^[34]。其训练过程区分覆盖多任务、多本体数据的预训练与面向下游技能的后训练：前者用于获得可迁移的通用能力，后者使用质量更高的任务示教形成稳定执行策略。由 ACT 到 π_0 的技术推进并非简单增加模型规模，而是将动作分块从单任务行为克隆的输出形式扩展为 VLA 动作专家的连续生成对象，并把任务级示教微调纳入通用模型的训练链路。

随后， π_0 -FAST 采用频域动作序列标记化（Frequency-space Action Sequence Tokenization, FAST），将高频连续轨迹压缩为离散动作标记，以自回归方式提高大规模 VLA 训练效率^[35]。该方法与 π_0 的流匹配路线形成连续动作生成和离散动作

建模两种实现。 $\pi_{0.5}$ 在此基础上进一步整合两条路线：预训练阶段采用 FAST 离散动作标记，以便将机器人动作数据与图文、目标检测和高层语义预测等异构任务共同训练；后训练阶段加入与 π_0 一致的流匹配动作专家，以连续动作块支持实时控制^[2]。在推理阶段， $\pi_{0.5}$ 先根据视觉观测与总体指令预测语言形式的高层子任务，再以该子任务为条件生成低层连续动作，从而把任务分解与动作控制纳入同一模型。由此， π 系列形成了“ π_0 建立流匹配动作专家- π_0 -FAST 提高动作序列训练效率- $\pi_{0.5}$ 通过异构协同训练和高低层统一推理扩展开放环境泛化”的演进路径。

上述研究表明，VLA 模仿学习已形成基于通用模型、通过任务示范进行下游微调的技术路线，且以动作块作为统一的输出形式。本课题以基于 OpenPI 微调的 $\pi_{0.5}$ 为主线模型、以 ACT 为对照，重点不在于改变模型结构，而在于检验数据与状态输入、动作块执行粒度和运行时监控三个环节对停靠误差的处理能力。

2.4 位姿扰动鲁棒性、数据覆盖与评价基准

模仿学习策略对训练分布之外的观测缺乏保证，位姿扰动是工业部署中最常见的分布偏移来源之一。Pumacay 等提出的 THE COLOSSEUM 基准把对象位姿、相机位姿、光照、背景、干扰物与物理参数等扰动轴分离开来，逐轴报告策略性能随扰动强度的变化，从而把“泛化能力”转化为可分级度量的退化曲线^[36]，其任务与扰动组织方式如图4所示。Jin 等的案例分析进一步表明，视觉策略可能同时依赖任务相关物理线索与背景视觉属性^[37]；Ishida 等则专门考察了移动操作中视角与背景变化对示范策略的影响^[16]。停车残差同时改变本体状态与三路相机视角，属于典型的多轴耦合扰动。

提高扰动鲁棒性的主要途径是扩大训练数据对扰动的覆盖，或向策略提供扰动的显式条件。动力学随机化通过扩大仿真参数分布提高策略对模型偏差的容忍度^[38]，其思想同样适用于真机示范采集中的初始位姿随机化；航点式模仿学习把动作锚定在少量关键路点上，减少了对精确轨迹复现的依赖^[23]。在评价协议方面，CALVIN 以语言条件的长时序任务链考察策略连续完成多个子任务的成功率，显式呈现误差随任务链长度的累积^[39]；LIBERO 以程序化生成的任务套件评估策略的知识迁移与遗忘^[40]；DROID 与 Open X-Embodiment 均建议按机器人、场景或日期分组留出以避免评价泄漏^[26,29]；RoboMimic 则强调示范质量与训练终止规则对结论的影响^[20]。

对本课题而言，上述工作提供了两方面依据。其一，停车残差可以作为一条明确的扰动轴，以程序化注入的方式分级施加，并绘制成功率随残差幅值变化的容忍曲线；其二，“随机停车数据增强”对应数据覆盖，“残差状态输入”对应显式条件，二者在文献中通常独立出现，其相对贡献需要通过固定停车、随机停车、




图 4: Pumacay 等提出的 THE COLOSSEUM 基准：任务层级与扰动维度^[36]

随机停车加残差输入三组消融来识别，这正是改进点一实验设计的来源。

2.5 动作块执行与闭环频率

动作块策略的执行方式决定了开环区间长度与推理频率之间的权衡。ACT 的消融表明块长增大总体上提高成功率，而时序集成通过对重叠预测加权平均进一步改善动作平滑性；两者均以固定块长与固定执行步数实现^[1]。扩散策略同样采用固定的预测时域与执行时域，并指出执行时域过长会削弱对新观测的响应^[7]。OpenVLA-OFT 系统比较了 VLA 微调中的动作解码方式、动作表示与学习目标，提出并行解码、连续动作块与 L1 回归相结合的高效微调方案，并把动作吞吐率作为与成功率并列的评价指标^[41]。FAST 通过频域动作词元压缩缩短自回归解码长度^[35]， $\pi_{0.5}$ 则以流匹配动作专家非自回归地生成整段动作块^[2]，两者都把降低单次推理成本作为实时控制的前提。

现有工作普遍将块长视为训练期确定的超参数，并在部署时对整个任务采用单一执行步数。对于 PCBA 上下料这类自由空间移动与精细对准交替出现的任务，长动作块在进槽、落台等接触阶段可能过度开环，而全程采用短执行步数又会显著提高推理开销。自由空间阶段可以容忍较长的开环执行，精细阶段则需要更短的执行区间以便及时纠正残差引起的偏差。在推理侧按阶段切换执行步数、并同时报告成功率与时延，尚未见系统的实现与评价，这是改进点二所要验证的内容。

2.6 运行时失败检测与恢复

模仿学习策略在分布外状态下的失败往往在动作层面提前显现，运行时失败检测的目标是在造成损坏之前发出预警。FAIL-Detect 提出只用成功示范数据进行模仿策略在线失败检测的模块化方法：从观测、视觉特征与策略动作中提取失败相关标量，以流密度估计建模不确定性，并用保形预测校准时变阈值，将失败识别表述为序列分布外检测，从而无需预先枚举失败类型或采集失败数据^[42]。Liu 等在交互式模仿学习部署中于共享潜空间训练动力学模型与失败分类器，通过对未来轨迹采样预测异常与失败，并结合分布外判据触发人工介入^[43]。在恢复方面，RACER 以视觉语言模型监督器在线描述错误与空间修正，由语言条件策略执行恢复动作，训练数据包含自动生成的扰动与恢复轨迹^[44]；REFLECT 把多模态历史压缩为可解释的失败报告，并由语言规划器生成纠正方案^[45]。

上述检测器普遍需要额外训练密度模型、分类器或恢复策略，且其信号来源与策略本身的动作生成过程相互独立。动作块策略的时序集成天然提供了另一类信号：同一时刻的动作由多次不同观测条件下的推理共同预测，当状态处于示范分布内时，这些预测应当一致；当停靠残差把状态推离示范分布时，预测之间的分歧会增大。以重叠预测之间的方差定义不一致度、以成功回合分位数标定阈值，可以在不引入新模型与失败数据的前提下实现在线检测，并与固定模板的恢复动作配合。该思路可视为 FAIL-Detect 框架的免训练简化实现，其检测性能、提前量与对总时延的影响需要在本课题的任务中实证检验，这构成改进点三。

2.7 国内外比较与研究现状评述

现有研究已形成三点共识。第一，多阶段双臂操作可以通过低成本遥操作示范与动作分块模仿学习获得，VLA 预训练进一步降低了下游任务的示范需求。第二，位姿扰动是模仿学习策略部署中的主要分布偏移来源，扩大数据覆盖与提供显式条件是两条互补的鲁棒性途径，评价应报告性能随扰动强度的退化曲线而非单一成功率。第三，动作块的执行方式与运行时监控直接决定策略在真实系统中的安全性，成功率之外还需要报告时延、误报与干预次数。

就本次检索的代表性样本而言，国外研究在动作分块模仿学习、移动操作全身遥操作、通用 VLA 模型与失败检测框架方面起步较早^[1,10,28,42]；国内团队在双臂扩散基础模型、轻量与高效 VLA 结构和三维输入模仿学习方面形成了针对性较强的研究^[21,22,30-33]，哈工大团队在精密装配示范学习方面也有持续积累^[19]。上述比较限于所选代表性样本及相应的方法侧重。

将上述进展映射到本课题的目标场景，仍有三个问题有待验证。其一，移动操作研究已认识到底盘定位残差的影响，但尚无工作把激光雷达定位给出的停车残

差作为策略的显式状态输入，并在示范采集中系统覆盖随机停靠；数据覆盖与显式条件的相对贡献亦缺少消融证据。其二，动作块执行长度在现有工作中是全任务统一的固定超参数，按自由空间与精细阶段区别设置执行步数的收益与时延代价尚未被系统评价。其三，现有失败检测器依赖额外训练，时序集成重叠预测的不一致度能否作为免训练的失败信号、其召回率与误报率能否满足产线要求，仍需实证。

基于以上问题，本研究以已跑通的 $\pi_{0.5}$ 与 ACT 流水线为基线，沿“停车误差-精细阶段放大-错误动作持续”的传递链依次设置事前、事中、事后三层改进，并在统一的残差注入协议、五工位任务链和多台机器人条件下按层叠加验证。研究的核心可检验问题是：三层改进能否在不改变策略网络结构的前提下，分别并累计地提高策略对停车误差的容忍度、精细阶段的成功率与失败发生后的可控性。

3 主要内容及方案

3.1 研究主线与总体技术路线

本课题的研究主线是停车误差在模仿学习策略执行过程中的传递与放大。如图5所示，误差传递链包含三个环节：激光雷达定位与导航停靠产生厘米级的位置与航向残差；残差在进槽、落台等精细阶段经机械臂作业半径放大为末端对准误差；动作块开环执行使错误动作持续输出直至失败或损坏。针对三个环节，本课题分别设置事前、事中、事后三层改进：改进点一以停车残差状态输入与随机停车数据增强补偿残差本身；改进点二以分阶段动作块执行缩短精细阶段的开环区间；改进点三以时序集成不一致度检测失败并以固定模板恢复。三层改进在技术与实验上相互依赖：残差注入下的容忍曲线是三层共同的评价基准；改进点二在精细阶段提高重推理频率，为改进点三提供密集的重叠预测；改进点一的残差注入在容忍边界之外制造受控的失败回合，为改进点三提供检测评价样本。

策略模型以基于 OpenPI 微调的 $\pi_{0.5}$ 为主线，三层改进均在其动作块推理接口上实现；同一数据上微调的 ACT 作为对照基线，用于说明改进点一的收益是否依赖特定模型。所有改进均不改变策略网络结构：改进点一只扩展状态维度与归一化统计量，改进点二与改进点三只作用于推理侧。整体验证按“基线-加改进点一-加改进点一二-加改进点一二三”四种配置逐层叠加，在相同的残差注入档位、相同的五工位任务链和相同的机器人上比较端到端成功率与时延。

3.2 任务定义与停车误差传递问题

PCBA 上下料任务由五个子任务顺序组成，记子任务集合为 $\mathcal{L} = \{\text{rack_pick}, \text{scan}, \text{unload_tester}, \text{load_tester}, \text{rack_place}\}$ ，分别对应从上料百叶车夹取 PCBA、扫码登记、从检测台取出上一块 PCBA、将当前 PCBA

名义工位系的变换

$$\Delta \mathbf{T}_k = ({}^O\mathbf{T}_{S_k})^{-1} {}^O\mathbf{T}_B = \begin{bmatrix} \mathbf{R}(\delta\theta_k) & \delta\mathbf{p}_k \\ \mathbf{0}^T & 1 \end{bmatrix}, \quad \delta\mathbf{p}_k = (\delta x_k, \delta y_k, \delta\theta_k)^T, \quad (1)$$

式中，底盘停靠于水平地面，残差退化为平面位姿； $\delta\mathbf{p}_k = (\delta x_k, \delta y_k)^T$ 为名义工位系中的位置残差， $\delta\theta_k$ 为航向残差， $\mathbf{R}(\cdot)$ 为平面旋转矩阵。以平面位姿 (x, y, θ) 表示时，

$$\delta\theta_k = \theta_B - \theta_{S_k}, \quad \delta\mathbf{p}_k = \mathbf{R}(\theta_{S_k})^T \left(\begin{bmatrix} x_B \\ y_B \end{bmatrix} - \begin{bmatrix} x_{S_k} \\ y_{S_k} \end{bmatrix} \right). \quad (2)$$

停车残差对操作精度的影响可由目标点在基座系中的位置变化刻画。设槽位、检测台卡口等操作目标固连于工位，在名义工位系中的平面位置为 $\mathbf{p}_G^{S_k}$ 。示范策略隐含地假定基座与工位系重合，其动作以 $\mathbf{p}_G^{S_k}$ 为目标；实际停靠后，同一目标在基座系中的位置为 $\mathbf{R}(\delta\theta_k)^T (\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k)$ ，与策略隐含目标之差为

$$\mathbf{e}_p = \mathbf{R}(\delta\theta_k)^T (\mathbf{p}_G^{S_k} - \delta\mathbf{p}_k) - \mathbf{p}_G^{S_k} \approx -\delta\mathbf{p}_k - \delta\theta_k \mathbf{J} \mathbf{p}_G^{S_k}, \quad \mathbf{J} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}, \quad (3)$$

其中，近似取到 $\delta\theta_k$ 的一阶项。由此得到末端对准误差的上界

$$\|\mathbf{e}_p\| \leq \|\delta\mathbf{p}_k\| + |\delta\theta_k| \|\mathbf{p}_G^{S_k}\|. \quad (4)$$

式(4)表明，位置残差直接进入末端误差，航向残差则经目标距离 $\|\mathbf{p}_G^{S_k}\|$ 放大；后者与机械臂作业半径同量级，因此零点几度的航向残差即可贡献毫米级误差。二者叠加后与 PCBA 进槽、落台的对准间隙同量级，这是误差传递链第一环节“厘米级停车误差在精细阶段放大”的定量依据。自由空间阶段的抓取目标容差较大，策略可依赖视觉纠正；精细阶段的偏差一旦超过间隙，动作块继续执行便导致卡滞或挤压。

3.3 改进点一：停车残差状态输入与随机停车数据增强（事前）

改进点一在数据与状态两个层面处理残差。数据层面，示范采集时不再要求机器人停靠于名义位姿，而是在名义位姿基础上叠加随机偏移：位置偏移 $\delta x_k, \delta y_k \sim \mathcal{U}(-3 \text{ cm}, 3 \text{ cm})$ ，航向偏移由导航停靠过程自然产生，不额外控制；每个回合的实际残差 δ_k 由激光雷达定位按式(2)计算并随回合记录。由此，示范数据覆盖了残差范围内的观测与动作组合，操作者在遥操作中对残差的自然修正被同步记录为动作标签。

状态层面，将残差拼接到式(19)中的本体状态，形成残差增广状态与观测

$$\begin{aligned}\tilde{\mathbf{x}}_t &= \left[\mathbf{x}_t^T, \bar{\boldsymbol{\delta}}_k^T \right]^T \in \mathbb{R}^{17}, \quad \bar{\boldsymbol{\delta}}_k = \left(\frac{\delta x_k}{\sigma_x}, \frac{\delta y_k}{\sigma_y}, \frac{\delta \theta_k}{\sigma_\theta} \right)^T, \\ \tilde{\mathbf{o}}_t &= \{ I_t^{\text{head}}, I_t^{\text{wrist},L}, I_t^{\text{wrist},R}, \tilde{\mathbf{x}}_t, \ell_t \},\end{aligned}\tag{5}$$

式中， $\mathbf{x}_t$ 为原 14 维双臂末端位姿与夹爪状态， σ_x 、 σ_y 、 σ_θ 为训练集上残差各分量的标准差，用于与其余状态分量保持相同量级。残差在一次停靠内为常量，在子任务切换后更新。对于 OpenPI，该改动只需扩展状态维度与归一化统计量，模型结构与式(24)的训练目标不变；ACT 对照基线作相同扩展。策略由此可以学习“残差-动作修正”的对应关系，而不必仅从图像中隐式推断停靠偏差。

改进点一的实验设计包括容忍曲线与消融两部分。容忍曲线在测试时以程序化方式注入停车残差：在导航停靠后，按 0 至 5 厘米、间隔 1 厘米的档位人为设定位置偏移，记录各档位下五个子任务的成功率，得到成功率随残差幅值变化的曲线。消融按表1设置三组配置，分别考察数据覆盖与显式条件的作用：配置 (a) 与 (b) 的差异反映随机停车数据增强的贡献，配置 (b) 与 (c) 的差异反映残差状态输入在数据覆盖之外的增量贡献。三组配置的示范回合数、训练步数与测试残差档位保持一致。

表 1: 改进点一的消融配置

配置	训练数据停车方式	状态含残差	考察问题
(a)	固定名义停靠	否	现有流水线基线，给出名义条件下的性能与残差注入下的退化速度
(b)	± 3 厘米随机停靠	否	仅靠数据覆盖，策略能否从图像中隐式推断并补偿残差
(c)	± 3 厘米随机停靠	是	显式残差输入在数据覆盖之外能否进一步减缓退化、扩大容忍范围

3.4 改进点二：分阶段动作块执行（事中）

改进点二不改变训练，只在推理侧按阶段调整每次推理后实际执行的动作步数。将时刻 t 的执行阶段记为 $\phi_t \in \{\text{free}, \text{fine}\}$ ，其中精细阶段对应进槽、落台等对准操作，自由阶段对应工位内的接近、搬运与撤离。阶段由当前子任务与末端到

目标的距离共同判定：

$$\phi_t = \begin{cases} \text{fine}, & \ell_t \in \mathcal{L}_{\text{fine}} \text{ 且 } \|\mathbf{p}_{E,t} - {}^B\mathbf{p}_G\| < d_{\text{fine}}, \\ \text{free}, & \text{其他}, \end{cases} \quad h_t = h_{\phi_t}, \quad h_{\text{fine}} \ll h_{\text{free}} \leq H, \quad (6)$$

式中， $\mathcal{L}_{\text{fine}} \subset \mathcal{L}$ 为含精细对准的子任务集合， $\mathbf{p}_{E,t}$ 为操作臂末端位置， ${}^B\mathbf{p}_G$ 为由工位标定与残差换算得到的基座系目标位置， d_{fine} 为进入精细阶段的距离阈值； h_{free} 与 h_{fine} 分别为两类阶段的执行步数。作为备选阶段信号， $\pi_{0.5}$ 由式(18)预测的子任务 $\hat{\ell}_t$ 也可用于阶段判定，其可靠性将与距离规则比较。

设第 i 次推理发生于时刻 t_i ，得到式(20)所示长度为 H 的动作块 $\hat{\mathbf{A}}_{t_i}$ ；机器人仅执行其前 $h_{\phi_{t_i}}$ 步，下一次推理时刻为 $t_{i+1} = t_i + h_{\phi_{t_i}}$ 。相应的重规划周期与推理时间约束为

$$\tau_\phi = h_\phi \Delta t, \quad \tau_{\text{inf}} \leq h_{\text{fine}} \Delta t, \quad (7)$$

式中， Δt 为控制周期， τ_{inf} 为单次推理耗时。式(7)的第二式要求精细阶段的执行时间不短于推理时间，否则采用异步推理，以最新完成的动作块覆盖尚未执行的部分。图7给出了两类阶段的执行时序：自由阶段以接近整块的长度执行，减少推理次数；精细阶段每执行少量步即重新推理，使残差引起的偏差能够在更短的开环区间内被新观测纠正，同时产生密集的重叠动作块。




图 7: 分阶段动作块执行的时序与重叠块集合

改进点二的对照为固定执行步数方式。模型按块长 H 训练一次，对照组在整个任务中分别固定执行 $h \in \{20, 50, 100\}$ 步，分阶段组按式(6)切换。评价指标包括分阶段成功率、稳态推理频率、首动作延迟与推理时延的 95 分位数，后三项参照

OpenVLA-OFT 的吞吐率报告方式^[41]。为检验改进点二对残差的作用，在改进点一的基础上重做残差注入容忍曲线，比较分阶段执行与各固定步数在不同残差档位下的成功率差异。

3.5 改进点三：基于时序集成不一致度的失败检测与模板恢复（事后）

改进点三利用分阶段执行产生的重叠动作块构造失败信号。在 OpenPI 推理侧加入与 ACT 一致的时序集成^[1]：记覆盖时刻 t 的动作块集合为 C_t ，各块对时刻 t 的预测及其指数加权平均为

$$C_t = \{i : t_i \leq t < t_i + H\}, \quad \hat{\mathbf{a}}_t^{(i)} = \hat{\mathbf{A}}_{t_i} [t - t_i],$$

$$\bar{\mathbf{a}}_t = \frac{\sum_{i \in C_t} w_i \hat{\mathbf{a}}_t^{(i)}}{\sum_{i \in C_t} w_i}, \quad w_i = \exp(-m r_i), \quad (8)$$

式中， $\hat{\mathbf{A}}_{t_i}[\cdot]$ 表示按块内偏移取动作， r_i 为块 i 在 C_t 中按推理先后排列的序号， $m > 0$ 控制新旧预测的相对权重。执行动作取 $\bar{\mathbf{a}}_t$ 。在精细阶段， $|C_t| = \lceil H/h_{\text{fine}} \rceil$ ，重叠预测最为密集；在自由阶段若 $h_{\text{free}} = H$ 则无重叠，此时不进行监测，与“失败集中于精细阶段”的任务特点一致。

不一致度定义为重叠预测围绕加权平均的归一化方差，并以滑动窗口平滑：

$$s_t = \frac{1}{|C_t|} \sum_{i \in C_t} \left\| \Lambda^{-1/2} (\hat{\mathbf{a}}_t^{(i)} - \bar{\mathbf{a}}_t) \right\|_2^2, \quad \tilde{s}_t = \frac{1}{W} \sum_{u=t-W+1}^t s_u, \quad (9)$$

式中， Λ 为训练集上各动作维度方差构成的对角矩阵，用于消除位置、姿态与夹爪分量的量纲差异； W 为窗口长度。当状态处于示范分布内时，不同观测条件下的推理给出一致的动作， s_t 较小；当残差把状态推离示范分布或末端已经卡滞时，各次推理的输出分歧增大， s_t 上升。

阈值由成功回合标定，无需失败数据与额外训练。记配置“加改进点一二”下的成功回合集合为 $\mathcal{E}_{\text{succ}}$ ，按阶段分别取其 $\tilde{s}_t$ 的 95 分位数作为阈值，并要求连续超阈值以抑制瞬时波动：

$$\eta_\phi = Q_{0.95}(\{\tilde{s}_t : t \in \mathcal{E}_{\text{succ}}, \phi_t = \phi\}), \quad \text{报警} \iff \tilde{s}_t > \eta_{\phi_t} \text{ 连续 } n_{\text{hold}} \text{ 步}. \quad (10)$$

若四台机器人的不一致度分布存在系统差异，则按机器人分别标定。检测器以召回率、误报率与提前量评价：

$$\text{Rec} = \frac{|\{e \in \mathcal{E}_{\text{fail}} : t_a^e \leq t_f^e\}|}{|\mathcal{E}_{\text{fail}}|}, \quad \text{FAR} = \frac{|\{e \in \mathcal{E}_{\text{succ}} : \text{报警}\}|}{|\mathcal{E}_{\text{succ}}|}, \quad \Delta t_{\text{lead}} = t_f^e - t_a^e, \quad (11)$$

式中， $\mathcal{E}_{\text{fail}}$ 为失败回合集合， t_a^e 为回合 e 的首次报警时刻， t_f^e 为按人工标注确定的失败发生时刻，如卡滞或挤压开始的时刻。失败回合主要由改进点一的残差注入

在容忍边界之外产生，从而使检测评价与容忍曲线共用同一批测试数据。

报警后执行固定模板恢复，不由模型生成恢复动作：停止当前动作块的执行；沿工位系竖直方向回退至安全高度 z_{safe} ，夹爪状态保持不变；回到当前子任务的入口位姿；重新获取观测并推理，重试一次；若重试过程中再次报警，则停机并交由人工处理。恢复模板参数由工位几何确定，与 RACER 等学习型恢复策略相比不需要失败恢复数据^[44]。整个监测与恢复流程如图8所示。改进点三的评价除式(11)外，还包括加入恢复后的最终成功率以及监测与集成计算带来的附加时延。该方案可视为 FAIL-Detect^[42] 的免训练简化实现：以策略自身重叠预测的不一致度替代额外训练的分层网络，以成功回合分位数替代保形阈值。




图 8: 基于时序集成不一致度的失败检测与模板恢复流程

3.6 整体验证方案

三层改进按表2的四种配置逐层叠加验证。所有配置使用相同的残差注入档位、相同的五工位任务链和相同的四台机器人，每台机器人在每个残差档位上执行相同数量的回合。端到端指标包括整链成功率与逐子任务的条件成功率，后者参照 CALVIN 对长时序任务链的评价方式^[39]，用于定位失败集中的阶段；同时记录各配置的稳态推理频率、首动作延迟与附加时延。数据划分按机器人与采集日期分组留出，避免同一回合的样本同时出现在训练与测试中。示范采集由一台机

器人完成，四台机器人参与测试，以检验改进对本体差异的稳健性。

表 2: 整体验证的叠加配置

配置	组成	主要考察指标
C0	基线: $\pi_{0.5}$ 固定执行步数; ACT 作对照	名义条件成功率、残差注入下的退化曲线
C1	C0 加改进点一	容忍曲线的偏移量, 消融 (a)(b)(c) 的差异
C2	C1 加改进点二	精细阶段成功率、推理频率与时延, 与固定步数对照
C3	C2 加改进点三	召回率、误报率、提前量、恢复后的最终成功率、附加时延

3.7 可行性分析

本课题的可行性建立在已完成工作与改进的低侵入性之上。其一, ACT 与 OpenPI 两条流水线已在目标平台上端到端跑通, 第5节所述的 VR 示范采集、数据组织与动作块推理闭环可直接复用, 改进只需在其上增加接口与推理逻辑。其二, 三层改进均不改变策略网络结构: 残差输入只扩展状态维度, OpenPI 微调在单张 A100 80G 显卡上即可完成; 分阶段执行与时序集成只涉及推理侧代码; 失败检测无需失败数据与额外模型。其三, 停车残差可直接由平台的激光雷达定位模块与工位标定结果按式(2)计算, 随机停靠与程序化残差注入均可通过修改导航目标姿态实现。其四, 四台机器人与真实的五工位场景为叠加验证提供了足够的重复条件。可能的风险与应对措施见第8节。

4 预期达到的目标

本课题预期在已跑通的 $\pi_{0.5}$ 与 ACT 模仿学习流水线基础上, 建立一套沿停车误差传递链逐层设防的策略鲁棒性改进方法, 并在四台轮式双臂机器人和真实的 PCBA 五工位上下料任务上完成叠加验证。总体目标是: 在不改变策略网络结构的前提下, 使策略对工位停车误差的容忍范围明显扩大, 精细阶段的成功率与安全性明显提高, 失败发生后能够被及时检测并以可控方式恢复或停机。

在改进点一方面, 预期残差注入下的成功率随残差幅值的衰减明显缓于固定停靠基线, 容忍曲线整体向更大残差方向偏移; 消融结果预期表明显式残差输入在随机停车数据覆盖之外具有额外收益, 并且该收益在 $\pi_{0.5}$ 与 ACT 两类模型上方向一致。

在改进点二方面, 预期分阶段执行在精细阶段的成功率高于任一固定执行步

数方式，同时整体推理开销不高于全程采用短步数的方式，首动作延迟与推理时延分位数保持在可用范围内；在残差注入条件下，分阶段执行与改进点一叠加后的容忍曲线优于单独采用改进点一。

在改进点三方面，预期基于时序集成不一致度的检测器在无需失败数据与额外训练的条件下，对残差引起的精细阶段失败具有较高的召回率与可接受的误报率，报警时刻明显早于卡滞或挤压发生；配合模板恢复后，部分失败回合转为成功，监测与集成带来的附加时延不影响任务节拍。

预期成果形式包括：面向 PCBA 上下料的三层鲁棒性改进方法及其在 OpenPI 推理侧的实现；四种配置在统一残差注入协议下的真机实验数据、容忍曲线与失败检测评价结果；以及以上内容为主体的硕士学位论文。

5 已完成的学术研究/实践工作

5.1 实验平台与坐标系定义

本研究已在轮式双臂机器人平台上完成示范采集与策略执行所需的基础接口建设。机器人上半身由左右两条七自由度机械臂、四自由度腰部和二自由度头部组成，共包含 20 个转动关节，并配置末端夹爪、头部相机和腕部相机。现阶段的双臂操作以左右机械臂末端笛卡尔位姿和夹爪状态作为核心状态与动作变量，执行模型将腰部、头部和移动底盘位姿作为固定参数，仅更新左右机械臂的关节状态。移动底盘由激光雷达定位与传统导航算法在工位间移动并停靠，停靠后锁定，操作阶段仅由双臂执行。

为统一描述机器人、工位与虚拟现实（Virtual Reality, VR）设备之间的空间关系，本文以 $s \in \{L, R\}$ 区分左、右机械臂，并定义以下坐标系：世界坐标系记为 $\{O\}$ ，机器人基座坐标系记为 $\{B\}$ ，左右末端执行器坐标系记为 $\{E_s\}$ ，第 k 个工位的名义工位坐标系记为 $\{S_k\}$ ；VR 参考坐标系记为 $\{V\}$ ，左右手控制器坐标系记为 $\{H_s\}$ 。其中， ${}^A\mathbf{T}_C$ 表示坐标系 $\{C\}$ 相对于坐标系 $\{A\}$ 的位姿，即把 $\{C\}$ 中的齐次坐标变换到 $\{A\}$ 中。该表示写为

$${}^A\mathbf{T}_C = \begin{bmatrix} {}^A\mathbf{R}_C & {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}, \quad (12)$$

式中， ${}^A\mathbf{R}_C \in \text{SO}(3)$ 为旋转矩阵， ${}^A\mathbf{p}_C \in \mathbb{R}^3$ 为坐标系原点的位置向量。若空间点在 $\{C\}$ 中的齐次坐标为 $\bar{\mathbf{p}}^C$ ，则其在 $\{A\}$ 中的表示为 $\bar{\mathbf{p}}^A = {}^A\mathbf{T}_C \bar{\mathbf{p}}^C$ 。连续坐标变换满足

$${}^A\mathbf{T}_D = {}^A\mathbf{T}_C {}^C\mathbf{T}_D, \quad ({}^A\mathbf{T}_C)^{-1} = \begin{bmatrix} ({}^A\mathbf{R}_C)^T & -({}^A\mathbf{R}_C)^T {}^A\mathbf{p}_C \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix}. \quad (13)$$

式(12)和式(13)构成后续 VR 增量映射、工位坐标系与停车残差定义的统一表示基础。基座系与末端系之间的正逆运动学由平台现有笛卡尔控制模块提供，本文不再展开。

5.2 基于 VR 遥操作的示范数据采集

在上述坐标关系基础上，本研究已构建基于 VR 设备的双臂遥操作与示范采集链路。系统读取头显及左右手控制器的空间位姿和交互信号，在遥操作回合开始时分别记录控制器初始位姿 ${}^V\mathbf{T}_{H_s}(t_0)$ 与机器人末端初始位姿 ${}^B\mathbf{T}_{E_s}(t_0)$ 。固定标定旋转 ${}^B\mathbf{R}_V$ 用于统一 VR 参考系与机器人基座系的轴向约定，比例系数 λ_s 用于调节操作者手部平移与机器人末端平移的尺度。由此，控制器相对初始位置的增量被映射为

$${}^B\mathbf{p}_{E_{s,d}}(t) = {}^B\mathbf{p}_{E_s}(t_0) + \lambda_s {}^B\mathbf{R}_V ({}^V\mathbf{p}_{H_s}(t) - {}^V\mathbf{p}_{H_s}(t_0)). \quad (14)$$

该增量形式以遥操作开始时的实际末端位置为基准，VR 空间的绝对坐标用于计算控制器相对初始位姿的运动增量。

控制器姿态首先相对于初始姿态计算，再经标定旋转映射到机器人基座系。末端目标姿态表示为

$${}^B\mathbf{R}_{E_{s,d}}(t) = {}^B\mathbf{R}_V \left[{}^V\mathbf{R}_{H_s}(t) ({}^V\mathbf{R}_{H_s}(t_0))^T \right] {}^V\mathbf{R}_B {}^B\mathbf{R}_{E_s}(t_0), \quad (15)$$

其中 ${}^V\mathbf{R}_B = ({}^B\mathbf{R}_V)^T$ 。式(14)与式(15)分别生成末端目标位置和姿态，两者组成 ${}^B\mathbf{T}_{E_{s,d}}(t)$ ，再由已有笛卡尔控制接口执行。手柄交互量 $u_s(t)$ 通过既定映射

$$g_{s,d}(t) = \mathcal{G}_s(u_s(t)) \quad (16)$$

转换为左右夹爪的开合指令。映射函数 $\mathcal{G}_s(\cdot)$ 的触发阈值与夹爪行程参数由平台配置确定。

机器人示范数据通常以一次完整的任务回合作为基本组织单元，将视觉观测、机器人状态与动作按时间步对齐，并在回合层关联任务指令；统一的数据语义有助于后续按不同观测窗口和动作空间构造训练样本^[1,26]。参照这一组织方式，本研究将当前采集的数据划分为任务、回合和时间步三个层级：任务层以自然语言描述界定操作目标，回合层对应一次完整的遥操作过程，时间步层则以动作时刻为索引，关联头部与左右腕部图像、双臂末端状态、夹爪状态及相应动作。第 n 个任务回合可表示为

$$\tau^{(n)} = \left\{ \left(t_k, I_k^{\text{head}}, I_k^{\text{wrist},L}, I_k^{\text{wrist},R}, \mathbf{x}_k, \mathbf{a}_k \right) \right\}_{k=1}^{K_n}, \quad (17)$$

其中， $\mathbf{x}_k$ 包含左右末端位姿与夹爪状态， $\mathbf{a}_k$ 包含对应时刻的双臂笛卡尔动作与夹

爪指令。任务语言描述作为策略的语义条件与相应任务回合关联。上述层级将任务语义与单次执行序列分开，同时保持观测、状态和动作在回合内部逐时对应，可直接为后续视觉-语言-动作策略构造单步样本或动作块样本。现有示范均在名义停靠位姿下采集，第3.3节将把采集扩展为随机停靠，并在回合层同步记录停车残差 δ_k 。

以“将印制电路板组件（Printed Circuit Board Assembly, PCBA）放置到百叶车指定承载位置”为例，该回合以右臂为操作臂，左臂保持固定。机器人在夹爪夹持状态下携带 PCBA 接近百叶车，调整末端位置和姿态完成放置，随后松开夹爪并撤离放置区域。该回合共包含 177 个时间对齐样本；每个时间步包含三路分辨率为 240×320 的彩色图像，以及 14 维双臂末端状态和 14 维双臂动作。状态与动作均按左右臂各 7 维组织，分别由三维位置、滚转-俯仰-偏航姿态和夹爪状态或指令组成。该样例表明，现有采集链路能够将多视角观测、机器人本体状态与遥操作动作组织为式(17)所定义的完整回合。

图9给出了该回合的起始、中间和结束观测，以及右手末端的三维运动轨迹。上部三幅图分别对应第 0、88 和 176 帧：前两帧处于夹持状态，结束帧处于松开状态；下部曲线以颜色和线型区分夹爪语义状态，以箭头表示工具坐标系 +Z 轴方向。轨迹在第 120 帧由夹持切换为松开，使视觉观测、末端位姿和 PCBA 释放事件能够在同一时间轴上对应。

图10概括了已完成系统中数据采集与策略执行之间的接口关系。VR 位姿经过增量映射后进入笛卡尔控制模块，机器人动作及多视角观测由同步记录模块组织为示范轨迹；同一示范数据集分别用于 ACT 与基于 OpenPI 的 $\pi_{0.5}$ 微调，离线训练得到的策略在部署阶段接收新的观测与语言指令，并通过同一笛卡尔接口输出动作块。由此，示范阶段与推理阶段共享机器人状态、动作定义和底层执行链路，两条流水线均已完成端到端验证。




图 9: 将 PCBA 放置到百叶车任务的示例观测、右手轨迹与夹爪状态




图 10: 已跑通的 ACT 与 OpenPI 两条模仿学习流水线及其接口关系

5.3 ACT 对照基线与基于 OpenPI 的 $\pi_{0.5}$ 推理闭环

在示范采集链路基础上，现有系统已完成两类动作块策略的微调与真机部署。ACT 以条件变分自编码器编码示范动作序列的风格变量，以 Transformer 编码器-解码器根据多视角图像与本体状态一次预测长度为 H 的动作块；推理时对多次预测在同一时刻的重叠部分按指数权重加权平均，即时序集成^[1]。课题组已在式(17)所示数据上完成 ACT 微调与真机执行，该模型在本课题中作为对照基线，用于检验改进点一的收益是否依赖特定模型结构。

作为主线模型，现有系统已接入基于 OpenPI 部署的 $\pi_{0.5}$ 视觉-语言-动作策略。该模型在 π_0 连续动作生成框架的基础上引入语义子任务预测，将长时程任务中的高层语义决策与低层动作块生成组织在统一模型中，其结构及训练流程如图11所示^[2]。

图11左侧为预训练阶段。模型以 SigLIP 视觉编码器和 Gemma 语言模型组成的预训练视觉-语言模型（Vision-Language Model, VLM）为主干，将多模态网络数据、异构机器人数据和任务提示统一表示为序列，并同时学习语义子任务、离散动作、图像描述及目标框等输出。机器人动作在该阶段由 FAST 分词器压缩为离散词元，使动作预测能够与语言建模任务共同采用自回归的下一词元预测目标。图中右侧为后训练与推理阶段：预训练得到的视觉-语言-动作模型（Vision-Language-Action Model, VLA）继续承担图像与语言理解，并在主干之外加入参数量较小的动作专家；动作专家接收连续动作的含噪中间状态，采用条件流匹配逐步生成连




图 11: $\pi_{0.5}$ 模型结构及两阶段训练流程^[2]

续动作块。由此，模型既保留预训练阶段获得的视觉与语义能力，又能以非自回归方式输出适用于实时控制的连续动作。

在层级推理过程中，VLA 主干首先根据当前多视角观测和高层任务指令自回归生成语义子任务 $\hat{\ell}_t$ ，例如将“整理卧室”转化为“拿起枕头”；随后，该子任务作为低层语言条件输入动作专家，后者由随机噪声生成长度为 H 的连续动作块。原模型的联合分布可分解为

$$\pi_{\theta}(\mathbf{A}_t, \hat{\ell}_t | \mathbf{z}_t, \ell_t) = \pi_{\theta}(\mathbf{A}_t | \mathbf{z}_t, \hat{\ell}_t) \pi_{\theta}(\hat{\ell}_t | \mathbf{z}_t, \ell_t), \quad (18)$$

其中， $\mathbf{z}_t$ 表示图像与机器人本体状态， ℓ_t 表示高层任务指令。式(18)的第二项对应图中的子任务预测，第一项对应动作专家的连续动作生成。结合本研究的平台接口，运行时动态给定的语言指令可直接作为低层动作生成条件；若后续启用自主语义分解，则可由模型预测的 $\hat{\ell}_t$ 替代该外部低层指令。为与现有推理接口保持一致，时刻 t 的策略输入写为

$$\mathbf{o}_t = \{I_t^{\text{head}}, I_t^{\text{wrist}, L}, I_t^{\text{wrist}, R}, \mathbf{x}_t, \ell_t\}, \quad (19)$$

其中， ℓ_t 为运行时给定的动态任务语言指令。策略一次推理输出长度为 H 的动作块：

$$\hat{\mathbf{A}}_t = \pi_{\theta}(\mathbf{o}_t) = [\hat{\mathbf{a}}_t, \hat{\mathbf{a}}_{t+1}, \dots, \hat{\mathbf{a}}_{t+H-1}]. \quad (20)$$

动作块中的每个元素均按照前述双臂笛卡尔动作与夹爪指令接口解释。机器人执行其中预设长度 h 的近期动作，且 $1 \leq h \leq H$ ；完成该段动作后，系统重新获取多视角图像和末端状态，并结合当前语言指令构造下一轮输入。该过程形成“状态

感知-策略推理-动作块执行-状态更新”的在线闭环。现有部署中 h 为全任务统一的固定值，第3.4节将其改为按阶段取值。

(1) 面向 $\pi_{0.5}$ 的模仿学习推导。将式(17)所示的专家示范按照长度为 H 的滑动窗口组织，可得动作块示教数据集

$$\mathcal{D}_E = \left\{ \left(\mathbf{o}_t^{(n)}, \mathbf{A}_t^{E, (n)} \right) \right\}_{n, t}, \quad \mathbf{A}_t^E = [\mathbf{a}_t^E, \dots, \mathbf{a}_{t+H-1}^E]. \quad (21)$$

行为克隆的基本目标是在专家数据分布上最大化条件动作块的对数似然，即

$$\theta_{IL} = \arg \min_{\theta} \mathcal{L}_{IL}(\theta), \quad \mathcal{L}_{IL}(\theta) = -\mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E} [\log \pi_{\theta}(\mathbf{A}_t^E | \mathbf{o}_t)]. \quad (22)$$

该目标使策略分布逼近专家在给定多视角图像、机器人状态和语言指令条件下的动作分布；动作块联合建模还保留了同一操作片段内各时刻动作之间的相关性。

$\pi_{0.5}$ 采用条件流匹配表示连续动作块分布^[2,34]。对归一化后的专家动作块 $\mathbf{A}_t^E$ ，采样高斯噪声 $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 和流时间 $\tau \in [0, 1]$ ，构造从数据到噪声的线性概率路径

$$\mathbf{A}_t^{\tau} = (1 - \tau)\mathbf{A}_t^E + \tau\epsilon, \quad \mathbf{u}_t^{\tau} = \frac{\partial \mathbf{A}_t^{\tau}}{\partial \tau} = \epsilon - \mathbf{A}_t^E. \quad (23)$$

设动作专家输出的条件向量场为 $\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau)$ ，则模仿微调可写为条件流匹配损失

$$\mathcal{L}_{FM}(\theta) = \mathbb{E}_{(\mathbf{o}_t, \mathbf{A}_t^E) \sim \mathcal{D}_E, \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \tau \sim p(\tau)} [\|\mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) - (\epsilon - \mathbf{A}_t^E)\|_2^2]. \quad (24)$$

最小化式(24)使网络学习式(23)的条件速度场。推理时从 $\mathbf{A}_t^1 \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 出发，沿

$$\frac{d\mathbf{A}_t^{\tau}}{d\tau} = \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau) \quad (25)$$

由 $\tau = 1$ 反向积分至 $\tau = 0$ ，即可得到条件动作块样本 $\hat{\mathbf{A}}_t = \mathbf{A}_t^0$ 。以步长 $\Delta\tau > 0$ 进行欧拉离散时，单步更新为

$$\mathbf{A}_t^{\tau-\Delta\tau} = \mathbf{A}_t^{\tau} - \Delta\tau \mathbf{v}_{\theta}(\mathbf{A}_t^{\tau}, \mathbf{o}_t, \tau). \quad (26)$$

因此，式(24)给出了示教动作对模型参数的监督关系，式(25)和式(26)则给出了从随机噪声生成连续动作块的推理过程。

5.4 阶段性工作总结

本节总结了已经形成的机器人平台、坐标定义、示范采集与策略部署基础。首先，前期工作以齐次变换统一表示世界、基座、末端、工位与 VR 各坐标系之间的关系，并明确了平台笛卡尔控制模块作为策略与机器人之间的执行接口。随后，前期工作通过 VR 参考位姿标定、位置增量映射和姿态增量映射，将双手控制器运动转换为双臂末端目标，完成了多视角视觉、机器人状态与动作的时间对齐，并以 PCBA 放置回合验证了数据组织方式。最后，同一示范数据分别用于 ACT 与基于

OpenPI 的 $\pi_{0.5}$ 微调，两条“VR 遥操作数采-模型微调-真机部署”流水线均已端到端跑通，形成带动态语言条件的动作块推理闭环；激光雷达定位与导航停靠作为平台既有能力可直接调用。尚未实现的部分正是本课题的三个改进点：停车残差尚未进入策略状态、示范仍在名义停靠下采集、动作块执行步数为全任务固定值、推理侧尚无时序集成与失败检测。

6 进度安排

研究进度将从 2026 年 7 月进入课题时开始计算，至 2027 年 12 月完成论文与答辩准备。各阶段按照“时间段-主要任务-阶段产出”编排，并在后期预留补充实验、设备维护和论文修改时间。

表 3: 研究进度安排

时间	主要任务	阶段产出
2026.07–2026.08	梳理文献与现有平台接口,确定五工位任务链、子任务划分与成功/失败判据;制定随机停靠示范采集规范与残差注入协议,完成开题。	开题报告、任务规范与评价协议初稿。
2026.09–2026.10	实现停车残差读取与工位标定接口,将残差增广状态接入 OpenPI 与 ACT 数据格式;按规范采集随机停靠示范并版本化。	残差接口、版本化示范数据与数据说明。
2026.11–2026.12	完成改进点一三组消融的微调与真机测试,绘制 0 至 5 厘米残差注入容忍曲线。	改进点一实验数据、容忍曲线与消融结论。
2027.01–2027.03	实现阶段判定与分阶段动作块执行,完成与固定执行步数的对照,记录成功率、推理频率与时延分位数;在残差注入下重做容忍曲线。	分阶段执行模块、时延与成功率对照数据。
2027.04–2027.06	在 OpenPI 推理侧实现时序集成与不一致度计算,标定分阶段阈值,实现模板恢复;评价召回率、误报率、提前量与恢复后成功率。	失败检测与恢复模块、检测器评价数据。

续表 3

时间	主要任务	阶段产出
2027.07–2027.09	在四台机器人上完成四种配置的叠加验证与补充重复实验，整理失败案例并分析本体差异。	整体验证数据、失败分类与方法适用边界。
2027.10–2027.12	核对数据、代码和图表，完成学位论文撰写、修改、送审与答辩准备。	学位论文定稿与答辩材料。

7 为完成课题所需的条件

本课题所需条件分为硬件平台、算力、数据、软件与评价环境五类，其中大部分已由课题组现有平台与前期工作具备，尚需补充的部分均可在进度安排的前两个阶段内完成，如表4所示。

表 4: 完成课题所需的条件

类别	已具备	尚需补充
硬件平台	四台轮式双臂机器人，各含两条七自由度机械臂、四自由度腰部、二自由度头部、末端夹爪、头部与腕部相机，以及激光雷达定位与导航模块；一台用于示范采集，四台用于实验。	工位周边的安全围栏与急停联动，用于失败注入实验中的物料与设备保护。
算力	8 卡 A100 80G 服务器，课题分配一张显卡，满足 $\pi_{0.5}$ 与 ACT 微调需求。	无。
数据	名义停靠下的 VR 遥操作示范回合，含 PCBA 放置样例；数据按任务、回合、时间步三级组织。	随机停靠示范回合及其残差记录；残差注入测试回合；失败回合的失败时刻人工标注。

续表 4

类别	已具备	尚需补充
软件	VR 遥操作与同步记录链路；ACT 与 OpenPI 两条微调与部署流水线；导航栈与笛卡尔控制接口。	停车残差读取与工位标定接口；残差增广状态的数据格式与归一化；推理侧的阶段判定、分阶段执行、时序集成与不一致度监测模块；模板恢复动作。
评价环境	真实的 PCBA 五工位场景：上料百叶车、扫码工位、检测台、下料百叶车。	程序化残差注入工具；分子任务成功判定与时延记录工具；四台机器人的统一评价脚本。

8 研究过程中可能遇到的问题以及解决的措施

三层改进分别依赖残差估计、阶段判定与不一致度信号的可靠性，其实验又受真机资源与本体差异约束。表5按风险来源列出可能遇到的问题、影响以及预防措施与降级方案。

表 5: 可能遇到的问题与解决措施

问题	影响	预防措施	降级方案
激光雷达定位残差估计存在噪声	残差输入本身带误差,削弱改进点一收益	停靠后静止采样多帧取均值; 以外部标定装置校验残差估计精度	仅使用估计精度可靠的位置分量, 航向分量退出状态输入
± 3 厘米随机停靠未覆盖真实残差分布	容忍曲线在大残差档位仍快速退化	采集前统计导航停靠残差的实际分布并据此设定范围	扩大随机范围或增加分档示范, 重训改进点一
阶段判定错误	精细阶段误判为自由阶段时开环区间过长, 反之推理开销上升	距离阈值留裕量; 以子任务标签与 $\pi_{0.5}$ 子任务预测双重校验	退回全程短步数执行, 牺牲部分时延

续表 5

问题	影响	预防措施	降级方案
时序集成与监测增加推理时延	精细阶段执行时间短于推理时间	采用异步推理, 以最新块覆盖; 不一致度计算向量化	提高 h_{fine} 至满足式(7)
阈值失准导致误报或漏报	误报触发不必要恢复, 漏报失去预警意义	按阶段与机器人分别标定; 引入连续超阈值步数 n_{hold}	调整分位数并以召回率-误报率曲线选取工作点
模板恢复动作引发碰撞	回退过程中夹爪或 PCBA 与槽位干涉	回退方向沿工位系竖直方向, 路径经离线校核; 恢复前先停止运动	报警后直接停机交人工, 不执行自动恢复
单张显卡算力限制	多组消融与四种配置的微调周期长	复用预训练检查点, 只微调必要参数; 按进度错峰安排训练	减少消融重复次数, 优先保证主线配置
四台机器人本体差异	同一策略在不同机器人上的成功率与不一致度分布不同	统一标定与零位校验; 评价按机器人分组报告	阈值按机器人单独标定; 必要时按机器人少量微调
VR 示范采集吞吐不足	随机停靠示范数量不够	自由空间段可由导航与预设航点自动完成, 仅遥操作精细段 ^[15]	缩小随机停靠范围并减少示范回合数

9 参考文献

- [1] Zhao T Z, Kumar V, Levine S, et al. Learning Fine-Grained Bimanual Manipulation with Low-Cost Hardware[C/OL] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.016>.
- [2] Black K, Brown N, Darpinian J, et al. $\pi_{0.5}$: A Vision-Language-Action Model with Open-World Generalization[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-25]. <https://www.pi.website/download/pi05.pdf>.
- [3] Levine S, Wagener N, Abbeel P. Learning Contact-Rich Manipulation Skills with Guided Policy Search[C/OL] // 2015 IEEE International Conference on Robotics and Automation (ICRA). 2015: 156-163. <http://dx.doi.org/10.1109/ICRA.2015.28>.

7138994.

- [4] Inoue T, Magistris G D, Munawar A, et al. Deep Reinforcement Learning for High Precision Assembly Tasks[C/OL] // 2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2017: 819-825. <http://dx.doi.org/10.1109/IROS.2017.8202244>.
- [5] Johannink T, Bahl S, Nair A, et al. Residual Reinforcement Learning for Robot Control[C/OL] // 2019 International Conference on Robotics and Automation (ICRA). 2019: 6023-6029. <http://dx.doi.org/10.1109/ICRA.2019.8794127>.
- [6] Elguea-Aguinaco Í, Serrano-Muñoz A, Chrysostomou D, et al. A Review on Reinforcement Learning for Contact-Rich Robotic Manipulation Tasks[J/OL]. Robotics and Computer-Integrated Manufacturing, 2023, 81: 102517. <http://dx.doi.org/10.1016/j.rcim.2022.102517>.
- [7] Chi C, Feng S, Du Y, et al. Diffusion Policy: Visuomotor Policy Learning via Action Diffusion[C/OL] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.026>.
- [8] Tang B, Lin M A, Akinola I, et al. IndustReal: Transferring Contact-Rich Assembly Tasks from Simulation to Reality[C/OL] // Robotics: Science and Systems XIX. 2023. <http://dx.doi.org/10.15607/RSS.2023.XIX.039>.
- [9] Sóti G, Huang X, Wurll C, et al. Train What You Know – Precise Pick-and-Place with Transporter Networks[C/OL] // 2023 IEEE International Conference on Robotics and Automation (ICRA). 2023: 5814-5820. <http://dx.doi.org/10.1109/ICRA48891.2023.10161242>.
- [10] Fu Z, Zhao T Z, Finn C. Mobile ALOHA: Learning Bimanual Mobile Manipulation with Low-Cost Whole-Body Teleoperation[C/OL] // Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024: 4066-4083. <https://proceedings.mlr.press/v270/fu25b.html>.
- [11] Xia F, Li C, Martín-Martín R, et al. ReLMoGen: Leveraging Motion Generation in Reinforcement Learning for Mobile Manipulation[C/OL] // 2021 IEEE International Conference on Robotics and Automation (ICRA). 2021: 4583-4590. <http://dx.doi.org/10.1109/ICRA48506.2021.9561315>.
- [12] Honerkamp D, Welschhold T, Valada A. N²M²: Learning Navigation for Arbitrary Mobile Manipulation Motions in Unseen and Dynamic Environments[J/OL]. IEEE Transactions on Robotics, 2023, 39(5): 3601-3619. <http://dx.doi.org/10.1109/TRO.2023.10161242>.

2023.3284346.

- [13] Yang T, Jing Y, Wu H, et al. MOMA-Force: Visual-Force Imitation for Real-World Mobile Manipulation[C/OL] // 2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2023: 6847-6852. <http://dx.doi.org/10.1109/IROS55552.2023.10342371>.
- [14] Qiu R-Z, Song Y, Peng X, et al. WildLMa: Long Horizon Loco-Manipulation in the Wild[C/OL] // 2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 10011-10019. <http://dx.doi.org/10.1109/ICRA55743.2025.11128535>.
- [15] Mandlekar A, Garrett C, Xu D, et al. Human-in-the-Loop Task and Motion Planning for Imitation Learning[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 3030-3060. <https://proceedings.mlr.press/v229/mandlekar23b.html>.
- [16] Ishida Y, Noguchi Y, Kanai T, et al. Robust Imitation Learning for Mobile Manipulator Focusing on Task-Related Viewpoints and Regions[C/OL] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024. <https://arxiv.org/abs/2410.01292>.
- [17] Yang C, Zeng C, Cong Y, et al. A Learning Framework of Adaptive Manipulative Skills from Human to Robot[J/OL]. IEEE Transactions on Industrial Informatics, 2019, 15(2): 1153-1161. <http://dx.doi.org/10.1109/TII.2018.2826064>.
- [18] Qin F, Xu D, Zhang D, et al. Robotic Skill Learning for Precision Assembly with Microscopic Vision and Force Feedback[J/OL]. IEEE/ASME Transactions on Mechatronics, 2019, 24(3): 1117-1128. <http://dx.doi.org/10.1109/TMECH.2019.2909081>.
- [19] Zang Y, Wang P, Zha F, et al. Peg-in-Hole Assembly Skill Imitation Learning Method Based on ProMPs under Task Geometric Representation[J/OL]. Frontiers in Neurorobotics, 2023, 17: 1320251. <http://dx.doi.org/10.3389/fnbot.2023.1320251>.
- [20] Mandlekar A, Xu D, Wong J, et al. What Matters in Learning from Offline Human Demonstrations for Robot Manipulation[C/OL] // Proceedings of Machine Learning Research, Vol 164: Proceedings of the 5th Conference on Robot Learning. [S.l.]: PMLR, 2022: 1678-1690. <https://proceedings.mlr.press/v164/mandlekar22a.html>.
- [21] Ze Y, Zhang G, Zhang K, et al. 3D Diffusion Policy: Generalizable Visuomotor Policy Learning via Simple 3D Representations[C/OL] // Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.067>.

- [22] Wang C, Fang H, Fang H-S, et al. RISE: 3D Perception Makes Real-World Robot Imitation Simple and Effective[C/OL] //2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 2870-2877. <http://dx.doi.org/10.1109/IROS58592.2024.10801678>.
- [23] Shi L X, Sharma A, Zhao T Z, et al. Waypoint-Based Imitation Learning for Robotic Manipulation[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2195-2209. <https://proceedings.mlr.press/v229/shi23b.html>.
- [24] Brohan A, Brown N, Carbajal J, et al. RT-1: Robotics Transformer for Real-World Control at Scale: arXiv:2212.06817[R/OL]. Mountain View, California, USA: Google Research, 2022 [2026-09-02]. <https://arxiv.org/abs/2212.06817>.
- [25] Brohan A, Brown N, Carbajal J, et al. RT-2: Vision-Language-Action Models Transfer Web Knowledge to Robotic Control[C/OL] // Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023: 2165-2183. <https://proceedings.mlr.press/v229/zitkovich23a.html>.
- [26] Open X-Embodiment Collaboration. Open X-Embodiment: Robotic Learning Datasets and RT-X Models[C/OL] //2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 6892-6903. <http://dx.doi.org/10.1109/ICRA57147.2024.10611477>.
- [27] Octo Model Team, Ghosh D, Walke H, et al. Octo: An Open-Source Generalist Robot Policy[C/OL] //Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.090>.
- [28] Kim M J, Pertsch K, Karamcheti S, et al. OpenVLA: An Open-Source Vision-Language-Action Model[C/OL] //Proceedings of Machine Learning Research, Vol 270: Proceedings of the 8th Conference on Robot Learning. [S.l.]: PMLR, 2024. <https://proceedings.mlr.press/v270/kim25c.html>.
- [29] Khazatsky A, Pertsch K, Nair S, et al. DROID: A Large-Scale In-The-Wild Robot Manipulation Dataset[C/OL] //Robotics: Science and Systems XX. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.120>.
- [30] Liu S, Wu L, Li B, et al. RDT-1B: A Diffusion Foundation Model for Bimanual Manipulation[C/OL] // The Thirteenth International Conference on Learning Representations (ICLR). 2025. https://proceedings.iclr.cc/paper_files/paper/2025/hash/49f80e4d2471ad4f2edf4f5f1ab62339-Abstract-Conference.html.

- [31] Wen J, Zhu Y, Li J, et al. TinyVLA: Toward Fast, Data-Efficient Vision-Language-Action Models for Robotic Manipulation[J/OL]. IEEE Robotics and Automation Letters, 2025, 10(4): 3988-3995. <http://dx.doi.org/10.1109/LRA.2025.3544909>.
- [32] Liu J, Liu M, Wang Z, et al. RoboMamba: Efficient Vision-Language-Action Model for Robotic Reasoning and Manipulation[C/OL] // Advances in Neural Information Processing Systems 37 (NeurIPS). 2024. https://proceedings.neurips.cc/paper_files/paper/2024/hash/46a126492ea6fb87410e55a58df2e189-Abstract-Conference.html.
- [33] Bu Q, Yang Y, Cai J, et al. UniVLA: Learning to Act Anywhere with Task-centric Latent Actions[C/OL] // Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.014>.
- [34] Black K, Brown N, Driess D, et al. π_0 : A Vision-Language-Action Flow Model for General Robot Control[R/OL]. San Francisco, California, USA: Physical Intelligence, 2024 [2026-08-27]. <https://arxiv.org/abs/2410.24164>.
- [35] Pertsch K, Stachowicz K, Ichter B, et al. FAST: Efficient Action Tokenization for Vision-Language-Action Models[R/OL]. San Francisco, California, USA: Physical Intelligence, 2025 [2026-08-27]. <https://arxiv.org/abs/2501.09747>.
- [36] Pumacay W, Singh I, Duan J, et al. THE COLOSSEUM: A Benchmark for Evaluating Generalization for Robotic Manipulation[C/OL] // Proceedings of Robotics: Science and Systems. 2024. <http://dx.doi.org/10.15607/RSS.2024.XX.133>.
- [37] Jin S, Wang R, Zahid M, et al. How Physics and Background Attributes Impact Video Transformers in Robotic Manipulation: A Case Study on Planar Pushing[C/OL] // 2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). 2024: 7391-7398. <http://dx.doi.org/10.1109/IROS58592.2024.10802583>.
- [38] Peng X B, Andrychowicz M, Zaremba W, et al. Sim-to-Real Transfer of Robotic Control with Dynamics Randomization[C/OL] // 2018 IEEE International Conference on Robotics and Automation (ICRA). 2018: 3803-3810. <http://dx.doi.org/10.1109/ICRA.2018.8460528>.
- [39] Mees O, Hermann L, Rosete-Beas E, et al. CALVIN: A Benchmark for Language-Conditioned Policy Learning for Long-Horizon Robot Manipulation Tasks[J/OL]. IEEE Robotics and Automation Letters, 2022, 7(3): 7327-7334. <http://dx.doi.org/10.1109/LRA.2022.3180108>.
- [40] Liu B, Zhu Y, Gao C, et al. LIBERO: Benchmarking Knowledge

- Transfer for Lifelong Robot Learning[C/OL] //Advances in Neural Information Processing Systems 36, Datasets and Benchmarks Track (NeurIPS). 2023. https://proceedings.neurips.cc/paper_files/paper/2023/hash/8c3c666820ea055a77726d66fc7d447f-Abstract-Datasets_and_Benchmarks.html.
- [41] Kim M J, Finn C, Liang P. Fine-Tuning Vision-Language-Action Models: Optimizing Speed and Success[C/OL] //Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.017>.
- [42] Xu C, Nguyen T K, Dixon E, et al. Can We Detect Failures Without Failure Data? Uncertainty-Aware Runtime Failure Detection for Imitation Learning Policies[C/OL] //Robotics: Science and Systems XXI. 2025. <http://dx.doi.org/10.15607/RSS.2025.XXI.073>.
- [43] Liu H, Dass S, Martín-Martín R, et al. Model-Based Runtime Monitoring with Interactive Imitation Learning[C/OL] // 2024 IEEE International Conference on Robotics and Automation (ICRA). 2024: 4154-4161. <http://dx.doi.org/10.1109/ICRA57147.2024.10611038>.
- [44] Dai Y, Lee J, Fazeli N, et al. RACER: Rich Language-Guided Failure Recovery Policies for Imitation Learning[C/OL] //2025 IEEE International Conference on Robotics and Automation (ICRA). 2025. <http://dx.doi.org/10.1109/ICRA55743.2025.11127799>.
- [45] Liu Z, Bahety A, Song S. REFLECT: Summarizing Robot Experiences for Failure Explanation and Correction[C/OL] //Proceedings of Machine Learning Research, Vol 229: Proceedings of the 7th Conference on Robot Learning. [S.l.]: PMLR, 2023. <https://proceedings.mlr.press/v229/liu23g.html>.